

ВВЕДЕНИЕ В ЧИСЛЕННЫЕ МЕТОДЫ

1. Математическое моделирование и использование ЭВМ в решении прикладных задач.

В современной науке и технике важную роль играет математическое моделирование, заменяющее эксперименты с реальными объектами экспериментами с их математическими моделями.

Математические модели являются одним из основных инструментов познания человеком явлений окружающего мира. Под математическими моделями понимают основные закономерности и связи, присущие изучаемому явлению. Это могут быть формулы или уравнения, наборы правил или соглашений, выраженные в математической форме. Испокон веков в математике, механике, физике и других точных науках естествознания для описания изучаемых ими явлений использовались математические модели. Так, законы Ньютона полностью определяют закономерности движения планет вокруг Солнца. Используя основные законы механики, относительно нетрудно составить уравнения, описывающие движение космического аппарата, например, от Земли к Луне. Однако получить их решение в виде простых формул не представляется возможным.

Применение компьютеров для математического моделирования изменило само понятие "решить задачу". До этого исследователь удовлетворялся написанием математической модели. А если ему еще удавалось доказать, что решение (алгоритм) в принципе существует, то этого было достаточно, если априори полагать, что модель адекватно описывает изучаемое явление. Поскольку, как правило, нет простых формул, описывающих поведение модели, а, стало быть, и объекта, который описывается моделью, то единственный путь – свести дело к вычислениям, применению численных методов решения задач.

В настоящее время выработалась технология исследования сложных проблем, основанная на построении и анализе с помощью ЭВМ математических моделей изучаемого объекта. Такой метод исследования называют **вычислительным экспериментом**.

Математическое моделирование и вычислительный эксперимент применяются сегодня не только в точных науках и технике, но и в экономических науках, социологии и многих других областях, традиционно считавшихся далекими от математики и компьютеров. Зачем нужен вычислительный эксперимент? Проектирование сложных объектов, например, атомных, космических и многих других требует проведения колоссальных объемов вычислений. Например, для решения многих прикладных задач аэродинамики и ядерной физики требуется выполнения более 10^{13} арифметических операций. Современные технологии зачастую используют предельные режимы, которые требуют учета сложных нелинейных факторов. Зачастую требуется изучить поведение объекта в

экстремальных и аварийных ситуациях, что практически невозможно путем натурального эксперимента, например, при изучении ядерных взрывов, последствий техногенных катастроф и во многих других ситуациях.

2. Вычислительный эксперимент и его этапы.

Широкое применение ЭВМ в математическом моделировании, достаточно мощная теоретическая и экспериментальная база позволяют говорить о вычислительном эксперименте как о новой технологии и методологии в научных и прикладных исследованиях.

Вычислительный эксперимент – это эксперимент над математической моделью объекта на ЭВМ, который состоит в том, что по одним параметрам модели вычисляются другие её параметры и на этой основе делаются выводы о свойствах явления, описываемого математической моделью.

В проведении вычислительного эксперимента участвует коллектив исследователей - специалисты в конкретной предметной области, математики теоретики, вычислители, прикладники, программисты. Это связано с тем, что моделирование реальных объектов на ЭВМ включает в себя большой объём работ по исследованию их физической и математической моделей, вычислительных алгоритмов, программированию и обработке результатов. Здесь можно заметить аналогию с работами по проведению натуральных экспериментов: составление программы экспериментов, создание экспериментальной установки, выполнение контрольных экспериментов, проведение серийных опытов, обработки экспериментальных данных и их интерпретация и т.д. Таким образом, проведение крупных комплексных расчётов следует рассматривать как эксперимент, проводимый на ЭВМ или вычислительный эксперимент.

Вычислительный эксперимент играет ту же роль, что и обыкновенный эксперимент при исследованиях новых гипотез. Современная гипотеза почти всегда имеет математическое описание, над которым можно выполнять эксперименты.

При введении этого понятия следует особо выделить способность компьютера выполнять большой объем вычислений, реализующих исследования. Иначе говоря, компьютер позволяет произвести замену физического, химического и т. д. эксперимента экспериментом вычислительным.

При проведении вычислительного эксперимента можно убедиться в необходимости и полезности последнего, особенно в случаях, когда провести натуральный эксперимент затруднительно или невозможно. Вычислительный эксперимент, по сравнению с натурным, значительно дешевле и доступнее, его подготовка и проведение требует меньшего времени, его легко переделывать, он даёт более подробную информацию. Кроме того, в ходе вычислительного эксперимента выявляются границы

применимости математической модели, которые позволяют прогнозировать эксперимент в естественных условиях. Поэтому использование вычислительного эксперимента ограничивается теми математическими моделями, которые участвуют в проведении исследования. По этой причине вычислительный эксперимент не может заменить полностью эксперимент натурный, и выход из этого положения состоит в их разумном сочетании. В этом случае в проведении сложного эксперимента используется широкий спектр математических моделей: прямые задачи, обратные задачи, задачи оптимизации, задачи идентификации.

Использование вычислительного эксперимента как средства решения сложных прикладных проблем имеет в случае каждой конкретной задачи и каждого конкретного научного коллектива свои специфические особенности. Тем не менее, всегда чётко просматриваются общие характерные основные черты, позволяющие говорить о единой структуре этого процесса. В настоящее время технологический цикл вычислительного эксперимента принято подразделять на ряд технологических этапов. И хотя такое деление в значительной степени условно, оно позволяет лучше понять сущность этого метода проведения теоретических исследований.

Таким образом, как и любой эксперимент, вычислительный эксперимент следует определенным правилам проведения. Схематически этапы вычислительного эксперимента можно представить следующим образом:




Рис. В. 1. Схема вычислительного эксперимента

Основу вычислительного эксперимента составляет триада: *модель – метод (алгоритм) – программа*. Сначала строится с некоторыми допущениями **физическая модель объекта**. Физическая модель—это ряд ограничений, предположений и упрощений, наложенных на рассматриваемое явление. Далее описывается **математическая модель**. Математическая модель—это уравнения, система уравнений или множество систем уравнений, которые с максимальной возможностью описывают физическую

модель. Затем необходимо решить эти системы уравнений. Как уже говорилось, обычно приходится применять **численные методы**. Под численным методом понимается совокупность *дискретной модели*, реализуемой на компьютере, и *вычислительного алгоритма*, позволяющего решить дискретизированную задачу. Для реализации численного метода необходимо разработать **программу** на одном из языков программирования или применить готовый пакет прикладных программ. В настоящее время существуют пакеты прикладных программ, такие как MathCAD, Matlab, Maple, Mathematica и другие, позволяющие решить большинство практически встречающихся задач. Однако грамотная постановка задачи, рациональный выбор метода решения и правильная интерпретация результатов требуют серьезных знаний численных методов. После отладки программы производятся **вычисления на компьютере** (обычно требуется провести много вариантов вычислений, для чего необходимо планировать вычислительный эксперимент) и **анализ результатов**. После получения результатов исследуется соответствие результатов вычислительного эксперимента процессу функционирования реального объекта и при необходимости уточняются компоненты схемы вычислительного эксперимента (рис. В.1) до получения удовлетворительных результатов.

3. Численные методы

В широком смысле под численным методом, как уже говорилось выше, понимается совокупность дискретной модели, реализуемой на компьютере, и вычислительного алгоритма, позволяющего решить дискретизированную задачу.

Одной и той же математической модели можно поставить в соответствие множество дискретных моделей и вычислительных алгоритмов, т. е. численных методов. При выборе численного метода необходимо учитывать две группы требований:

- дискретная модель должна быть адекватной математической модели;
- численный метод должен быть корректным и реализуемым на компьютере.

Для обеспечения адекватности дискретная модель должна обладать свойствами *сходимости численного метода*, *выполнения дискретных аналогов сохранения и качественно правильного поведения решения*. Сходимость численного метода, например, означает, что при уменьшении шага разбиения интервала интегрирования точность численного интегрирования возрастает. Различные математические модели являются выражением физических законов сохранения, поэтому для дискретной модели законы сохранения также должны выполняться. Качественно правильное поведение дискретной модели означает, что из-за дискретного характера поведения модели не теряются некоторые детали поведения реальной системы.

Корректность численного метода означает, что дискретная задача должна быть однозначно разрешимой и устойчивой к погрешностям исходных данных и погрешностям вычислений. Реализуемость численного метода на компьютере ограничена объемом памяти и быстродействием компьютера. Вычислительный алгоритм должен предъявлять разумные требования к ресурсам компьютера. Например, математически корректный метод Крамера решения систем линейных алгебраических уравнений абсолютно неприменим для решения реальных задач: если принять, что каждая арифметическая операция выполняется за 10^{-6} с, то для решения системы с 20 неизвестными методом Крамера потребуется более миллиона лет. В то же время простейшим методом Гаусса эта система будет решена за доли секунды.

В узком смысле под **численными методами** понимают методы приближённого решения математических задач, сводящиеся к выполнению конечного числа элементарных операций над числами. В качестве элементарных операций фигурируют арифметические действия, выполняемые обычно приближённо, а также вспомогательные операции — записи промежуточных результатов, выборки из таблиц и т.п. Числа задаются ограниченным набором цифр в некоторой позиционной системе счисления (десятичной, двоичной и т.п.). Таким образом, в численных методах числовая прямая заменяется дискретной системой чисел (сеткой); функция непрерывного аргумента заменяется таблицей её значений в сетке; операции анализа, действующие над непрерывными функциями, заменяются алгебраическими операциями над значениями функций в сетке.

Целью курса "Численные методы" является изучение теоретических основ и получение практических навыков решения вычислительных задач и проведения вычислительного эксперимента.

ГЛАВА 1. ОШИБКИ ВЫЧИСЛЕНИЙ

1.1 Источники и классификация погрешностей

В настоящее время разработана технология исследования сложных проблем, основанная на построении и анализе с помощью ЭВМ математических моделей изучаемого объекта. В соответствии с ней решение большинства практических задач включает следующие этапы:

- 1) создание математической модели задачи;
- 2) интерпретация математической модели в виде, доступном для реализации на ЭВМ (построение численного метода решения);
- 3) разработка программы и проведение вычислений.

Этот процесс неизбежно носит приближенный характер, так как на каждом этапе вносятся те или иные погрешности. Они обусловлены следующими причинами:

- а) математическое описание задачи является упрощенным;
- б) недостаточно точно заданы исходные данные, являющиеся, как правило, результатом проведенных экспериментов;
- в) всякий численный метод, используемый для решения математической задачи, является приближенным в том смысле, что он не дает точного решения задачи, (для точного решения, например, может потребоваться неограниченно большое число арифметических операций);
- г) в самом процессе решения задачи в ЭВМ при вводе исходных данных, выполнении арифметических операций и при выводе результатов производятся округления.

Погрешности в решении задачи, обусловленные пунктами «а» и «б», называются *неустраняемыми*. При переходе от математической модели к численному методу (пункт «в») возникает *погрешность метода*. Построение численного метода для математической модели состоит из двух этапов – формулировки дискретной модели и разработки вычислительного алгоритма, позволяющего отыскать решение дискретной задачи. Соответственно погрешность метода подразделяется на *погрешность дискретизации* или *погрешность аппроксимации* и на возникающую в процессе решения (пункт «г») *вычислительную погрешность* или *погрешность округления*.

Основной вопрос состоит в том, чтобы узнать, будут ли близкими результаты, полученные с использованием приближенных вычислений, к тем, которые могли бы быть получены с использованием точных расчетов. Поэтому анализ погрешности численного результата должен являться обязательным этапом решения любой практической задачи. Полная погрешность является результатом сложного взаимодействия всех видов погрешностей и ответ на вопрос, какая из трех погрешностей является преобладающей, не может быть однозначным. Типичной является ситуация, когда неустраняемая погрешность значительно превышает погрешность метода, а вычислительной погрешностью мож-

но пренебречь по сравнению с погрешностью метода. В общем случае надо стремиться, чтобы погрешности имели один порядок.

В связи с этим при анализе погрешностей возникают две задачи: *прямая* - зная точность исходных данных, оценить точность полученного результата, и *обратная* – определить точность, с которой необходимо задавать исходную информацию, чтобы обеспечить требуемую точность решения.

И в том, и в другом случае необходимо представление о точных и приближенных числах, абсолютной и относительной погрешностях, о представлении чисел в ЭВМ.

1.2. Приближенные числа, их абсолютные и относительные погрешности

Точные и приближенные числа. При численном решении задач приходится оперировать двумя видами чисел - *точными* и *приближенными*. К точным относятся числа, которые дают истинное значение исследуемой величины. К приближенным относятся числа, близкие к истинному значению, причем степень близости определяется погрешностью вычислений. Например, в утверждениях "в аудитории 102 слушателя", "в январе 31 день", "стоимость костюма 75 долларов" числа 102, 31 и 75 - точные. В высказываниях типа "сто метров спортсмен пробежал за 10,1 сек.", "масса мороженого 100 грамм", "расстояние от Бреста до Москвы равно 1054 км." числа 10,1; 100; 1054 - приближенные. Это связано с тем, что при измерениях появление приближенных чисел связано с несовершенством измерительных приборов. Кроме того, часто нет необходимости знать точное значение интересующей величины. Ясно, что пассажиру, едущему из Бреста в Москву неважно, что данное в справочниках расстояние в 1054 км. от Бреста до Москвы может быть короче на 200 м или длиннее на 150 м.

Погрешности, абсолютная и относительная. Пусть x - точное значение числа, а $\hat{x}$ - его приближение, или приближенное значение. Говорят, что число $\hat{x}$ есть приближенное значение числа x с *недостатком*, если $\hat{x} \leq x$, и приближенное значение с *избытком*, если $x \leq \hat{x}$. При этом определении число x будет для самого себя приближением одновременно с недостатком и с избытком.

Если x - точное, вообще говоря, неизвестное значение некоторой величины, а $\hat{x}$ - его приближение, то разность $x - \hat{x}$ называется ошибкой, или погрешностью приближения. Часто знак ошибки $x - \hat{x}$ неизвестен, поэтому используется так называемая *абсолютная погрешность* $\Delta(\hat{x})$ приближенного числа $\hat{x}$, определяемая равенством

$$\Delta(\hat{x}) = |x - \hat{x}|, \quad (1.1)$$

откуда имеем

$$x = \hat{x} \pm \Delta(\hat{x}). \quad (1.2)$$

Изучаемая числовая величина есть величина именованная, т.е. определяемая во вполне определенных единицах измерения, например, в сантиметрах, килограммах и т.п. Погрешность (1.1) имеет ту же размерность. Однако часто

возникает необходимость заменить эту погрешность безразмерным числом - *относительной погрешностью*. При этом из-за незнания точного значения изучаемой величины принято называть относительной погрешностью величину

$$\delta(\hat{x}) = \frac{\Delta(\hat{x})}{|\hat{x}|} = \left| \frac{x - \hat{x}}{\hat{x}} \right|. \quad (1.3)$$

Относительную погрешность часто выражают в процентах: $\delta(\hat{x}) = \frac{\Delta(\hat{x})}{|\hat{x}|} \cdot 100\%$.

Интервалы приближения. Поскольку точное значение x определяемой величины неизвестно, то и погрешности $\Delta(\hat{x})$ и $\delta(\hat{x})$ в соотношениях (1.1) и (1.3) тоже неизвестны. Однако, бывают известны оценки Δ и δ сверху и снизу этих величин, т.е. для чисел Δ и δ выполнены неравенства.

$$\Delta(\hat{x}) \leq \Delta, \quad \delta(\hat{x}) \leq \delta. \quad (1.4)$$

В этом случае говорят, что абсолютная и относительная погрешности приближенного числа $\hat{x}$ не превосходят Δ и δ соответственно. Если $\Delta(\hat{x}) = |x - \hat{x}| \leq \Delta$, то говорят, что число $\hat{x}$ является приближением числа x с точностью Δ . В этом случае, согласно (1.1) и (1.4),

$$\hat{x} - \Delta \leq x \leq \hat{x} + \Delta. \quad (1.5)$$

Числа Δ и δ называются *предельными абсолютной и относительной погрешностями приближенного числа*.

Практическое применение изложенного состоит в нахождении для числа x приближения $\underline{\Delta}$ с недостатком и приближения $\overline{\Delta}$ с избытком, для которых $\underline{\Delta} \leq x \leq \overline{\Delta}$. В этом случае говорят, что имеется *интервал приближения* величины x . Согласно (1.5), если известна предельная абсолютная погрешность Δ , то границы интервала приближения имеют вид: $\underline{\Delta} = \hat{x} - \Delta$, $\overline{\Delta} = \hat{x} + \Delta$.

Предположим, что имеется два интервала приближения величины x : $\underline{\Delta}_1 \leq x \leq \overline{\Delta}_1$ и $\underline{\Delta}_2 \leq x \leq \overline{\Delta}_2$. Тогда можно, очевидно, без потери информации заменить эти два интервала приближения на один: $\max(\underline{\Delta}_1, \underline{\Delta}_2) \leq x \leq \min(\overline{\Delta}_1, \overline{\Delta}_2)$.

Запись приближенных чисел. Верные значащие цифры. Запись приближенных чисел должна подчиняться правилам, связанным с понятиями о верных значащих цифрах.

Первая слева отличная от нуля цифра числа x и все расположенные справа от нее, называются *значащими*. Например, числа 0.00028745 и 200.37500 имеют соответственно 5 и 8 значащих цифр. Цифра a_i числа, записанного в десятичной системе, называется *верной*, если $\Delta(\hat{x}) < 10^i$, т.е. если абсолютная погрешность числа $\hat{x}$ не превосходит одной единицы соответствующего разряда десятичного числа. Цифры, не являющиеся верными, называются *сомнительными*. Если верная цифра a_i - значащая, то она называется *верной значащей цифрой*. Вид записи приближенного числа должен показывать его абсолютную погрешность, которая не должна превосходить единицы последнего разряда, сохраняемого при записи. Другими словами, приближенные числа принято записы-

вать таким образом, чтобы все цифры числа, кроме нулей впереди, если они есть, были значащими и верными цифрами.

Пример 1. Числа 27,0563 и 27,0563000, как приближенные, различны. Абсолютная погрешность первого числа не превосходит 10^{-4} ($i = -4$), а второго 10^{-7} ($i = -7$).

Пример 2. Числа $x_1=34,174562$ и $x_2=375,16342$ содержат пять верных цифр. Определить их абсолютную погрешность.

Δ В числе x_1 последняя верная значащая цифра 4, считая слева, находится на третьем месте после запятой, т.е. $i=-3$. Следовательно, по определению $\Delta(\hat{x}_1) = 10^{-3} = 0,001$. Во втором числе x_2 последняя значащая цифра 6 имеет индекс $i=-2$. Следовательно, $\Delta(\hat{x}_2) = 10^{-2} = 0,01$.

Пример 3. Абсолютная погрешность чисел $x_1=28,9356$ и $x_2=183,45123$ составляет $\Delta = 0,03$. Определить, какие цифры являются верными, и округлить числа, оставив только верные цифры.

Δ При заданной максимальной абсолютной погрешности $\Delta = 0,03$ верной значащей цифрой, по определению, должна быть та a_i , для которой $\Delta(\hat{x}) \leq 10^{-i} \leq 0,03$, т.е. $i=-2$. Значит, в заданных числах все цифры являются верными. Округлив эти числа до указанной точности, получим $\hat{x}_1 = 28,94$, $\hat{x}_2 = 183,45$.

Замечание. При записи чисел имеются определенные тонкости. Например, запись числа 5,1813 означает, что абсолютная погрешность этого приближенного числа не превосходит 0,0001, а запись числа 680 - что абсолютная погрешность его не превосходит единицы. Если же второе число имеет большую точность, следует писать 680,0. Тем самым числа $68 \cdot 10$; 680; 680,0; 680,00 имеют различную степень точности. Если надо показать, что у числа 680,00 первые три цифры верные значащие, то его следует писать в виде 680, а для числа 600028 с тремя верными слева значащими цифрами следует писать $600 \cdot 10^3$. В соответствии с этим округлением, например, число 28065 при 1, 2 или 3 верными значащими цифрами будет записана в виде $3 \cdot 10^4$, $28 \cdot 10^3$, $280 \cdot 10^2$ соответственно.

Связь между числом верных знаков и погрешностью числа. Пусть число $\hat{x}$ является приближенным значением точного числа x и имеет вид

$$\hat{x} = a_n \cdot 10^n + a_{n-1} \cdot 10^{n-1} + \dots + a_i \cdot 10^i + \dots + a_{-m} \cdot 10^{-m}, \quad a_n \geq 1,$$

где цифры $a_n, a_{n-1}, \dots, a_i$ - верные. По определению, число верных знаков числа $\hat{x}$ определяется неравенством $\Delta(\hat{x}) = |x - \hat{x}| < 10^i$. Разделив обе части этого неравенства на $|\hat{x}|$, получим

$$\delta(\hat{x}) = \frac{|x - \hat{x}|}{|\hat{x}|} \leq \frac{10^i}{|a_n \cdot 10^n + a_{n-1} \cdot 10^{n-1} + \dots + a_i \cdot 10^i + \dots + a_{-m} \cdot 10^{-m}|}.$$

Это неравенство еще больше усилится, если число $\hat{x}$ заменить заведомо меньшим числом $a_n \cdot 10^n$. Тогда будем иметь

$$\delta(\hat{x}) \leq \frac{10^i}{a_n \cdot 10^n} = \frac{1}{a_n} \cdot 10^{i-n}.$$

Таким образом, относительная погрешность числа характеризуется количеством верных цифр числа l , отсчитываемых от a_n - первой значащей цифры числа до a_i - последняя значащая цифра этого числа ($l = i - n$). За предельную относительную погрешность δ приближенного числа $\hat{x}$ можно принять величину

$$\delta(\hat{x}) \leq \frac{1}{a_n} \cdot 10^{i-n}. \quad (1.6)$$

Пример 4. Какова предельная относительная погрешность в процентах чисел $x_1 = 358,563$ и $x_2 = 0,047$, если все их цифры верные?

Δ Для числа x_1 имеем $n = 3$, $i = -3$. По формуле (1.6) получаем

$$\delta_1 = \frac{1}{3} \cdot 10^{-3-3} \cdot 100\% = 0,00003\%$$

Для числа x_2 при $n = -2$, $i = -3$ будем иметь

$$\delta_1 = \frac{1}{4} \cdot 10^{-3-(-2)} \cdot 100\% = 2,5\%$$

Пример 5. Со сколькими верными десятичными знаками надо взять $\sqrt[3]{28}$, чтобы погрешность не превышала 0,25%?

Δ Так как $\sqrt[n]{1+\alpha} \approx 1 + \frac{\alpha}{n}$, при достаточно малых α , то

$$\sqrt[3]{28} = \sqrt[3]{27+1} = \sqrt[3]{27\left(1+\frac{1}{27}\right)} = 3\left(1+\frac{1}{81}\right) \approx 3,037037$$

По условию $\delta \leq 0,25\%$, т.е. $\delta \leq 0,0025$. Для числа $\sqrt[3]{28}$ имеем $a_n = 3$, $n = 0$. Согласно формуле (1.6), имеем

$$0,0025 \geq \frac{1}{3} \cdot 10^{i-0} \Leftrightarrow 10^i \leq 0,0075 \Rightarrow i = -4$$

Таким образом, число $\sqrt[3]{28} \approx 3,037037$ имеет пять верных цифр, считая их слева, т.е. $\sqrt[3]{28} \approx 3,0370$.

Оценки погрешности при арифметических действиях. Оценим теперь погрешности, возникающие при арифметических операциях с приближенными числами.

Пусть x и y - точные числа, $\hat{x}$ и $\hat{y}$ - их приближения, $\Delta(\hat{x})$ и $\Delta(\hat{y})$ - их абсолютные, а $\delta(\hat{x})$ и $\delta(\hat{y})$ - их относительные погрешности соответственно.

1) *Погрешность суммы и разности.* Согласно определению (1.1), имеем:

$$\Delta(\hat{x} + \hat{y}) = |(x + y) - (\hat{x} + \hat{y})| = |(x - \hat{x}) + (y - \hat{y})| \leq |x - \hat{x}| + |y - \hat{y}| = \Delta(\hat{x}) + \Delta(\hat{y}).$$

Таким образом,

$$\Delta(\hat{x} + \hat{y}) \leq \Delta(\hat{x}) + \Delta(\hat{y}), \quad (1.7)$$

т.е. *абсолютная погрешность суммы не превосходит суммы их абсолютных погрешностей.*

Аналогично получаем оценку погрешности для разности двух чисел:

$$\Delta(\hat{x} - \hat{y}) = |(x - y) - (\hat{x} - \hat{y})| = |(x - \hat{x}) - (y - \hat{y})| \leq |x - \hat{x}| + |y - \hat{y}| = \Delta(\hat{x}) + \Delta(\hat{y}),$$

т.е.

$$\Delta(\hat{x} - \hat{y}) \leq \Delta(\hat{x}) + \Delta(\hat{y}). \quad (1.8)$$

Пусть теперь $x_1, x_2, \dots, x_n$ - точные числа, а $\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n$ - соответствующие приближения. Тогда обобщая (1.7), будем иметь

$$\Delta(\hat{x}_1 + \hat{x}_2 + \dots + \hat{x}_n) \leq \Delta(\hat{x}_1) + \Delta(\hat{x}_2) + \dots + \Delta(\hat{x}_n). \quad (1.9)$$

Из полученных результатов вытекает следующее правило сложения приближенных чисел различной абсолютной точности:

- 1) выделяются числа, имеющие наибольшую абсолютную погрешность (числа наименьшей точности);
- 2) более точные числа округляются таким образом, чтобы сохранить в них на один знак больше, чем в выделенном числе (запасной знак);
- 3) производится сложение или вычитание всех чисел с учетом сохраненных знаков;
- 4) полученный результат округляется на один знак.

Пример 6. Вычислить $a = 0.1732 + 17.45 - 0.00354$, где все цифры чисел верные.

Δ Поскольку цифры всех чисел верные, то погрешность вычисления первого слагаемого не превышает 0.0001, второго – 0.01, третьего - 0.00001. Наибольшую погрешность имеет второе слагаемое 17.45, поэтому числа 0.1732 и 0.00354 округляются до трех знаков после запятой. В результате получим приближенное число $\hat{a} = 0.173 + 17.45 - 0.004 = 17.619$. Допускаемая при этом погрешность $\Delta(\hat{a})$ не превышает величины $\Delta = 0.01 + 0.001 + 0.00001 = 0.01101$. Округлив $\hat{a}$ до двух знаков после запятой, окончательно получим $\hat{a} = 17.62$.

Относительная погрешность суммы и разности приближенных чисел, согласно (1.3), (1.7) и (1.8), определяются соотношениями:

$$\delta(\hat{x} + \hat{y}) = \frac{\Delta(\hat{x} + \hat{y})}{|\hat{x} + \hat{y}|} \leq \frac{\Delta(\hat{x}) + \Delta(\hat{y})}{|\hat{x} + \hat{y}|}, \quad (1.10)$$

$$\delta(\hat{x} - \hat{y}) = \frac{\Delta(\hat{x} - \hat{y})}{|\hat{x} - \hat{y}|} \leq \frac{\Delta(\hat{x}) + \Delta(\hat{y})}{|\hat{x} - \hat{y}|}, \quad (1.11)$$

соответственно.

2) *Погрешность произведения.* Согласно (1.2), $x = \hat{x} \pm \Delta(\hat{x})$, $y = \hat{y} \pm \Delta(\hat{y})$. Тогда

$$\Delta(\hat{x}\hat{y}) = |xy - \hat{x}\hat{y}| = |(\hat{x} + \Delta(\hat{x}))(\hat{y} + \Delta(\hat{y})) - \hat{x}\hat{y}| = |\hat{x}\hat{y} + \hat{x}\Delta(\hat{y}) + \hat{y}\Delta(\hat{x}) + \Delta(\hat{x})\Delta(\hat{y}) - \hat{x}\hat{y}| \leq \\ \leq |\hat{x}|\Delta(\hat{y}) + |\hat{y}|\Delta(\hat{x}) + \Delta(\hat{x})\Delta(\hat{y})$$

Таким образом,

$$\Delta(\hat{x} \cdot \hat{y}) \leq |\hat{x}|\Delta(\hat{y}) + |\hat{y}|\Delta(\hat{x}) + \Delta(\hat{x})\Delta(\hat{y}), \quad (1.12)$$

$$\delta(\hat{x} \cdot \hat{y}) = \frac{\Delta(\hat{x} \cdot \hat{y})}{|\hat{x} \cdot \hat{y}|} = \frac{|\hat{x}|\Delta(\hat{y}) + |\hat{y}|\Delta(\hat{x}) + \Delta(\hat{x})\Delta(\hat{y})}{|\hat{x}||\hat{y}|} = \delta(\hat{x}) + \delta(\hat{y}) + \delta(\hat{x}) \cdot \delta(\hat{y}). \quad (1.13)$$

Из соотношения (1.12) получаем правило умножения приближенных чисел различной абсолютной точности.

- 1) выделяется число с наименьшим количеством верных значащих цифр;
- 2) оставшиеся сомножители округляются таким образом, чтобы они содержали на одну значащую цифру больше, чем количество верных значащих цифр в выделенном числе;
- 3) в произведении сохраняется столько значащих цифр, сколько верных значащих цифр имеет выделенное число.

Пример 7. Найти произведение приближенных чисел $x_1 = 3.75$ и $x_2 = 0.73788$, все цифры которых верные.

Δ Число x_1 содержит три верные значащие цифры, а число x_2 - пять. Поэтому второе число x_2 округляем до четырех значащих цифр: $x_2 = 0.7379$. Тогда $\hat{a} = x_1 \cdot x_2 = 3.75 \cdot 0.7379 = 2.767125$. В этом произведении сохраняем три значащие цифры, так что $\hat{a} = 2.76$. Заметим, что если считать числа x_1 и x_2 точными, то $x_1 \cdot x_2 = 3.75 \cdot 0.73788 = 2.76705$.

3) *Погрешность частного.* При $y \neq 0$ и $\hat{y} \neq 0$ имеем

$$\Delta\left(\frac{\hat{x}}{\hat{y}}\right) = \left|\frac{x}{y} - \frac{\hat{x}}{\hat{y}}\right| = \left|\frac{\hat{x} + \Delta(\hat{x})}{\hat{y} + \Delta(\hat{y})} - \frac{\hat{x}}{\hat{y}}\right| = \left|\frac{\hat{x} \cdot \hat{y} + \hat{y} \cdot \Delta(\hat{x}) - \hat{x} \cdot \hat{y} - \hat{x} \cdot \Delta(\hat{y})}{\hat{y}(\hat{y} + \Delta(\hat{y}))}\right| = \\ = \left|\frac{\hat{y} \cdot \Delta(\hat{x}) - \hat{x} \cdot \Delta(\hat{y})}{\hat{y}^2 \left(1 + \frac{\Delta(\hat{y})}{\hat{y}}\right)}\right| \leq \frac{|\hat{x}| \cdot \Delta(\hat{y}) + |\hat{y}| \cdot \Delta(\hat{x})}{\hat{y}^2 \left[1 + \frac{\Delta(\hat{y})}{\hat{y}}\right]}$$

Так как $|a + b| \geq ||a| - |b||$, то $\left|1 + \frac{\Delta(\hat{y})}{\hat{y}}\right| \geq \left|1 - \frac{\Delta(\hat{y})}{\hat{y}}\right| = |1 - \delta(\hat{y})|$. Отсюда получаем,

что

$$\Delta\left(\frac{\hat{x}}{\hat{y}}\right) \leq \frac{|\hat{x}| \cdot \Delta(\hat{y}) + |\hat{y}| \cdot \Delta(\hat{x})}{\hat{y}^2 |1 - \delta(\hat{y})|}, \quad (1.14)$$

$$\delta\left(\frac{\hat{x}}{\hat{y}}\right) = \frac{\Delta\left(\frac{\hat{x}}{\hat{y}}\right)}{\left|\frac{\hat{x}}{\hat{y}}\right|} \leq \frac{\delta(\hat{x}) + \delta(\hat{y})}{|1 - \delta(\hat{y})|}. \quad (1.15)$$

Таким образом, получаем следующее правило деления приближённых чисел различной абсолютной погрешности:

- 1) выделяется число с наименьшим количеством верных значащих цифр;
- 2) оставшиеся числа округляются таким образом, чтобы они содержали на одну значащую цифру больше, чем выделенное число;
- 3) в полученном результате деления сохраняется столько значащих цифр, сколько верных значащих цифр имеет выделенное число.

На практике при работе с числами достаточно хорошей точности обычно считают, что $\Delta(\hat{x}) \cdot \Delta(\hat{y}) \approx 0$, $\delta(\hat{x}) \cdot \delta(\hat{y}) \approx 0$, $1 - \delta(\hat{y}) \approx 1$. Поэтому вместо формул (1.12)-(1.15) пользуются более упрощёнными формулами:

$$\Delta(\hat{x} \cdot \hat{y}) \leq |\hat{x}| \cdot \Delta(\hat{y}) + |\hat{y}| \cdot \Delta(\hat{x}), \quad \delta(\hat{x} \cdot \hat{y}) \leq \delta(\hat{x}) + \delta(\hat{y}),$$

$$\Delta\left(\frac{\hat{x}}{\hat{y}}\right) \leq \frac{|\hat{x}| \cdot \Delta(\hat{y}) + |\hat{y}| \cdot \Delta(\hat{x})}{\hat{y}^2}, \quad \delta\left(\frac{\hat{x}}{\hat{y}}\right) \leq \delta(\hat{x}) + \delta(\hat{y}).$$

1.3. Вычислительная погрешность

Представление чисел в ЭВМ. Одним из источников вычислительной погрешности являются особенности представления чисел в ЭВМ и арифметические операции с ними. Рассмотрим эти особенности.

Целые числа, представимые в ЭВМ (целые машинные числа) - это все целые числа, принадлежащие замкнутому интервалу $[N^-, N^+]$. В языке Паскаль, например - это числа диапазона $[-32768, 32767]$. Арифметические операции с целыми машинными числами выполняются на ЭВМ точно, если результат принадлежит интервалу $[N^-, N^+]$. В противном случае фиксируется ошибочная ситуация, а результат операции не определен или не имеет смысла. Поэтому при вычислениях следует заботиться о том, чтобы результаты арифметических операций не выходили за пределы интервала $[-32768, 32767]$.

Вещественные числа могут быть записаны в двух формах. Обычную форму записи числа в виде

$$x = \pm a_n a_{n-1} \dots a_1 a_0, a_{-1} a_{-2} \dots a_{-m}$$

называют записью с *фиксированной запятой*. В позиционной системе счисления с основанием β эта запись означает, что

$$x = \pm a_n \cdot \beta^n + a_{n-1} \cdot \beta^{n-1} + \dots + a_1 \cdot \beta + a_0 + a_{-1} \cdot \beta^{-1} + a_{-2} \cdot \beta^{-2} + \dots + a_{-m} \cdot \beta^{-m}.$$

Каждое из чисел a_n может принимать одно из значений $\{0, 1, \dots, \beta - 1\}$. Числа a_n называются разрядами. Например, в десятичной системе запись 1358,7604 определяет число

$$1 \cdot 10^3 + 3 \cdot 10^2 + 5 \cdot 10 + 8 + 7 \cdot 10^{-1} + 6 \cdot 10^{-2} + 0 \cdot 10^{-3} + 4 \cdot 10^{-4}.$$

Третий разряд перед запятой этого числа равен 3, второй разряд после запятой – 6.

О числах, записанных в виде $0,63750 \cdot 10^6$; $637,50 \cdot 10^3$; $6,3750 \cdot 10^5$; $6375,0 \cdot 10$, говорят, что они записаны в *форме с плавающей запятой*. Запись числа с плавающей запятой, как следует из примера, не является однозначной. Для устранения этой неоднозначности принято первый множитель брать меньше единицы, и он должен состоять только из значащих цифр. Такая форма записи числа называется *нормализованной* -

$$x = m \cdot \beta^p \quad (1.16)$$

Здесь p - целое число (положительное, отрицательное или нуль), называемое *порядком* числа x , m - число с фиксированной запятой, называемое *мантиссой* числа x . Первая после запятой цифра числа m всегда отлична от нуля:

$$\beta^{-1} \leq |m| < 1. \quad (1.17)$$

Так, в рассмотренном примере, нормализованной формой записи числа 63750 будет $0,63750 \cdot 10^6$. Заметим, что в этой записи все цифры мантиссы верные. Для числа - 0,00384 нормализованной будет форма $- 0,384 \cdot 10^{-2}$.

Для записи вещественных чисел в ЭВМ отводится фиксированное число разрядов (разрядная сетка), в которой выделены разряды для записи мантиссы, порядка, знаков мантиссы и порядка. Таким образом, множество машинных вещественных чисел характеризуется следующими четырьмя целыми константами: основанием счисления β , $\beta \geq 2$, точностью t , нижней границей экспоненты e^- и верхней границей экспоненты e^+ . Ненулевые машинные вещественные числа имеют вид

$$x = \pm \left(\frac{d_1}{\beta} + \frac{d_2}{\beta^2} + \dots + \frac{d_t}{\beta^t} \right) \beta^p = \pm d_1 d_2 \dots d_t \cdot \beta^p$$

где $0 \leq d_i < \beta$, $d_i \neq 0$, $e^- \leq p \leq e^+$.

Вещественный машинный нуль нуль представляется в ЭВМ специальным образом. Обычно это число, у которого $d_1 = d_2 = \dots = d_t = 0$ или $p < e^-$.

В языке Паскаль реализованы следующие типы вещественных чисел: *real*, *single*, *double*, *extended*, некоторые характеристики которых приведены в таблице 1.1.

Минимальное положительное число ε_0 , которое может быть представлено в ЭВМ, называется *машинным нулем* ($\varepsilon_0 = \beta^{e^- - 1}$). Максимальное положительное число ε_∞ - *машинной бесконечностью* ($\varepsilon_\infty = \beta^{e^+} (1 - \beta^{-t})$). Таким образом, машинные вещественные числа принадлежат замкнутому интервалу $-\varepsilon_\infty \leq x \leq \varepsilon_\infty$. На интервале $-\varepsilon_0 \leq x \leq \varepsilon_0$ лежит только одно машинное вещественное число – машинный нуль.

Таблица 1.1

Тип	Наименование	Занимаемая память	Число значащих цифр	Диапазон допустимых значений
<i>real</i>	вещественный	6 байт	11-12	$2.9 \cdot 10^{-39} \div 1.7 \cdot 10^{38}$
<i>single</i>	с одинарной точностью	4 байта	7-8	$1.5 \cdot 10^{-38} \div 3.4 \cdot 10^{38}$
<i>double</i>	с двойной точностью	8 байт	15-16	$5.0 \cdot 10^{-324} \div 1.7 \cdot 10^{308}$
<i>extended</i>	с повышенной точностью	10 байт	19-20	$3.4 \cdot 10^{-4932} \div 1.1 \cdot 10^{4932}$

Округление чисел в ЭВМ. Из-за конечности разрядной сетки в ЭВМ можно представить точно лишь конечное подмножество вещественных чисел. Рассмотрим два машинных вещественных числа f_1 и f_2 ($f_1 < f_2$) таких, что между f_1 и f_2 нет других машинных чисел. Справедливо неравенство

$$\frac{f_2 - f_1}{f_1} \leq \varepsilon_1 = \beta^{1-t}.$$

Число $\varepsilon_1 = \beta^{-t+1}$ называют *машинным эпсилоном*. Оно зависит от разрядности мантииссы и характеризует точность представления чисел в ЭВМ. Для любого вещественного числа x , $f_1 \leq x \leq f_2$ выполняется неравенство

$$\max(|f_1 - x|, |f_2 - x|) \leq \varepsilon_1 |x|.$$

Таким образом, любое вещественное число x , не представимое точно, заменяется ближайшим к нему числом $\hat{x}$, представимым точно. Такая замена называется *округлением числа x* . Величина погрешности замены не превышает $\varepsilon_1 |x|$ и зависит от способа округления.

Простейшим является отбрасывание всех разрядов мантииссы числа x , которые выходят за пределы разрядной сетки. Предельная относительная погрешность округления при таком способе равна

$$\delta(\hat{x}) \leq \varepsilon_1. \quad (1.18)$$

При более точном *симметричном* округлении к последнему сохраняемому разряду мантииссы прибавляется единица, если первый отбрасываемый двоичный разряд равен 1. Предельная относительная погрешность округления в данном случае вдвое меньше:

$$\delta(\hat{x}) \leq \frac{1}{2} \beta^{-t+1} = \frac{1}{2} \varepsilon_1. \quad (1.19)$$

Таким образом, можно считать, что машинные константы ε_0 , ε_∞ и ε_1 характеризуют погрешность представления вещественных чисел в ЭВМ.

Можно считать, что точное число x из диапазона $\varepsilon_0 \leq |x| \leq \varepsilon_\infty$ и отвечающее ему округленное число $\hat{x}$ связаны равенством

$$\hat{x} = x(1 + \varepsilon), \quad |\varepsilon| \leq \varepsilon_1. \quad (1.20)$$

Если же число превышает по абсолютной величине ε_∞ , то оно не приближается никакими машинными числами. При появлении такого числа в процессе вычислений происходит так называемое переполнение разрядной сетки и вычисления прекращаются. Числа, меньшие по абсолютной величине ε_0 , приближаются машинным нулем с погрешностью ε_0 .

Накопление погрешностей округления. Ошибочно полагать, что в силу малости величин ε_0 и ε_1 , ошибки округления практически не влияют на результаты вычислений. В процессе проведения вычислений погрешности округления могут накапливаться, так как выполнение каждой из четырех арифметических операций вносит некоторую погрешность.

Пусть a и b - два машинных числа, а знак $*$ обозначает одну из четырех арифметических операций. Поскольку ЭВМ выполняет промежуточные вычисления с двойной точностью, т.е. с мантиссой, содержащей $2t$ разрядов, то округлению до t разрядов подвергается лишь окончательный результат. Таким образом, выполнение каждой арифметической операции вносит относительную погрешность, не превышающую ε_1 :

$$\delta(\hat{a * b}) \leq \varepsilon_1, \quad (1.21)$$

или
$$(\hat{a * b}) = (a * b) \cdot (1 + \varepsilon) + \varphi,$$

где $|\varepsilon| \leq \varepsilon_1$, $|\varphi| \leq \varepsilon_0$, $\varepsilon\varphi = 0$.

Ввиду отсутствия ассоциативности и дистрибутивности машинных операций анализ погрешностей в алгоритмах, реализованных на ЭВМ, очень сложен.

Для оценки влияния погрешностей округления на результат вычислений по некоторому алгоритму (*прямая задача теории погрешностей*), предположим, что этот результат является действительной функцией от входных параметров:

$$y = f(x_1, x_2, \dots, x_n) = f(\vec{x}).$$

Поскольку входные данные $\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n$ неточны, $\hat{y} = f(\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n) = f(\hat{\vec{x}})$ - приближенное значение результата. Пусть известна область G в пространстве переменных $x_1, x_2, \dots, x_n$:

$$G = \{\vec{x} \mid |x_i - \hat{x}_i| \leq \Delta x_i, i = 1, \dots, n\},$$

которой принадлежат значения входных параметров. Если $f(x_1, x_2, \dots, x_n)$ - непрерывно дифференцируемая функция своих аргументов, то по формуле конечных приращений Лагранжа имеем следующую оценку погрешности:

$$\Delta y = y - \hat{y} = f(\vec{x}) - f(\vec{\hat{x}}) = \sum_{i=1}^n \frac{\partial f(\vec{\theta})}{\partial x_i} \cdot \Delta x_i \leq \sum_{i=1}^n m_i \cdot \Delta x_i. \quad (1.22)$$

Здесь $(\theta_1, \theta_2, \dots, \theta_n)$ - точка, расположенная между $(x_1, x_2, \dots, x_n)$ и $(\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n)$,

$$m_i = \sup_G \frac{\partial f(\vec{x})}{\partial x_i}$$

Оценка показывает, что накопление погрешностей округления зависит от величины входных параметров и от характера алгоритма.

Если $f(x_1, x_2, \dots, x_n) \neq 0$ и $x_i \neq 0, i=1, \dots, n$, справедлива следующая оценка относительной погрешности:

$$\delta(\hat{y}) = \sum_{i=1}^n \frac{x_i}{f(\vec{x})} \cdot \frac{\partial f(\vec{\theta})}{\partial x_i} \cdot \delta(x_i). \quad (1.23)$$

Коэффициенты

$$K_i = \frac{x_i}{f(\vec{x})} \cdot \frac{\partial f(\vec{\theta})}{\partial x_i}$$

являются коэффициентами усиления относительных погрешностей входных данных. Если значения всех коэффициентов усиления ограничены по абсолютной величине единицей, то накопления погрешностей не происходит. Коэффициенты K_i часто называют *числами обусловленности* задачи.

Часто возникает *обратная задача теории погрешностей*: с какой точностью должны быть заданы входные данные, чтобы получить результат требуемой точности?

Применительно к поставленной выше *прямой задаче* оценивания погрешности результата вычисления значения функции $u = f(x_1, x_2, \dots, x_n)$ при заданных оценках погрешностей аргументов, *обратная задача* заключается в оценивании $\Delta(x_i)$ (или $\delta(x_i)$) по известной величине приращения Δu . Поскольку главной, т.е. линейной частью этого приращения является полный дифференциал du , за границу абсолютной погрешности результата приближенно может быть принята величина

$$\Delta(u) = \sum_{i=1}^n \left| \frac{\partial u}{\partial x_i} \right| \cdot \Delta(x_i) \quad (1.24)$$

Из формулы (1.23) легко получается формула приближенной оценки относительной погрешности значения u :

$$\delta(u) = \frac{\Delta u}{|u|} = \sum_{i=1}^n \left| \frac{\partial u}{\partial x_i} \right| \cdot \frac{\Delta(x_i)}{|u|} = \sum_{i=1}^n \left| \frac{\partial u}{u \partial x_i} \right| \cdot \Delta(x_i) = \sum_{i=1}^n \left| \frac{\partial \ln u}{\partial x_i} \right| \cdot \Delta(x_i) \quad (1.25)$$

Для случая дифференцируемой функции одной переменной грубое решение обратной задачи очевидно:

если $y = f(x)$, то $\Delta(u) \approx |dy| = |f'(x)| \cdot \Delta x$, откуда $\Delta x \approx \frac{\Delta(u)}{|f'(x)|}$

Для функций большего числа переменных обратная задача, вообще говоря, некорректна. Для ее решения нужны дополнительные условия.

Например, можно применить принцип равных влияний, состоящий в предположении, что частные дифференциалы $|\frac{\partial u}{\partial x_i}| \cdot \Delta(x_i)$ в (1.24) одинаково

влияют на погрешность значения функции, тогда $\Delta(u) = n \cdot |\frac{\partial u}{\partial x_i}| \cdot \Delta(x_i)$, откуда

$$\Delta(x_i) = \frac{\Delta(u)}{n \cdot |\frac{\partial u}{\partial x_i}|}.$$

В качестве другого довольно естественного допущения можно принять равенство относительных погрешностей всех аргументов, т.е. считать

$$\delta(x_i) = \frac{\Delta(x_i)}{|x_i|} = p \quad \text{при всех } i = \overline{1, n}.$$

Тогда $\Delta(x_i) = p \cdot |x_i|$, и значит $\Delta(u) = p \cdot \sum_{i=1}^n |\frac{\partial u}{\partial x_i}| x_i$.

Из последнего равенства получаем величину $p = \frac{\Delta(u)}{\sum_{i=1}^n |x_i| \frac{\partial u}{\partial x_i}}$, характеризующую

относительный уровень точности задания аргументов, на основе которого за границы абсолютных погрешностей принимаем

$$\Delta(x_i) = \frac{|x_i| \cdot \Delta(u)}{\sum_{i=1}^n |x_i| \frac{\partial u}{\partial x_i}}.$$

Рассмотренный выше аналитический способ учета погрешностей действий, предполагающий точное оценивание погрешностей чрезвычайно громоздок и не может быть рекомендован при массовых вычислениях.

При больших количествах однотипных вычислений вступают в силу уже вероятностные или статические законы формирования погрешностей.

В частности, если $n > 10$ и все слагаемые округлены до m -го десятичного разряда, то для подсчета абсолютной погрешности суммы S применяют правило Чеботарева

$$\Delta(S) = \sqrt{3n} \cdot 0,5 \cdot 10^{-m}$$

Различие в результатах классического и статистического подходов к оцениванию погрешности суммы рассмотрим на примере оценки погрешности среднего арифметического нескольких приближенных чисел.

Пусть $x = \frac{x_1 + x_2 + \dots + x_n}{n}$ - среднее арифметическое n ($n > 10$) приближенных

чисел (например, результатов измерений), имеющих одинаковый уровень абсолютных погрешностей $\Delta(x_i) = 0,5 \cdot 10^{-m}$. Тогда классическая оценка абсолютной погрешности величины x есть

$$\Delta(x) = \frac{1}{n}(\Delta(x_1) + \Delta(x_2) + \dots + \Delta(x_n)) = \frac{1}{n} \cdot n \cdot 0,5 \cdot 10^{-m} = 0,5 \cdot 10^{-m} = \Delta x_i$$

т.е. такая же, как у исходных данных. В то же время по формуле Чеботарева

$$\Delta(x) = \frac{1}{n} \sqrt{3n} \cdot 0,5 \cdot 10^{-m} = \sqrt{\frac{3}{n}} \cdot 0,5 \cdot 10^{-m} = \sqrt{\frac{3}{n}} \cdot \Delta(x_i) \xrightarrow{n \rightarrow \infty} 0.$$

Как видим, применение правила Чеботарева приводит к естественному выводу о том, что арифметическое усреднение результатов измерений увеличивает точность, чего нельзя сказать на основе классической теории погрешностей.

Прямое применение статических оценок погрешностей также является достаточно сложным делом. Однако именно такие оценки подкрепляют практические правила работы с приближенными числами, составляют основу *технического подхода*. Этот подход связывают с именем известного кораблестроителя, математика и механика А.Н. Крылова (1863-1945г).

Согласно принципу Крылова приближенное число должно записываться так, чтобы в нем все значащие цифры, кроме последней, были верными и лишь последняя была бы сомнительна и притом в среднем не более чем на одну единицу (“в среднем” здесь понимается в вероятностном смысле).

Устойчивость и корректность постановки задачи. Пусть в результате решения задачи по исходному значению величины x находится значение искомой величины y . Если исходная величина имеет абсолютную погрешность $\Delta(x)$, то решение y имеет погрешность $\Delta(y)$. Задача называется *устойчивой по исходному параметру x* , если решение y непрерывно зависит от x , т.е. если малое приращение исходной величины x приводит к малому приращению искомой величины y . Другими словами, малые погрешности в исходной величине приводят к малым погрешностям в результате расчётов.

Задача называется поставленной *корректно*, если для любых значений исходных данных её решение существует, единственно и устойчиво по исходным данным.

Отсутствие устойчивости означает, что даже незначительные погрешности в исходных данных приводят к большим погрешностям в решении или вообще к неверному результату.

Пример 8. Пусть задана система

$$\begin{cases} 3,0000 \cdot x - 7,0001 \cdot y = 0,9998, \\ 3,0000 \cdot x - 7,0000 \cdot y = 1. \end{cases}$$

Легко проверить, что $x=5$, $y=2$ являются решениями этой системы. Рассмотрим теперь систему, близкую к ней:

$$\begin{cases} 3,0000 \cdot x - 7,0001 \cdot y = 1, \\ 3,0000 \cdot x - 7,0000 \cdot y = 1. \end{cases}$$

Эта система, как нетрудно убедиться, имеет решение $x=\frac{1}{3}$, $y=0$.

Как видно, изменение исходных данных на $2 \cdot 10^{-4}$ одной из правых частей значительно изменило решение системы.

Рассмотрим снова систему, близкую к исходной:

$$\begin{cases} 3,0000 \cdot x - 7,0000 \cdot y = 0,9998, \\ 3,0000 \cdot x - 7,0000 \cdot y = 1. \end{cases}$$

Легко видеть, что эта система несовместна, т.е. не имеет решений.

Системы такого вида называются *плохо обусловленными*. Они довольно часто встречаются в приложениях при решении практических задач.

ГЛАВА 2. ЧИСЛЕННЫЕ МЕТОДЫ ЛИНЕЙНОЙ АЛГЕБРЫ

2.1. Основные сведения из линейной алгебры

К численным методам линейной алгебры относятся численные методы решения следующих задач:

- решение систем линейных алгебраических уравнений,
- обращение матриц,
- вычисление определителей квадратных матриц,
- нахождение собственных значений и векторов матриц (решение спектральной задачи линейной алгебры).

Напомним основную терминологию - определения, обозначения, понятия и факты линейной алгебры, и обозначения, которые непосредственно связаны с материалом книги и будут использоваться в дальнейшем.

Векторы и матрицы. Матричные операции. Прямоугольную таблицу вещественных чисел вида

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix}$$

называют *прямоугольной матрицей* размера $m \times n$ или $m \times n$ - *матрицей*. Числа a_{ij} называют *элементами* этой матрицы. Первый индекс (i) - номер строки, а второй индекс (j) - номер столбца, на пересечении которых расположен данный элемент a_{ij} . Матрица, состоящая из одной строки, называется *вектор-строкой* и обозначается $\vec{x} = (x_1, x_2, \dots, x_n)$. Матрица, состоящая из одного столбца - *вектор-столбцом*. Матрица A размера $n \times n$ называется *квадратной*, а число n - *порядком* этой матрицы.

Квадратная матрица вида

$$D = \begin{bmatrix} \alpha_1 & 0 & \dots & 0 \\ 0 & \alpha_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \alpha_n \end{bmatrix}$$

называется *диагональной*. Если все элементы диагонали равны между собой, матрица называется *скалярной*, и если они равны единице – *единичной* (обозначается E или I).

Квадратная матрица U называется *верхней треугольной*, если ее элементы, расположенные выше диагонали, не равны нулю:

$$U = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ 0 & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & a_{nn} \end{bmatrix}.$$

Квадратная матрица L называется *нижней треугольной*, если ее элементы, расположенные ниже диагонали, не равны нулю:

$$L = \begin{bmatrix} a_{11} & 0 & \dots & 0 \\ a_{21} & a_{22} & \dots & 0 \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}$$

Переставив в матрице строки и столбцы, получают так называемую *транспонированную к матрице A матрицу* размера $n \times m$,

$$A^T = \begin{bmatrix} a_{11} & a_{21} & \dots & a_{m1} \\ a_{12} & a_{22} & \dots & a_{m2} \\ \dots & \dots & \dots & \dots \\ a_{1n} & a_{2n} & \dots & a_{mn} \end{bmatrix}$$

с элементами $a'_{ij} = a_{ji}$.

Квадратная матрица называется *симметричной*, если она равна своей транспонированной матрице: $a_{ij} = a_{ji}$.

Квадратная матрица называется *ленточной*, если ее элементы удовлетворяют соотношениям: $a_{ij} = 0$, $m_1 < i - j$; $j - i > m_2$ для некоторых чисел m_1, m_2 . Шириной ленты называют число $s = m_1 + m_2 + 1$.

Матрица называется *разреженной*, если отношение количества ненулевых элементов к общему числу ее элементов (коэффициент плотности) меньше или равно $1/n$.

Сравнивать, складывать и вычитать можно только матрицы одинаковых размеров. Указанные операции выполняются над одноименными элементами матриц.

Произведение матрицы $A_{m \times n}$ справа на матрицу $B_{l \times k}$ определено только в том случае, когда число столбцов матрицы A равно числу строк матрицы B ($l = n$). Произведением $C = AB$ называется матрица $C_{m \times k}$ с элементами

$$c_{ij} = \sum_{p=1}^n a_{ip} b_{pj}, \quad i = 1, \dots, m; \quad j = 1, \dots, k.$$

В дальнейшем, если мы пишем формулу произведения AB для каких-либо матриц A и B , то без дополнительных оговорок предполагаем, что операция умножения этих матриц определена, т.е. число столбцов матрицы A равно числу строк матрицы B . Одна из главных особенностей, которая отличает алгебру матриц от алгебры чисел, заключается в том, что матрица AB не равна

матрице BA (даже в случае квадратных матриц) т.е. операция умножения матриц не коммутативна.

Матрица A называется *нормальной*, если она перестановочна со своей транспонированной матрицей: $A^T A = A A^T$.

Определитель квадратной матрицы. Миноры. Ранг матрицы. Определителем квадратной матрицы порядка n называется сумма $n!$ членов вида $(-1)^k a_{1k_1} a_{2k_2} \dots a_{nk_n}$, каждый из которых равен произведению n элементов матрицы, взятых по одному из каждой строки и каждого столбца. При этом знак члена определяется количеством инверсий k в перестановке $k_1, k_2, \dots, k_n$ из чисел $1, 2, \dots, n$.

Перестановкой из n чисел $1, 2, 3, \dots, n$ называется любое упорядоченное расположение этих чисел. Количество всех перестановок равно $n!$. Два числа в перестановке образуют инверсию, если большее число стоит перед меньшим. Например, в перестановке 2413 число инверсий равно 3.

Определители второго и третьего порядков, например, равны:

$$\det A = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = (-1)^0 a_{11} a_{22} + (-1)^1 a_{12} a_{21} = a_{11} a_{22} - a_{12} a_{21},$$

$$\det A = \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11} a_{22} a_{33} + a_{12} a_{23} a_{31} + a_{13} a_{21} a_{32} - a_{13} a_{22} a_{31} - a_{11} a_{23} a_{32} - a_{12} a_{21} a_{33}.$$

Вычисление определителей более высокого порядка можно свести к вычислению определителей второго и третьего порядков.

Легко заметить, что определитель треугольной и диагональной матриц равен произведению диагональных элементов.

Минором элемента a_{ij} квадратной матрицы A называется определитель матрицы M_{ij} порядка $n-1$, полученной вычеркиванием i -й строки и j -го столбца матрицы. Алгебраическим дополнением элемента называется выражение $A_{ij} = (-1)^{i+j} \det M_{ij}$.

Минором k -го порядка матрицы A называется определитель матрицы M , образованной элементами, стоящими на пересечении любых k строк и столбцов матрицы A . Минор матрицы называется *главным*, если он образован элементами, стоящими на пересечении строк и столбцов с одинаковыми номерами. *Рангом* матрицы A называется максимальный порядок отличных от нуля миноров матрицы. Ранг прямоугольной матрицы $A_{m \times n}$ не может превышать $\min\{m, n\}$ и равен r , если найдется, по крайней мере, один ее минор порядка r , отличный от нуля, а все миноры порядка $r+1$ и выше равны нулю.

Обратная матрица. Квадратная матрица называется *невырожденной*, если ее определитель отличен от нуля, в противном случае матрица называется

вырожденной. Для невырожденной матрицы существует обратная матрица A^{-1} такая, что $A^{-1}A = A A^{-1} = E$.

Для матриц небольшого порядка обратную матрицу можно найти, используя матрицу, составленную из алгебраических дополнений (присоединенную матрицу):

$$A^{-1} = \frac{1}{\det A} \begin{bmatrix} A_{11} & A_{12} & \dots & A_{1n} \\ A_{21} & A_{22} & \dots & A_{2n} \\ \dots & \dots & \dots & \dots \\ A_{n1} & A_{n2} & \dots & A_{nn} \end{bmatrix}^T. \quad (2.1)$$

Матрица, обратная произведению $C=AB$ квадратных невырожденных матриц, определяется следующим образом: $C^{-1} = B^{-1}A^{-1}$.

В численных методах линейной алгебры большую роль играют ортогональные матрицы. Квадратная матрица является *ортогональной*, если $A^T A = E$, т.е. для ортогональной матрицы $A^T = A^{-1}$. Ортогональные матрицы обладают следующими свойствами:

- строки (столбцы) ортогональных матриц попарно ортогональны;
- сумма квадратов элементов каждой строки (столбца) ортогональной матрицы равна 1;
- определитель ортогональной матрицы равен 1.

Норма вектора и норма матрицы. Множество R_n всех n -мерных вещественных векторов образует линейное пространство E . *Нормой вектора* $\vec{x} \in R_n$ называется действительное число $\|\vec{x}\|$, которое ставится в соответствие вектору и обладает свойствами (аксиомами нормы):

1. $\|\vec{x}\| \geq 0$, причём $\|\vec{x}\| = 0$ тогда и только тогда, когда $\vec{x}$ - нулевой вектор ($\vec{x} = (0, 0, \dots, 0)$);
2. $\|\alpha \vec{x}\| = |\alpha| \cdot \|\vec{x}\|$ для любого действительного числа α ;
3. $\|\vec{x} + \vec{y}\| \leq \|\vec{x}\| + \|\vec{y}\|$ для любых $\vec{x}$ и $\vec{y}$ из E .

Свойство 3 нормы вектора называется *неравенством треугольника*.

Пространство E с определённой на нём нормой называется *линейным нормированным пространством*.

Норма в пространстве E вводится неоднозначно несколькими способами:

1. Норма $\|\vec{x}\|_1$ определяется соотношением

$$\|\vec{x}\|_1 = \sum_{j=1}^n |x_j| = |x_1| + |x_2| + \dots + |x_n| \quad (2.2)$$

2. Норма $\|\vec{x}\|_2$ имеет вид

$$\|\vec{x}\|_2 = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2} \quad (2.3)$$

и определяется с помощью скалярного произведения векторов $\vec{x} = (x_1, x_2, \dots, x_n)$ и $\vec{y} = (y_1, y_2, \dots, y_n)$ из $E = \mathbf{R}^n$:

$$(\vec{x}, \vec{y}) = x_1 y_1 + x_2 y_2 + \dots + x_n y_n. \quad (2.4)$$

3. Норма $\|\vec{x}\|_3$ вводится с помощью соотношения

$$\|\vec{x}\|_\infty = \max\{|x_1|, |x_2|, \dots, |x_n|\} = \max_{1 \leq j \leq n} |x_j|. \quad (2.5)$$

Легко проверить, что величины $\|\vec{x}\|_1, \|\vec{x}\|_2, \|\vec{x}\|_3$, определённые равенствами (2.2), (2.3), (2.5) соответственно, удовлетворяют аксиомам 1-3 нормы вектора. Эти наиболее распространенные на практике нормы называют соответственно октаэдрической, сферической и кубической по названию поверхностей, определяемых уравнением $\|\vec{x}\| = 1, \vec{x} \in R^3$.

Пространства E с различными введенными нормами, вообще говоря, являются различными линейными нормированными пространствами. Вектор $\vec{x}$ из E называется *нормированным*, если его норма равна единице, т.е. $\|\vec{x}\| = 1$.

Пусть A - квадратная $n \times n$ матрица. Тогда для любого $\vec{x} \in E$ вектор $\vec{y} = A\vec{x}$ тоже принадлежит E , и его норма равна $\|\vec{y}\| = \|A\vec{x}\|$.

Норму $\|A\|$ матрицы A определим следующим образом

$$\|A\| = \sup_{\vec{x} \neq 0} \frac{\|A\vec{x}\|}{\|\vec{x}\|}, \quad (2.6)$$

где $\|\vec{x}\|$ и $\|A\vec{x}\|$ - введенные выше нормы векторов $\vec{x}$ и $A\vec{x}$. Норма матрицы, определённой равенством (2.6), называется *согласованной с нормой вектора*.

Из определения (2.6) имеем

$$\|A\| = \sup_{\vec{x} \neq 0} \frac{\|A\vec{x}\|}{\|\vec{x}\|} \geq \frac{\|A\vec{x}\|}{\|\vec{x}\|}, \|\vec{x}\| \neq 0.$$

Отсюда

$$\|A\vec{x}\| \leq \|A\| \cdot \|\vec{x}\| \quad (2.7)$$

причём это соотношение справедливо и при $\vec{x} = \vec{0}$.

На основании (2.7) для любого $\vec{x}$ из E выполняются неравенства

$$\|BA\vec{x}\| \leq \|B(A\vec{x})\| \leq \|B\| \cdot \|A\vec{x}\| \leq \|B\| \cdot \|A\| \cdot \|\vec{x}\|,$$

отсюда

$$\|A^2 \cdot \vec{x}\| \leq \|A\|^2 \cdot \|\vec{x}\|, \dots, \|A^k \vec{x}\| \leq \|A\|^k \cdot \|\vec{x}\|,$$

т.е.

$$\|A^k\| \leq \|A\|^k.$$

Вид согласованной нормы матрицы зависит от избранной нормы вектора в E . Так, для $\|\cdot\|_1$ имеем

$$\|\vec{Ax}\|_1 = \sum_{i=1}^n \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \sum_{i=1}^n \sum_{j=1}^n |a_{ij}| \cdot |x_j| = \sum_{j=1}^n |x_j| \cdot \sum_{i=1}^n |a_{ij}| \leq \max_{1 \leq j \leq n} \left\{ \sum_{i=1}^n |a_{ij}| \right\} \cdot \sum_{j=1}^n |x_j|.$$

Можно найти вектор $\vec{x}$ из E такой, что это неравенство выполняется как верное равенство, т.е. будем иметь для найденного $\vec{x}$:

$$\|A\vec{x}\|_1 = \max_{1 \leq j \leq n} \left\{ \sum_{i=1}^n |a_{ij}| \right\} \cdot \|\vec{x}\|_1$$

Отсюда и из определения (2.6) получаем, что если норма вектора определяется равенством (2.2), то согласованная норма матрицы A даётся формулой

$$\|A\|_1 = \max_{1 \leq j \leq n} \left\{ \sum_{i=1}^n |a_{ij}| \right\}, \quad (2.8)$$

т.е. норма $\|A\|_1$ есть максимальная сумма модулей элементов столбцов
матрицы A .

Для нормы $\|\vec{x}\|_2$, определяемой скалярным произведением, согласованная норма $\|A\|$, матрицы A имеет вид

$$\|A\|_2 = \left(\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2 \right)^{\frac{1}{2}}. \quad (2.9)$$

Для нормы $\|\vec{x}\|_3$, согласованная норма матрицы A даётся формулой

$$\|A\|_3 = \max_{1 \leq i \leq n} \left\{ \sum_{j=1}^n |a_{ij}| \right\}, \quad (2.10)$$

т.е. норма $\|A\|_3$ есть максимальная сумма модулей элементов строк матрицы A .

Системы линейных алгебраических уравнений (СЛАУ). Система m линейных алгебраических уравнений с n неизвестными записывается в виде:

[illegible]

Здесь a_{ij} – заданные числа – коэффициенты системы; $b_1, b_2, \dots, b_m$ – тоже заданные числа – правые части системы; $x_1, x_2, \dots, x_n$ – неизвестные, которые следует найти. Введя матрицу A коэффициентов и векторы-столбцы неизвестных и правых частей (свободных членов), систему (2.11) можно коротко записать в *векторно-матричном* виде:

$$A\vec{x} = \vec{b}. \quad (2.12)$$

Решением системы (2.11) называется набор чисел $x_1 = \alpha_1, x_2 = \alpha_2, \dots, x_n = \alpha_n$, подстановка которых в каждое из равенств (2.11) превращают всех их в тождества. Система (2.11) называется *совместной*, если

она имеет хотя бы одно решение. Если система не имеет решений, она называется *несовместной (противоречивой)*. Система (2.11) называется *определенной*, если она имеет единственное решение, и *неопределенной*, если решений больше одного.

Расширенной матрицей системы (2.11) называется матрица B размерами $n \times (n+1)$, полученная из матрицы A добавлением столбца свободных членов и содержащая всю информацию о системе:

$$B = [A | \vec{b}] = \left[\begin{array}{cccc|c} a_{11} & a_{12} & \dots & a_{1n} & b_1 \\ a_{21} & a_{22} & \dots & a_{2n} & b_2 \\ \dots & \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nn} & b_n \end{array} \right].$$

С этой матрицей можно обращаться так же, как и с системой - переставлять строки, прибавлять кратное одной строки к другой, исключая неизвестные и приводя матрицу к треугольному или диагональному виду.

Вопрос о совместности системы линейных алгебраических уравнений (СЛАУ) полностью решается теоремой Кронекера-Капелли, которая утверждает, что *система линейных алгебраических уравнений (2.11) совместна тогда и только тогда, когда ранг расширенной системы B равен рангу матрицы A : $r(A) = r(B)$* . Совместная система имеет единственное решение, если ранг системы равен числу неизвестных n , и бесконечно много решений, если $r(A) < n$.

Если матрица A - квадратная и ее определитель $|A| \neq 0$, то такая система всегда совместна и имеет единственное решение, которое может быть найдено по формулам Крамера,

$$x_i = \frac{\det A_i}{\det A}, \quad i = 1, \dots, n \quad (2.13)$$

где $\det A_i$ - определитель матрицы, в которой столбец коэффициентов при вычисляемом неизвестном заменен столбцом свободных членов. Эти формулы применимы на практике только при небольших n ($n = 2, 3$).

При решении совместной системы линейных алгебраических уравнений с прямоугольной матрицей вначале устанавливают ранг матрицы - $r(A) = r$, а затем переставляют уравнения и неизвестные таким образом, чтобы отличный от нуля минор матрицы, имеющий порядок r , занял положение в верхнем левом углу матрицы. Если $r = n$ и $r \leq m$, система имеет единственное решение, которое можно найти, решая первые n уравнений преобразованной системы. Если $r < n$ и $r \leq m$, то систему решают относительно первых r неизвестных $x_1, x_2, \dots, x_r$, а неизвестным $x_{r+1}, x_{r+2}, \dots, x_n$ придают произвольные значения. Различных наборов может быть бесконечно много, поэтому система в этом случае будет неопределенной.

Таким образом, при решении СЛАУ общего вида необходимо рассмотреть следующие вопросы:

- совместна или несовместна система;

- определена или не определена совместная система;
- как описать совокупность решений неопределенной системы;
- как разработать метод получения единственного решения определенной системы.

В дальнейшем при рассмотрении методов решения систем линейных уравнений будем предполагать, что система определена, т.е. однозначно разрешима.

Методы решения СЛАУ делятся на две группы – прямые и итерационные. *Прямые методы* используют конечные соотношения или формулы для вычисления неизвестных. К прямым (или точным) методам решения СЛАУ относятся алгоритмы, которые в предположении, что вычисления ведутся без округлений, позволяют получить точное решение системы за конечное число арифметических действий $Q(A)$. В прямых методах число необходимых для решения задачи арифметических операций зависит только от вида вычислительной схемы и от порядка матрицы n . Считают, что для произвольной невырожденной матрицы прямые методы с оценкой числа операций $Q(A)=O(n^3)$ являются оптимальными.

Итерационные методы – это методы последовательного улучшения решения и методы последовательных приближений. В них задается начальное приближенное решение. Потом с помощью некоторого алгоритма проводится один цикл вычислений, уточняющих начальное приближенное решение. Если уточненное значение не удовлетворяет требуемой точности, то, приняв это новое значение за начальное, снова с помощью алгоритма улучшают его. Итерации проводятся до тех пор, пока не будет получено решение с требуемой точностью. Алгоритмы решения линейных систем с использованием итерационных методов обычно более сложные по сравнению с прямыми методами и объем вычислений заранее трудно определить.

2.2. Прямые методы решения систем линейных алгебраических уравнений (СЛАУ)

Большинство прямых методов основано на идее последовательного эквивалентного преобразования заданной системы с целью исключения неизвестных из части уравнений. В результате исходная система преобразуется в эквивалентную ей систему с матрицей более простой формы, например треугольной или диагональной и ее решение уже не представляет труда.

В основе рассматриваемых ниже методов лежит следующее утверждение
Пусть все главные миноры матрицы A отличны от нуля, т.е.

$$a_{11} \neq 0, \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} \neq 0, \dots, \det A \neq 0. \quad (2.14)$$

Тогда существуют такие нижняя L и верхняя U треугольные матрицы, что матрица A представима в виде произведения этих матриц:

$$A = LU. \quad (2.15)$$

Если элементы диагонали одной из треугольных матриц фиксированы (ненулевые), то такое разложение единственно.

Например,

$$\begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & 0 & \dots & 0 \\ l_{21} & l_{22} & \dots & 0 \\ \dots & \dots & \dots & \dots \\ l_{n1} & l_{n2} & \dots & l_{nn} \end{bmatrix} \begin{bmatrix} 1 & U_{12} & \dots & U_{1n} \\ 0 & 1 & \dots & U_{2n} \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

Для решения исходной задачи не обязательно искать в явном виде именно разложение (2.15). Принципиальное значение этого утверждения заключается в обосновании возможности сведения общей задачи решения системы (2.12) к двум специальным:

$$\begin{aligned} Ly &= b, \\ Ux &= y. \end{aligned} \quad (2.16)$$

Таким образом, решение системы прямыми методами может быть осуществлено поэтапно: на первом этапе систему (2.12) преобразуют к одной из систем (2.16), на втором - решают упрощенную систему и получают значения неизвестных.

К числу наиболее известных прямых методов относится метод Гаусса и его модификации. Рассмотрим вначале вариант, который иногда называют *схемой единственного деления*.

Метод Гаусса (схема единственного деления). Основная идея метода состоит в том, что система (2.11) приводится к эквивалентной ей системе с верхней треугольной матрицей и единичной диагональю (*прямой ход исключения*). Из полученной системы последовательно, начиная с последнего уравнения, находят неизвестные $x_n, x_{n-1}, \dots, x_1$ (*обратный ход исключения*).

Рассмотрим применение метода на примере системы третьего порядка:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 = b_1, \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 = b_2, \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 = b_3. \end{cases} \quad (2.17)$$

Предположим, что $a_{11} \neq 0$, разделим первое уравнение системы на коэффициент a_{11} . Для исключения x_1 из второго уравнения вычтем из него первое уравнение, умноженное на a_{21} . Затем, умножив первое уравнение на a_{31} , вычтем его из третьего уравнения, исключая тем самым из него x_1 . Получим равносильную систему уравнений вида

$$\begin{aligned} x_1 + a'_{12}x_2 + a'_{13}x_3 &= b'_1, \\ a'_{22}x_2 + a'_{23}x_3 &= b'_2, \\ a'_{32}x_2 + a'_{33}x_3 &= b'_3, \end{aligned} \quad (2.18)$$

где

$$\begin{aligned} a'_{1j} &= a_{1j} / a_{11}, & j &= 1, 2, 3, & b'_1 &= b_1 / a_{11}, \\ a'_{ij} &= a_{ij} - a_{i1}a'_{1j}, & b'_i &= b_i - a_{i1}b'_1, & i, j &= 2, 3 \end{aligned} \quad (2.19)$$

Аналогично исключим x_2 из третьего уравнения системы (2.17). Пусть $a'_{22} \neq 0$, разделим второе уравнение системы на коэффициент a'_{22} . Для исключения x_2 из третьего уравнения вычтем из него первое уравнение, умноженное на a'_{32} . В результате получим систему

$$\begin{aligned} x_1 + a'_{12}x_2 + a'_{13}x_3 &= b'_1, \\ x_2 + a''_{23}x_3 &= b''_2, \\ a''_{33}x_3 &= b''_3, \end{aligned} \quad (2.20)$$

где

$$\begin{aligned} a''_{23} &= a'_{23} / a'_{22}, & b''_2 &= b'_2 / a'_{22}, \\ a''_{33} &= a'_{33} - a'_{32}a''_{23}, & b''_3 &= b'_3 - a'_{32}b''_2. \end{aligned}$$

Обратный ход начинается с решения третьего уравнения системы (2.20). Находим

$$x_3 = \frac{b''_3}{a''_{33}}.$$

Используя найденное x_3 , из второго уравнения системы (2.20) найдем x_2 :

$$x_2 = b''_2 - a''_{23}x_3,$$

затем — x_1 :

$$x_1 = b'_1 - a'_{12}x_2 - a'_{13}x_3.$$

Обобщим этот алгоритм на случай линейной системы с произвольным числом уравнений. Для удобства дальнейших преобразований обозначим элементы правой части в расширенной матрице как $a_{i(n+1)}$

$$B = \left[\begin{array}{ccccc|c} a_{11} & a_{12} & a_{13} & \dots & a_{1n} & a_{1(n+1)} \\ a_{21} & a_{22} & a_{23} & \dots & a_{2n} & a_{2(n+1)} \\ \dots & \dots & \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & a_{n3} & \dots & a_{nn} & a_{n(n+1)} \end{array} \right]. \quad (2.21)$$

На первом шаге разделим первое уравнение системы на a_{11} . Обозначим коэффициенты полученного *приведенного* уравнения $U_{1j}^{(1)} = a_{1j} / a_{11}$, ($j = 2, \dots, n+1$), домножим его на коэффициент a_{21} и вычтем из второго уравнения системы, исключая тем самым x_1 из второго уравнения (обнуляя коэффициент a_{21} матрицы). Поступим аналогично с остальными уравнениями и получим новую систему, матрица которой в первом столбце, кроме первого элемента, содержит только нули, т.е.

$$\left[\begin{array}{ccccc|c} 1 & U_{12}^{(1)} & U_{13}^{(1)} & \dots & U_{1n}^{(1)} & U_{1(n+1)}^{(1)} \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & \dots & a_{2n}^{(1)} & a_{2(n+1)}^{(1)} \\ \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & a_{n2}^{(1)} & a_{n3}^{(1)} & \dots & a_{nn}^{(1)} & a_{n(n+1)}^{(1)} \end{array} \right]. \quad (2.22)$$

Первое уравнение в дальнейших преобразования не участвует. Описанный выше процесс исключения неизвестных применим к матрице $[a_{ij}^{(1)}]$ размерами $(n-1) \times n$, которую называют *активной*. После k аналогичных шагов получим k приведенных уравнений с коэффициентами

$$U_{lj}^{(l)} = a_{lj}^{(l-1)} / a_{ll}^{(l-1)}, \quad (l = 1, \dots, k, \quad j = k+1, \dots, n+1) \quad (2.23)$$

и активную матрицу $[a_{ij}^{(k)}]$ размерами $(n-k) \times (n-k+1)$, элементы которой вычисляются по формулам

$$a_{ij}^{(k)} = a_{ij}^{(k-1)} - a_{ik}^{(k-1)} \times U_{kj}^{(k)}, \quad (i = k+1, \dots, n, \quad j = k+1, \dots, n+1). \quad (2.24)$$

Прямой ход метода Гаусса заканчивается после n шагов определением $U_{n(n+1)}^{(n)}$.

Обратный ход метода Гаусса заключается в последовательном определении компонент решения, начиная с x_n и заканчивая x_1 , по следующим формулам:

$$x_n = U_{n(n+1)}^{(n)}, \quad x_k = U_{k(n+1)}^{(k)} - \sum_{i=k+1}^n U_{ki}^{(k)} x_i, \quad k = n-1, \dots, 1. \quad (2.25)$$

Элементы $a_{kk}^{(k-1)}$, на которые осуществляется деление, называются *ведущими* или *главными* элементами. Для возможности выполнения расчетов по описанному алгоритму предполагалось, что все они отличны от нуля ($a_{kk}^{(k-1)} \neq 0$).

Решение системы алгебраических уравнений методом Гаусса требует $\frac{1}{3}(n^3 + 3n^2 + n)$ операций умножения и деления и $\frac{1}{6}(2n^3 + 3n^2 - 5n)$ операций сложения. Таким образом, оценка числа необходимых для решения задачи арифметических операций $Q(A) \approx \frac{2}{3}n^3$ и метод Гаусса относится к числу опти-

мальных. Для реализации метода требуется хранить $n^2 + n + 1$ машинных слов.

Метод Гаусса с выбором ведущего элемента. Возможность прекращения вычислений из-за деления на нуль - не единственная неприятность, связанная с реализацией алгоритма метода Гаусса по формулам (2.23) – (2.25). Так как реальные вычисления производятся с машинными числами, то неизбежны ошибки округления и их накопление. Если ведущий элемент очень мал, то при

делении и дальнейшем вычитании приведенного уравнения из последующих возникает большая вычислительная погрешность. Для устранения обрыва вычислительного процесса и уменьшения этой погрешности рекомендуется осуществлять перестановку уравнений. Если на каком-либо шаге m ведущий элемент равен нулю (или меньше некоторого малого числа $\varepsilon > 0$ близкого к минимально допустимому на ЭВМ числу), то нужно переставить строки расширенной матрицы местами, сделав ведущей ту строку, у которой коэффициент при x_m не равен нулю. Это всегда возможно, т.к. по предположению система однозначно разрешима и все коэффициенты при x_m не могут одновременно равняться нулю.

Метод с выбором *ведущего* (*разрешающего* или *главного*) элемента является одной из модификаций метода Гаусса, позволяющей исключить деление на нуль и повысить точность вычислений. Идея метода заключается в том, чтобы при прямом ходе в алгоритме метода Гаусса на каждом шаге исключения производить выбор наибольшего по модулю элемента в качестве *ведущего*. Этого достигают перестановкой строк или столбцов матрицы коэффициентов. Существуют различные стратегии выбора ведущего элемента: выбор в строке, столбце или по всей активной матрице. Наибольший эффект достигается при выборе наибольшего по модулю элемента во всей активной матрице, однако такая модификация метода Гаусса встречается довольно редко, также как и модификация с выбором элемента в строке. Это связано с сильным усложнением алгоритма, т.к. перестановка столбцов местами равносильна переобозначению переменных. Возникает необходимость запоминать номера переставляемых столбцов и выполнять обратное переобозначение переменных после окончания вычислений. Наиболее распространённой в вычислительной практике является стратегия выбора *главного элемента столбца* - нахождение максимального по модулю элемента k -го столбца матрицы $[a_{ij}^{(k)}]$ и использование его в качестве ведущего элемента на k -м шаге исключения. В этом случае для невырожденных систем гарантируется, что ведущие элементы не равны нулю, и уменьшается погрешность при делении и последующем вычитании при преобразованиях.

Эффективность использования максимального ведущего элемента во многих случаях зависит от величины элементов строк и столбцов матрицы A . Желательно, чтобы матрица была уравновешена, т.е. выполнялись условия

$$r_i \approx c_i, \quad \text{где } r_i = \sum_{j=1}^n |a_{ij}|, \quad c_k = \sum_{j=1}^n |a_{jk}|.$$

Поэтому рекомендуется масштабировать предварительно каждое уравнение исходной системы, разделив на его наибольший по абсолютной величине коэффициент. Это делает рост элементов промежуточных матриц ограниченным. Более экономным является совмещение масштабирования и поиска мак-

симального элемента в строке – неявное масштабирование, при котором в качестве ведущего выбирают элемент $a_{jj}^{(j-1)}$, для которого $\frac{|a_{jj}^{(j-1)}|}{r_j} = \max_{i=j, \dots, n} \left(\frac{|\tilde{a}_{ij}^{(j-1)}|}{r_i} \right)$.

Выбор в качестве ведущего элемента максимального по модулю элемента столбца уменьшает вычислительную погрешность, но не устраняет ее полностью. Поэтому при выполнении расчетов с машинными числами необходим контроль за точностью вычислений. Одна из наиболее простых схем контроля основана на том, что увеличение значений всех неизвестных на единицу равносильно замене данной системы контрольной системой, в которой свободные члены равны суммам всех коэффициентов соответствующей строки расширенной матрицы. Решая вместе с заданной также и контрольную систему, мы получаем возможность контролировать попутно каждый шаг расчета.

Специфической особенностью решения СЛАУ методом Гаусса является то, что в процессе приведения матрицы системы к треугольному виду преобразованиями прямого хода правая часть системы участвует только пассивно – в виде дополнительного столбца расширенной матрицы. Это означает, что можно одновременно решать несколько систем с одинаковой матрицей коэффициентов и различными правыми частями. Для этого достаточно составить расширенную матрицу вида

$$B = \left[\begin{array}{ccccc|cc} a_{11} & a_{12} & a_{13} & \dots & a_{1n} & a_{1(n+1)} \dots & a_{1(n+k)} \\ a_{21} & a_{22} & a_{23} & \dots & a_{2n} & a_{2(n+1)} \dots & a_{2(n+k)} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & a_{n3} & \dots & a_{nn} & a_{n(n+1)} \dots & a_{n(n+k)} \end{array} \right], \quad (2.26)$$

в которой для удобства дальнейших преобразований элементы m -й правой части обозначены как $a_{i(n+m)}$, и выполнять все операции метода Гаусса над этой расширенной матрицей.

Метод оптимального исключения. В этой модификации метода Гаусса операции прямого и обратного хода метода выполняются попеременно. На первом шаге после приведения первого уравнения исключается неизвестное x_1 из второго уравнения, а затем с помощью приведенного второго уравнения – неизвестное x_2 из первого. После k таких шагов матрица системы имеет вид

$$\left[\begin{array}{cccc|cc} 1 & \dots & 0 & a_{1(k+1)}^{(k)} & \dots & a_{1n}^{(k)} & a_{1(n+1)}^{(k)} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & \dots & 1 & a_{k(k+1)}^{(k)} & \dots & a_{kn}^{(k)} & a_{k(n+1)}^{(k)} \\ a_{(k+1)1}^{(k)} & \dots & a_{(k+1)k}^{(k)} & a_{(k+1)(k+1)}^{(k)} & \dots & a_{(k+1)n}^{(k)} & a_{(k+1)(n+1)}^{(k)} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ a_{n1}^{(k)} & \dots & a_{nk}^{(k)} & a_{n(k+1)}^{(k)} & \dots & a_{nn}^{(k)} & a_{n(n+1)}^{(k)} \end{array} \right] \quad (2.26)$$

На $k+1$ -м шаге, используя первые k уравнений, исключают неизвестные $x_1, x_2, \dots, x_k$ из $(k+1)$ -го уравнения. Затем посредством этого уравнения исключается неизвестное x_{k+1} из первых k уравнений и т.д.

Таким образом, в результате прямого хода матрица системы приводится к диагональному виду с единицами на главной диагонали. При этом отпадает необходимость обратного хода, поскольку столбец правой части приведенной матрицы $[a_{i(n+1)}^{(n)}]$ и является вектором решения.

Метод Гаусса-Жордана. В этой модификации метода Гаусса операции исключения переменных для каждого приводимого уравнения осуществляют не только ниже, но и выше главной диагонали. Операции с первым уравнением системы полностью аналогичны стандартной схеме. Второе уравнение системы после приведения и домножения на соответствующие коэффициенты вычитают не только из третьего и последующих уравнений, но и из первого. В результате k таких шагов получаем матрицу

$$\left[\begin{array}{cccccc|c} 1 & \dots & 0 & a_{1(k+1)}^{(k)} & \dots & a_{1n}^{(k)} & a_{1(n+1)}^{(k)} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & \dots & 1 & a_{k(k+1)}^{(k)} & \dots & a_{kn}^{(k)} & a_{k(n+1)}^{(k)} \\ 0 & \dots & 0 & a_{(k+1)(k+1)}^{(k)} & \dots & a_{(k+1)n}^{(k)} & a_{(k+1)(n+1)}^{(k)} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & \dots & 0 & a_{n(k+1)}^{(k)} & \dots & a_{nn}^{(k)} & a_{n(n+1)}^{(k)} \end{array} \right]. \quad (2.27)$$

На $k+1$ -м шаге ведущим является элемент $a_{(k+1)(k+1)}^{(k)}$. Разделив $k+1$ уравнение системы на ведущий элемент, получают *приведенное* уравнение, посредством которого исключают неизвестное x_{k+1} из остальных уравнений системы.

Как и в методе оптимального исключения, матрица системы приводится к диагональному виду и вектором решения является столбец $[a_{i(n+1)}^{(n)}]$.

LU – разложение или компактная схема Гаусса. Как отмечалось выше, матрицу A можно представить в виде произведения нижней треугольной матрицы L (*lower*) и верхней треугольной матрицы U (*upper*). Это разложение единственно с точностью до выбора диагональных элементов матриц. Рассмотрим разложение, которое соответствует полученному в схеме метода единственного деления метода Гаусса, где U - верхняя треугольная матрица с единичной диагональю:

$$\begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & 0 & \dots & 0 \\ l_{21} & l_{22} & \dots & 0 \\ \dots & \dots & \dots & \dots \\ l_{n1} & l_{n2} & \dots & l_{nn} \end{bmatrix} \begin{bmatrix} 1 & U_{12} & \dots & U_{1n} \\ 0 & 1 & \dots & U_{2n} \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

Это равенство равносильно следующей системе относительно n^2 неизвестных элементов l_{ij} и U_{ij} матриц L и U :

$$a_{ij} = \sum_{k=1}^{\min(i,j)} l_{ik} \times U_{kj} \quad (i=1,\dots,n \quad j=1,\dots,n). \quad (2.28)$$

Специфика этой системы позволяет находить неизвестные одно за другим посредством алгоритма, который называется *компактной схемой* метода Гаусса или *схемой Халецкого*. Элементы l_{im} и U_{mi} ($m=1,\dots,n$) вычисляются по формулам (2.29) в следующем порядке: вначале элементы m -го столбца матрицы L , затем m -й строки матрицы U .

$$\begin{aligned} l_{i1} &= a_{i1}, & U_{1j} &= a_{1j} / l_{11}, \quad i=1,\dots,n, \quad j=2,\dots,n, \\ l_{im} &= a_{im} - \sum_{k=1}^{m-1} l_{ik} \times U_{km}, & & m=2,\dots,n, \quad i=m,\dots,n, \\ U_{mj} &= (a_{mj} - \sum_{k=1}^{m-1} l_{mk} \times U_{kj}) / l_{mm}, & & j=m+1,\dots,n. \end{aligned} \quad (2.29)$$

Тогда решение системы $Ax=b$ сводится к последовательному решению двух систем:

$$\begin{aligned} Ly &= b, \\ Ux &= y. \end{aligned} \quad (2.30)$$

В отличие от схемы единственного деления компактная схема менее удобна для усовершенствования с целью уменьшения влияния вычислительных погрешностей путем выбора ведущих элементов. Достоинством ее можно считать то, что LU – разложение играет роль обратной матрицы и может использоваться при решении серии систем с одной и той же матрицей и разными правыми частями.

Нахождение определителя и обратной матрицы. Как отмечалось выше, особенностью решения СЛАУ методом последовательного исключения неизвестных является применение только элементарных преобразований системы – вычитания строк и деления строки на ведущий элемент в процессе приведении матрицы системы к треугольному виду. Это позволяет применить прямой ход метода Гаусса для нахождения определителя матрицы:

$$\det A = (-1)^p \sum_{k=1}^n a_{kk}^{(k-1)},$$

где $a_{kk}^{(k-1)}$ – ведущий элемент на k – м шаге, а p – число перестановок строк матрицы при выполнении прямого хода. Если ведущий элемент на каком-то шаге окажется равным нулю, то матрица – вырожденная, т.е. $\det A = 0$.

Метод Гаусса можно использовать и для нахождения обратной матрицы для невырожденной матрицы A . По определению обратная матрица A^{-1} удовлетворяет условию:

$$AA^{-1}=E=\begin{pmatrix} 1 & 0 & \dots & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & \dots & 0 & 1 & 0 \\ 0 & 0 & \dots & 0 & 1 \end{pmatrix}.$$

Рассмотрим обратную матрицу как n столбцов:

$$A^{-1}=[Y_1, Y_2, \dots, Y_n], \quad \text{где } Y_j - j\text{-ый столбец } A^{-1}.$$

Тогда

$$AA^{-1}=[AY_1, AY_2, \dots, AY_n]=E.$$

Таким образом, каждый столбец обратной матрицы является решением системы с одной и той же матрицей коэффициентов:

$$AY_1=\begin{pmatrix} 1 \\ 0 \\ \dots \\ 0 \end{pmatrix}, \quad AY_2=\begin{pmatrix} 0 \\ 1 \\ \dots \\ 0 \end{pmatrix}, \dots, \quad AY_n=\begin{pmatrix} 0 \\ 0 \\ \dots \\ 1 \end{pmatrix}.$$

Как уже отмечалось выше, метод Гаусса позволяет одновременно решать несколько систем с одинаковой матрицей коэффициентов и различными правыми частями. Это связано с тем, что в преобразованиях прямого хода правая часть системы участвует только пассивно – в виде дополнительного столбца расширенной матрицы. Отсюда очевиден алгоритм построения обратной матрицы: необходимо решить n систем с основной матрицей A и правыми частями, в которых один элемент равен 1, а все остальные равны 0. Для этого достаточно составить расширенную матрицу вида

$$[A, E]=\begin{pmatrix} a_{11} & \dots & a_{1n} & 1 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ a_{ln} & \dots & a_{nn} & 0 & 0 & \dots & 1 \end{pmatrix}$$

и выполнять все операции метода Гаусса над этой расширенной матрицей. На месте единичной матрицы будет получена обратная матрица A^{-1} .

Метод прогонки решения систем с трехдиагональными матрицами коэффициентов. Этот метод является модификацией метода Гаусса для систем специального вида с трехдиагональной матрицей A , т.е. с матрицей, все элементы которой, не лежащие на главной и двух побочных диагоналях, равны нулю ($a_{ij} = 0$ при $j > i + 1$ и $j < i - 1$).

Отсюда и из предыдущего равенства находим, что

$$\begin{aligned} A_1 &= -\frac{c_1}{b_1}, \\ B_1 &= \frac{d_1}{b_1}. \end{aligned} \quad (2.34)$$

Далее, из второго уравнения системы (2.31) и соотношения (2.33) получаем равенство

$$a_2(A_1x_2 + B_1) + b_2x_2 + c_2x_3 = d_2,$$

Отсюда выразим x_2 через x_3 :

$$x_2 = \frac{-c_2x_3 + d_2 - a_2B_1}{a_2A_1 + b_2},$$

а из (2.32) имеем

$$x_2 = A_2x_3 + B_2.$$

Из этих двух равенств находим коэффициенты A_2 и B_2 :

$$\begin{aligned} A_2 &= -\frac{c_2}{a_2A_1 + b_2}, \\ B_2 &= \frac{d_2 - a_2B_1}{a_2A_1 + b_2}. \end{aligned}$$

Продолжая этот процесс далее, можно вычислить прогоночные коэффициенты A_i и B_i для любого номера i :

$$A_i = -\frac{c_i}{a_iA_{i-1} + b_i}, B_i = \frac{d_i - a_iB_{i-1}}{a_iA_{i-1} + b_i}, i = \overline{2, n-1}. \quad (2.35)$$

Таким образом, коэффициенты A_i и B_i уравнений (2.32), связывающие соседние значения x_i и x_{i+1} , $i = \overline{1, n-1}$, можно определить из рекуррентных соотношений (2.35), поскольку начальные коэффициенты A_1 и B_1 , согласно (2.34), известны.

Обратная прогонка состоит в последовательном вычислении неизвестных x_i . Сначала определяется x_n .

Из (2.32) при $i = n-1$ получаем равенство

$$x_{n-1} = A_{n-1}x_n + B_{n-1}.$$

Последнее уравнение системы (2.31) имеет вид

$$a_nx_{n-1} + b_nx_n = d_n.$$

Исключив из этих двух уравнений x_{n-1} , найдём, что

$$x_n = \frac{d_n - a_nB_{n-1}}{b_n + a_nA_{n-1}}. \quad (2.36)$$

Далее из (2.32) при $i = n-2$ и последнего уравнения системы (2.31) получаем

$$x_{n-2} = A_{n-2}x_{n-1} + B_{n-2},$$

$$a_{n-1}x_{n-2} + b_{n-1}x_{n-1} + c_{n-1}x_n = d_{n-1},$$

где x_n уже известно. Исключив из этих двух уравнений x_{n-2} , найдём x_{n-1} .

Продолжая процесс далее, последовательно вычислим значение $x_{n-1}, \dots, x_2, x_1$.

Заметим, что при нахождении прогоночных коэффициентов A_i и B_i по формулам (2.35) надо учитывать возможность деления на нуль. Можно показать, что при выполнении условия *преобладания диагональных элементов*, т.е. условия $|b_i| \geq |a_i| + |c_i|$, причём хотя бы для одного i имеет место строгое неравенство, знаменатели в формулах (2.35) не обращаются в нуль, система (2.31) в этом случае имеет единственное значение. При этом модули прогоночных коэффициентов A_i не превосходят единицы.

Условие преобладания диагональных элементов обеспечивает также устойчивость метода прогонки относительно погрешностей округлений. Это позволяет использовать метод прогонки для решения больших систем уравнений. Отметим, что в ряде случаев для хорошо обусловленных систем вида (2.31) метод прогонки оказывается устойчивым и при нарушении условия преобладания диагональных элементов.

Число арифметических действий, выполняемых при решении системы (2.31) методом прогонки по формулам (2.32), (2.35) и (2.36), зависит линейно от числа неизвестных:

$$Q = 6(n-2) + 5 + 2(n-1) = 8n - 9$$

При решении же произвольной системы линейных алгебраических уравнений методом Гаусса число действий пропорционально кубу числа неизвестных.

Исследование погрешностей решения СЛАУ прямыми методами. Ошибки округления, совершаемые в процессе вычислений, почти всегда приводят к тому, что вычисленное решение $\vec{x}^*$ в определенной степени отличается от теоретического решения $\vec{x} = A^{-1}\vec{b}$. Оценить погрешность вычисленного решения $\vec{x}^*$ можно при помощи двух векторов: ошибки $\Delta\vec{x} = \vec{x} - \vec{x}^*$ и невязки $\vec{r} = A\vec{x}^* - \vec{b}$. Из теории матриц известно, что если одна из этих величин равна нулю, то и другая также должна быть равна нулю. Но они не обязаны одновременно быть “малыми”. Доказано, что метод Гаусса с частичным выбором ведущего элемента гарантированно дает малые невязки, но отсюда, к сожалению, нельзя сделать вывод, что и ошибка мала.

Для большинства алгоритмов решения систем влияние ошибок округления можно учесть, используя *принцип эквивалентных возмущений*. Считают, что процесс решения исходной системы $A\vec{x} = \vec{b}$ с учетом погрешностей округления эквивалентен точному решению некоторой возмущенной системы

$(A + \Delta A)(\vec{x} + \Delta \vec{x}) = (\vec{b} + \Delta \vec{b})$. И каждому вычислительному алгоритму соответствует своя матрица эквивалентных возмущений ΔA .

Рассмотрим систему уравнений, правая часть которой получила приращение («возмущение») $\Delta \vec{b}$. Реакцией решения на возмущение правой части будет вектор поправок $\Delta \vec{x}$, т.е. решением «возмущенной» системы

$$A(\vec{x} + \Delta \vec{x}) = (\vec{b} + \Delta \vec{b})$$

будет вектор «возмущенный» вектор $\vec{x} + \Delta \vec{x}$.

Абсолютную погрешность решения будем оценивать нормой разности между точным и приближенным решениями $\|\Delta \vec{x}\| = \|\vec{x} - \vec{x}^*\|$, а относительную – отношением абсолютной погрешности к норме решения (точного или приближенного).

Выясним связь между относительными погрешностями векторов правых частей и решения системы. Иными словами, получим оценку вида

$$\frac{\|\Delta \vec{x}\|}{\|\vec{x}\|} \leq (?) \frac{\|\Delta \vec{b}\|}{\|\vec{b}\|}$$

с неизвестным пока коэффициентом.

Для этого подставим исходную систему в «возмущенную» и получим уравнение для поправки $\Delta \vec{x}$:

$$A\Delta \vec{x} = \Delta \vec{b},$$

из которого найдем её явное выражение $\Delta \vec{x} = A^{-1}\Delta \vec{b}$. Нормируя это выражение и исходную систему, получим следующие неравенства

$$\|\vec{b}\| \leq \|A\| \cdot \|\vec{x}\|, \quad \|\Delta \vec{x}\| \leq \|A^{-1}\| \cdot \|\Delta \vec{b}\|.$$

Эти неравенства одинакового смысла можно перемножить

$$\|\vec{b}\| \cdot \|\Delta \vec{x}\| \leq \|A\| \cdot \|\vec{x}\| \cdot \|A^{-1}\| \cdot \|\Delta \vec{b}\|$$

и разделить на $\|\vec{b}\| \cdot \|\vec{x}\|$. Получим искомую оценку связи между величиной «возмущения» правой части системы и величиной реакции системы:

$$\frac{\|\Delta \vec{x}\|}{\|\vec{x}\|} \leq \|A\| \cdot \|A^{-1}\| \cdot \frac{\|\Delta \vec{b}\|}{\|\vec{b}\|}. \quad (2.37)$$

Коэффициент этой связи называется *числом (мерой) обусловленности* матрицы A и обозначают $cond(A)$ или M_A

$$cond(A) = \|A\| \cdot \|A^{-1}\|.$$

Это же самое число является коэффициентом роста относительных погрешностей при неточном задании элементов матрицы исходной системы, т.е. для решения «возмущенной» системы

$$(A + \Delta A)(\vec{x} + \Delta \vec{x}) = \vec{b}.$$

Справедливо неравенство

$$\frac{\|\Delta \vec{x}\|}{\|\vec{x}\|} \leq \text{cond}(A) \cdot \frac{\|\Delta A\|}{\|A + \Delta A\|}. \quad (2.38)$$

В случае одновременного возмущения элементов матрицы исходной системы и её правой части справедлива следующая оценка относительной погрешности решения

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\text{cond}(A)}{1 - \text{cond}(A) \cdot \frac{\|\Delta A\|}{\|A\|}} \cdot \left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|} \right). \quad (2.39)$$

Отсюда видно, что на точность решения влияют *два фактора*: число обусловленности матрицы и эквивалентные возмущения. Если $\text{cond}(A)$ велико, то малым относительным погрешностям системы могут соответствовать большие относительные погрешности решения. Другими словами, неравенства (2.37) – (2.39) показывают, что чем больше число обусловленности матрицы A , тем сильнее сказывается на решении линейной системы ошибка в исходных данных. Системы с большим $\text{cond}(A)$ называются *плохо обусловленными*. Плохо обусловленные системы рекомендуется решать, увеличивая, насколько можно, точность задания коэффициентов матрицы и правой части, а также проводить промежуточные вычисления с повышенной точностью.

Назвать «пороговое» значение, начиная с которого систему можно считать хорошо или плохо обусловленной, трудно. Здесь может играть роль размерность задачи, точность, с которой должно быть найдено ее решение, точность представления чисел в ЭВМ и т.д. Нижней границей числа обусловленности является 1, т.е. $\text{cond}(A) \geq 1$ всегда. Можно также указать верхнюю границу для числа обусловленности, превышение которой при решении систем на конкретной ЭВМ может привести к заведомо ложным результатам.

Установлено, что относительная невязка и относительные эквивалентные возмущения системы имеют величину, сравнимую с ошибкой округления, независимо от того, насколько плохо обусловлена матрица:

$$\frac{\|b - Ax^*\|}{\|Ax\|} = O(\beta^{-t}), \quad \frac{\|\delta A\|}{\|A\|} = O(n \cdot \beta^{-t}).$$

Здесь β – основание системы представления чисел с плавающей точкой, а t – число цифр мантииссы, используемых при представлении чисел в ЭВМ.

Таким образом, для относительной погрешности решения справедлива следующая оценка

$$\frac{\|\Delta x\|}{\|x\|} = O(\text{cond}(A) \cdot n \cdot \beta^{-t}) \quad (2.40)$$

и из нее видно, что нельзя рассчитывать на получение результата с точностью ε , если $\text{cond}(A) \geq \frac{\varepsilon}{n \cdot \beta^{-t}}$.

2.3. Итерационные методы решения СЛАУ

Для решения итерационным методом исходная система линейных алгебраических уравнений $A\vec{x} = \vec{b}$ должна быть каким-либо способом (таких способов существует бесконечное множество) приведена к виду

$$\vec{x} = G\vec{x} + \vec{f}, \quad (2.41)$$

где G - некоторая матрица, $\vec{f}$ - преобразованный вектор свободных членов.

Систему (2.41) можно рассматривать как задачу о неподвижной точке линейного отображения G и определить последовательность $\{\vec{x}^{(k)}\}$ приближений к неподвижной точке в пространстве R^n рекуррентным равенством

$$\vec{x}^{(k)} = G\vec{x}^{(k-1)} + \vec{f}. \quad (2.42)$$

Для начала вычислений задается начальное приближение - произвольный вектор $\vec{x}^{(0)}$ - и строится рекуррентная последовательность векторов $\vec{x}^{(0)}, \vec{x}^{(1)}, \dots, \vec{x}^{(k)}, \dots$ по формуле (2.42). Этот итерационный процесс называется *методом простых итераций* (МПИ). Если последовательность $\{\vec{x}^{(k)}\}$ сходится к некоторому вектору $\vec{x}$, то, согласно (2.41), этот вектор и есть решение системы $A\vec{x} = \vec{b}$.

Для выяснения условий применимости метода простой итерации надо найти ответы на следующие вопросы:

- Какие требования нужно предъявить к $G, \vec{f}, \vec{x}^{(0)}$, чтобы последовательность $\{\vec{x}^{(k)}\}$ сходилась к решению исходной задачи?
- С какой скоростью сходится этот процесс?
- Сколько нужно сделать итераций, чтобы при заданном начальном приближении получить решение задачи с заданной точностью?

Ответы на эти вопросы содержатся в следующих теоремах.

Теорема 2.1. Если $\|G\| < 1$, то система уравнений (2.41) имеет единственное решение $\vec{x}^*$ и последовательные приближения $\vec{x}^{(k)}$ сходятся к решению $\vec{x}^*$ со скоростью геометрической прогрессии.

Δ Допустим, что $\vec{x}^*$ - решение системы (2.41), то есть имеет место равенство

$$\vec{x}^* = G\vec{x}^* + \vec{f}. \quad (2.43)$$

Отсюда, используя неравенство треугольника для нормы вектора, получаем

$$\|\vec{x}^*\| = \|G\vec{x}^* + \vec{f}\| \leq \|G\vec{x}^*\| + \|\vec{f}\| \leq \|G\| \cdot \|\vec{x}^*\| + \|\vec{f}\|, \text{ т. е.}$$

$\|\vec{x}^*\| \leq \|G\| \cdot \|\vec{x}^*\| + \|\vec{f}\|$. Отсюда

$$\|\vec{x}^*\| \leq \frac{\|\vec{f}\|}{1 - \|G\|}. \quad (2.44)$$

Из этого неравенства следует, что система $\vec{x} = G\vec{x}$ имеет только нулевое решение. Следовательно, неоднородная система $\vec{x} = G\vec{x} + \vec{f}$ имеет единственное решение при любом свободном $\vec{f}$.

Пусть теперь $\vec{r}^k = \vec{x}^* - \vec{x}^k$, где $\vec{x}^*$ - решение системы (2.41). Вычитая из равенства (2.43) равенство (2.41), будем иметь

$$\vec{r}^k = \vec{x}^* - \vec{x}^k = G\vec{x}^* - G\vec{x}^{k-1} = G(\vec{x}^* - \vec{x}^{k-1}) = G\vec{r}^{k-1}, \text{ т.е.}$$

$$\vec{r}^k = G\vec{r}^{k-1} = G^2\vec{r}^{k-2} = \dots = G^k\vec{r}^0,$$

где $\vec{r}^0 = \vec{x}^* - \vec{x}^0$ - погрешность начального приближения. Отсюда и из (2.41) получаем неравенство

$$\|\vec{r}^k\| = \|G^k\vec{r}^0\| \leq \|G\|^k \cdot \|\vec{r}^0\|.$$

Так как $\|G\| < 1$, то из полученного неравенства следует, что $\vec{r}^k$ стремится к нулю при $k \rightarrow \infty$ не медленнее геометрической прогрессии со знаменателем $q = \|G\| < 1$. $\square$

Из теоремы 1 вытекает

Следствие: Если для матрицы $G = [g_{ij}]$ выполнено одно из условий:

- 1) $\|G\|_1 = \left\{ \sum_{1 \leq j \leq n} |g_{ij}| \right\} < 1$;
- 2) $\|G\|_2 = \left\{ \sum_{i=1}^n \sum_{j=1}^n g_{ij}^2 \right\}^{1/2} < 1$;
- 3) $\|G\|_3 = \left\{ \sum_{i=1}^n |g_{ij}| \right\} < 1$,

то последовательность $(\vec{x})$, построенная по рекуррентной формуле (2.42), сходится к единственному решению системы (2.41).

Теперь рассмотрим проблему оценки погрешности итераций.

Пусть $\|G\| < 1$, тогда, согласно теореме 1, система (2.41) имеет единственное решение $\vec{x}^*$, для которого справедливо равенство (2.42). Из равенств (2.41) и (2.43) имеем:

$$\vec{x}^* - \vec{x}^{(k)} = G(\vec{x}^* - \vec{x}^{(k-1)}) \Rightarrow \vec{x}^* = \vec{x}^{(k)} + G(\vec{x}^* - \vec{x}^{(k-1)}). \quad (2.45)$$

Вычтя $\vec{x}^{(k-1)}$ из обеих частей последнего равенства, будем иметь

$$\vec{x}^* - \vec{x}^{(k-1)} = \vec{x}^{(k)} - \vec{x}^{(k-1)} + G(\vec{x}^* - \vec{x}^{(k-1)}).$$

Отсюда, используя свойства нормы, получаем

$$\|\vec{x}^* - \vec{x}^{(k-1)}\| \leq \|\vec{x}^{(k)} - \vec{x}^{(k-1)}\| + \|G\| \cdot \|\vec{x}^* - \vec{x}^{(k-1)}\|$$

или

$$(1 - \|G\|) \cdot \|x^* - \bar{x}^{(k-1)}\| \leq \|\bar{x}^{(k)} - \bar{x}^{(k-1)}\|.$$

Так как $\|G\| < 1$, то из последнего неравенства следует, что

$$\|x^* - \bar{x}^{(k-1)}\| \leq \frac{1}{1 - \|G\|} \|\bar{x}^{(k)} - \bar{x}^{(k-1)}\|. \quad (2.46)$$

Из (2.45) находим

$$\|\bar{x}^* - \bar{x}^{(k)}\| \leq \|G\| \cdot \|\bar{x}^* - \bar{x}^{(k-1)}\|.$$

Отсюда и из неравенства (2.46) будем иметь

$$\|x^* - \bar{x}^{(k)}\| \leq \frac{\|G\|}{1 - \|G\|} \|\bar{x}^{(k)} - \bar{x}^{(k-1)}\|. \quad (2.47)$$

Неравенство (2.47) позволяет оценить норму погрешности k -го приближения через норму разности двух последовательных приближений и норму матрицы G . Эта оценка называется *апостериорной* и широко используется на практике. Если применить это неравенство k раз, то получим *априорную* оценку погрешности

$$\|x^* - \bar{x}^{(k)}\| \leq \frac{\|G\|^k}{1 - \|G\|} \|\bar{x}^{(1)} - \bar{x}^{(0)}\| \quad (2.48)$$

В приведенной выше теореме 2.1 сформулировано достаточное условие сходимости метода простой итерации. *Необходимое и достаточное условие* сформулировано в следующей теореме, которая приводится без доказательства.

Теорема 2.2. Для сходимости метода простой итерации (МПИ) при любом начальном приближении $\bar{x}^{(0)}$ к решению системы (2.41) необходимо и достаточно, чтобы все собственные значения матрицы G были по абсолютной величине меньше единицы.

На практике это трудно проверить, и обычно пользуются *достаточными условиями сходимости* – итерации сходятся, если какая-нибудь норма матрицы меньше единицы, т.е.

$$\|G\|_1 = \max_{1 \leq i \leq n} \sum_{j=1}^n |g_{ij}| = \alpha < 1 \quad \text{или} \quad \|G\|_2 = \max_{1 \leq j \leq n} \sum_{i=1}^n |g_{ij}| = \beta < 1.$$

Чем меньше норма матрицы G , тем быстрее сходится итерационный процесс.

Рассмотрим один из простейших способов преобразования системы к виду (2.41) – решим каждое i -е уравнение исходной системы относительно x_i :

$$x_i = -\frac{1}{a_{ii}} \left[\sum_{j=1, j \neq i}^n a_{ij} x_j - b_i \right]. \quad (2.49)$$

Рассмотрим два классических метода, использующих преобразованную таким образом систему – метод Якоби и метод Зейделя.

Метод Якоби использует следующий алгоритм построения приближений:

$$x_i^{(k)} = -\frac{1}{a_{ii}} \left[\sum_{j=1, j \neq i}^n a_{ij} x_j^{(k-1)} - b_i \right]. \quad (2.50)$$

Если A - матрица с доминирующей диагональю, т.е. $|a_{ii}| > \sum_{j \neq i}^n |a_{ij}|$, то метод

Якоби сходится при любом начальном приближении $x^{(0)}$.

Модификация метода Якоби, в которой при k -й итерации для вычисления следующего $x_i^{(k)}$ используются уже вычисленные на этом шаге $x_1^{(k)}, x_2^{(k)}, \dots, x_{i-1}^{(k)}$, называется **методом Зейделя**:

$$x_i^{(k)} = -\frac{1}{a_{ii}} \left[\sum_{j=1}^{i-1} a_{ij} x_j^{(k)} + \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} - b_i \right], \quad (2.51)$$

и приводит, как правило, к ускорению сходимости. Этот метод может быть реализован на ЭВМ без привлечения дополнительной памяти, т.к. полученное новое значение $x_i^{(k)}$ запоминается на месте старого.

Приведенные выше методы Якоби и Зейделя относятся к *одношаговым итерационным методам*, когда для нахождения $x^{(k+1)}$ требуется помнить только одну предыдущую итерацию $x^{(k)}$. Для исследования сходимости удобнее записывать итерационные методы не в координатной, а в матричной форме, придерживаясь стандартной формы записи итерационных методов.

Канонической формой одношагового итерационного метода решения СЛАУ называется его запись в виде

$$B_{k+1} \frac{x^{(k+1)} - x^{(k)}}{\tau_{k+1}} + Ax^{(k)} = b, \quad (2.52)$$

где B_{k+1} - матрица, задающая тот или иной итерационный метод, τ_{k+1} - итерационный параметр. Числовые параметры τ_k вводят для ускорения сходимости. Способ выбора итерационных параметров определяется при исследовании сходимости метода, когда выясняется при каких значениях параметров метод сходится и когда сходимость будет наиболее быстрой (соответствующие параметры называются оптимальными).

Итерационный метод называют *явным*, если B_{k+1} - единичная матрица. *Неявные* итерационные методы имеет смысл применять лишь в том случае, когда решение системы уравнений с матрицей B_k требует меньше машинной памяти или времени или алгоритмически проще, чем решение исходной системы.

Итерационный метод называется *стационарным*, если $B_{k+1}=B$ и $\tau_{k+1}=\tau$, (т.е. не зависят от номера итерации), и *нестационарным* в противоположном случае. Согласно этой классификации метод Якоби является одношаговым явным стационарным методом с диагональной матрицей $B=D_A$ ($b_{ii}=a_{ii}$) и $\tau=1$, метод Зейделя - неявным методом с нижней треугольной матрицей $B=D_A+L_A$.

Методом простой итерации называют явный метод с постоянным параметром

$$\frac{x^{(k+1)} - x^{(k)}}{\tau} + Ax^{(k)} = b, \text{ или } x^{(k+1)} = x^{(k)} - \tau \cdot r^{(k)},$$

где $r^{(k)} = Ax^{(k)} - b$ - вектор невязки. Метод сходится для симметричных положительно определенных матриц при $0 < \tau < \frac{2}{\|A\|}$.

Для *окончания итерационного процесса* на практике используют три способа. При первом определяют величину стабилизации и прекращают вычисления, если она меньше ε , т.е.

$$\frac{\|x^{(k+1)} - x^{(k)}\|}{\max\{\|x^{(k)}\|, \|x^{(k+1)}\|\}} \leq \varepsilon.$$

Недостатком этого способа является то, что при медленно сходящихся итерациях величина стабилизации может быть малой, хотя приближенное решение сильно отличается от точного.

При втором способе вычисляют нормы невязки до начала итераций и на каждой итерации. Итерации прекращают при выполнении неравенства

$$\frac{\|Ax^{(k)} - b\|}{\|Ax^{(0)} - b\|} \leq \varepsilon.$$

При третьем способе предварительно оценивается число итераций, необходимое для получения заданной точности ε . Если для погрешности итерационного метода выполняются оценки

$$\|x^{(k)} - x\| \leq q^k \|x^{(0)} - x\|,$$

где $q \in (0,1)$, то говорят, что метод сходится со скоростью геометрической прогрессии со знаменателем q . Можно определить, потребовав, чтобы $q^n < \varepsilon$, число итераций n , достаточное для того, чтобы начальная погрешность уменьшилась в заданное число раз:

$$n \geq n_0(\varepsilon) = \frac{\ln(1/\varepsilon)}{\ln(1/q)}.$$

Целая часть числа $n_0(\varepsilon)$ называется *минимальным числом итераций, необходимым для получения заданной точности ε* .

Величину $\ln(1/q)$ называют *скоростью сходимости итерационного метода*. Скорость сходимости целиком определяется методом и не зависит ни от номера итерации, ни от выбора начального приближения, ни от задаваемой

точности. Качество различных итерационных методов сравнивают обычно по их скорости сходимости: чем выше скорость сходимости, тем лучше метод.

2.3 Вычисление собственных значений и собственных векторов

Под полной проблемой собственных значений понимается проблема нахождения всех собственных значений матрицы A так же как и принадлежащих этим собственным значениям собственных векторов (или векторов, образующих канонический базис). Напомним, что собственными значениями матрицы A называются корни ее характеристического полинома, т. е. корни уравнения

$$\begin{aligned} \varphi(\lambda) = |A - \lambda E| &= \begin{vmatrix} a_{11} - \lambda & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} - \lambda & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nn} - \lambda \end{vmatrix} = \\ &= (-1)^n (\lambda^n - p_1 \lambda^{n-1} - \dots - p_{n-1} \lambda - p_n) = 0 \end{aligned} \quad (2.53)$$

Определение компонент собственного вектора требует решения системы n однородных уравнений с n неизвестными; для вычисления всех собственных векторов матрицы, вообще говоря, требуется решить n систем вида:

$$(A - \lambda_i E)X_i = 0, \quad (2.54)$$

где $X_i = (x_{1i}, x_{2i}, \dots, x_{ni})$ — собственный вектор матрицы A , принадлежащий собственному значению λ_i .

Коэффициенты p_i характеристического полинома являются, с точностью до знака, суммами всех миноров определителя матрицы A порядка i , опирающихся на главную диагональ. Непосредственное вычисление коэффициентов p_i является чрезвычайно громоздким и требует огромного числа операций.

Совершенно естественно, поэтому, появление специальных вычислительных приемов, упрощающих численное решение поставленных задач. Большинство методов, дающих решение полной проблемы собственных значений, включает предварительное вычисление коэффициентов характеристического полинома, которое осуществляется теми или иными средствами, минуя вычисление многочисленных миноров. Собственные значения вычисляются затем по какому-либо методу для приближенного вычисления корней полинома.

По большей части собственные векторы матрицы удается определить, используя промежуточные результаты вычислений, проведенных для определения коэффициентов характеристического полинома. Конечно, для определения собственного вектора, принадлежащего тому или другому собственному значению, это собственное значение должно быть уже вычислено. Методы этой группы

являются точными, т. е. если их осуществлять для матриц, элементы которых заданы точно (рациональными числами) и вычисления проводить точно (по правилам действий над обыкновенными дробями), то в результате будет получено точное значение коэффициентов характеристического полинома, и компоненты собственных векторов окажутся выраженными точными формулами через собственные значения.

Наряду с точными методами для решения проблемы собственных значений имеются методы итерационные, в которых собственные значения получаются как пределы некоторых числовых последовательностей, так же как и компоненты принадлежащих им собственных векторов. В итерационных методах, как правило, собственные значения вычисляются непосредственно, без предварительного вычисления коэффициентов характеристического полинома. Это существенно упрощает задачу, так как вычисление корней полинома, коэффициенты которого известны, достаточно трудоемко.

Однако итерационные методы более приспособлены к решению частичной проблемы собственных значений. Под частичной проблемой мы подразумеваем задачу нахождения одного или нескольких собственных значений и соответствующих им собственных векторов.

Полная и частичная проблемы собственных значений совершенно различны, как по методам их решения, так и по области приложений. Решение полной проблемы для матриц даже не очень высокого порядка неизбежно оказывается весьма громоздким, и возможность решения частичной проблемы, минуя тяжести решения полной, является очень ценной для практики.

Метод А. М. Данилевского.

Элегантный и весьма эффективный метод вычисления коэффициентов характеристического полинома предложен А.М. Данилевским. Геометрический смысл этого метода состоит в следующем. Данная матрица A рассматривается как матрица оператора в базисе:

$$e_1 = (1, 0 \dots 0)', e_2 = (0, 1 \dots 0)', \dots, e_n = (0, 0 \dots 1)'$$

Предполагается, что векторы $e_1, Ae_1, A^{n-1}e_1$ линейно-независимы. Тогда

$$A^n e_1 = p_1 A^{n-1} e_1 + p_2 A^{n-2} e_1 + \dots + p_n e_1$$

Ясно, что коэффициенты $p_1, p_2, \dots, p_n$ - искомые коэффициенты характеристического полинома.

В базисе $e_1, Ae_1, A^{n-1}e_1$ рассматриваемый оператор, очевидно, будет иметь так называемую матрицу Фробениуса

$$P = \begin{bmatrix} 0 & 0 & \dots & p_n \\ 1 & 0 & \dots & p_{n-1} \\ 0 & 1 & \dots & p_{n-2} \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & p_1 \end{bmatrix},$$

содержащую в явном виде искомые коэффициенты характеристического полинома.

Переход от базиса $e_1, e_2, \dots, e_n$ к базису $e_1, Ae_1, A^{n-1}e_1$ осуществляется постепенно в $n-1$ шагов. Каждый шаг состоит в переходе от базиса $e_1, Ae_1, A^{k-1}e_1, e_{k+1}, \dots, e_n$ к базису $e_1, Ae_1, A^{k-1}e_1, A^k e_1, e_{k+2}, \dots, e_n$.

Для осуществимости всего процесса необходимо считать, что все промежуточные системы векторов действительно являются базисами, т.е. состоят из линейно-независимых векторов. Ниже будет рассмотрено, как следует поступать в случаях вырождения. Пока же мы будем рассматривать лишь невырожденный процесс.

Обозначим через $A^{(k)}$ матрицу, полученную при $k-1$ -м шаге процесса, так что $A = A^{(1)}, P = A^{(n)}$. Столбцами матрицы $A^{(k)}$ являются координаты векторов $e_1, A^2 e_1, \dots, A^k e_1, Ae_{k+1}, \dots, Ae_n$ в базисе $e_1, Ae_1, A^{k-1}e_1, e_{k+1}, \dots, e_n$. Поэтому первые $k-1$ столбцов матрицы $A^{(k)}$ будут совпадать с одноименными столбцами матрицы Фробениуса P . Имеем $A^{(k+1)} = S_k^{-1} A^{(k)} S_k$ где S_k - соответствующая матрица преобразования координат. Ясно что

$$S_k = \begin{bmatrix} 1 & \dots & s_{1,k+1} & \dots & 0 \\ 0 & \dots & s_{2,k+1} & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & \dots & s_{n,k+1} & \dots & 1 \end{bmatrix}$$

где $s_{1,k+1}, s_{2,k+1}, \dots, s_{n,k+1}$ координаты вектора $A^{(k)}e_1$ в базисе $e_1, Ae_1, A^{k-1}e_1, e_{k+1}, \dots, e_n$. Эти координаты, как мы видели выше, есть не что иное, как элементы $a_{ik}^{(k)}$ k -ого столбца матрицы $A^{(k)}$.
Имеем далее:

$$S_k^{-1} = \begin{bmatrix} 1 & \dots & -\frac{s_{1,k+1}}{s_{k+1,k+1}} & \dots & 0 \\ 0 & \dots & -\frac{s_{2,k+1}}{s_{k+1,k+1}} & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & \dots & \frac{1}{s_{k+1,k+1}} & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & \dots & -\frac{s_{n,k+1}}{s_{k+1,k+1}} & \dots & 1 \end{bmatrix}$$

Вычисление матрицы $A^{(k+1)}$ целесообразно проводить в два приема. В начале вычисляется вспомогательная матрица $B^{(k)} = S_k^{-1} A^{(k)}$. Это действие, в силу строения матрицы S_k^{-1} , состоит в том, что $(k+1)$ -я строка матрицы $A^{(k)}$ умножается на $\frac{1}{a_{k+1,k}^{(k)}}$, а от каждой из остальных строк вычитается полученная

$(k+1)$ -я строка матрицы $B^{(k)}$, умноженная на соответствующий элемент k -го столбца матрицы $A^{(k)}$. В результате этих действий первые $(k-1)$ столбцов не изменятся, в k -ом же столбце на $(k+1)$ -м месте окажется единица, а все остальные элементы станут нулями. Вычисления остальных элементов матрицы $B^{(k)}$ будут двухчленными, напоминающими вычисления метода Гаусса. Полученная матрица $B^{(k)}$ умножается затем справа на S_k . При этом изменяется только один, именно $(k+1)$ столбец. Его элементами будут:

$$\sum_{j=1}^n b_{1j}^{(k)} a_{jk}^{(k)}, \sum_{j=1}^n b_{2j}^{(k)} a_{jk}^{(k)}, \dots, \sum_{j=1}^n b_{nj}^{(k)} a_{jk}^{(k)}$$

Иначе говоря, $(k+1)$ -й столбец матрицы $A^{(k+1)}$ есть результат итерации k -го столбца матрицы $A^{(k)}$ матрицей $B^{(k)}$.

Таким образом, переход от матрицы $A^{(k)}$ к матрице $A^{(k+1)}$ происходит по формулам:

$$b_{k+1,j}^{(k)} = \frac{1}{a_{k+1,k}^{(k)}} a_{k+1,j}^{(k)},$$

$$b_{i,j}^{(k)} = a_{i,j}^{(k)} - a_{i,k}^{(k)} b_{k+1,j}^{(k)}, \quad (i \neq k+1)$$

$$a_{i,j}^{(k+1)} = b_{i,j}^{(k)}, \quad (j \neq k+1)$$

$$a_{i,k+1}^{(k+1)} = \sum_{j=1}^n b_{i,j}^{(k)} a_{j,k}^{(k)}.$$

Число операций, нужных для вычисления по методу А.М. Данилевского, значительно меньше, чем по другим методам – общее число умножений и делений равно $n^3 - n^2$.

Таким образом, после нахождения матрицы $A^{(k+1)}$, характеристический многочлен выписывается по виду последнего столбца.

$$\text{Т.к. } A^{(k+1)}y = \lambda y \text{ и } A^{(k+1)} = S_k^{-1} A^{(k)} S_k, \quad \text{то } S_k^{-1} A^{(k)} S_k y = \lambda y.$$

Умножая это равенство слева на матрицу S_k , получим:

$$A^{(k)} S_k y = \lambda S_k y.$$

Таким образом, собственные векторы исходной матрицы A легко находятся по соответствующим собственным векторам ее канонической формы Фробениуса. Если λ - известное собственное значение матрицы Фробениуса, то

$$A^{(k+1)}y = \lambda y$$

$$p_1 y_1 + p_2 x_2 + \dots + p_n y_n = \lambda y_1$$

$$y_1 = \lambda y_2$$

$$y_2 = \lambda y_3$$

.....

$$y_{n-1} = \lambda y_n$$

Положим $y_n = 1$ и найдем все остальные значения:

$$x_i = S_k y_i = M_{n-1} M_{n-2} \dots M_1 y_i$$

где матрицы M_i ($i = 1, \dots, n-1$) отличаются только одной строкой от единичной матрицы.

Метод А. Н. Крылова.

Идея А. Н. Крылова заключалась в предварительном преобразовании уравнения (1) в эквивалентное ему уравнение вида

$$D(\lambda) = \begin{bmatrix} b_{11} - \lambda & b_{12} & \dots & b_{1n} \\ b_{21} - \lambda^2 & b_{22} & \dots & b_{2n} \\ \dots & \dots & \dots & \dots \\ b_{n1} - \lambda^n & b_{n2} & \dots & b_{nn} \end{bmatrix} = 0, \quad (2.55)$$

развертывание которого по степеням λ осуществляется, очевидно, значительно проще, при помощи разложения определителя по минорам 1-ого столбца.

Равенство нулю определителя (2.63) есть необходимое и достаточное условие для того, чтобы система однородных уравнений

$$\begin{cases} \lambda x_1 = a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n, \\ \lambda x_2 = a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n, \\ \dots \\ \lambda x_n = a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n \end{cases} \quad (2.56)$$

имела решение $x_1, x_2, \dots, x_n$, отличное от нулевого.

Преобразуем систему (2.56) следующим образом. Умножим первое уравнение на λ и заменим $\lambda x_1, \dots, \lambda x_n$ их выражениями (2.56) через $x_1, \dots, x_n$. Это дает

$$\lambda^2 x_1 = b_{21}x_1 + b_{22}x_2 + \dots + b_{2n}x_n, \quad (2.57)$$

где

$$b_{2k} = \sum_{s=1}^n a_{1s} a_{sk}. \quad (2.58)$$

Умножим далее уравнение (2.57) на λ и снова заменим $\lambda x_1, \dots, \lambda x_n$ их выражениями через $x_1, \dots, x_n$:

$$\lambda^3 x_1 = b_{31}x_1 + b_{32}x_2 + \dots + b_{3n}x_n.$$

Повторяя этот процесс $(n-1)$ раз, мы перейдем от системы (2.56) к системе

$$\begin{cases} \lambda x_1 = b_{11}x_1 + b_{12}x_2 + \dots + b_{1n}x_n, \\ \lambda x_2 = b_{21}x_1 + b_{22}x_2 + \dots + b_{2n}x_n, \\ \dots \\ \lambda x_n = b_{n1}x_1 + b_{n2}x_2 + \dots + b_{nn}x_n \end{cases} \quad (2.59)$$

коэффициенты которой b_{ik} будут определяться по рекуррентным формулам

$$b_{1k} = a_{1k},$$

$$b_{ik} = \sum_{s=1}^n b_{i-1,s} a_{sk}, \quad i = 2, \dots, n; \quad k = 1, \dots, n \quad (2.60)$$

Очевидно, что определитель системы (2.59) будет иметь вид (2).

Система (2.59) имеет ненулевое решение для всех значений λ , удовлетворяющих уравнению (1). Таким образом, $D(\lambda)$ обращается в нуль при всех λ , являющихся корнями уравнения (1). Покажем, что

$$\frac{D(\lambda)}{\varphi(\lambda)} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ b_{11} & b_{12} & \dots & b_{1n} \\ \dots & \dots & \dots & \dots \\ b_{n-1,1} & b_{n-1,2} & \dots & b_{n-1,n} \end{bmatrix} = N$$

т. е. при $N \neq 0$ $D(\lambda)$ отличается от искомого характеристического полинома только численным множителем.

Введем в рассмотрение векторы B_i с компонентами $b_{i1}, b_{i2}, \dots, b_{in}$.

Равенства $b_{ik} = \sum_{s=1}^n b_{i-1,s} a_{sk}$ показывают, что $B_i = A' B_{i-1}$ ($i=2, \dots, n$),

$$B_1 = A' B_0, \quad \text{где} \quad B_0 = (1, 0, \dots, 0)'.$$

Тогда $B_i = (A')^i B_0$ ($i=1, \dots, n$).

Итерационный степенной метод.

Зачастую не нужно находить весь спектр - все собственные значения (и все собственные векторы), а необходимо найти максимальное и минимальное из них. Существует степенной метод определения спектрального радиуса матрицы, т.е. максимального собственного значения матрицы, и соответствующего ему собственного вектора.

Пусть дана матрица A и пусть ее собственные значения, соответствующие собственным векторам $x^{(1)}, x^{(2)}, x^{(3)} \dots x^{(n)}$, упорядочены по абсолютным величинам $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$. Тогда, выбрав некоторый вектор $y^{(0)}$, например, вектор, компоненты которого равны единице $y^{(0)} = (1, 1, \dots, 1)^T$, можно для определения λ_1 построить следующий итерационный процесс:

$$\begin{aligned}
(y^{(k)}, y^{(k)}) &= \alpha_1^2 \lambda_1^{2k} + \alpha_2^2 \lambda_2^{2k} + \dots + \alpha_n^2 \lambda_n^{2k} = \\
&\lambda_1^{2k} (\alpha_1^2 + \delta_1(k)) \quad , \delta_1(k) = \alpha_2^2 \left(\frac{\lambda_2}{\lambda_1}\right)^{2k} + \dots + \alpha_n^2 \left(\frac{\lambda_n}{\lambda_1}\right)^{2k}; \\
(y^{(k)}, y^{(k+1)}) &= \alpha_1^2 \lambda_1^{2k+1} + \alpha_2^2 \lambda_2^{2k+1} + \dots + \alpha_n^2 \lambda_n^{2k+1} = \\
&\lambda_1^{2k} (\alpha_1^2 \lambda_1 + \delta_2(k)) \quad , \delta_2(k) = \alpha_2^2 \lambda_2 \left(\frac{\lambda_2}{\lambda_1}\right)^{2k} + \dots + \alpha_n^2 \lambda_n \left(\frac{\lambda_n}{\lambda_1}\right)^{2k}.
\end{aligned}$$

Отметим, что при $k \rightarrow \infty$, $\delta_1(k) \rightarrow 0$, $\delta_2(k) \rightarrow 0$.

Положим
$$\mu_k = \frac{(y^{(k)}, y^{(k+1)})}{(y^{(k)}, y^{(k)})}$$

Согласно предыдущим представлениям:

$$\mu_k = \frac{\alpha_1^2 \lambda_1 + \delta_2(k)}{\alpha_1^2 + \delta_1(k)}$$

Следовательно, имеет место сходимости $\mu_k \rightarrow \lambda_1, k \rightarrow \infty$, т.е. величина μ_k может служить приближением к искомому собственному значению λ_1 .

Отметим, что $\rho(A) = |\lambda_1|$. Следовательно, величина $|\mu_k|$ для больших k является приближенным значением для спектрального радиуса матрицы A .

Пусть $r(x) = \frac{(x, Ax)}{(x, x)}$, $x \neq 0$ - отношение Релея. Поскольку $y^{(k+1)} = Ay^{(k)}$, то

$$\mu_k = \frac{(y^{(k)}, Ay^{(k)})}{(y^{(k)}, y^{(k)})} = r(y^{(k)}).$$

В практических вычислениях степенной метод сопровождается процедурой евклидовой нормировки последовательных приближений $y^{(k)}$. Тогда модифицированная схема степенного метода имеет вид:

$$y^{(0)} \in R^n, y^{(k)} = \frac{Ay^{(k-1)}}{\|Ay^{(k-1)}\|}, \mu_k = (y^{(k)}, Ay^{(k)}), k = 1, 2, \dots$$

Пусть A - симметричная, невырожденная матрица. Поставим задачу отыскания минимального по модулю собственного значения λ_n , в предположении его единственности. Рассмотрим обратную матрицу A^{-1} . Как известно, обратная величина $\frac{1}{\lambda_n}$ есть максимальное по модулю собственное значение матрицы

A^{-1} с соответствующим собственным вектором $x^{(n)}$. Поэтому для отыскания

собственной пары $\left(\frac{1}{\lambda_n}, x^{(n)}\right)$ можно использовать степенной метод применительно к матрице A^{-1} :

$$y^{(0)} \in R^n, y^{(k)} = A^{-1} y^{(k-1)}, k = 1, 2, \dots$$

$$y^{(k)} \approx \alpha x^n, \quad \mu_k \approx \frac{1}{\lambda_n}.$$

Отметим, что вектор $y^{(k)}$ является решением линейной системы $Ay = y^{(k-1)}$. Таким образом, степенной метод для отыскания собственной пары $(\lambda_n, x^{(n)})$ имеет вид (обратные итерации):

$$y^{(0)} \in R^n, Ay^{(k)} = y^{(k-1)}, k = 1, 2, \dots$$

Рассмотрим также случай, когда матрица A имеет два наибольших по модулю собственных значения и эти значения вещественны и противоположны по знаку. Будем считать, что собственные значения матрицы A распределены по модулю следующим образом $|\lambda_1| = |\lambda_2| > |\lambda_3| \geq \dots \geq |\lambda_n|$ и $\lambda_1 = -\lambda_2$.

Тогда, в силу формулы (2.61), получим:

$$(y^{(k)}, y^{(k)}) = \alpha_1^2 \lambda_1^{2k} + \alpha_2^2 \lambda_2^{2k} + \dots + \alpha_n^2 \lambda_n^{2k} = [\lambda_1 = -\lambda_2]$$

$$\lambda_1^{2k} (\alpha_1^2 + \alpha_2^2 + \delta_1(k)) \quad , \delta_1(k) = \alpha_3^2 \left(\frac{\lambda_3}{\lambda_1}\right)^{2k} + \dots + \alpha_n^2 \left(\frac{\lambda_n}{\lambda_1}\right)^{2k};$$

$$(y^{(k)}, y^{(k+1)}) = \alpha_1^2 \lambda_1^{2k+1} + \alpha_2^2 \lambda_2^{2k+1} + \dots + \alpha_n^2 \lambda_n^{2k+1} = [\lambda_1 = -\lambda_2]$$

$$\lambda_1^{2k} (\alpha_1^2 \lambda_1 - \alpha_2^2 \lambda_1 + \delta_2(k)) \quad , \delta_2(k) = \alpha_3^2 \lambda_3 \left(\frac{\lambda_3}{\lambda_1}\right)^{2k} + \dots + \alpha_n^2 \lambda_n \left(\frac{\lambda_n}{\lambda_1}\right)^{2k}.$$

Отсюда видно, что скалярные произведения $(y^{(k)}, y^{(k)})$ и $(y^{(k)}, y^{(k+1)})$ нельзя одновременно использовать для определения λ_1 , ибо у них различные главные части. Однако, в этом случае можно определить λ_1^2 .

Рассмотрим:

$$(y^{(k)}, y^{(k)}) = \alpha_1^2 \lambda_1^{2k} + \alpha_2^2 \lambda_2^{2k} + \dots + \alpha_n^2 \lambda_n^{2k} = [\lambda_1 = -\lambda_2]$$

$$\lambda_1^{2k} (\alpha_1^2 + \alpha_2^2 + \delta_1(k)) \quad , \delta_1(k) = \alpha_3^2 \left(\frac{\lambda_3}{\lambda_1}\right)^{2k} + \dots + \alpha_n^2 \left(\frac{\lambda_n}{\lambda_1}\right)^{2k};$$

$$(y^{(k)}, y^{(k+2)}) = \alpha_1^2 \lambda_1^{2k+2} + \alpha_2^2 \lambda_2^{2k+2} + \dots + \alpha_n^2 \lambda_n^{2k+2} = [\lambda_1 = -\lambda_2]$$

$$\lambda_1^{2k+2} (\alpha_1^2 + \alpha_2^2 + \delta_2(k)) \quad , \delta_2(k) = \alpha_3^2 \lambda_3 \left(\frac{\lambda_3}{\lambda_1}\right)^{2k+2} + \dots + \alpha_n^2 \lambda_n \left(\frac{\lambda_n}{\lambda_1}\right)^{2k}.$$

Отметим, что при $k \rightarrow \infty$, $\delta_1(k) \rightarrow 0$, $\delta_2(k) \rightarrow 0$. Следовательно:

$$\frac{(y^{(k)}, y^{(k+2)})}{(y^{(k)}, y^{(k)})} = \frac{\lambda_1^{2k+2} (\alpha_1^2 + \alpha_2^2 + \delta_1(k))}{\lambda_1^{2k} (\alpha_1^2 + \alpha_2^2 + \delta_1(k))} = \lambda_1^2$$

Для нахождения собственных векторов, принадлежащих λ_1 и λ_2 целесообразно построить:

$$\begin{aligned} y^{(k)} + \lambda_1 y^{(k-1)} &= \alpha_1 \lambda_1^k x^{(1)} - \alpha_2 \lambda_1^k x^{(2)} + \dots + \alpha_n \lambda_n^k x^{(n)} + \\ &+ \alpha_1 \lambda_1^k x^{(1)} + \alpha_2 \lambda_1^k x^{(2)} + \dots + \alpha_n \lambda_1 \lambda_n^{k-1} x^{(n)} = \lambda_1^k (2\alpha_1 x^{(1)} + O(\left|\frac{\lambda_3}{\lambda_1}\right|^k)), \end{aligned}$$

$$\begin{aligned} y^{(k)} - \lambda_1 y^{(k-1)} &= \alpha_1 \lambda_1^k x^{(1)} - \alpha_2 \lambda_1^k x^{(2)} + \dots + \alpha_n \lambda_n^k x^{(n)} + \\ &+ \alpha_1 \lambda_1^k x^{(1)} - \alpha_2 \lambda_1^k x^{(2)} + \dots + \alpha_n \lambda_1 \lambda_n^{k-1} x^{(n)} = \lambda_2^k (2\alpha_2 x^{(2)} + O(\left|\frac{\lambda_3}{\lambda_1}\right|^k)). \end{aligned}$$

Отсюда видно, что с точностью до постоянного множителя в качестве собственного вектора, отвечающему λ_1 , можно приближенно взять вектор $y^{(k)} + \lambda_1 y^{(k-1)}$, а в качестве собственного вектора, отвечающему λ_2 , можно приближенно взять вектор $y^{(k)} - \lambda_1 y^{(k-1)}$.

Рассмотрим теперь случай, когда матрица A имеет пару наибольших по модулю комплексно-сопряженных собственных значений. Будем считать, что

$$|\lambda_1| = |\lambda_2| > |\lambda_3| \geq \dots \geq |\lambda_n|,$$

$$\lambda_1 = re^{i\theta}, \lambda_2 = re^{-i\theta}.$$

В силу формулы (2.61) имеем:

$$y^{(k)} = \alpha_1 \lambda_1^k x^{(1)} + \alpha_2 \lambda_2^k x^{(2)} + \dots + \alpha_n \lambda_n^k x^{(n)} \quad (2.62)$$

Пусть $\alpha_1 x^{(1)}$ и $\alpha_2 x^{(2)}$ отличны от нуля. Поскольку матрица A и начальный вектор $y^{(0)}$ вещественны, то вещественным будет и вектор $y^{(k)} = A^k y^{(0)}$. Значит, в формуле (2.62) величины $\alpha_1 x^{(1)}$ и $\alpha_2 x^{(2)}$ должны быть комплексно-сопряженными. Пусть $\alpha_1 x^{(1)} = \text{Re}^{i\mu}$ и $\alpha_2 x^{(2)} = \text{Re}^{-i\mu}$. Теперь из формулы (2.62) получим:

$$y^{(k)} = 2Rr^k \cos(k\theta + \mu) + \dots + \alpha_n \lambda_n^k x^{(n)} \quad (2.63)$$

При достаточно большом k в силу условия $|\lambda_2| > |\lambda_3|$ из формулы (2.63) получим:

$$y^{(k)} = 2Rr^k \cos(k\theta + \mu) + O(|\lambda_3|^k) \quad (2.64)$$

Наряду с равенством (2.64) будут иметь место следующие аналогичные равенства:

$$y^{(k+1)} = 2Rr^{k+1} \cos((k+2)\theta + \mu) + O(|\lambda_3|^{k+1}) , \quad (2.65)$$

$$y^{(k+2)} = 2Rr^{k+2} \cos((k+2)\theta + \mu) + O(|\lambda_3|^{k+2}) . \quad (2.66)$$

Введем в рассмотрение определитель:

$$I^{(k)} = \begin{vmatrix} y^{(k)} & y^{(k+1)} \\ y^{(k+1)} & y^{(k+2)} \end{vmatrix}$$

и вычислим его значения, используя формулы (2.64)-(2.66). Получим:

$$\begin{aligned} I^{(k)} &= 4R^2 r^{2k+2} \{ \cos((k+2)\theta + \mu) \cos(k\theta + \mu) - \cos^2((k+1)\theta + \mu) \} + Mr^k O(|\lambda_3|^k) = \\ &= -4R^2 r^{2k+2} \sin^2 \theta + Mr^k O(|\lambda_3|^k), \end{aligned}$$

где M – некоторая константа, $\sin^2 \theta \neq 0$, ибо λ_1 и λ_2 по предположению комплексные числа. Аналогичным путем получим:

$$I^{(k-1)} = -4R^2 r^{2k} \sin^2 \theta + Mr^{k-1} O(|\lambda_3|^k)$$

Значит, модуль комплексного числа λ_1 можно приближенно вычислить по формуле:

$$r^2 \approx \frac{I^{(k)}}{I^{(k-1)}} \approx \frac{y^{(k)} y^{(k+2)} - y^{(k+1)} y^{(k+1)}}{y^{(k-1)} y^{(k+1)} - y^{(k)} y^{(k)}} .$$

После того, как мы найдем r , аргумент комплексного числа можно находить приближенно по формуле:

$$\cos \theta \approx \frac{y^{(k+2)} + r^2 y^{(k)}}{2ry^{(k+1)}} ,$$

т.к.

$$\begin{aligned}
y^{(k+2)} + r^2 y^{(k)} &= 2Rr^{k+2} \{\cos((k+2)\theta + \mu) + \cos(k\theta + \mu)\} + MO(|\lambda_3|^k) \\
&= 2Rr^{k+2} \cos((k+1)\theta + \mu) \cos \theta + MO(|\lambda_3|^k) = 2ry^{(k+1)} \cos \theta + MO(|\lambda_3|^k).
\end{aligned}$$

Зная приближенные значения модуля и аргумента комплексного числа, можно вычислить собственные значения:

$$\lambda_1 = r(\cos \theta + i \sin \theta) \quad , \quad \lambda_2 = r(\cos \theta - i \sin \theta).$$

ГЛАВА 3. АППРОКСИМАЦИЯ ФУНКЦИЙ

3.1. Постановка задачи

Задача приближения функций возникает в различных ситуациях как самостоятельная задача, так и как составная часть при решении более сложных задач. Функция $y=f(x)$ считается заданной, если любому допустимому значению x сопоставлено значение y . Но нередко оказывается, что нахождение этого значения невозможно, т.к. неизвестна явная связь между x и y или же вычисление $f(x)$ очень трудоемко. Простейшая задача, приводящая к приближению функций, заключается в следующем: в результате экспериментальных исследований получают таблицу значений некоторой функции $f(x)$ при фиксированных значениях аргумента x_i , т.е. $f(x_i)$ ($i = \overline{0, n}$). Аналитическая зависимость между x и y неизвестна, что не позволяет вычислить значения функции $f(x)$ в промежуточных точках, отличающихся от экспериментальных x_i . Для отыскания этих значений строят приближенную функцию $\varphi(x)$, расчеты по которой либо совпадают, либо в некотором смысле близки к полученным экспериментально.

Аналогичная задача возникает, если по ходу вычислений приходится многократно вычислять одну и ту же функцию, аналитический вид которой известен, но для получения ее значений необходимо провести большой объем вычислений. Например, $f(x)$ может быть определена как решение сложной задачи, в которой x играет роль параметра, или $f(x)$ измеряется в дорогостоящем эксперименте. При этом можно вычислить небольшую таблицу значений функции, но прямое нахождение функции при большом числе значений аргумента будет практически невозможно. В таких случаях целесообразно приближенно заменить функцию $f(x)$ некоторой функцией $\varphi(x)$, которая была бы близка в некотором смысле к $f(x)$ и просто вычислялась.

Проблема приближения функций общего вида классом более простых функций называется *аппроксимацией* и возникает, таким образом, в двух принципиально различных случаях:

- 1) функция *известна* (либо задана аналитически, но регулярные вычисления слишком трудоемки даже при использовании ЭВМ, либо неявно - в любом случае существует возможность вычислить ограниченное количество значений функции в некотором диапазоне значений аргумента). Замена более простой функцией необходима для облегчения как вычисления значений, так и выполнения операций дифференцирования и интегрирования (как аналитического, так и численного);
- 2) известна лишь *частичная информация о функции* (точная или приближенная), например, таблица значений функции и, возможно, производных при некоторых дискретных значениях аргумента. Требуется восстановить по имеющимся данным вид зависимости.

Если приближение строится на заданном дискретном множестве $\{x_i\}$, то аппроксимация называется точечной. При построении приближения на непрерывном множестве точек (например, на отрезке $[a, b]$) аппроксимация называется непрерывной или интегральной). Близость исходной функции $f(x)$ и более простой аппроксимирующей функции $\varphi(x)$ обеспечивают путем введения в аппроксимирующую функцию *свободных параметров* $c_0, c_1, c_2, \dots, c_n$ и соответствующим их выбором. Если $\varphi(x, c_0, c_1, c_2, \dots, c_n)$ нелинейно зависит от параметров, то аппроксимация называется *нелинейной*. В случае *линейной аппроксимации* $\varphi(x)$ представима в виде так называемого *обобщенного многочлена* по некоторой системе функций $\{\varphi_k(x)\}$ ($k = \overline{0, n}$) :

$$\varphi(x, c_0, c_1, \dots, c_n) = \sum_{k=0}^n c_k \varphi_k(x). \quad (3.1)$$

Само понятие близости или *меры отклонения* аппроксимирующей функции от заданной и способ выбора наилучших значений параметров c_k определяется конкретным видом аппроксимации.

Интерполяция. Близость *интерполирующей* функции $\varphi(x)$ к исходной состоит в том, что их значения совпадают на заданной системе точек x_j ($j = \overline{0, n}$), называемых узлами. Значения аппроксимирующих параметров c_i определяются из следующей системы уравнений:

$$\varphi(x_j, c_0, c_1, c_2, \dots, c_n) = f(x_j), \quad j = \overline{0, n}$$

или

$$\sum_{k=0}^n c_k \varphi_k(x_j) = f(x_j) \quad j = \overline{0, n} \quad (3.2)$$

в случае линейной интерполяции. Для того чтобы задача линейной интерполяции имела единственное значение, необходимо и достаточно неравенства нулю определителя системы при любом расположении узлов x_i :

$$\det\{\varphi_k(x)\} = \begin{vmatrix} \varphi_0(x_0) & \varphi_1(x_0) & \dots & \varphi_n(x_0) \\ \varphi_0(x_1) & \varphi_1(x_1) & \dots & \varphi_n(x_1) \\ \dots & \dots & \dots & \dots \\ \varphi_0(x_n) & \varphi_1(x_n) & \dots & \varphi_n(x_n) \end{vmatrix} \neq 0, \quad \forall x_i \neq x_j \quad (3.3)$$

Выполнение или невыполнение этого требования зависит от выбора системы функций $\varphi_k(x)$. Система функций, удовлетворяющая требованию

$\det\{\varphi_k(x_i)\} \neq 0$ при $\forall x_i \neq x_j, x_i \in [a, b]$ называется *чебышевской* системой на $[a, b]$.

На практике чаще всего используются следующие системы функций :

- 1) $1, x, x^2, \dots, x^n, \dots;$
- 2) $1, \sin x, \cos x, \dots, \sin nx, \cos nx, \dots;$
- 3) $e^{\alpha_0 x}, e^{\alpha_1 x}, \dots, e^{\alpha_n x}, \dots,$

где α_i - некоторая числовая последовательность попарно-различных действительных чисел.

Интерполирование называется соответственно алгебраическим, тригонометрическим (применяется для 2π -периодических функций) и экспоненциальным. Часто используются также кусочно-полиномиальные функции (сплайны).

Среднеквадратичное приближение. Мерой отклонения при среднеквадратичном приближении является евклидова норма разности функций $f(x)$ и $\varphi(x)$

$$\|f(x) - \varphi(x, c_0, c_1, \dots, c_n)\|_E = (f - \varphi, f - \varphi)^{1/2}.$$

Здесь (α, β) - скалярное произведение двух функций, определяемое в общем случае одним из двух способов:

1. Если функции заданы во всех точках некоторого отрезка $[a, b]$ и интегрируемы с квадратом на $[a, b]$, то

$$(\alpha(x), \beta(x)) = \int_a^b \alpha(x) \beta(x) w(x) dx. \quad (3.4)$$

2. Если же функции заданы на дискретном множестве точек $\{x_j\}$ ($j = \overline{0, m}$) отрезка $[a, b]$, то

$$(\alpha(x), \beta(x)) = \sum_{j=1}^m \alpha(x_j) \beta(x_j) w(x_j). \quad (3.5)$$

Функция $w(x)$ называется *весом* и положительна на отрезке $[a, b]$.

В задаче о наилучшем среднеквадратичном приближении вес $w(x) \equiv 1$ и мера отклонения аппроксимирующей функции от заданной определяется нормой

$$\|f(x) - \varphi(x, c_0, c_1, \dots, c_n)\|_E = \left(\int_a^b (f(x) - \varphi(x, c_0, c_1, \dots, c_n))^2 dx \right)^{1/2},$$

или

$$\|f(x) - \varphi(x, c_0, c_1, \dots, c_n)\|_E = \left(\sum_{j=1}^m (f(x_j) - \varphi(x_j, c_0, c_1, \dots, c_n))^2 \right)^{1/2}.$$

Задача о наилучшем среднеквадратичном приближении состоит в нахождении параметров c_i , минимизирующих норму $\|f - \varphi\|_E$ для функции $\varphi(x)$, принадлежащей некоторому классу функций. Обычно этот класс достаточно узок - его выбирают по ряду соображений профессионально-теоретического характера, либо по диаграмме $(x_j, f(x_j))$ ($j = \overline{0, m}$). Если экспериментальные точки располагаются вдоль некоторой линии, сходной по форме, например, с графиком гиперболической, показательной логарифмической или других функций, то соответствующая функция с неизвестными параметрами выбирается в качестве аппроксимирующей. Затем проводится линеаризация этой функции с помощью замены переменных и задача сводится к нахождению многочлена первой степени. Этот способ очень эффективен и часто используется при получении эмпирических формул.

При условии линейной независимости системы функций $\{\varphi_k(x)\}$ *многочлен наилучшего среднеквадратичного приближения* существует и единственен. На практике часто применяют среднеквадратичное приближение алгебраическими многочленами в дискретном варианте. При этом желательно, чтобы число точек m было больше степени многочлена n хотя бы в полтора-два раза. Среднеквадратичные приближения функций алгебраическими многочленами используются обычно в тех случаях, когда приближаемая функция не обладает достаточной гладкостью и для нее не удастся построить подходящего интерполяционного многочлена, а также если значения функции известны в достаточно большом числе точек, но со случайными ошибками.

Равномерное приближение. Мерой близости аппроксимирующей функции к исходной при равномерном приближении является чебышевская норма

$$\|f(x) - \varphi(x, c_0, c_1, \dots, c_n)\|_{C[a,b]} = \max_{x \in [a,b]} |f(x) - \varphi(x, c_0, c_1, \dots, c_n)|, \quad (3.6)$$

равная максимальному отклонению этих функций друг от друга на отрезке $[a, b]$.

Наилучшее равномерное приближение определяется условием

$$\min \left(\max_{x \in [a,b]} |f(x) - \varphi(x, c_0, c_1, \dots, c_n)| \right),$$

где минимум ищется на множестве функций $\varphi(x, c_0, c_1, c_2, \dots, c_n)$. Если выбрана линейная аппроксимация с чебышевской системой функций $\{\varphi_k(x)\}$, то наилучшее равномерное приближение единственно.

Принципиальное различие двух приближений показано на рис. 1, где Δ - абсолютное отклонение функции $\varphi(x)$ от функции $f(x)$, определяемое как $\|f - \varphi\|_{C[a,b]}$, $\tilde{\Delta}$ - среднеквадратичное отклонение, определяемое как $\frac{\|f - \varphi\|_E}{\sqrt{b-a}}$ (или $\frac{\|f - \varphi\|_E}{\sqrt{n}}$, если задана в узлах $x_1, \dots, x_n$).




Рис. 1

3.2. Применение алгебраических многочленов для аппроксимации функций

В различных разделах численного анализа для аппроксимации функций наиболее часто используются алгебраические многочлены. Алгебраическим многочленом (полиномом) степени n называется функция вида

$$P_n(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n = \sum_{k=0}^n a_k x^k, \quad (3.7)$$

где a_k - некоторые числовые коэффициенты ($a_n \neq 0$).

Они применяются при решении нелинейных, дифференциальных и интегральных уравнений, вычислении производных и интегралов. Это связано с их простой структурой: полиномы просто складывать, умножать, интегрировать и дифференцировать. Чтобы вычислить значение алгебраического многочлена, нужно выполнить конечное число арифметических операций – сложений, вычитаний и умножений, что легко реализуется на ЭВМ.

Основой для применения полиномов в качестве приближений к непрерывным функциям является свойство полноты семейства алгебраических многочленов в классе непрерывных функций, выражаемое теоремой Вейерштрасса:

Если $f(x)$ - непрерывная на замкнутом отрезке $[a, b]$ функция, то для любого $\varepsilon > 0$ существует многочлен $P_n(x)$ некоторой степени $n = n(\varepsilon)$, для которого при любых $x \in [a, b]$ выполняется неравенство $|f(x) - P_n(x)| < \varepsilon$.

Эта теорема утверждает принципиальную возможность приближения полиномами вообще, однако неизвестна ни степень этого аппроксимирующего многочлена, ни алгоритм его построения. Из теоремы также не следует, что такое приближение можно осуществить интерполированием по заданным узлам или построив алгебраический многочлен наилучшего среднеквадратичного приближения.

Доказано, что среди всех алгебраических многочленов n -й степени $P_n(x)$ существует, и притом единственный, многочлен наилучшего равномерного приближения $P_n^*(x)$, для которого

$$\|f(x) - P_n^*(x)\|_{C[a,b]} \leq \|f(x) - P_n(x)\|_{C[a,b]},$$

однако построение этого многочлена в общем случае вызывает большие затруднения. Поэтому на практике ограничиваются построением многочлена, близкого к наилучшему и дающего равномерное приближение заданной функции $f(x)$ с требуемой точностью ε , т.е. удовлетворяющего условию

$$\|f(x) - P_n(x)\|_{C[a,b]} \leq \varepsilon.$$

Таким многочленом является интерполяционный многочлен с узлами, особым образом расположенными на отрезке $[a, b]$.

Формы записи алгебраического многочлена. Запись многочлена в виде (3.7) называется *степенной формой* и является стандартной для математических текстов. Она очень удобна для дифференцирования и интегрирования полинома, но вычисление его значения непосредственно по формуле (3.7) может привести к потере значащих цифр при больших значениях аргумента.

Смещенной или *центрированной* степенной формой многочлена называется запись его в виде

$$P_n(x) = b_0 + b_1(x - c) + b_2(x - c)^2 + \dots + b_n(x - c)^n = \sum_{k=0}^n b_k(x - c)^k. \quad (3.8)$$

Фактически смещенная форма (3.8) представляет собой разложение полинома в ряд Тейлора в окрестности точки c и, следовательно, $b_k = \frac{P_n^{(k)}(c)}{k!}$. Если необ-

ходимо вычислять значения $P_n(x)$ на отрезке $[a, b]$, то для уменьшения вычислительной погрешности рекомендуется в качестве c выбрать середину отрезка.

Обобщением смещенной формы является *форма Ньютона*:

$$P_n(x) = d_0 + d_1(x - c_1) + d_2(x - c_1)(x - c_2) + \dots + d_n(x - c_1)(x - c_2) \dots (x - c_n). \quad (3.9)$$

При совпадающих узлах ($c_1 = c_2 = \dots = c_n = c$) она становится смещенной, а при нулевых узлах ($c_k = 0$) – степенной.

Многочлен называется *факторизованным*, если он записан в виде

$$P_n(x) = (x - c_1)(x - c_2) \cdots (x - c_n), \quad (3.10)$$

где c_k – нули многочлена. Эта форма записи соответствует форме Ньютона (3.9), в которой старший коэффициент равен единице, а остальные – нулю. Все c_k различны, если нули *простые*, если же какое-то значение c_m встречается l раз, то такой нуль называется *кратным* (или *нулем кратности l*). Для этого значения справедливо

$$P_n(c_m) = P'_n(c_m) = P''_n(c_m) = \dots = P_n^{(l-1)}(c_m) = 0, P_n^{(l)}(c_m) \neq 0. \quad (3.11)$$

Если известны только некоторые нули многочлена $c_1, c_2, \dots, c_p$, то он может быть записан в *частично факторизованном* виде:

$$P_n(x) = (x - c_1)(x - c_2) \cdots (x - c_p) Q_r(x), \quad (3.12)$$

где $r = n - \sum_{i=1}^p l_i$, l_i – кратность i -го нуля.

Степенная форма записи многочлена (3.7) может рассматриваться как линейная комбинация функций $1, x, x^2, \dots, x^n$, образующих базис пространства многочленов степени n . Если выбрать в качестве базиса какую-либо систему ортогональных многочленов $\{\tilde{P}_k(x)\} (k = \overline{0, n})$, то можно представить $P_n(x)$ в виде

$$P_n(x) = a_0 \tilde{P}_0(x) + a_1 \tilde{P}_1(x) + a_2 \tilde{P}_2(x) + \dots + a_n \tilde{P}_n(x) = \sum_{k=0}^n a_k \tilde{P}_k(x), \quad (3.13)$$

который называется *разложением по ортогональным многочленам*.

Напомним, что система функций $\{\varphi_k(x)\} (k = \overline{0, n})$ называется *ортонормальной*, если скалярное произведение любых двух различных функций системы, определяемое формулами (3.4) или (3.5), равно нулю:

$$(\varphi_i, \varphi_j) = \begin{cases} S_i > 0, & i = j \\ 0, & i \neq j \end{cases} \quad i, j = \overline{0, n}. \quad (3.14)$$

Для последовательности ортогональных многочленов справедлива трехчленная рекуррентная формула

$$\tilde{P}_{k+1}(x) = A_k(x - B_k) \tilde{P}_k(x) - C_k \tilde{P}_{k-1}(x), \quad k = 0, 1, \dots, \quad (3.15)$$

по которой с учетом того, что $\tilde{P}_{-1}(x) = 0, \tilde{P}_0(x) = 1$, может быть найден многочлен любой степени. Коэффициенты $A_k \neq 0, B_k, C_k$, весовые функции $w(x)$ и

отрезок $[a, b]$, на котором многочлены ортогональны, различны для различных систем многочленов. Каждый ортогональный многочлен степени k имеет ровно k корней на интервале (a, b) , причем нули многочленов $\tilde{P}_k(x)$ и $\tilde{P}_{k+1}(x)$ перемежаются.

Исключительно простой и очень эффективный базис для представления многочлена в виде (3.13) обеспечивается *многочленами Чебышева* $T_k(x)$. Эти многочлены ортогональны на отрезке $[-1, 1]$ с весом $w(x) = \frac{1}{\sqrt{1-x^2}}$, трехчленная рекуррентная формула (3.15) для них имеет вид:

$$T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x), \quad (3.16)$$

т.е. $A_0 = 0, B_0 = 0, A_k = 2, B_k = 0, C_k = 1, k = 1, 2, \dots$

Коэффициент при старшей степени у $T_n(x)$ равен 2^{n-1} . Этот многочлен имеет $n+1$ экстремум на отрезке $[-1, 1]$, причем экстремальное значение многочлена $T_n(x)$ равно ± 1 и достигается в точках $x_k = \cos \frac{k\pi}{n}, k = \overline{0, n}$. Корни

многочлена $T_n(x)$ равны $x_j = \cos \frac{(2j+1)\pi}{2n}, j = \overline{0, n}$ и расположены неравномерно на отрезке $[-1, 1]$: сравнительно редко в середине и гуще к его концам.

Многочлены Чебышева иногда называют *наименее уклоняющимися от нуля*, т.к. среди всех многочленов степени n со старшим коэффициентом, равным единице, наименьшее значение максимума модуля на отрезке $[-1, 1]$ имеет модифицированный многочлен Чебышева $\bar{T}_n(x) = 2^{-n+1} T_n(x)$

$$\max_{x \in [-1, 1]} |\bar{T}_n(x)| = 2^{-n+1}.$$

Разложения по ортогональным многочленам (3.13), в частности по многочленам Чебышева, используют для уменьшения вычислительной погрешности.

Вычисление значений алгебраического многочлена и его производных. Запишем многочлен (3.9) в более удобном для вычислений виде:

$$P_n(x) = d_0 + (x - c_1)(d_1 + (x - c_2)(d_2 + (x - c_3)(d_3 + \dots (x - c_{n-1})(d_{n-1} + (x - c_n)d_n) \dots))). \quad (3.17)$$

Согласно формуле (3.17) вычисление значения $P_n(x^*)$ сводится к последовательному нахождению величин

$$\begin{aligned}\tilde{d}_n &= d_n, \\ \tilde{d}_{n-1} &= \tilde{d}_n(x^* - c_n) + d_{n-1}, \\ \tilde{d}_{n-2} &= \tilde{d}_{n-1}(x^* - c_{n-1}) + d_{n-2}, \\ &\dots, \\ \tilde{d}_1 &= \tilde{d}_2(x^* - c_2) + d_1, \\ \tilde{d}_0 &= \tilde{d}_1(x^* - c_1) + d_0 = P_n(x^*).\end{aligned}\tag{3.18}$$

Этот алгоритм называется *схемой Горнера* и является самым экономным для реализации на ЭВМ. Вычисление значения многочлена в форме Ньютона с его помощью требует всего n умножений и $2n$ сложений, если же многочлен задан в степенной форме, - n умножений и всего n сложений. Для сравнения – вычисление многочлена в степенной форме по формуле (3.7) требует в общем случае $2n - 1$ умножений и n сложений.

$$P_n(x) = \tilde{d}_0 + \tilde{d}_1(x - x^*) + \tilde{d}_2(x - x^*)(x - c_2) + \cdots + \tilde{d}_n(x - x^*)(x - c_1) \cdots (x - c_{n-1}),$$

который также представляет собой многочлен в форме Ньютона, но с узлами x^* , c_1 , c_2 , ..., c_{n-1} . Таким образом, однократное применение алгоритма добавляет точку, в которой вычислялось значение многочлена, в качестве первого узла, сдвигает остальные узлы и “вытесняет” последний. Поэтому алгоритм можно использовать для преобразования одной формы Ньютона в другую.

С помощью этого алгоритма можно также определить частное и остаток при делении $P_n(x)$ на многочлен первой степени:

$$\begin{aligned} P_n(x) &= \tilde{d}_0 + (x - c)(\tilde{d}_1 + \tilde{d}_2(x - c_1) \cdots + \tilde{d}_n(x - c_1) \cdots (x - c_{n-1})) = \\ &= P_n(c) + (x - c)Q_{n-1}(x). \end{aligned}$$

Неоднократное повторное применение алгоритма в точке c приводит многочлен к виду, позволяющему вычислять его производные:

$$\begin{aligned} P_n(x) &= \tilde{\tilde{d}}_0 + (x-c) \left(\tilde{\tilde{d}}_1 + \tilde{\tilde{d}}_2(x-c) \cdots + \tilde{\tilde{d}}_n(x-c)(x-c_1) \cdots (x-c_{n-2}) \right) = \\ &= \tilde{\tilde{d}}_0 + (x-c) \tilde{\tilde{d}}_1 + (x-c)^2 Q_{n-2}(x) = \dots = \\ &= \sum_{i=1}^m \hat{d}_i (x-c)^i + (x-c)^{m+1} Q_{n-m-1}(x). \end{aligned}$$

Действительно, $P_n^{(k)}(c) = k! \hat{d}_k$, $k = 0, 1, \dots, m$, где $\hat{d}_k$ - коэффициенты, преобразованные по формулам (3.18) $m+1$ раз при $x^* = c$.

Значение многочлена в форме (3.13) эффективно вычисляется без непосредственного вычисления ортогональных многочленов с помощью обобщенного алгоритма (3.18), основанного на рекуррентном соотношении (3.15):

$$\begin{aligned}\tilde{a}_n &= a_n, \\ \tilde{a}_{n-1} &= a_{n-1} + \tilde{a}_n A_{n-1}(x^* - B_{n-1}), \\ \tilde{a}_j &= a_j + \tilde{a}_{j+1} A_j(x^* - B_j) - \tilde{a}_{j+2} C_{j+1}, \quad j = n-2, n-3, \dots, 0 \\ P_n(x^*) &= \tilde{a}_0.\end{aligned}\quad (3.19)$$

3.3. Интерполирование алгебраическими многочленами

Пусть функция $f(x)$ определена на отрезке $[a, b]$ и непрерывна на нем. Пусть, далее, $x_0, x_1, \dots, x_n$ - различные точки этого отрезка, называемые *узлами*, такие что $a \leq x_0 < x_1 < x_2 < \dots < x_{n-1} < x_n \leq b$.

Предположим, что известны значения y_i этой функции в узлах x_i , т.е. $y_i = f(x_i)$, $i = \overline{0, n}$. Рассмотрим систему $\varphi_k(x) = x^k$, $k = \overline{0, n}$. Задача интерполирования алгебраическими многочленами функции $f(x)$ на $[a, b]$ состоит в том, чтобы построить многочлен степени не выше n

$$P_n(x) = a_0 + a_1 x + a_2 x^2 + \dots + a_n x^n = \sum_{k=0}^n a_k x^k$$

с действительными коэффициентами, значения которого совпадают со значениями функции $f(x)$ в узлах x_i . Многочлен $P_n(x)$, удовлетворяющий поставленным условиям, называется *интерполяционным*, а точки $x_0, x_1, \dots, x_n$ - *узлами интерполирования*.

Поскольку система функций $\{x^k\}$ - чебышевская, то определитель (3.3) в этом случае есть определитель Вандермонда:

$$\det(\varphi_k(x)) = \begin{vmatrix} 1 & x_0 & \dots & x_0^n \\ 1 & x_1 & \dots & x_1^n \\ \dots & \dots & \dots & \dots \\ 1 & x_n & \dots & x_n^n \end{vmatrix} = \prod_{n \geq k > m \geq 0} (x_k - x_m). \quad (3.20)$$

Он отличен от нуля при любых различных между собой значениях x_i и сформулированная задача разрешима. Таким образом, алгебраический многочлен $P_n(x)$, интерполирующий функцию $f(x)$ по ее значениям в узлах x_i , существует

и единственен (с точностью до формы записи). Непосредственное нахождение коэффициентов a_i из условия интерполирования

$$P_n(x_i) = f(x_i), \quad i = \overline{0, n} \quad (3.21)$$

приводит к сильному искажению их величины вычислительной погрешностью. Поэтому интерес представляют формы записи интерполяционного многочлена, не использующие непосредственное решение системы (3.21). Наиболее употребительна запись $P_n(x)$ в форме Лагранжа и в форме Ньютона.

Оценка погрешности интерполирования. Рассмотрим погрешность замены функции интерполяционным многочленом: $R_n(x) = f(x) - P_n(x)$. Эта величина зависит от многих факторов – от свойств функции $f(x)$, числа и расположения узлов x_i , положения точки x относительно узлов. Будем предполагать, что функция $f(x)$ имеет $n + 1$ непрерывную производную. Погрешность интерполирования удобно представить в следующем виде:

$$R_n(x) = f(x) - P_n(x) = \omega(x) \cdot r_n(x),$$

где $\omega(x)$ - многочлен степени $n + 1$

$$\omega(x) = (x - x_0)(x - x_1)(x - x_2) \dots (x - x_n) = \prod_{k=0}^n (x - x_k), \quad (3.22)$$

обращающийся в нуль в узлах интерполирования $x_0, x_1, \dots, x_n$, $r_n(x)$ - некоторая функция, значения которой в узлах x_i могут быть любыми, т.к. $\omega(x_i) = 0$ и $R_n(x_i) = 0$. Введем вспомогательную функцию

$$F(t) = P_n(t) + \omega(t) \cdot r_n(x) - f(t), \quad (3.23)$$

где x играет роль параметра и принимает любое фиксированное значение ($x \in [a, b]$, $x \neq x_i$, $i = \overline{0, n}$). Очевидно, что эта функция обращается в нуль при $t = x_i$, $i = \overline{0, n}$ и $t = x$, т.е. имеет $n + 2$ нуля на отрезке $[a, b]$. Между двумя нулями гладкой функции расположен нуль ее производной, поэтому $F'(t)$ имеет $n + 1$ нуль на отрезке $[a, b]$, $F''(t)$ - n нулей. Продолжая эти рассуждения, получим, что функция $F^{(n+1)}(t)$ имеет один нуль, т.е. существует точка $\xi \in (a, b)$, для которой

$$F^{(n+1)}(\xi) = 0 + (n + 1)! r_n(x) - f^{(n+1)}(\xi) = 0.$$

Отсюда

$$r_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}.$$

Таким образом,

$$R_n(x) = \omega(x) \frac{f^{(n+1)}(\xi)}{(n+1)!}, \quad (3.24)$$

где $a < \xi < b$. Из равенства (3.24) получается оценка погрешности интерполяции в точке $x \in [a, b]$:

$$|R_n(x)| = |f(x) - P_n(x)| = \frac{|f^{(n+1)}(\xi)|}{(n+1)!} |\omega(x)| \leq \frac{M_{n+1}}{(n+1)!} |\omega(x)|, \quad (3.25)$$

где $M_{n+1} = \max_{x \in [a, b]} |f^{(n+1)}(x)|$, и оценка максимальной погрешности интерполирования на всем отрезке $[a, b]$:

$$\max_{x \in [a, b]} |f(x) - P_n(x)| \leq \frac{M_{n+1}}{(n+1)!} \max_{x \in [a, b]} |\omega(x)|. \quad (3.26)$$

Оценку погрешности интерполирования по формуле (3.26) можно провести до вычисления интерполяционного полинома - подобная оценка называется *априорной*. Оценить максимум $\omega(x)$ при произвольном расположении узлов интерполирования сложно. Однако таблицы чаще всего имеют постоянный шаг $h = x_{i+1} - x_i$, а узлы берутся из таблицы подряд. В этом случае локальные максимумы функции $|\omega(x)|$ на интервалах $[x_i, x_{i+1}]$ увеличиваются по мере продвижения от центрального интервала к крайним, так что наименьшей погрешность аппроксимации будет в интервалах, примыкающих к центральному узлу. На рис. 2 изображен примерный вид графиков при $n = 4$ и $n = 5$.




Рис. 2

Поэтому при интерполировании по таблице с постоянным шагом выгодно выбирать узлы так, чтобы точка x , в которой необходимо вычислить значение

функции, располагалась ближе к центру этой конфигурации узлов. Для центрального интервала (при четном количестве узлов) справедлива следующая оценка погрешности:

$$|f(x) - P_n(x)| < \sqrt{\frac{2}{n\pi}} M_{n+1} \left(\frac{h}{2}\right)^{n+1}. \quad (3.27)$$

Можно подобрать узлы интерполирования так, чтобы минимизировать максимум многочлена $|\omega(x)|$. Для этого $|\omega(x)|$ должен быть модифицированным многочленом Чебышева $\bar{T}_{n+1}(x)$ со старшим коэффициентом, равным единице: $\bar{T}_{n+1}(x) = 2^{-n} T_{n+1}(x)$. Как отмечалось ранее, этот многочлен имеет наименьшее значение максимума модуля среди всех многочленов степени $n+1$ со старшим коэффициентом, равным единице: $\max_{x \in [-1, 1]} |\bar{T}_{n+1}(x)| = 2^{-n}$.

Таким образом, если в качестве узлов интерполирования на отрезке $[a, b]$ взять точки, соответствующие корням многочлена Чебышева:

$$x_k = \frac{a+b}{2} + \frac{b-a}{2} \cos \frac{(2k+1)\pi}{2(n+1)}, \quad k = \overline{0, n}, \quad (3.28)$$

то оценка погрешности интерполирования приобретает следующий вид:

$$\max_{x \in [a, b]} |f(x) - P_n(x)| \leq \frac{M_{n+1}}{(n+1)!} \frac{(b-a)^{n+1}}{2^{2n+1}}. \quad (3.29)$$

Эта оценка не может быть улучшена для конкретного n .

Интерполяционная формула Лагранжа. Представим многочлен $P_n(x)$ в виде линейной комбинации значений функции $f(x)$ в узлах интерполяции

$$L_n(x) = \sum_{i=0}^n \ell_i(x) f(x_i). \quad (3.30)$$

Условие интерполирования (3.21) будет выполнено, если потребовать выполнения условий

$$\ell_i(x_k) = \begin{cases} 0, & i \neq k \\ 1, & i = k \end{cases}, \quad i = \overline{0, n},$$

которые означают, что каждая из функций $\ell_i(x)$ имеет не менее n нулей на $[a, b]$. Поэтому коэффициенты $\ell_i(x)$ можно представить в виде:

$$\ell_i(x) = \lambda_i (x - x_0)(x - x_1) \dots (x - x_{i-1})(x - x_{i+1}) \dots (x - x_n).$$

Из условия $\ell_i(x)=1$ получаем:

$$\lambda_i^{-1} = (x_i - x_0) \dots (x_i - x_{i-1})(x_i - x_{i+1}) \dots (x_i - x_n).$$

Таким образом, коэффициенты $\ell_i(x)$ находятся по формуле

$$\ell_i(x) = \frac{\prod_{k \neq i} (x - x_k)}{\prod_{k \neq i} (x_i - x_k)}. \quad (3.31)$$

Часто ее записывают в другой форме:

$$\ell_i(x) = \frac{\omega(x)}{(x - x_i)\omega'(x_i)}. \quad (3.32)$$

Здесь $\omega(x)$ - многочлен степени $n+1$ (3.12), его производная в точке x_i равна

$$\omega'(x_i) = (x_i - x_0) \dots (x_i - x_{i-1})(x_i - x_{i+1}) \dots (x_i - x_n). \quad (3.33)$$

Интерполяционный многочлен Лагранжа имеет вид

$$\begin{aligned} L_n(x) &= \sum_{k=0}^n f(x_k) \frac{(x - x_0) \dots (x - x_{k-1})(x - x_{k+1}) \dots (x - x_n)}{(x_k - x_0) \dots (x_k - x_{k-1})(x_k - x_{k+1}) \dots (x_k - x_n)} = \\ &= \sum_{k=0}^n f(x_k) \frac{\prod_{j=0, j \neq k}^n (x - x_j)}{\prod_{j=0, j \neq k}^n (x_k - x_j)}, \end{aligned} \quad (3.34)$$

или

$$L_n(x) = \sum_{k=0}^n \frac{\omega(x)}{(x - x_k)\omega'(x_k)} f(x_k). \quad (3.35)$$

Пример 1. Построить интерполяционный многочлен Лагранжа для функции

$f(x) = \sin \frac{\pi x}{2}$ по узлам $x_0 = 0, x_1 = \frac{1}{3}, x_2 = 1$. Получить равномерную оценку погрешности на отрезке $[0,1]$.

Δ . Найдем значение функции в узлах:

$$y_0 = f(0) = 0, y_1 = f(x_1) = \frac{1}{2}, y_2 = f(x_2) = 1.$$

Составим многочлен $\omega(x)$:

$$\omega(x) = (x-0)\left(x-\frac{1}{3}\right)(x-1) = x\left(x-\frac{1}{3}\right)(x-1).$$

Отсюда

$$\omega'(0) = \frac{1}{3}, \omega'\left(\frac{1}{3}\right) = -\frac{2}{9}, \omega'(1) = \frac{2}{3}.$$

По формуле (3.35) при $n = 2$ имеем

$$L_2(x) = 0 \cdot \frac{\left(x-\frac{1}{3}\right)(x-1)}{\frac{1}{3}} + \frac{1}{2} \cdot \frac{x(x-1)}{-\frac{2}{9}} + 1 \cdot \frac{x\left(x-\frac{1}{3}\right)}{\frac{2}{3}} = -\frac{3}{4}x^2 + \frac{7}{4}x.$$

Поскольку $\left|\sin^3 \frac{\pi x}{2}\right| = \frac{\pi^3}{8} \left|\cos \frac{\pi x}{2}\right| \leq \frac{\pi^3}{8}$, то, согласно неравенству (3.25),

получаем следующую оценку погрешности интерполирования:

$$|R_2(x)| \leq \frac{\pi^3}{8 \cdot 3!} |\omega(x)| = \frac{\pi^3}{48} \left|x\left(x-\frac{1}{3}\right)(x-1)\right|.$$

Для получения равномерной оценки погрешности находим $\max_{0 \leq x \leq 1} |\omega(x)| = 0,079$. Таким образом, окончательно имеем оценку

$|R_n(x)| \leq \frac{\pi^3}{48} \cdot 0,079 = 0,05$, т.е. погрешность интерполяции на отрезке $[0,1]$ не превышает пяти процентов. Δ

Если сам интерполяционный многочлен $L_n(x)$ не требуется, а нужно лишь его значение в промежуточной точке x , не совпадающей с узлом, нет необходимости получать интерполяционный многочлен в степенной форме (3.7) и затем вычислять. Можно воспользоваться схемой Милна, которая позволяет вычислить значение $L_n(x)$, не определяя его коэффициенты. Для этого все $(n+1)^2$ разностей, входящих в формулу (3.34), располагают в виде квадратной таблицы:

$x - x_0$	$x_0 - x_1$	$x_0 - x_2$		$x_0 - x_n$
$x_1 - x_0$	$x - x_1$	$x_1 - x_2$		$x_1 - x_n$
.....				

$x_n - x_0$	$x_n - x_1$	$x_n - x_2$		$x - x_n$
-------------	-------------	-------------	-------	-----------

Тогда коэффициенты $l_i(x)$ равны отношению произведения D элементов, расположенных на главной диагонали, к произведениям D_i элементов i -й строки:

$$l_i(x) = D / D_i.$$

Интерполяционный многочлен можно записать в виде

$$L_n(x) = D \sum_{i=0}^n \frac{f(x_i)}{D_i}. \quad (3.36)$$

Для вычисления значения $L_n(x)$ по этой схеме требуется $2n$ умножений.

Пример 2. Вычислить, пользуясь схемой Милна, значение таблично заданной функции $f(x)$ в точке $x = 1$.

x	-2	-1	2	3
$f(x)$	-12	-8	3	5

▽ Составляем таблицу разностей для $x = 1$

$$\begin{array}{c|cccc|c} & 1+2 & -2+1 & -2-2 & -2-3 & D_i \\ \hline -1+2 & 1+1 & -1-2 & -1-3 & 3 & -1 & -4 & -5 & -60 \\ \hline 2+2 & 2+1 & 1-2 & 2-3 & 1 & 2 & -3 & -4 & 24 \\ \hline 3+2 & 3+1 & 3-2 & 1-3 & 4 & 3 & -1 & -1 & 12 \\ \hline & & & & 5 & 4 & 1 & -2 & -40 \end{array} =$$

$$D = 3 * 2 * (-1) * (-2) = 12$$

$$f(1) \approx L_3(1) = 12 * \left(\frac{-12}{-60} + \frac{-8}{24} + \frac{3}{12} + \frac{5}{-40} \right) = -0.1$$

▽

При вычислениях на ЭВМ одним из наиболее приемлемых алгоритмов интерполирования, особенно при достаточно большом количестве узлов, является схема Эйткена, согласно которой последовательно вычисляются многочлены:

$$L_{i,i+1}(x) = \frac{1}{x_{i+1} - x_i} \begin{vmatrix} f(x_i), & x_i - x \\ f(x_{i+1}), & x_{i+1} - x \end{vmatrix},$$

$$L_{i,i+1,i+2}(x) = \frac{1}{x_{i+2} - x_i} \left| \begin{array}{cc} L_{i,i+1}(x), & x_i - x \\ L_{i+1,i+2}(x), & x_{i+2} - x \end{array} \right|,$$

$$L_{i,i+1,i+2,i+3}(x) = \frac{1}{x_{i+3} - x_i} \left| \begin{array}{cc} L_{i,i+1,i+2}(x), & x_i - x \\ L_{i+1,i+2,i+3}(x), & x_{i+3} - x \end{array} \right|.$$

Интерполяционный многочлен n -й степени $L_n(x)$ при этом имеет вид

$$L_n(x) = L_{0,1,\dots,n}(x) = \frac{1}{x_n - x_0} \left| \begin{array}{cc} L_{0,1,\dots,n-1}(x), & x_0 - x \\ L_{1,2,\dots,n}(x), & x_n - x \end{array} \right|. \quad (3.37)$$

Вычисления по схеме Эйткена удобно расположить в таблице:

x_i	$f(x_i)$	$x_i - x$	$L_{i-1,i}(x)$	$L_{i-2,i-1,i}(x)$		$L_{0,1,\dots,n}(x)$
x_0	$f(x_0)$	$x_0 - x$				
			$L_{0,1}$			
x_1	$f(x_1)$	$x_1 - x$		$L_{0,1,2}$		
			$L_{1,2}$		...	
x_2	$f(x_2)$	$x_2 - x$		...		$L_{0,1,\dots,n}$
...	...	...	...			
x_{n-1}	$f(x_{n-1})$	$x_{n-1} - x$		$L_{n-2,n-1,n}$		
			$L_{n-1,n}$			
x_n	$f(x_n)$	$x_n - x$				

Описанный рекуррентный процесс интерполяции не требует априорного задания степени полинома и дает возможность контролировать достигнутую точность: можно постепенно подключать новые узлы до тех пор, пока абсолютная величина разности между двумя последовательными значениями $L_{0,1,\dots,k}(x)$ и $L_{0,1,\dots,k+1}(x)$ станет меньше заданной величины ε .

Пример 3. Вычислить, пользуясь схемой Эйткена, значение таблично заданной функции $f(x)$ в точке $x = 2$.

x	0	1	3	4
$f(x)$	-4	0.5	0.5	8

∇ Составляем таблицу для $x = 2$:

x_i	$f(x_i)$	$x_i - x$	$L_{i-1,i}$	$L_{i-2,i-1,i}$	$L_{0,1,2,3}$
0	-4	-2			
			$\frac{1}{1-0} \begin{vmatrix} -4 & -2 \\ 0.5 & -1 \end{vmatrix} = 5$		
1	0.5	-1		$\frac{1}{3-0} \begin{vmatrix} 5 & -2 \\ 0.5 & 1 \end{vmatrix} = 2$	
			$\frac{1}{3-1} \begin{vmatrix} 0.5 & -1 \\ 0.5 & 1 \end{vmatrix} = 0.5$		$\frac{1}{4-0} \begin{vmatrix} 2 & -2 \\ -2 & 2 \end{vmatrix} = 0$
3	0.5	1		$\frac{1}{4-1} \begin{vmatrix} 0.5 & -1 \\ -7 & 2 \end{vmatrix} = -2$	
			$\frac{1}{4-3} \begin{vmatrix} 0.5 & 1 \\ 8 & 2 \end{vmatrix} = -7$		
4	8	2			

$$f(2) \approx L_3(2) = L_{0,1,2,3} = 0.$$

▽

Интерполяционный многочлен в форме Лагранжа (3.34) удобно применять в тех случаях, когда ведется многократное интерполирование по одним и тем же узлам. В этом случае можно один раз найти коэффициенты Лагранжа (3.31), которые зависят только от узлов и точки x , и использовать для всех функций. Недостатком интерполяционных формул (3.34, 35) является то, что каждое из слагаемых представляет собой многочлен n -й степени, зависящий от всех узлов. Поэтому при увеличении числа точек x_i и, соответственно, степени многочлена, вычисления по формуле Лагранжа надо производить заново. От этого недостатка свободен интерполяционный многочлен в форме Ньютона.

Интерполяционная формула Ньютона выражает интерполяционный многочлен $P_n(x)$ через значение $f(x)$ в одном из узлов и через *разделенные разности* функции $f(x)$, построенные по узлам x_j (среди x_j нет совпадающих).

Разделенными разностями первого порядка называются отношения

$$f(x_i, x_j) = \frac{f(x_j) - f(x_i)}{x_j - x_i}, \quad i \neq j, \quad i, j = \overline{0, n}. \quad (3.38)$$

Будем рассматривать разделенные разности, составленные по соседним узлам, т.е. выражения $f(x_0, x_1), f(x_1, x_2), \dots, f(x_{n-1}, x_n)$. По этим разделенным разностям первого порядка можно построить *разделенные разности второго порядка*:

$$\begin{aligned}
f(x_0, x_1, x_2) &= \frac{f(x_1, x_2) - f(x_0, x_1)}{x_2 - x_0}, \\
f(x_1, x_2, x_3) &= \frac{f(x_2, x_3) - f(x_1, x_2)}{x_3 - x_1}, \\
f(x_{n-2}, x_{n-1}, x_n) &= \frac{f(x_{n-1}, x_n) - f(x_{n-2}, x_{n-1})}{x_n - x_{n-2}}.
\end{aligned}$$

Аналогично определяются разделенные разности более высокого $(k+1)$ -го порядка по уже известным разностям порядка k :

$$f(x_j, x_{j+1}, \dots, x_{j+k}, x_{j+k+1}) = \frac{f(x_{j+1}, x_{j+2}, \dots, x_{j+k+1}) - f(x_j, x_{j+1}, \dots, x_{j+k})}{x_{j+k+1} - x_j}. \quad (3.39)$$

При вычислении разделенных разностей принято записывать их в виде таблицы.

x_0	$\underline{f(x_0)}$				
		$\underline{f(x_0, x_1)}$			
x_1	$f(x_1)$		$\underline{f(x_0, x_1, x_2)}$		
		$f(x_1, x_2)$		...	
x_2	$f(x_2)$		...		$\underline{f(x_0, x_1, \dots, x_n)}$
		...			
...	...		$f(x_{n-2}, x_{n-1}, x_n)$		
...	...	$f(x_{n-1}, x_n)$			
x_n	$f(x_n)$				

Заметим, что добавление нового узла не изменит уже вычисленных коэффициентов и таблица будет просто дополнена новым столбцом и новой наклонной строкой разделенных разностей.

Разделенные разности обладают рядом полезных свойств. Они являются *симметричными функциями* своих аргументов, т.е. зависят только от значений x_j , но не от порядка, в котором они следуют в списке аргументов. Разделенные разности n -го порядка выражаются через значения функции в узлах по формуле

$$\begin{aligned}
f(x_0, x_1, \dots, x_n) &= \sum_{k=0}^n \frac{f(x_k)}{(x_k - x_0) \dots (x_k - x_{k-1})(x_k - x_{k+1}) \dots (x_k - x_n)} = \\
&= \sum_{k=0}^n \frac{f(x_k)}{\omega'(x_k)}.
\end{aligned} \quad (3.40)$$

Если на отрезке $[a, b]$ функция $f(x)$ имеет k непрерывных производных, то в наименьшем интервале, содержащем узлы x_j , существует такая точка ξ , что

$$f(x_0, x_1, \dots, x_k) = \frac{f^{(k)}(\xi)}{k!}, \quad (3.41)$$

т.е. разделенная разность k -го порядка является оценкой значения производной порядка k , деленной на $k!$.

Пусть x - произвольная точка отрезка $[x_0, x_n]$. Тогда по определению разделенной разности (3.38)

$$f(x, x_0) = \frac{f(x_0) - f(x)}{x_0 - x}.$$

Отсюда находим

$$f(x) = f(x_0) + (x - x_0)f(x_0, x). \quad (3.42)$$

Далее, из

$$f(x, x_0, x_1) = \frac{f(x_0, x_1) - f(x, x_0)}{x_1 - x}$$

следует

$$f(x, x_0) = f(x_0, x_1) + (x - x_1)f(x, x_0, x_1).$$

Отсюда и из равенства (3.41) находим

$$\begin{aligned} f(x) &= f(x_0) + (x - x_0)((x - x_1)f(x, x_0, x_1) + f(x_0, x_1)) = \\ &= f(x_0) + (x - x_0)f(x_0, x_1) + (x - x_0)(x - x_1)f(x, x_0, x_1). \end{aligned}$$

По индукции получаем формулу

$$\begin{aligned} f(x) &= f(x_0) + (x - x_0)f(x_0, x_1) + (x - x_0)(x - x_1)f(x_0, x_1, x_2) + \dots + \\ &+ (x - x_0)(x - x_1) \cdots (x - x_{n-1})f(x_0, x_1, x_2, \dots, x_n) + \\ &+ (x - x_0)(x - x_1) \cdots (x - x_n)f(x, x_0, x_1, x_2, \dots, x_n) = \\ &= N_n(x) + (x - x_0)(x - x_1) \cdots (x - x_n)f(x, x_0, x_1, x_2, \dots, x_n). \end{aligned}$$

Многочлен n -й степени $N_n(x)$ называется *интерполяционным многочленом Ньютона для интерполирования вперед*. При его записи в качестве коэффициентов используется выделенная верхняя наклонная строка в построенной таблице разделенных разностей:

$$\begin{aligned} N_n^{(B)}(x) &= f(x_0) + f(x_0, x_1)(x - x_0) + f(x_0, x_1, x_2)(x - x_0)(x - x_1) + \\ &+ \dots + f(x_0, x_1, \dots, x_{n-1}, x_n)(x - x_0)(x - x_1) \dots (x - x_{n-1}) \end{aligned} \quad (3.43)$$

Равносильный вариант многочлена Ньютона для интерполирования назад можно записать, используя нижнюю наклонную строку в таблице разделенных разностей, в следующем виде:

$$N_n^{(H)}(x) = f(x_n) + f(x_{n-1}, x_n)(x - x_n) + f(x_{n-2}, x_{n-1}, x_n)(x - x_n)(x - x_{n-1}) + \dots + f(x_0, x_1, \dots, x_n)(x - x_n)(x - x_{n-1}) \dots (x - x_1). \quad (3.44)$$

Интерполяционный многочлен в форме Ньютона в силу свойства (3.41) разделенных разностей является разностным аналогом формулы Тейлора.

Поскольку интерполяционный многочлен единственен, то многочлен Ньютона совпадает с многочленом Лагранжа. Многочлен Ньютона имеет то преимущество перед многочленом Лагранжа, что при добавлении дополнительного узла многочлен Лагранжа преобразуется заново, а в многочлене Ньютона появляется только дополнительное слагаемое.

При проведении расчетов по формуле Ньютона безразлично, в каком порядке пронумерованы узлы; - это полезно помнить при подключении в расчет новых узлов. Добавление одного узла x_{n+1} приводит к появлению добавочного слагаемого вида $f(x_0, x_1, \dots, x_n, x_{n+1})(x - x_0)(x - x_1) \dots (x - x_n)$ в выражении (3.43).

Для построения интерполяционного полинома Ньютона используются только диагональные элементы приведенной таблицы, остальные элементы являются промежуточными данными. Поэтому в программе, реализующей вычисление коэффициента полинома, разделенные разности для экономии памяти можно разместить в массиве, где первоначально хранились значения функции $f(x)$ в узлах. Этот массив будет частично обновляться при вычислении разделенных разностей очередного порядка. Так, при вычислении разностей k -го порядка первые k элементов массива остаются неизменными, остальные элементы заменяем разделенными разностями. Таким образом, после окончания вычислений все коэффициенты полинома Ньютона будут размещены последовательно в массиве узловых значений функции $f(x)$. Для их определения требуется $n(n-1)$ операций сложения и вдвое меньше делений.

После определения коэффициентов полинома Ньютона, вычисление его значений при конкретных аргументах x наиболее экономично проводить по схеме Горнера (17), (3.18).

Пример 4. Составить таблицу разделенных разностей и построить интерполяционный многочлен Ньютона по следующим данным:

x	0	2	3	5
$f(x)$	1	3	2	5

∇ Таблица строится по формулам (3.38), (3.39) и имеет вид:

X_i	$f(x_j)$	$f(x_j, x_{j+1})$	$f(x_j, x_{j+1}, x_{j+2})$	$f(x_j, x_{j+1}, x_{j+2}, x_{j+3})$
0	1			
		1		
2	3		-2/3	
		-1		3/10
3	2		5/6	
		3/2		
5	5			

Многочлен Ньютона для интерполирования вперед записываем, используя верхнюю наклонную строку построенной таблицы:

$$N_3^{(B)}(x) = 1 + 1 \cdot x + (-\frac{2}{3}) \cdot x \cdot (x-2) + \frac{3}{10} \cdot x \cdot (x-2) \cdot (x-3).$$

Для интерполирования в конце таблицы запишем многочлен с коэффициентами, расположенными в нижней наклонной строке таблицы:

$$N_3^{(H)}(x) = 5 + \frac{3}{2} \cdot (x-5) + \frac{5}{6} \cdot (x-5) \cdot (x-3) + \frac{3}{10} \cdot (x-5) \cdot (x-3) \cdot (x-2).$$

Если преобразовать оба многочлена в степенную форму, то получим одинаковый результат, что подтверждает единственность интерполяционного многочлена:

$$P_3(x) = 1 + \frac{62}{15} \cdot x - \frac{13}{6} \cdot x^2 + \frac{3}{10} \cdot x^3. \quad \nabla$$

Рассмотрим погрешность замены функции интерполяционным многочленом в форме Ньютона. Априорная оценка погрешности интерполирования известна (формула (3.25)). Однако на практике удобнее пользоваться *апостериорной оценкой*, т.е. оценкой, получаемой после вычислений, поскольку обычно величины производных функции $f(x)$ заранее неизвестны. Из формулы (3.43) и свойства (3.41) разделенных разностей следует, что правая часть неравенства (3.25) приближенно совпадает по модулю с новым слагаемым в выражении (3.43), появляющимся при добавлении $(n+1)$ -го узла:

$$R_n(x) = f(x) - P_n(x) \approx \omega(x) \cdot f(x_0, x_1, \dots, x_n, x_{n+1}).$$

Эта особенность делает интерполяционный многочлен в форме Ньютона одним из наиболее приемлемых алгоритмов интерполирования, особенно при достаточно большом количестве узлов. Можно постепенно подключать новые узлы до тех пор, пока абсолютная величина очередного слагаемого станет меньше заданной величины ε или же начнет возрастать. Описанный рекуррентный про-

цесс интерполяции не требует априорного задания степени полинома и дает возможность контролировать достигнутую точность, т.к. в ходе вычисления многочлена Ньютона фактически определяются приближенные значения производных функции $f(x)$.

Интерполирование с кратными узлами. Более общая постановка задачи интерполирования состоит в следующем. В узлах x_i , $i = \overline{0, n}$, среди которых нет совпадающих, заданы значения функции $f(x_i)$ и ее производных $f^{(k)}(x_i)$ до порядков $N_i - 1$ включительно. Число N_i называется кратностью узла x_i . Требуется построить алгебраический многочлен $H_n(x)$ степени $n = N_0 + N_1 + \dots + N_m - 1$, у которого в узлах совпадали бы не только значения функции и многочлена, но и значения их производных до порядков $N_i - 1$ включительно, т.е.

$$H_n^{(k)}(x_i) = f^{(k)}(x_i), \quad i = \overline{0, n}, \quad k = \overline{0, N_i - 1}. \quad (3.45)$$

Такую интерполяцию называют *кратной* или *эрмитовой*. Существует единственный многочлен, удовлетворяющий условиям (3.45). Этот многочлен называется *интерполяционным многочленом Эрмита* и может быть представлен аналогично многочлену Лагранжа в виде линейной комбинации значения функции и ее производных:

$$H_n(x) = \sum_{i=0}^m \sum_{k=0}^{N_i-1} p_{ki}(x) f^{(k)}(x_i), \quad (3.46)$$

где

$$p_{ki}(x) = \frac{\Omega(x)}{k!(x-x_i)^{N_i-k}} \left\{ \frac{(x-x_i)^{N_i}}{\Omega(x)} \right\}_{(x_i)}^{(N_i-k-1)},$$

$$\Omega(x) = (x-x_0)^{N_0} (x-x_1)^{N_1} \dots (x-x_m)^{N_m}.$$

Выражение в фигурных скобках $\{F(x)\}_{(x_i)}^{(N_i-k-1)}$ обозначает сумму первых $N_i - k$ членов разложения функции $F(x)$ в ряд Тейлора в окрестности точки x_i .

Оценка погрешности интерполирования имеет вид

$$|R_n(x)| = |f(x) - H_n(x)| = \frac{|f^{(n+1)}(\xi)|}{(n+1)!} |\Omega(x)| \leq \frac{M_{n+1}}{(n+1)!} |\Omega(x)|. \quad (3.47)$$

Сравнив эту оценку с оценкой погрешности интерполирования многочленом Ньютона той же степени (3.25), заметим, что на одной и той же сетке узлов погрешность интерполирования многочленом Ньютона будет больше, т.к. его

вспомогательный многочлен $\omega(x)$ содержит больше узлов, чем $\Omega(x)$ и поэтому в него входят большие сомножители. Очевидно, что чем более высокие производные используются при построении интерполяционного многочлена Эрмита заданной степени, тем меньше требуемое число узлов и тем меньшей будет величина погрешности.

Запись многочлена Эрмита (3.46) в явном виде настолько громоздкая, что пользоваться ею для вычислений практически невозможно. Интерполяционный многочлен Эрмита можно построить путем предельного перехода в многочленах Ньютона или Лагранжа.

Запишем многочлен Ньютона с $n+1$ узлами, повторяя каждый узел N_i раз:

$$H_n(x) = P_n \left(x, \underbrace{x_0, \dots, x_0}_{N_0}, \underbrace{x_1, \dots, x_1}_{N_1}, \dots, \underbrace{x_m, \dots, x_m}_{N_m} \right)$$

Если формально подставить в это выражение кратные узлы, то потребуются вычислять разделенные разности, содержащие неопределенность типа $0/0$. Ее можно раскрыть с помощью предельного перехода. Например, для узлов двойной кратности (узлы более чем двойной кратности почти не встречаются в практике вычислений):

$$\begin{aligned} f(x_0, x_0) &= \lim_{x_1 \rightarrow x_0} \frac{f(x_1) - f(x_0)}{x_1 - x_0} = f'(x_0), \\ f(x_0, x_0, x_1) &= \frac{1}{x_0 - x_1} [f'(x_0) - f(x_0, x_1)], \\ f(x_0, x_0, x_1, x_1) &= \frac{1}{(x_0 - x_1)^2} [f'(x_0) - 2f(x_0, x_1) + f'(x_0)]. \end{aligned}$$

При вычислении на практике значений интерполяционного многочлена Эрмита в таблицу разделенных разностей вместо разделенных разностей в кратных узлах записывают, согласно (3.41), значения

$$f(x_i, x_i, \dots, x_i) = \frac{f^{(k)}(x_i)}{k!}. \quad (3.48)$$

Остальные элементы таблицы рассчитываются как обычно – по формулам (3.39).

Пример 5. Вычислить $\ln(1.5)$ по заданным значениям в узлах $x_0=1$ и $x_1=2$:

$$f(1) = 0, f'(1) = 1, f(2) = 0.693147, f'(2) = 0.5$$

∇ Так как узлы $x_0=1$ и $x_1=2$ двойной кратности, то первый и последний элементы столбца разделенных разностей первого порядка заполним согласно (3.48), не вычисляя:

$$f(x_0, x_0) = f'(x_0) = 1, \quad f(x_1, x_1) = f'(x_1) = 0.5.$$

Таблица разделенных разностей имеет вид:

x_i	$f(x_j)$	$f(x_j, x_{j+1})$	$f(x_j, x_{j+1}, x_{j+2})$	$f(x_j, x_{j+1}, x_{j+2}, x_{j+3})$
1	0.0			
		1.0		
1	0.0		-0.306853	
		0.693147		0.113706
2	0.693147		-0.193147	
		0.5		
2	0.693147			

Разделенные разности второго и третьего порядков и $f(x_0, x_1)$ вычислены по формулам (3.38), (3.39):

$$f(x_0, x_1) = \frac{0.693147 - 0.0}{2 - 1} = 0.693147, \quad f(x_0, x_0, x_1) = \frac{0.693147 - 1.0}{2 - 1} = -0.306853,$$

$$f(x_0, x_1, x_1) = \frac{0.5 - 0.693147}{2 - 1} = -0.193147,$$

$$f(x_0, x_0, x_1, x_1) = \frac{-0.193147 - 0.306853}{2 - 1} = 0.113706.$$

Интерполяционный многочлен Эрмита третьей степени имеет вид

$$H_3(x) = 0. + (x - 1) + (-0.306853) \cdot (x - 1)^2 + 0.113706 \cdot (x - 1)^2 (x - 2).$$

Требуемое значение $\ln(1.5) \approx H_3(1.5) = 0.409074$. Согласно формуле (3.47) погрешность оценивается величиной

$$R_3(1.5) \leq \frac{1}{4!} \max_{x \in [1, 2]} |f^{(4)}(x)| (1.5 - 1)^2 (1.5 - 2)^2 = 0.015625.$$

Поскольку $\ln(1.5) = 0.405465$, то реальная погрешность вычисления равна 0.00361, т.е. в 5 раз меньше оценки. Это значит, что незнание точного значения ξ в выражениях (3.25) и (3.47) позволяет использовать априорные оценки интерполирования только для предварительной оценки порядка погрешности. ∇

Отметим, что наиболее известным частным случаем интерполяционного многочлена Эрмита является отрезок ряда Тейлора – многочлен, который в одном узле x_0 совпадает с функцией и всеми ее заданными производными.

Интерполирование по равностоящим узлам. Узлы x_j называются равностоящими, если они расположены на одинаковом расстоянии h , называемом *шагом*, друг от друга: $x_j = x_0 + jh$, $j = \overline{0, n}$. Хотя оптимальное распределение узлов, как установлено выше, является неравномерным, традиционно наиболее часто используются таблицы значений функций с постоянным шагом. Если требуется высокая точность вычисления значений функции, а отрезок интерполирования $[a, b]$ большой, то одним интерполяционным многочленом приемлемой степени даже с оптимальным распределением узлов обычно не удастся обеспечить требуемую точность на всем отрезке. В таких случаях часто пользуются достаточно подробными таблицами значений функции в узлах, расположенных равномерно. Когда задается значение аргумента x , то по нескольким ближайшим узлам строится полином, позволяющий вычислить $f(x)$ с требуемой или максимально возможной точностью. В случае равноотстоящих узлов имеется много различных формул интерполирования, которые отличаются очередностью выбора узлов и их расположением по отношению к точке x .

При интерполировании в начале или в конце таблицы принято записывать интерполяционный многочлен в виде формул Ньютона для интерполирования вперед или назад. Если точка интерполирования x лежит вблизи некоторого внутреннего узла x_m , то узлы интерполирования выбираются в порядке удаленности от x_m : $(x_m, x_m + h, x_m - h, \dots, x_m + kh, x_m - kh)$ при $x > x_m$ или $(x_m, x_m - h, x_m + h, \dots, x_m - kh, x_m + kh)$ при $x < x_m$. Такие интерполяционные формулы называются *формулами Гаусса* для интерполирования вперед и назад соответственно. Если точка интерполяции лежит вблизи середины отрезка $[x_m, x_{m+1}]$, применяют *формулу Бесселя*. Узлы при этом берутся попарно в следующем порядке: $(x_m, x_{m+1}), (x_{m-1}, x_{m+2}), \dots, (x_{m-k+1}, x_{m+k})$. При построении этих интерполяционных формул используются *конечные разности*, которые определяются аналогично разделенным.

Конечными разностями первого порядка называются величины

$$\Delta f_k = f(x_{k+1}) - f(x_k) = f_{k+1} - f_k, \quad k = \overline{0, n-1}.$$

Конечные разности второго порядка определяются через разности первого порядка по формуле

$$\begin{aligned} \Delta^2 f_k &= \Delta f_{k+1} - \Delta f_k = (f_{k+2} - f_{k+1}) - (f_{k+1} - f_k) = \\ &= f_{k+2} - 2f_{k+1} + f_k, \quad k = \overline{0, n-2}. \end{aligned}$$

Аналогично, *конечные разности m -го порядка* определяются через разности $m-1$ -го порядка по формуле

$$\Delta^m f_k = \Delta^{m-1} f_{k+1} - \Delta^{m-1} f_k = \sum_{j=0}^m (-1)^j C_m^j f_{k+m-j},$$

где $C_m^j = \frac{m!(m-j)!}{j!}$ -коэффициенты бинома Ньютона.

Между разделенной и конечной разностями k -го порядка имеется следующая связь:

$$f(x_i, x_{i+1}, \dots, x_{i+k}) = \frac{\Delta^k f_i}{k! h^k}. \quad (3.49)$$

При вычислении конечные разности записывают в виде таблицы, полностью аналогичной таблице разделенных разностей.

Введем безразмерную переменную $t = \frac{x - x_0}{h}$ и, используя свойство (3.49), перепишем формулу (3.43) для интерполирования в начале таблицы в следующем виде:

$$\begin{aligned} N_n^{(H)}(x) = N_n(x_0 + th) = f_0 + t \frac{\Delta f_0}{1!} + t(t-1) \frac{\Delta^2 f_0}{2!} + \dots + \\ + t(t-1)\dots(t-n+1) \frac{\Delta^n f_0}{n!}. \end{aligned} \quad (3.50)$$

Остаточный член формулы (3.50) также преобразуем:

$$r_n(x) = h^{n+1} t(t-1)\dots(t-n) \frac{f^{n+1}(\xi)}{(n+1)!}. \quad (3.51)$$

Аналогично, формула Ньютона (3.44) для интерполирования в конце таблицы принимает вид

$$\begin{aligned} N_n^{(K)}(x) = N_n(x_n + qh) = f_n + q \frac{\Delta f_{n-1}}{1!} + q(q+1) \frac{\Delta^2 f_{n-2}}{2!} + \dots \\ + q(q+1)\dots(q+n-1) \frac{\Delta^n f_0}{n!}, \end{aligned} \quad (3.52)$$

где $q = \frac{x - x_n}{h}$ и погрешность равна $r_n(x) = h^{n+1} q(q+1)\dots(q+n) \frac{f^{n+1}(\xi)}{(n+1)!}$.

Интерполяционные многочлены (3.50), (3.52) называются *многочленами Ньютона-Грегори* и используются для интерполирования соответственно в начале и конце таблицы.

При убывании h погрешность интерполирования будет убывать как h^{n+1} . Поэтому говорят, что интерполяционный многочлен имеет погрешность

$O(h^{n+1})$ и обеспечивает $n+1$ порядок точности интерполяции. Величина присутствующего в оценке (3.51) многочлена $\tilde{\omega}(t) = t(t-1)\dots(t-n)$ не зависит h , а только от n и от t , изменяющегося на отрезке $[0, n]$. Колебания функции вблизи середины отрезка $[0, n]$ меньше, чем у его концов. Поэтому узлы интерполирования $x_k, \dots, x_{k+n}$ целесообразно выбирать так, чтобы точка x оказалась возможно ближе к середине отрезка $[x_k, x_{k+n}]$.

При интерполировании в точке, расположенной вблизи x_m , применяются формулы Гаусса, причем первая - при $x > x_m$, а вторая - при $x < x_m$:

$$P_{2k}^{(B)}(x) = P(x_m + gh) = f_m + g \frac{\Delta f_m}{1!} + g(g-1) \frac{\Delta^2 f_{m-1}}{2!} + \\ + g(g^2-1) \frac{\Delta^3 f_{m-1}}{3!} + \dots + g(g^2-1)\dots(g^2-(k-1)^2)(g-k) \frac{\Delta^{2k} f_{m-k}}{(2k)!}, \quad (3.53)$$

$$P_{2k}^{(H)}(x) = f_m + g \frac{\Delta f_{m-1}}{1!} + g(g+1) \frac{\Delta^2 f_{m-1}}{2!} + g(g^2-1) \frac{\Delta^3 f_{m-2}}{3!} + \dots + \\ + g(g^2-1)\dots(g^2-(k-1)^2)(g+k) \frac{\Delta^{2k} f_{m-k}}{(2k)!}. \quad (3.54)$$

Здесь $g = \frac{x - x_n}{h}$.

Остаточный член формул может быть записан в виде

$$r_{2k}(x) = h^{2k+1} g(g^2-1)(g^2-2^2)\dots(g^2-k^2) \frac{f^{(2k+1)}(\xi)}{(2k+1)!}.$$

Среднее арифметическое формул Гаусса называется *формулой Стирлинга* и практически используется при $|g| \leq 0.25$.

При $0,25 \leq g \leq 0,75$ применяется интерполяционная *формула Бесселя*:

$$\begin{aligned}
P_{2k-1}(x) = P_{2k-1}(x_m + gh) = & \frac{f_m + f_{m+1}}{2} + (g - \frac{1}{2}) \frac{\Delta f_m}{1!} + \\
& + g(g-1) \frac{\Delta^2 f_{m-1} + \Delta^2 f_m}{2 \cdot 2!} + (g - \frac{1}{2})g(g-1) \frac{\Delta^3 f_{m-1}}{3!} + \\
& + (g+1)g(g-1)(g-2) \frac{\Delta^4 f_{m-2} - \Delta^4 f_{m-1}}{2 \cdot 4!} + \dots + \\
& + (g+k-2)\dots(g-k+1) \frac{\Delta^{2k-2} f_{m-k+1} - \Delta^{2k-2} f_{m-k+2}}{2 \cdot (2k-2)!}, \\
r_{2k-1}(x) = & h^{2k} (g+k-1)\dots(g-k) \frac{f^{(2k)}(\xi)}{2k!}.
\end{aligned} \tag{3.55}$$

Если точка интерполирования совпадает с серединой отрезка $[x_m, x_{m+1}]$, то формула (3.55) упрощается:

$$P_{2k-1}(x) = \frac{f_m + f_{m+1}}{2} - \frac{\Delta^2 f_{m-1} + \Delta^2 f_{m+2}}{16} + \frac{13}{16} (\Delta^4 f_{m-2} + \Delta^4 f_{m+1}) + \dots \tag{3.56}$$

Этот специальный случай формулы Бесселя называется *формулой интерполирования на середину*. Ее используют для уплотнения таблиц, т.е. для составления таблиц с более мелким шагом.

Пример 6. Пользуясь таблицей значений функции $sh(x)$ (первые два столбца таблицы), заданной на отрезке $[1, 1.8]$ с шагом $h = 0.1$, вычислить значения $sh(1.05), sh(1.77), sh(1.4171)$ и $sh(1.45224)$.

x_i	f_i	$\Delta f_i * 10^{-5}$	$\Delta^2 f_i * 10^{-5}$	$\Delta^3 f_i * 10^{-5}$	$\Delta^4 f_i * 10^{-5}$
1.0	1.17520	16045			
1.1	1.33565	17381	1336	175	
1.2	1.50946	18892	1511	189	14
1.3	1.69838	20592	1700	206	3
1.4	1.90430	22498	1906	225	2
1.5	2.12928	24629	2131	246	2
1.6	2.37557		2377	25	4

		27006	271
1.7	2.64563	2648	
		29654	
1.8	2.94217		

∇ Составляем таблицу конечных разностей, записывая их в единицах пятого разряда. Замечаем, что четвертые разности практически постоянны (отличаются друг от друга на 2-4 единицы пятого разряда, т.е. $\max \Delta^5 f_i \approx 4 \cdot 10^{-5}$). Для интерполирования будем пользоваться полиномом четвертой степени ($n=4$).

Первое требуемое значение $x=1.05$ расположено в начале таблицы. Используем первую формулу Ньютона-Грегори (3.50):

$$g = \frac{x - x_0}{h} = \frac{1.05 - 1}{0.1} = 0.5,$$

$$\begin{aligned} sh(1.05) &= 1.17520 + 0.5 \cdot 0.16045 + 0.5 \cdot (-0.5) \frac{0.01336}{2!} + 0.5 \cdot (-0.5)(-1.5) \frac{0.00175}{3!} + \\ &+ 0.5 \cdot (-0.5)(-1.5)(-2.5) \frac{0.00014}{4!} = 1.253855 \end{aligned}$$

При $x=1.77$ для интерполирования используется формула (3.52) поскольку точка расположена в конце таблицы.

$$g = \frac{x_n - x}{h} = \frac{1.8 - 1.77}{0.1} = 0.3,$$

$$\begin{aligned} sh(1.77) &= 2.94217 + 0.3 \cdot 0.29654 + 0.3 \cdot 1.3 \frac{0.02648}{2!} + 0.3 \cdot 1.3 \cdot 2.3 \frac{0.00271}{3!} + \\ &+ 0.3 \cdot 1.3 \cdot 2.3 \cdot 3.3 \frac{0.00025}{4!} = 3.0362956 \end{aligned}$$

Точка $x=1.4171$ ближе всего расположена к узлу $x_4=1.4$ и $x > x_4$ поэтому для интерполирования выбираем первую формулу Гаусса и узлы x_4, x_5, x_3, x_6, x_2 .

$$g = \frac{x_n - x}{h} = \frac{1.4171 - 1.4}{0.1} = 0.171,$$

$$\begin{aligned} sh(1.4171) &= 1.9043 + 0.171 \cdot 0.22498 + 0.171 \cdot (-0.829) \frac{0.01906}{2!} + 0.171 \cdot (-0.829) \times \\ &\times (-1.829) + 0.171 \cdot (-0.829) \cdot (-1.829) \cdot (-2.829) \frac{0.00019}{4!} = 2.05894 \end{aligned}$$

Для $x=1.45224$ величина $g = \frac{1.45224-1.4}{0.1} = 0.5224$. Т.к. g близко к 0.5, воспользуемся формулой Бесселя (3.55), взяв в качестве узлов $x_4, x_5, x_3, x_6, x_7, x_2$,

$$f(x) = \frac{f_4 + f_3}{2} + (g - 0.5)\Delta f_4 + \frac{g(g-1)}{2} \frac{\Delta^2 f_3 + \Delta^2 f_4}{2} + \\ + \frac{g(g-0.5)(g-1)}{3!} \Delta^3 f_3 + \frac{g(g^2-1)(g-2)}{4!} \frac{\Delta^4 f_2 + \Delta^4 f_3}{2}.$$

Находим значение функции

$$sh(1.45224) = \frac{1.90430 + 2.12928}{2} + 0.0224 \cdot 0.22498 + 0.12475 \frac{0.01906 + 0.02131}{2} - \\ - 0.00093 \cdot 0.00225 + 0.02335 \frac{0.00019 + 0.00021}{2} = 2.01931.$$

▽

Линейная и квадратичная интерполяции являются важными частными случаями интерполяции алгебраическими многочленами, широко используемыми при составлении таблиц функций и их использовании.

Интерполяция по двум узлам x_0, x_1 называется *линейной*, поскольку в этом случае интерполяционный многочлен $P_1(x) = a_0 + a_1x$ является линейной функцией и принимает согласно равенству (3.46), следующий вид

$$N_1(x) = f_0 + \frac{f_1 - f_0}{x_1 - x_0} (x - x_0) = N_1(x_0 + th) = f_0 + t \frac{\Delta f_0}{1!}.$$

Геометрически линейная интерполяция означает замену графика функции $f(x)$ на отрезке $[x_0, x_1]$ хордой, соединяющей точки $(x_0, f_0), (x_1, f_1)$.

При линейной интерполяции дважды непрерывно дифференцируемой функции $f(x)$ погрешность определяется соотношением

$$R_1(x) = h^2 f''(\xi) \frac{t(t-1)}{2}. \quad (3.57)$$

Поскольку максимум модуля функции $\tilde{\omega}(t) = t(t-1)$ достигается при $t=0.5$ и равен 0.25, то эта величина не превосходит $\frac{M_2}{8} h^2$, где $M_2 = \max_{x_0 \leq x \leq x_1} (f''(x))$.

Часто требование допустимости линейной интерполяции является слишком жестким и вместо него требуют допустимую *квадратичную интерполяцию*, т.е. интерполяцию многочленом второй степени. Геометрически квадратичная

интерполяция функции $f(x)$ с узлами x_0, x_1, x_2 означает замену ее графика параболой, проходящей через точки $(x_0, f_0), (x_1, f_1), (x_2, f_2)$.

Простейшим случаем квадратичной интерполяции будет интерполяция многочленом Ньютона-Грегори (3.50) при $n=2$ по узлам x_q, x_{q-1}, x_{q+1} , где x_q – ближайший к точке интерполирования узел таблицы:

$$N_2(x) = N_2(x_q + th) = f_q + t\Delta f_q + \frac{t(t-1)}{2} \Delta^2 f_q, \quad 0 \leq t \leq 0.5. \quad (3.58)$$

Остаточный член этой формулы равен

$$R_2(x) = h^3 f'''(\xi) \frac{t(t-1)(t+1)}{3!}.$$

Максимум модуля функции $\tilde{\omega}(t) = t(t^2 - 1)$ для $0 \leq t \leq 0.5$ достигается при $t = 0.5$ и величина погрешности интерполирования не превосходит $\frac{h^3 M_3}{16}$.

Другим способом замены функции многочленом второй степени является использование многочлена Бесселя (3.55) с узлами $x_{q-1}, x_q, x_{q+1}, x_{q+2}$:

$$P_2(x) = \frac{f_q + f_{q+1}}{2} + (t - \frac{1}{2}) \frac{\Delta f_q}{1!} + t(t-1) \frac{\Delta^2 f_{q-1} + \Delta^2 f_q}{2 \cdot 2!}, \quad (3.59)$$

где $0 \leq t \leq 1$. Оценка остаточного члена при $n = 2$ равна

$$R_2(x) \leq \frac{h^3 M_3}{72\sqrt{3}} + \frac{3h^4 M_4}{128}.$$

При малых h главной частью является первое слагаемое, а оно в $4.5\sqrt{3} \approx 7.79$ раз меньше, чем оценка погрешности многочлена Ньютона-Грегори (3.51). Следовательно, для того чтобы получить одинаковую точность при квадратичном интерполировании по формуле (3.58), нужны более подробные таблицы (с вдвое меньшим шагом h), чем для интерполирования многочленом Бесселя (3.59).

Пример 7. Каким должен быть шаг таблицы $\sin x$ на $[0, \pi/2]$, чтобы погрешность а) линейной интерполяции, б) квадратичной, в) интерполяции многочленом Бесселя не превосходила $0.5 \cdot 10^{-6}$?

∇ Поскольку производная любого порядка функции $\sin x$ ограничена единицей: $\max |(\sin x)^{(n)}| \leq 1$, то выполнение $R_n(x) \leq 0.5 \cdot 10^{-6}$ равносильно

а) при линейном интерполировании выполнению $\frac{h^2}{8} \leq 0.5 \cdot 10^{-6}$, откуда следует, что шаг $h \leq 0.002$;

б) при квадратичном - $\frac{h^3 M_3}{16} \leq 0.5 \cdot 10^{-6}$, откуда следует, что шаг $h \leq 0.02$, т.е. в десять раз больше, чем при линейной интерполяции;


в) при интерполяции многочленом Бесселя - $\frac{h^3 M_3}{72\sqrt{3}} + \frac{3h^4 M_4}{128} \leq 0.5 \cdot 10^{-6}$ и шаг $h \leq 0.038$. При составлении таблиц этот неудобный шаг заменили бы на 0.03. ∇

Сходимость процесса интерполирования алгебраическими многочленами. Рассмотрим условия, при которых погрешность интерполирования $R_n(x)$ стремится к нулю, т.е. многочлен $L_n(x)$ сходится к $f(x)$. Можно уменьшить погрешность, если сохранить степень интерполяционного многочлена и уменьшать расстояния между узлами, т.е. пользоваться более подробными таблицами. Тогда, если $f(x)$ имеет непрерывные производные до $(n+1)$ порядка, и производная, входящая в оценку (3.26), ограничена, то многочлен $L_n(x)$ равномерно сходится к $f(x)$ на отрезке $[a, b]$ при $\max_i |x_i - x_{i+1}| \rightarrow 0$.

Увеличение же степени интерполяционного многочлена далеко не всегда приводит к уменьшению погрешности. Сходимость интерполяционного процесса при $n \rightarrow \infty$ зависит как от выбора последовательности узлов $\{x_0^{(n)}, x_1^{(n)}, \dots, x_n^{(n)}\}$, так и от гладкости функции $f(x)$. У функции может быть конечное число производных, или же максимум M_n n -й производной может быстро расти с увеличением n . Известны примеры несложных функций, для которых интерполяционный процесс расходится. Так, последовательность интерполяционных многочленов, построенных для непрерывной функции $f(x) = |x|$ по равноотстоящим узлам на отрезке $[-1, 1]$ не сходится к функции ни в одной точке отрезка, кроме точек -1, 0, 1. На рис. 3 изображены графики функции $f(x) = |x|$ и двух интерполяционных многочленов, построенных по равноотстоящим узлам.

Для заданной непрерывной функции можно добиться сходимости за счет выбора расположения узлов интерполяции, но строить такие последовательности узлов чрезвычайно сложно и, кроме того, для различных функций они различны. На практике избегают пользоваться интерполяционными многочленами высокой степени. Если 3-5 узлов не обеспечивают требуемой точности, то рекомендуется уменьшить шаг таблицы, разбить весь отрезок $[a, b]$ на частичные

отрезки и на каждом приближенно заменить функцию многочленом невысокой степени (так называемая *кусочно-полиномиальная интерполяция*).



Такой способ интерполирования имеет следующий недостаток: на “стыках” частичных отрезков будет терпеть разрыв первая производная двух соседних интерполяционных многочленов. Возможно, что в точке “стыка” не совпадут и значения многочленов, если эта точка не является их общим узлом. От этого недостатка свободен один из способов кусочно-полиномиальной интерполяции — интерполяция сплайнами.

Интерполирование сплайнами. Свое название эти аппроксимирующие функции получили от английского слова *spline*, обозначающего специальную гибкую линейку, используемую чертежниками.

Полиномиальным сплайном называют функцию, которая непрерывна на отрезке $[a, b]$, имеет на этом отрезке несколько непрерывных производных и на каждом частичном отрезке является алгебраическим многочленом. Максимальная по всем частичным отрезкам степень многочлена называется *степенью сплайна*, а разность между степенью сплайна и порядком наивысшей непрерывной производной — *дефектом сплайна*.

На практике наиболее широкое распространение получили сплайны первой и третьей степени.

Пусть отрезок $[a, b]$, на котором определена непрерывная функция $f(x)$, разбит узлами $a = x_0 < x_1 < \dots < x_n = b$ на n частичных отрезков $[x_k, x_{k+1}]$, $k = \overline{0, n-1}$, где $h_k = x_{k+1} - x_k$ — длина каждого отрезка. Значения функции в узлах известны.

Интерполяционный сплайн первой степени $S_1(x)$ геометрически представляет собой ломаную, проходящую через точки (x_k, f_k) , и на каждом отрезке имеет вид

$$S_{1,k}(x) = f_k + \frac{x - x_k}{h_k} (f_{k+1} - f_k).$$

Дефект сплайна первой степени равен единице.

Интерполяционным кубическим сплайном, соответствующим данной функции $f(x)$ и данным узлам x_k , называют функцию $S_3(x)$, которая удовлетворяет следующим условиям:

а) на каждом отрезке $[x_k, x_{k+1}]$, $k = \overline{0, n-1}$ функция $S_3(x)$ является многочленом третьей степени вида

$$S_{3,k}(x) = a_k + b_k(x - x_k) + c_k(x - x_k)^2 + d_k(x - x_k)^3; \quad (3.60)$$

б) функция $S_3(x)$, а также ее первая и вторая производные непрерывны на отрезке $[a, b]$;

в) в узлах выполняются условия интерполирования

$$S_3(x_k) = f(x_k), \quad k = \overline{0, n}.$$

Задача построения кубического сплайна сводится к нахождению $4n$ неизвестных коэффициентов a_k, b_k, c_k, d_k . Для ее решения используют условия интерполирования в $n+1$ узле и условия непрерывности сплайна и его первой и второй производных во внутренних n узлах, что дает в общей сложности $4n - 2$ линейных уравнения. Два недостающих уравнения получают из условий закрепления концов сплайна, задавая *граничные условия* для $S_3(x)$, т.е. значения сплайна или его производных на концах отрезка. В частности, при свободном закреплении концов можно приравнять к нулю кривизну линии в этих точках, откуда следует равенство нулю вторых производных в этих точках:

$$S_3''(a) = S_3''(b) = 0. \quad (3.61)$$

Сплайн, удовлетворяющий им, называется *естественным кубическим сплайном* и является самой гладкой среди всех функций данного класса, интерполирующих заданную функцию $f(x)$. Он единственный из них обладает свойством минимальной кривизны.

Составим линейную алгебраическую систему для нахождения неизвестных коэффициентов a_k, b_k, c_k, d_k .

Из условий интерполирования в узлах получаем $2n$ уравнений:

$$\begin{aligned} S_{3,k}(x_k) &= f_k = a_k, \\ S_{3,k}(x_{k+1}) &= a_k + b_k h_k + c_k h_k^2 + d_k h_k^3 = f_{k+1}. \end{aligned} \quad (3.62)$$

Условия непрерывности первых и вторых производных в узлах интерполяции равносильны равенству в каждом внутреннем узле x_k значений производных, вычисленные слева и справа от узла:

$$\begin{aligned} S'_{3,k}(x_{k+1}) &= S'_{3,k+1}(x_{k+1}) \Rightarrow b_k + 2c_k h_k + 3d_k h_k^2 = b_{k+1} \\ S''_{3,k}(x_{k+1}) &= S''_{3,k+1}(x_{k+1}) \Rightarrow c_k + 3d_k h_k = c_{k+1}. \end{aligned} \quad (3.63)$$

Соотношения (3.61), (3.62) и (3.63) составляют систему $4n$ линейных алгебраических уравнений для определения $4n$ коэффициентов, но в каждом уравнении не более 4 ненулевых коэффициентов. Эту систему можно преобразовать к системе $n-1$ уравнения относительно c_k .

Из первых равенств системы находим все коэффициенты a_k : $a_k = f_k$. Теперь выразим сначала d_k , а затем b_k в (3.63) через c_k :

$$b_k = \frac{f_{k+1} - f_k}{h_k} - \frac{h_k}{3}(c_{k+1} + 2c_k), \quad d_k = \frac{c_{k+1} - c_k}{3h_k}. \quad (3.64)$$

Найденные значения подставим в (3.62) и получим следующую систему уравнений только относительно коэффициентов c_k :

$$h_{k-1}c_{k-1} + 2(h_{k-1} + h_k)c_k + h_k c_{k+1} = 3 \left[\frac{f_{k+1} - f_k}{h_{k+1}} - \frac{f_k - f_{k-1}}{h_k} \right], \quad (3.65)$$

$$k = 1, 2, \dots, n-1, \quad c_0 = c_n = 0.$$

Обозначим для краткости правую часть уравнений (3.65) через r_k . Матрица системы является симметричной трехдиагональной, т.е. имеет отличные от нуля элементы только на главной и двух примыкающих к ней диагоналях:

$$\begin{bmatrix} 2(h_1 + h_2) & h_2 & 0 & \dots & 0 & 0 & r_1 \\ h_2 & 2(h_2 + h_3) & h_3 & \dots & 0 & 0 & r_2 \\ 0 & h_3 & 2(h_3 + h_4) & \dots & 0 & 0 & r_3 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & h_{n-1} & 2(h_{n-1} + h_n) & r_{n-1} \end{bmatrix}.$$

Такие системы легко решаются *методом прогонки*, который представляет собой вариант метода Гаусса. Прямой ход сводится к исключению элементов нижней диагонали и вычислению прогоночных коэффициентов α_k, β_k по формулам

$$\alpha_1 = 2(h_0 + h_1), \quad \beta_1 = r_1,$$

$$\alpha_k = 2(h_{k-1} + h_k) - \frac{h_{k-1}^2}{\alpha_{k-1}}, \quad \beta_k = r_k - \frac{\beta_{k-1}h_{k-1}}{\alpha_{k-1}}, \quad k = 2, \dots, n-1. \quad (3.66)$$

Коэффициенты c_k получают посредством обратной подстановки:

$$c_{n-1} = \frac{\beta_{n-1}}{\alpha_{n-1}}, \quad c_k = \frac{\beta_k - h_k c_{k+1}}{\alpha_k}, \quad k = n-1, n-2, \dots, 1.$$

Система (3.65) имеет единственное решение, следовательно, коэффициенты сплайна $S_3(x)$ также однозначно определяются по формулам (3.64).

Кубические сплайн-функции обладают хорошими аппроксимирующими свойствами и достаточно хорошо приближают гладкие функции вместе с несколькими производными. Если интерполируемая функция $f(x)$ принадлежит к классу $C_{k+1}[a, b]$, $0 \leq k \leq 3$ (т.е. имеет непрерывную $k+1$ -ю производную на $[a, b]$), то для погрешности интерполирования функции справедлива следующая оценка:

$$\|f^{(m)}(x) - S_3^{(m)}(x)\|_c \leq C_m h^{k+1-m} \max_{[a,b]} |f^{(k+1)}(x)|, \quad m = 0, 1, \dots, k,$$

где C - неотрицательная константа, не зависящая от шага h сетки, на которой задана функция. Таким образом, погрешность для гладких функций имеет порядок $O(h^4)$. Даже для непрерывной функции, не имеющей непрерывной производной (например, $y = |x|$) погрешность имеет порядок $O(h)$. Поэтому интерполирование кубическими сплайнами является *сходящимся процессом*, т.е. при неограниченном возрастании числа узлов последовательность сплайнов сходится равномерно к интерполируемой функции $f(x)$, причем скорость сходимости повышается вместе с гладкостью функции. Таким свойством не обладает полиномиальная интерполяция, и в этом заключается преимущество интерполирования кубическими сплайнами.

3.4. Среднеквадратическое приближение функций

Постановка задачи. Мерой отклонения аппроксимирующей функции $\varphi(x)$ от заданной функции $f(x)$ при среднеквадратичном приближении является евклидова норма разности функций

$$\|f(x) - \varphi(x)\|_E = (f(x) - \varphi(x), f(x) - \varphi(x))^{1/2}, \quad (3.67)$$

где скалярное произведение определяется формулой (3.4) или (3.5).

Задача нахождения обобщенного многочлена наилучшего среднеквадратичного приближения состоит в определении коэффициентов $c_0^*, c_1^*, \dots, c_n^*$ многочлена (3.1), которые бы минимизировали среднеквадратичное отклонение:

$$\|f(x) - \varphi^*(x)\|_E = \min_{a_0, a_1, \dots, a_n} \left\| f(x) - \sum_{k=0}^n c_k \cdot \varphi(x) \right\|. \quad (3.68)$$

Согласно (3.62) имеем

$$\begin{aligned}\|f - \varphi\|^2 &= (f - \varphi, f - \varphi) = (f, f) - 2(f, \varphi) + (\varphi, \varphi) = \\ &= (f, f) - 2(f, \sum_{k=0}^n c_k \varphi_k) + (\sum_{i=0}^n c_i \varphi_i, \sum_{j=0}^n c_j \varphi_j) = \\ &= (f, f) - 2 \sum_{j=0}^n c_j (f, \varphi_j) + \sum_{i=0}^n \sum_{j=0}^n c_i c_j (\varphi_i, \varphi_j) = Q(c_1, c_2, \dots, c_n),\end{aligned}\tag{3.69}$$

где через $Q(c_0, c_1, \dots, c_n)$ обозначена квадратичная форма от искомых коэффициентов $c_0, c_1, \dots, c_n$. Приравняв частные производные квадратичной формы к нулю, получим линейную систему

$$\frac{\partial \mathcal{Q}}{\partial c_0} = -2(f, \varphi_0) + 2(c_0(\varphi_0, \varphi_0) + c_1(\varphi_0, \varphi_1) + \dots + c_n(\varphi_0, \varphi_n)) = 0,$$

$$\frac{\partial \mathcal{Q}}{\partial c_1} = -2(f, \varphi_1) + 2(c_0(\varphi_1, \varphi_0) + c_1(\varphi_1, \varphi_1) + \dots + c_n(\varphi_1, \varphi_n)) = 0,$$

$$\frac{\partial \mathcal{Q}}{\partial c_n} = -2(f, \varphi_n) + 2(c_0(\varphi_n, \varphi_0) + c_1(\varphi_n, \varphi_1) + \dots + c_n(\varphi_n, \varphi_n)) = 0$$

ИЛИ

$$\begin{aligned}
 (\varphi_0, \varphi_0) \cdot c_0 + (\varphi_0, \varphi_1) \cdot c_1 + \dots + (\varphi_0, \varphi_n)c_n &= (f, \varphi_0), \\
 (\varphi_1, \varphi_0) \cdot c_0 + (\varphi_1, \varphi_1) \cdot c_1 + \dots + (\varphi_1, \varphi_n)c_n &= (f, \varphi_1), \\
 .\quad.\quad.\quad.\quad.\quad.\quad.\quad.\quad.\quad.\quad.\quad.\quad.\quad.\quad.\quad.\quad.&\\
 (\varphi_n, \varphi_1) \cdot c_0 + (\varphi_n, \varphi_2) \cdot c_1 + \dots + (\varphi_n, \varphi_n)c_n &= (f, \varphi_n).
 \end{aligned}
 \tag{3.70}$$

Уравнения системы (3.70) называются *нормальными*, а ее определитель – *определителем Грама*. Если система функций $\{\varphi_k(x)\}$ линейно независима на $[a, b]$, то определитель Грама этой системы не равен нулю и *многочлен наилучшего среднеквадратичного приближения* существует и единственен.

При практическом приближении функций нужно проявлять осторожность при выборе системы $\{\varphi_k(x)\}$. Неудачный выбор может привести к катастрофической вычислительной погрешности при определении коэффициентов c_k . Причина – в плохой обусловленности матрицы системы (3.70). Поэтому в качестве систем $\{\varphi_k(x)\}$ целесообразно брать системы ортогональных функций или в каком-то смысле близкие к ним.

Если функции $\varphi_k(x)$ ортогональны на $[a, b]$, то $(\varphi_i(x), \varphi_j(x)) = 0$ для $i \neq j$ и матрица системы нормальных уравнений становится диагональной. Коэффициенты определяются непосредственно по формуле

$$c_i = \frac{(f(x), \varphi_i(x))}{(\varphi_i(x), \varphi_i(x))}, \quad i = \overline{0, n} \quad (3.71)$$

и называются *коэффициентами Фурье функции $f(x)$ по ортогональной системе $\varphi_k(x)$* . Из (3.70) с учетом (3.71) находим

$$\|f - \varphi\|^2 = (f, f) - \sum_{j=0}^n c_j^2 (\varphi_j, \varphi_j), \quad (3.72)$$

откуда следует, что при добавлении к системе $\varphi_k(x)$ новых функций (с ростом n) величина отклонения многочлена от исходной функции убывает (не возрастает). Коэффициенты Фурье обладают полезным свойством: каждый из них определяется независимо от остальных, и если требуется изменить число используемых функций, то не нужно искать заново уже найденные коэффициенты.

Среднеквадратичная аппроксимация алгебраическими многочленами. Выберем последовательность степеней аргумента x в качестве системы $\{\varphi_k(x)\}$:

$$\varphi_0(x) = x^0 = 1, \quad \varphi_1(x) = x^1 = x, \dots, \quad \varphi_n(x) = x^n.$$

Так как эта система линейно независима на отрезке $[a, b]$ при любом n , то существует единственный алгебраический многочлен наилучшего среднеквадратичного приближения

$$P_n^*(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n = \sum_{k=0}^n a_k x^k.$$

Система нормальных уравнений (3.65) для нахождения коэффициентов $a_0, a_1, \dots, a_n$ этого многочлена для непрерывной на отрезке $[a, b]$ функции имеет вид

$$\sum_{k=0}^n a_k \int_a^b x^{j+k} dx = \int_a^b f(x) x^j dx, \quad j = \overline{0, n}. \quad (3.73)$$

Пример 8. На отрезке $[0, 1]$ построить многочлен наилучшего среднеквадратичного приближения $P_2(x) = a + bx$ для функции $f(x) = \sqrt{x}$.

∇ Составим систему нормальных уравнений для нахождения a и b :

$$(1,1) = \int_0^1 1 \cdot 1 dx = 1, \quad (1,x) = \int_0^1 x dx = \frac{x^2}{2} \Big|_0^1 = \frac{1}{2}, \quad (x,x) = \int_0^1 x \cdot x dx = \frac{x^3}{3} \Big|_0^1 = \frac{1}{3}.$$

Далее,

$$(f, \varphi_1) = \int_0^1 \sqrt{x} \cdot 1 dx = \int_0^1 x^{\frac{1}{2}} dx = \frac{2}{3} x^{\frac{3}{2}} \Big|_0^1 = \frac{2}{3}, \quad (f, \varphi_2) = \int_0^1 \sqrt{x} \cdot x dx = \int_0^1 x^{\frac{3}{2}} dx = \frac{2}{5}.$$

Таким образом, нормальная система (3.73) имеет вид

$$\begin{bmatrix} 1 & 1/2 \\ 1/2 & 1/3 \end{bmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} 2/3 \\ 2/5 \end{pmatrix} \Rightarrow \begin{pmatrix} a \\ b \end{pmatrix} = \frac{1}{\Delta} \begin{bmatrix} 1/3 & -1/2 \\ -1/2 & 1 \end{bmatrix} \begin{pmatrix} 2/3 \\ 2/5 \end{pmatrix},$$

где $\Delta = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}$. Итак, $a = 12 \left(\frac{2}{9} - \frac{1}{5} \right) = \frac{12}{45} = \frac{4}{15}$, $b = 12 \left(-\frac{1}{3} + \frac{2}{5} \right) = \frac{12}{15} = \frac{4}{5}$.

Искомый многочлен $P_2(x) = \frac{4}{15} + \frac{4}{5}x$. Среднеквадратичное отклонение равно

$$\|f - P_2\| = \left(\int_0^1 \left(\sqrt{x} - \frac{4}{15} - \frac{4}{5}x \right)^2 dx \right)^{\frac{1}{2}} = \frac{\sqrt{2}}{30}. \quad \nabla$$

При вычислении интегралов в правых частях системы (3.73) могут возникнуть трудности, поэтому среднеквадратичную аппроксимацию алгебраическими многочленами чаще применяют в дискретном варианте. Такой способ построения многочлена называется *методом наименьших квадратов* (МНК).

Метод наименьших квадратов. Пусть значения функции $y_i = f(x_i)$ известны в узлах аппроксимации x_i , $i = \overline{0, m}$, $m \geq n$. Скалярное произведение двух функций определяется формулой (3.5) и при построении аппроксимирующего многочлена $P_n^*(x)$ требуется так подобрать его коэффициенты, чтобы минимизировать сумму квадратов отклонений значений функции от значений многочлена в узлах аппроксимации:

$$\begin{aligned} \Phi &= \Phi(a_0, a_1, \dots, a_n) = ((P_n(x_i) - y_i), (P_n(x_i) - y_i)) = \sum_{i=0}^m \varepsilon_i^2 = \\ &= \sum_{i=0}^m (P_n(x_i) - y_i)^2 = \sum_{i=0}^m \left(a_0 + a_1 x_i + \dots + a_{n-1} x_i^{n-1} + a_n x_i^n - y_i \right)^2, \end{aligned} \quad (3.74)$$

Система нормальных уравнений (3.70) для определения коэффициентов многочлена наилучшего среднеквадратичного приближения в дискретном варианте МНК примет вид:

[illegible]

Можно доказать, что если среди узлов $x_0, x_1, x_2, \dots, x_m$ нет совпадающих и $n \leq m$ то эта система имеет единственное решение. Если $m = n$, то в силу единственности интерполяционного многочлена получаем, что $P_n(x) = L_n(x)$, где $L_n(x)$ - интерполяционный многочлен Лагранжа.

Отметим, что коэффициентами системы (3.75) являются суммы степеней чисел x_i , а правыми частями - суммы произведений y_i и степеней x_i . Нетрудно заметить, что для формирования матрицы этой системы достаточно вычислить только элементы первой строки и последнего столбца $\sum_{i=0}^m x_i, \sum_{i=0}^m x_i^2, \dots, \sum_{i=0}^m x_i^{2n}$, остальные элементы не являются “оригинальными” и заполняются с помощью циклического сдвига элементов предыдущей строки.

Выбор степенных функций в качестве $\varphi_k(x)$ не является оптимальным с точки зрения решения нормальной системы, т.к. в этом случае матрица системы нормальных уравнений ((3.70) и (3.75)) часто плохо обусловлена. Для отрезка $[0,1]$, например, элементами матрицы (3.75) являются величины $g_{ij} = \frac{1}{i+j+1}$.

Такая матрица называется *матрицей Гильберта*, ее число обусловленности $cond\ G \approx e^{3.5n}$, т.е. система $\{x^k\}$ почти линейно зависима. Действительно, графики кривых x^k на отрезке $[0,1]$ очень похожи и совпадают в окрестности нуля. Это демонстрирует основную проблему, с которой сталкиваются при решении нормальных систем для определения коэффициентов многочлена наилучшего среднеквадратичного приближения в степенной форме. Приемлемые результаты в этом случае можно получить, если для аппроксимации достаточно полинома невысокой точности ($n \leq 4-5$), т.к. добавление новых функции x^k , вопреки

(3.72), будет ухудшать качество аппроксимации. Для того чтобы найти коэффициенты с высокой точностью рекомендуется для решения нормальной системы применять методы, использующие ортогональные преобразования, либо воспользоваться системами ортогональных многочленов в качестве $\{x^k\}$.

Среднеквадратичная аппроксимация ортогональными многочленами. Свойство ортогональности классических многочленов Чебышева, Лежандра, Лагерра и других заключается в том, что для каждого типа многочленов существует отрезок, на котором обращаются в нуль скалярные произведения полиномов разных порядков с весовой функцией $w(x)$:

$$(P_k(x), P_l(x)) = \int_{\alpha}^{\beta} P_k(x) P_l(x) w(x) dx = 0, \quad k \neq l. \quad (3.76)$$

Заданный интервал всегда можно привести с помощью линейных преобразований к отрезку, где определены и ортогональны многочлены, выбранные в качестве системы $\{\varphi_k(x)\}$. Если число узлов достаточно велико, то интегрирование в (3.76) можно приближенно заменить суммированием по узлам, что равносильно определению скалярных произведений по формуле (3.5). Таким образом недиагональные элементы матрицы системы нормальных уравнений (3.70) будут малы по абсолютной величине и система становится почти диагональной и хорошо обусловленной, что позволяет уменьшить погрешность ее решения.

Использование систем ортогональных многочленов дискретной переменной. Если воспользоваться представлением (3.13) алгебраического многочлена наилучшего среднеквадратичного приближения *по ортогональным многочленам дискретной переменной*

$$P_n(x) = c_0 \tilde{P}_0(x) + c_1 \tilde{P}_1(x) + c_2 \tilde{P}_2(x) + \dots + c_n \tilde{P}_n(x) = \sum_{k=0}^n c_k \tilde{P}_k(x), \quad (3.77)$$

то можно совсем отказаться от процедуры численного решения системы нормальных уравнений для нахождения его коэффициентов. Для этого нужно использовать многочлены, скалярные произведения (3.5) которых обращаются в нуль на заданном множестве узлов x_k . Тогда матрица Грама системы (3.70) будет диагональной и коэффициенты c_k являются коэффициентами Фурье и определяются непосредственно по формуле (3.71):

$$c_k = \frac{(f(x), \tilde{P}_k(x))}{(\tilde{P}_k(x), \tilde{P}_k(x))} = \frac{\sum_{i=0}^m f(x_i) \tilde{P}_k(x_i)}{\sum_{i=0}^m (\tilde{P}_k(x_i))^2}. \quad (3.78)$$

Известны классические ортогональные многочлены дискретной переменной. Например, система многочленов Чебышева $P_{n(m)}(x)$, $n = \overline{0, m}$ ортогональна на дискретном множестве целочисленных точек $x_i = i$, $i = \overline{0, m}$:

$$P_{n(m)}(x) = \sum_{j=0}^m (-1)^j \frac{C_m^j C_{m+j}^j}{n(n-1)\dots(n-j+1)} x(x-1)\dots(x-j+1),$$

где C_m^j - биномиальные коэффициенты.

При произвольном расположении узлов система ортогональных многочленов Чебышева может быть построена рекурсивно по следующему алгоритму:

[illegible]

где коэффициенты b_{k+1} и d_{k+1} находятся из условия ортогональности многочлена степени $k+1$ многочленам степеней k и $k-1$ и равны

$$b_{k+1} = \frac{\sum_{i=0}^m x_i (P_{k(m)}(x_i))^2}{\sum_{i=0}^m (P_{k(m)}(x_i))^2}, \quad d_{k+1} = \frac{\sum_{i=0}^m (P_{k(m)}(x_i))^2}{\sum_{i=0}^m (P_{k-1(m)}(x_i))^2}. \quad (3.80)$$

Коэффициенты c_k алгебраического многочлена наилучшего среднеквадратичного приближения можно вычислять по формуле (3.78) одновременно с вычислением b_{k+1} и d_{k+1} .

После определения коэффициентов c_k , b_{k+1} и d_{k+1} значение многочлена наилучшего среднеквадратичного приближения для произвольного аргумента в форме (3.78) можно эффективно вычислять без непосредственного вычисления значений ортогональных многочленов. Для этого применяется обобщенная схема Горнера (3.19):

$$\begin{aligned} S_n &= c_n, \\ \tilde{a}_{n-1} &= c_{n-1} + S_n(x^* - b_{n-1}), \\ S_k &= c_k + S_{k+1}(x^* - b_{k+1}) - S_{k+2}d_{k+1}, \quad k = n-2, n-3, \dots, 0, \\ P_n(x^*) &= S_0. \end{aligned}$$

3.5. Равномерное приближение алгебраическими многочленами

Мерой близости аппроксимирующего многочлена $P_n(x)$ к исходной функции при равномерном приближении является чебышевская норма

$$\|f(x) - P_n(x)\|_{C[a,b]} = \max_{x \in [a,b]} |f(x) - P_n(x)|,$$

равная максимальному отклонению этих функций друг от друга на отрезке $[a, b]$.

Как отмечалось ранее, из теоремы Вейерштрасса следует, что для любой непрерывной функции может быть построен аппроксимирующий многочлен с любой требуемой точностью ε , т.е. удовлетворяющий условию

$$\|f(x) - P_n(x)\|_{C[a,b]} \leq \varepsilon.$$

однако степень его неизвестна и зависит от ε .

П.Л.Чебышевым в 1859г. доказана следующая теорема:

Если $f(x)$ - непрерывная на замкнутом отрезке $[a, b]$ функция, то среди всех алгебраических многочленов n -й степени $P_n(x)$ существует единственный многочлен наилучшего равномерного приближения $P_n^(x)$, для которого*

$$\|f(x) - P_n^*(x)\|_{C[a,b]} = \min \|f(x) - P_n(x)\|_{C[a,b]}. \quad (3.81)$$

Чтобы многочлен $P_n(x)$ был многочленом наилучшего равномерного приближения, необходимо и достаточно существования на $[a, b]$ по крайней мере $n + 2$ точек $a \leq x_0 < x_1 < \dots < x_{n+1} \leq b$ таких, что

$$f(x_i) - P_n^*(x_i) = \sigma(-1)^i \|f(x) - P_n(x)\|_{C[a,b]}, \quad i = \overline{0, n+1}, \quad (3.82)$$

где $\sigma = \text{signum}[f(x_0) - P_n(x_0)]$. Если производная $f^{(n+1)}(x)$ не меняет знак на $[a, b]$, то $a = x_0, b = x_{n+1}$.

Точки $x_0, x_1, \dots, x_{n+1}$ называются точками чебышевского альтернанса.

Согласно этой теореме построение многочлена наилучшего равномерного приближения $P_n^*(x)$, степень n которого уже определена, сводится к решению следующей системы нелинейных уравнений:

$$\begin{aligned} f(x_i) - P_n^*(x_i) &= (-1)^i d, & i &= \overline{0, n+1} \\ \varphi(x_i) [f'(x_i) - P_n^{*'}(x_i)] &= 0, & i &= \overline{0, n+1} \end{aligned} \quad (3.83)$$

для нахождения $n + 1$ неизвестных коэффициентов многочлена $P_n^*(x)$, расстояния $d = \pm \|f(x) - P_n^*(x)\|_{C[a,b]}$ и точек $a \leq x_0 < x_1 < \dots < x_{n+1} \leq b$ чебышевского альтернанса. Функция $\varphi(x)$ введена для того, чтобы отличить экстремум отклонения во внутренних точках отрезка, где производная должна равняться нулю ($\varphi(x)=1$), от экстремума в граничных точках ($\varphi(a)=0, \varphi(b)=0$). Алгоритм Ремеза, например, решает эту систему методом Ньютона и в качестве начального приближения использует коэффициенты a_k и отклонение $\|f(x) - P_n(x)\|_{C[a,b]}$ некоторого многочлена $P_n(x)$ степени n , интерполирующего заданную функцию на $[a, b]$. Тем не менее построение многочлена наилучшего равномерного приближения при помощи этого алгоритма в общем случае вызывает большие затруднения.

На практике, как правило, ограничиваются **интерполяционными многочленами**, дающими, как будет показано ниже, почти наилучшее равномерное приближение заданной функции. В самом деле, из условия (3.82) теоремы следует, что погрешность аппроксимации должна менять знак $n + 1$ раз. Поэтому по теореме о среднем значении непрерывной функции должны существовать точки $x_k < \xi_k < x_{k+1}, k = \overline{0, n}, \xi_0 < \xi_1 < \dots < \xi_n$, в которых погрешность равна нулю. Это значит, что **многочлен наилучшего равномерного приближения $P_n^*(x)$ интерполирует функцию** в этих точках. Мы могли бы построить этот многочлен как интерполяционный, если бы знали узлы интерполирования ξ_k .

Прежде чем рассмотреть вопросы, связанные с выбором узлов для построения интерполяционного многочлена, дающего хорошее равномерное приближение заданной функции, рассмотрим способы оценки нижней границы $\text{dist}(f - P_n) \leq \|f(x) - P_n^*(x)\|_{C[a,b]}$ наименьшего равномерного отклонения для многочленов степени n . Знание этой оценки позволит определить наименьшую возможную степень многочлена $n = n(\varepsilon)$, аппроксимирующего функцию с требуемой точностью ε .

Пусть $a \leq x_0 < x_1 < \dots < x_{n+1} \leq b$ - некоторые точки на $[a, b]$. Напомним, что разделенная разность $(n + 1)$ -го порядка многочлена степени n равна нулю. Тогда, согласно свойству (3.40), разделенная разность $(n + 1)$ -го порядка функции может быть записана следующим образом:

$$f(x_0, x_1, \dots, x_{n+1}) = f(x_0, x_1, \dots, x_{n+1}) - P_n(x_0, x_1, \dots, x_{n+1}) = \sum_{i=0}^{n+1} \frac{(f(x_i) - P_n(x_i))}{w'(x_i)},$$

откуда следует

$$|f(x_0, x_1, \dots, x_{n+1})| \leq \|f(x) - P_n(x)\| \cdot W(x_0, x_1, \dots, x_{n+1}),$$

$$W(x_0, x_1, \dots, x_{n+1}) = \sum_{i=0}^{n+1} \frac{1}{w'(x_i)}.$$

Таким образом, для наименьшего равномерного отклонения справедлива оценка

$$\text{dist}(f - P_n) \geq \frac{|f(x_0, x_1, \dots, x_{n+1})|}{W(x_0, x_1, \dots, x_{n+1})}. \quad (3.84)$$

Вычисление нижней границы наименьшего равномерного отклонения можно упростить, если в качестве x_k использовать точки, соответствующие точкам, в которых достигается экстремальное значение многочлена Чебышева $T_{n+1}(x)$:

$$x_k = \frac{a+b}{2} + \frac{b-a}{2} \cos \frac{k\pi}{n+1}, \quad k = \overline{0, n+1}.$$

Тогда

$$\frac{1}{w'(x_k)} = \frac{(-1)^k 2^{2n}}{(n+1)(b-a)^n} \begin{cases} 1, & k=0, k=n+1 \\ 2, & k=\overline{1, n} \end{cases}, \quad W(x_0, x_1, \dots, x_n, x_{n+1}) = \left(\frac{2}{b-a} \right)^n$$

и оценка вычисляется по формуле

$$\text{dist}(f - P_n) \geq \frac{(b-a)^n}{2(n+1)} \left| f(a) + 2 \sum_{k=1}^n (-1)^k f(x_k) + (-1)^{n+1} f(b) \right|.$$

На практике для определения наименьшей возможной степени аппроксимирующего многочлена выбирают некоторое значение n , проверяют выполнение неравенства $\text{dist}(f - P_n) \leq \varepsilon$ и увеличивают n до тех пор, пока это неравенство не выполнится. Затем строят интерполяционный многочлен n -й степени, выбрав предварительно узлы интерполирования. Поскольку нахождение узлов ξ_k , в которых многочлен наилучшего равномерного приближения $P_n^*(x)$ интерполирует функцию еще более трудоемкая задача, чем определение коэффициентов этого многочлена из системы (3.83), то узлы для интерполяционного многочлена, близкого к наилучшему, выбирают, исходя из следующей теоремы:

Для равномерного отклонения любого многочлена степени $\leq n$, интерполирующего непрерывную на $[a, b]$ функцию в узлах $a \leq x_0 < x_1 < \dots < x_n \leq b$, справедлива следующая оценка:

$$\|f(x) - P_n^*(x)\|_{C[a,b]} \leq \|f(x) - P_n(x)\|_{C[a,b]} \leq (1 + \|\Lambda_n(x)\|) \|f(x) - P_n^*(x)\|_{C[a,b]},$$

где $\Lambda_n(x)$ - функция Лебега, которая равна сумме модулей коэффициентов Лагранжа (3.31):

$$\Lambda_n(x) = \sum_{k=0}^n |\ell_k(x)| = \sum_{k=0}^n \left| \prod_{j=0, j \neq k}^n \frac{(x - x_j)}{(x_k - x_j)} \right|.$$

Таким образом для построения интерполяционного многочлена, наиболее близкого к многочлену наилучшего равномерного приближения $P_n^*(x)$, нужно выбирать такие узлы интерполяции, которые минимизировали бы чебышевскую норму функции Лебега. Это требование почти выполняется, если в качестве узлов интерполирования на отрезке $[a, b]$ взять точки, соответствующие корням многочлена Чебышева (3.28), т.к. при их использовании достигается наименьшая ошибка интерполирования (3.29) для функции, имеющей на $[a, b]$ ограниченную $(n+1)$ -ю производную. Еще лучший результат (в пределах 2% минимальной $\|\Lambda_n(x)\|$ для любых n) дают *расширенные узлы Чебышева*:

$$x_k = \frac{a+b}{2} + \frac{b-a}{2} \left[\cos \frac{(2k+1)\pi}{2(n+1)} \bigg/ \cos \frac{\pi}{2(n+1)} \right], \quad k = \overline{0, n}. \quad (3.85)$$

Например, при интерполировании многочленом степени $n \leq 47$ по расширенным узлам Чебышева норма $\|\Lambda_n(x)\| \leq 3$, т.е. погрешность аппроксимации функции не более чем в 4 раза превышает наилучшую возможную $\|f(x) - P_n^*(x)\|_{C[a,b]}$ для многочленов степени n . (При использовании узлов Чебышева это справедливо только для $n \leq 26$, а при равномерном расположении узлов – $n \leq 3$, т.к. норма растет очень быстро с ростом n : $\|\Lambda_n^{(равн)}(x)\| \geq e^{0.5n}$.)

ГЛАВА 4. ЧИСЛЕННОЕ ДИФФЕРЕНЦИРОВАНИЕ

В общем случае вопросы численного дифференцирования имеют два аспекта. *Во-первых*, данную операцию приходится выполнять в тех случаях, когда информация об исследуемой функции задана в табличной форме или в виде набора результатов экспериментальных исследований. К численному дифференцированию прибегают также и в случае, когда задан явный аналитический вид функции, но выражение для производной оказывается достаточно сложным и желательно его заменить более простым. *Во-вторых*, своеобразное численное дифференцирование осуществляется при построении дискретного аналога обыкновенных дифференциальных уравнений или уравнений в частных производных, которые не могут быть решены аналитически вследствие нелинейности или сложной геометрии исследуемой области. Эти аспекты имеют в своей основе много общего, однако и различие между ними весьма существенно. В данной главе рассмотрим приближенное вычисление производных таблично заданной функции.

Таким образом, *задача численного дифференцирования* состоит в приближенном вычислении значения производной функции $y = f(x)$ в некоторой точке x^* по заданным в конечном числе точек (узлах сетки) значениям этой функции $y_i = f(x_i)$.

4.1. Применение интерполяционных многочленов для численного дифференцирования

При численном дифференцировании функцию $y = f(x)$ аппроксимируют легко вычисляемой функцией $\varphi(x)$ и приближённо полагают $y^{(m)} \approx \varphi^{(m)}(x)$. При этом можно использовать различные подходы. В качестве аппроксимирующей функции обычно выбирают интерполяционный многочлен. Если узлы интерполирования расположены неравномерно, то таким многочленом могут быть полиномы Лагранжа или Лежандра, а если равномерно, то лучше использовать полином Ньютона, так как он дает меньшую вычислительную погрешность по сравнению с другими. Сейчас мы рассмотрим простейший случай – аппроксимацию интерполяционным многочленом Ньютона, т.е.

$$f^{(m)}(x) \approx N_n^{(m)}(x), 0 \leq m \leq n.$$

Вывод формул упрощается, если ввести вспомогательную переменную $\xi_i = x - x_i$. Запишем этот многочлен и продифференцируем его почленно:

$$\begin{aligned}
N_n(x) &= y(x_0) + \xi_0 y(x_0, x_1) + \xi_0 \xi_1 y(x_0, x_1, x_2) + \xi_0 \xi_1 \xi_2 y(x_0, x_1, x_2, x_3) + \dots, \\
N_n^{(1)}(x) &= y(x_0, x_1) + (\xi_0 + \xi_1) y(x_0, x_1, x_2) + (\xi_0 \xi_1 + \xi_0 \xi_2 + \xi_1 \xi_2) y(x_0, x_1, x_2, x_3) + \dots, \\
N_n^{(2)}(x) &= 2y(x_0, x_1, x_2) + 2(\xi_0 + \xi_1 + \xi_2) y(x_0, x_1, x_2, x_3) + \dots
\end{aligned}$$

Общая формула имеет, таким образом, вид:

$$\begin{aligned}
N_n^{(k)}(x) &= k! \left[y(x_0, x_1, \dots, x_k) + \left(\sum_{i=0}^k \xi_i \right) y(x_0, x_1, \dots, x_{k+1}) + \right. \\
&\quad \left. + \left(\sum_{i>j \geq 0}^{i=k+1} \xi_i \xi_j \right) y(x_0, x_1, \dots, x_{k+2}) + \left(\sum_{i>j>l \geq 0}^{i=k+2} \xi_i \xi_j \xi_l \right) y(x_0, x_1, \dots, x_{k+3}) + \dots \right]. \quad (4.1)
\end{aligned}$$

Обрывая ряд на некотором числе слагаемых, получим приближённое выражение для соответствующей производной. Наиболее простые выражения соответствуют случаю, когда в формуле (4.1) оставляется только первое слагаемое:

$$\begin{aligned}
y'(x) &\approx y(x_0, x_1) = \frac{y(x_0) - y(x_1)}{x_0 - x_1}, \\
\frac{1}{2} y''(x) &\approx y(x_0, x_1, x_2) = \frac{1}{x_0 - x_2} \left(\frac{y_0 - y_1}{x_0 - x_1} - \frac{y_1 - y_2}{x_1 - x_2} \right), \\
\frac{1}{k!} y^{(k)}(x) &\approx y(x_0, x_1, \dots, x_k) = \sum_{p=0}^k y_p \prod_{\substack{i=0 \\ i \neq p}}^k (x_p - x_i)^{-1}. \quad (4.2)
\end{aligned}$$

Заметим, что формулы (4.1) и (4.2) справедливы для произвольной неравномерной сетки.

Исследование точности полученных выражений при численных расчётах удобно делать при помощи *апостериорной* оценки, т.е. по скорости убывания слагаемых ряда (4.1). Если шаг сетки табличных значений достаточно мал, то погрешность близка к первому отброшенному слагаемому ряда. Пусть мы используем узлы $x_i, i = 0, 1, \dots, n$. Тогда первое отброшенное слагаемое содержит разделённую разность $y(x_0, x_1, \dots, x_{n+1})$, которая согласно (4.2) примерно равна $y^{(n+1)}/(n+1)!$. Перед ней стоит сумма произведений различных множителей ξ_i ; каждое произведение содержит $n+1-k$ множителей, а вся сумма состоит из C_{n+1}^k слагаемых. Отсюда следует оценка погрешности формулы (4.1) с $n+1$ узлами:

$$R_n^{(k)} \leq \frac{M_{n+1}}{(n+1-k)!} \underbrace{\max_i |\xi_i|}_{i}^{n+1-k}, \quad M_{n+1} = \max |y^{(n+1)}|, \quad (4.3)$$

В частности, если сетка равномерная, то $\max|\xi_i| < nh$, откуда

$$R_n^{(k)} < M_{n+1} \left(\frac{en}{n+1-k} h \right)^{n+1-k} = O(h^{n+1-k}). \quad (4.4)$$

Эти оценки можно несколько улучшить за счёт более детального рассмотрения множителей ξ_i . Заметим, что строгое априорное исследование погрешности формулы (4.1) для произвольного расположения узлов приводит к той же оценке (4.3).

Таким образом, порядок точности формулы (4.1) по отношению к шагу сетки равен числу оставленных в ней слагаемых, или, что то же самое, он равен числу узлов интерполяции минус порядок производной. Поэтому минимальное число узлов, необходимое для вычисления k -той производной, равно $k+1$; оно приводит к формулам (4.2) и обеспечивает первый порядок точности. Эти выводы соответствуют общему принципу: при почленном дифференцировании ряда скорость его сходимости уменьшается.

Если учесть ухудшение сходимости ряда при дифференцировании, то можно сделать вывод: даже если функция задана хорошо составленной таблицей на довольно подробной сетке, то практически численным дифференцированием можно хорошо определить первую и вторую производные, а третью и четвёртую – лишь удовлетворительно. Более высокие производные редко удаётся вычислить с приемлемой точностью.

4.2. Вывод простейших формул численного дифференцирования

Предположим, что функция $f(x)$ определена и непрерывна на $[a, b]$ и обладает необходимой гладкостью (т.е. производные требуемого порядка у этой функции существуют). Рассмотрим равномерную сетку на отрезке $[a, b]$

$$x_i = a + ih, \quad i = \overline{0, n}, \quad (4.5)$$

где $h = \frac{b-a}{n}$ - шаг сетки.

Запишем интерполяционный многочлен Ньютона в начале таблицы, используя конечные разности $\Delta^k y_0$:

$$N_n(x) = y_0 + \frac{\Delta y_0}{h} \cdot (x - x_0) + \frac{\Delta^2 y_0}{2!h^2} (x - x_0)(x - x_1) + \dots + \frac{\Delta^n y_0}{n!h^n} (x - x_0)(x - x_1) \dots (x - x_{n-1})$$

Вывод формул упрощается, если ввести вспомогательную переменную

$$q = \frac{x - x_0}{h}:$$

$$N_n(x_0 + qh) = y_0 + q\Delta y_0 + \frac{q(q-1)}{2!}\Delta^2 y_0 + \dots + \frac{q(q-1)\dots(q-n+1)}{n!}\Delta^n y_0 \quad (4.6)$$

Продифференцируем выражение (4.6) и получим конечноразностную формулу численного дифференцирования:

$$f'(x) \approx q'_x \left[N_n(x_0 + qh) \right]'_q = \frac{1}{h} \left(y_0 + q\Delta y_0 + \frac{q^2 - q}{2}\Delta^2 y_0 + \frac{q^3 - 3q^2 + 2q}{6}\Delta^3 y_0 + \right. \\ \left. + \frac{q^4 - 6q^3 + 11q^2 - 6q}{24}\Delta^4 y_0 + \dots \right)'_q$$

т.е.

$$f'(x) \approx \frac{1}{h} \left(\Delta y_0 + \frac{2q-1}{2}\Delta^2 y_0 + \frac{3q^2-6q+2}{6}\Delta^3 y_0 + \frac{4q^3-18q^2+22q-6}{24}\Delta^4 y_0 + \dots \right) \quad (4.7)$$

Дальнейшее дифференцирование приводит к приближенным формулам для вычисления второй и третьей производных:

$$f''(x) \approx \frac{1}{h^2} \left(\Delta^2 y_0 + \Delta^3 y_0 \cdot (q-1) + \frac{\Delta^4 y_0 \cdot (6q^2 - 18q + 11)}{12} + \dots \right), \\ f'''(x) \approx \frac{1}{h^3} \left(\Delta^3 y_0 + \left(q - \frac{3}{2}\right) \Delta^4 y_0 + \dots \right). \quad (4.8)$$

Здесь учитывалось, что

$$\frac{df'(x)}{dx} = \frac{df'(x)}{dq} \cdot \frac{dq}{dx} = \frac{1}{h} \cdot \frac{df'(x)}{dq}$$

Аналогично можно определить и следующие производные функции $f(x)$. Но при вычислении производных более высоких порядков следует учитывать большее количество членов ряда Ньютона для обеспечения точности результата. При использовании формул (4.7)-(4.8) для приближенного вычисления производных в заданной точке x^* , принадлежащей некоторой окрестности точки x_0 , следует найти соответствующее значение $\tilde{q}$ пере-

менной $q = \frac{x^* - x_0}{h}$ и подставить его в формулы.

Если производные функции $f(x)$ надо определить в узлах интерполяции, т.е. $x = x_i$, то тогда формулы (4.7)-(4.8) для первой и второй производных заметно упрощаются, так как в этом случае $q \equiv 0$.

Простейшие формулы численного дифференцирования. Рассмотрим несколько частных случаев интерполяционных многочленов степени $n=1,2,3$.

На основе линейной интерполяции получим формулу

$$f'(x) \approx \frac{\Delta y_0}{h} \quad \text{для } x \in (x_0 - \delta, x_1 + \delta), \quad (4.9)$$

на основе квадратичной интерполяции -

$$f'(x) \approx \frac{1}{h} \left(\Delta y_0 + \frac{2q-1}{2} \Delta^2 y_0 \right) \quad \text{для } (x_0 - \delta, x_2 + \delta) \quad (4.10)$$

на основе кубической интерполяции:

$$f'(x) \approx \frac{1}{h} \left(\Delta y_0 + \frac{2q-1}{2} \Delta^2 y_0 + \frac{3q^2-6q+2}{6} \Delta^3 y_0 \right), \quad \text{для } (x_0 - \delta, x_3 + \delta) \quad (4.11)$$

и т.д. В дальнейшем особый интерес представляют частные случаи формул (4.9) – (4.11), связывающие приближенные значения производной функции $f'(x)$ в узлах x_0, x_1, x_2, x_3 с узловыми значениями самой функции.

При $n=1$ из (4.9) получаем

$$f'(x_0) \approx y'_0 = \frac{y_1 - y_0}{h} \quad (4.12)$$

и

$$f'(x_1) \approx y'_1 = \frac{y_1 - y_0}{h}. \quad (4.13)$$

Соотношение (4.12) называется правой разностной производной функции $f(x)$ в точке x_0 , а соотношение (4.13) - левой разностной производной функции $f(x)$ в точке x_1 .

При $n=2$ из (4.11) получаем три формулы:

$$\begin{aligned} f'(x_0) \approx y'_0 &= \frac{1}{h} (y_1 - y_0 + \frac{(x_0 - x_0) - 1}{2} (y_2 - 2y_1 + y_0)) = \frac{1}{h} \left(y_1 - y_0 - \frac{1}{2} (y_2 - 2y_1 + y_0) \right) = \\ &= \frac{1}{2h} (2y_1 - 2y_0 - y_2 + 2y_1 - y_0) = \frac{1}{2h} (-3y_0 + 4y_1 - y_2), \quad (4.14) \\ f'(x_1) \approx y'_1 &= \frac{1}{h} \left(y_1 - y_0 + \frac{2 \frac{x_1 - x_0}{h} - 1}{2} (y_2 - 2y_1 + y_0) \right) = \end{aligned}$$

$$= \frac{1}{h} \left(y_1 - y_0 + \frac{1}{2} (y_2 - 2y_1 + y_0) \right) = \frac{1}{2h} (2y_1 - 2y_0 + y_2 - 2y_1 + y_0) = \frac{1}{2h} (-y_0 + y_2) \quad (4.15)$$

$$\begin{aligned} f'(x_2) \approx y'_2 &= \frac{1}{h} \left(y_1 - y_0 + \frac{2(x_2 - x_0) - 1}{2} (y_2 - 2y_1 + y_0) \right) = \\ &= \frac{1}{2h} (2y_1 - 2y_0 + 3y_2 - 6y_1 + 3y_0) = \frac{1}{2h} (y_0 + 4y_1 + 3y_2). \end{aligned} \quad (4.16)$$

Соотношение (4.15) называется центральной разностной производной функции $f(x)$ в точке x_1 , т.к. для вычисления использует значения функции в узлах слева и справа - y_0 и y_2 .

При $n=3$ из (4.11) получаем четыре формулы для вычисления первой производной

$$\begin{aligned} f'(x_0) \approx y'_0 &= \\ &= \frac{1}{h} \left(y_1 - y_0 + \frac{\frac{2(x_0 - x_0) - 1}{h}}{2} (y_2 - 2y_1 + y_0) + \frac{3\left(\frac{x_0 - x_0}{h}\right)^2 - 6\left(\frac{x_0 - x_0}{h}\right) + 2}{6} (y_3 - 3y_2 + 3y_1 - y_0) \right) = \\ &= \frac{1}{h} \left(y_1 - y_0 - \frac{1}{2} (y_2 - 2y_1 + y_0) + \frac{1}{3} (y_3 - 3y_2 + 3y_1 - y_0) \right) = \\ &= \frac{1}{6h} (6y_1 - 6y_0 - 3y_2 - 6y_1 - 3y_0 + 2y_3 - 6y_2 + 6y_1 - 2y_0) = \\ &= \frac{1}{6h} (-11y_0 + 18y_1 - 9y_2 + 2y_3) \end{aligned} \quad (4.17)$$

$$f'(x_1) \approx y'_1 = \frac{1}{6h} (-2y_0 - 3y_1 + 6y_2 - y_3)$$

$$f'(x_2) \approx y'_2 = \frac{1}{6h} (y_0 - 6y_1 + 3y_2 + 2y_3)$$

$$f'(x_3) \approx y'_3 = \frac{1}{6h} (2y_0 - 9y_1 + 18y_2 - 11y_3).$$

Наиболее часто используется в приближениях простейшая аппроксимация второй производной с помощью конечной разности второго порядка $\frac{\Delta^2 y_0}{h^2}$ на промежутке $(x_0 - \delta, x_2 + \delta)$, получающаяся из (4.8) при $n=2$.

В частности, в точке x_1 имеем приближенное равенство

$$f''(x_1) \approx y''_1 = \frac{y_0 - 2y_1 + y_2}{h^2}. \quad (4.18)$$

Эта формула вместе с формулами (4.12) - (4.17) широко используются при построении конечноразностных методов решения краевых задач для обыкновенных дифференциальных уравнений второго порядка.


Погрешность простейших формул численного дифференцирования.

При замене дифференциального выражения разностным возникает погрешность, выражение для которой нетрудно получить, используя формулу Тейлора:

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{1}{2} f''(x_0)(x - x_0)^2 + \frac{1}{3!} f'''(x_0)(x - x_0)^3 + \dots r_n(x)$$

Будем предполагать, что $f(x)$ обладает достаточной гладкостью для выведения оценок погрешности простейших формул численного дифференцирования.

Кроме того, будем использовать формулу Тейлора в i -ом узле сетки x_i , т.е. считать, что исходная информация о функции соответствует рисунку и речь идет об аппроксимации производных в i -ом узле сетки (или в отстоящих от него на расстоянии h узлах x_{i-1} и x_{i+1}).



Простейшая несимметричная (левая или правая) разностная производная.

Запишем представление функции $f(x)$ по формулам Тейлора в окрестности точки x_i :

$$f(x) = f(x_i) + \frac{f'(x_i)}{1!} (x - x_i) + \frac{f''(\xi)}{2!} (x - x_i)^2$$

Выразив отсюда $f'(x_i)$, имеем:

$$f'(x_i) = \frac{f(x) - f(x_i)}{(x - x_i)} - \frac{f''(\xi)}{2}(x - x_i) \quad (4.19)$$

Первый член правой части – разностное отношение, аппроксимирующее производную вблизи x_i , а второй – остаточный член, характеризующий точность такой аппроксимации.

Если зафиксировать в (4.19) $x = x_{i-1}$, то приходим к формуле левой разностной производной с остаточным членом:

$$f'(x_i) = \frac{y_i - y_{i-1}}{h} + \frac{f''(\xi_{i-1})}{2}h, \quad (4.20)$$

где одновременно зафиксировается и неизвестная точка $\xi = \xi_{i-1} \in (x_{i-1}, x_i)$.

Аналогично при $x = x_{i+1}$ из (4.19) получаем формулу правой разностной производной с остаточным членом:

$$f'(x_i) = \frac{y_{i+1} - y_i}{h} - \frac{f''(\xi_{i+1})}{2}h \quad (4.21)$$

В приближенном равенстве $f'(x_i) \approx \frac{y_{i+1} - y_i}{h}$ при $i=0$ узнаём выведенное ранее соотношение (4.12). Остаточные члены в (4.20) и (4.21) указывают на то, что, пользуясь аппроксимацией производной первого разностными производными

$$f'(x_i) \approx \frac{y_i - y_{i-1}}{h} \quad \text{и} \quad f'(x_i) \approx \frac{y_{i+1} - y_i}{h},$$

мы совершаем ошибку $O(h)$, т.е. эти формулы численного дифференцирования имеют первый порядок точности.

Простейшая симметричная разностная производная. Запишем представление функции $f(x)$ по формулам Тейлора в окрестности точки x_i :

$$f(x) = f(x_i) + f'(x_i)(x - x_i) + \frac{1}{2}f''(x_i)(x - x_i)^2 + \frac{1}{6}f'''(\xi)(x - x_i)^3$$

Из этого разложения при $x = x_{i-1}$ и $x = x_{i+1}$ получаем соответственно:

$$f(x_{i+1}) = f(x_i) + f'(x_i)h + \frac{1}{2}f''(x_i)h^2 + \frac{1}{6}f'''(\xi_{i+1})h^3$$

и

$$f(x_{i-1}) = f(x_i) - f'(x_i)h + \frac{1}{2}f''(x_i)h^2 - \frac{1}{6}f'''(\xi_{i-1})h^3.$$

Выполнив почленное вычитание этих равенств, получаем

$$y_{i+1} - y_i = 2hf'(x_i) + \frac{h^3}{6}[(f'''(\xi_{i+1}) + f'''(\xi_{i-1}))],$$

откуда с помощью теоремы о среднем, примененной к сумме третьих производных в квадратных скобках, приходим к формуле симметричной аппроксимации $f'(x_i)$ с остаточным членом:

$$\boxed{f'(x_i) = \frac{y_{i+1} - y_i}{2h} - \frac{h^2}{6}f'''(\xi_i)}, \quad (4.22)$$

где ξ_i - некоторая точка из интервала (x_{i-1}, x_{i+1}) .

Эта формула означает, что аппроксимация первой производной функции симметричной разностной производной

$$f'(x_i) \approx \frac{y_{i+1} - y_i}{2h}$$

имеет второй порядок точности относительно шага h - $O(h^2)$.

4.3. Некорректность операции численного дифференцирования

В формулах численного дифференцирования с постоянным шагом значения функции y_i делятся на h^m , где m – порядок вычисляемой производной. Поэтому при малом h неустранимые погрешности в значениях функции оказывают сильное влияние на результат численного дифференцирования. Поэтому операцию вычисления разностных отношений называют некорректной. Оказывается, что погрешность, возникающая при вычислении разностных отношений, намного превышает погрешность в задании значений функции и даже может неограниченно возрастать при стремлении шага h сетки к нулю.

Пусть значения $y_i = f(x_i)$ заданы с погрешностью, т.е. вместо точного значения $y_i = f(x_i)$ имеем $\tilde{y}_i = y_i + \delta_i$ и граница абсолютной погрешности и функции в каждой точке удовлетворяет неравенству $\delta_i \leq \bar{\Delta}$. Если в некоторой окрестности точки x_0 производные, через которые выражаются остаточные члены в формулах (4.20), (4.22), непрерывны и удовлетворяют неравенствам

$$|f'''(x)| \leq \overline{M}_3, \quad |f^{(4)}(x)| \leq \overline{M}_4, \quad (4.23)$$

где $\overline{M}_3$, $\overline{M}_4$ - некоторые числа. Тогда полная погрешность формул (4.20) - (4.22) (без учета погрешностей округления) не превосходит соответственно величин

$$\begin{aligned} \varepsilon_1 &= \frac{\overline{\Delta} + \overline{\Delta}}{2h} + \frac{h^2}{6} \overline{M}_3, \\ \varepsilon_2 &= \frac{\overline{\Delta} + 2\overline{\Delta} + \overline{\Delta}}{h^2} + \frac{h^2}{12} \overline{M}_4 \end{aligned}$$

Минимизация по h этих величин приводит к следующим значениям h :

$$h_1 = \left(\frac{3\Delta}{\overline{M}_3} \right)^{1/3}, \quad h_2 = 2 \left(\frac{3\Delta}{\overline{M}_4} \right)^{1/4}, \quad (4.24)$$

при этом

$$\varepsilon_1 = \frac{3}{2} \left(\frac{\overline{M}_3 \Delta^{-2}}{3} \right)^{1/3}, \quad \varepsilon_2 = 2 \left(\frac{\overline{M}_4 \Delta}{3} \right)^{1/2}. \quad (4.25)$$

Если при выбранном для какой-либо из формул (4.20) - (4.22) значении h отрезок $[x_{-1}, x_1]$ не выходит за пределы окрестности точки x_0 , в которой выполняется соответствующее неравенство (4.23), то найденное h является оптимальным и полная погрешность численного дифференцирования оценивается соответствующей величиной (4.25).

ГЛАВА 5. ЧИСЛЕННОЕ ИНТЕГРИРОВАНИЕ

Численное интегрирование - раздел вычислительной математики, занимающийся разработкой и применением методов приближённого вычисления определённых интегралов. В настоящее время процедуры вычисления интегралов в виде команд или подпрограмм имеются практически во всех специализированных пакетах математического профиля (Mathcad, Maple V, MATLAB и т.п.). В связи с этим при вычислении интегралов от функций различной сложности больше внимания уделяется не столько разработке эффективных методов или их программной реализации, сколько перенесению этих команд в приложение пользователя. Однако, процедура вычисления интеграла является лишь этапом в реализации математической модели некоторого процесса. Для грамотного применения существующих методов численного интегрирования кроме знания самих квадратурных формул необходимо иметь представление о сходимости, эффективности и точности выбранного метода.

В этой главе рассмотрены основные методы численного интегрирования, основанные на полиномиальной аппроксимации подынтегральной функции, - простейшие формулы прямоугольников, трапеций и некоторые формулы более высокой точности, в том числе наивысшей алгебраической точности Гаусса – Кристоффеля.

5.1 Обзор основных методов численного интегрирования

Пусть требуется найти определённый интеграл

$$I(f) = \int_a^b f(x) \rho(x) dx, \quad \rho(x) > 0,$$

где $f(x)$ - заданная на отрезке $[a, b]$ функция, а весовая функция $\rho(x)$ непрерывна на интервале (a, b) . (Весовую функцию используют для получения более точных формул. Обычно, если не сделано специальных оговорок, будем полагать $\rho(x) \equiv 1$). Для функций, имеющих на промежутке $[a, b]$ конечное число точек разрыва первого рода, такое значение существует, единственно и может быть формально получено по определению:

$$I(f) = \lim_{n \rightarrow \infty} \sum_{i=1}^n f(\xi_i)(x_i - x_{i-1})$$

где $\{x_i\}_{i=0}^n$ - произвольная упорядоченная система точек отрезка $[a, b]$ такая, что $\max\{x_0 - a, x_i - x_{i-1}, b - x_n\} \rightarrow 0, n \rightarrow \infty$, ξ_i - произвольная точка элементарного промежутка $[x_{i-1}, x_i]$.

Если для непрерывной на отрезке $[a, b]$ функции $f(x)$ известны значения первообразной $F(x)$ при $x = a$ и $x = b$, то по формуле Ньютона - Лейбница

$$I(f) = F(b) - F(a).$$

На практике редко удастся вычислить точно определенный интеграл по формуле Ньютона-Лейбница, так как первообразную функцию не всегда удастся выразить через элементарные функции или ее нахождение связано с необходимостью выполнения весьма сложных преобразований. Распространенной также является ситуация, когда подынтегральная функция задана таблицей экспериментально полученных значений. Во всех этих случаях применяется приближенное вычисление определенного интеграла, основанное на замене интеграла линейной комбинацией значений подынтегральной функции в некоторых узлах отрезка интегрирования, т.е. суммой, похожей на интегральную и называемой *квадратурной суммой*:

$$\int_a^b f(x) dx \approx S_n(f) = \sum_{k=1}^n A_k f(x_k) \quad (5.1)$$

Точки $\{x_k\}_{k=1}^n$, $x_k \in [a, b]$ называют *узлами квадратурной формулы*, а коэффициенты A_k - *коэффициентами (или весами) квадратурной формулы*. Узлы и коэффициенты квадратурной суммы не зависят от функции $f(x)$.

Разность между точным и приближенным значениями интеграла

$$R_n(f) = \int_a^b f(x) dx - \sum_{k=0}^n A_k f(x_k) \quad (5.2)$$

называется *погрешностью квадратурной формулы*.

Говорят, что квадратурная формула *точна для многочленов степени m* , если при замене $f(x)$ на произвольный алгебраический многочлен степени m приближенное равенство (5.1) становится точным.

Для каждой непрерывной функции $f(x)$ значение интеграла может быть вычислено с помощью сумм $S_n(f)$ с любой точностью. Выбор квадратурной формулы определяется классом Ω , к которому относят конкретную функцию $f(x)$, способом задания функции и имеющимися вычислительными средствами.

Квадратурная формула содержит $2n+1$ не зависящих от функции $f(x)$ параметров: n , x_k , A_k ($k=1, \dots, n$), которые выбирают так, чтобы при $f \in \Omega$ погрешность её была допустимо малой. Точность квадратурной формулы для $f \in \Omega$ характеризует величина $r_n(\Omega)$ – точная верхняя грань $|r_n(f)|$ на множестве Ω :

$$|r_n(\Omega)| = \sup_{f \in \Omega} |R_n(f)|$$

Пусть

$$W_n(\Omega) = \inf_{x_k, A_k} r_n(\Omega)$$

Квадратурная формула, для которой $W_n(\Omega) = r_n(\Omega)$, называется оптимальной на классе Ω . Веса и узлы в оптимальной квадратурной формуле могут быть произвольными или подчинёнными определённым связям.

Методы численного интегрирования классифицируются по способу выбора узлов и получения коэффициентов квадратурных формул.

Методы Ньютона-Котеса основаны на полиномиальной интерполяции подынтегральной функции в равноотстоящих узлах x_k , и определению подлежат только веса A_k . Методы отличаются друг от друга степенью n используемого полинома. Простейшими из них являются: методы прямоугольников ($n=0$), метод трапеций ($n=1$), метод Симпсона (парабол) ($n=2$).

В *методах наивысшей алгебраической точности (методы Гаусса-Кристоффеля)* стремятся достигнуть нужной точности с возможно меньшим числом вычислений значений функции и используют неравноотстоящие узлы, обеспечивающие минимальную погрешность интегрирования. В этих методах определяются и веса A_k и узлы x_k .

В *методах Монте-Карло* узлы выбираются с помощью датчика случайных чисел, ответ носит вероятностный характер. Эти методы часто применяют для вычисления кратных интегралов.

К *специальным* относятся методы, учитывающие особенности конкретных подынтегральных функций, что позволяет существенно сократить время и уменьшить погрешность вычислений. К ним относятся формулы Филона, вычисляющие часто встречающиеся в радиотехнических задачах интегралы, в которых функция описывает несущее высокочастотное колебание с модулированной амплитудой.

Различают два класса квадратурных формул: *элементарные* и *составные*. Элементарная формула строится для всего отрезка интегрирования. Поскольку заменой переменной интегрирование по отрезку $[a, b]$ сводится к интегрированию по отрезку $[-1, 1]$, то для определения весов и узлов элементарных формул достаточно знать их для отрезка $[-1, 1]$. В случае составных формул исходный интеграл представляется в виде:

$$I(f) = \sum_{i=0}^{N-1} \int_{a_i}^{a_{i+1}} f(x) dx \quad (5.3)$$

и для вычисления интегралов по отрезкам $[a_i, a_{i+1}]$ применяются элементарные квадратурные формулы.

Простейшие составные квадратурные формулы можно вывести непосредственно из определения интеграла, т.е. из представления (5.1). Зафиксировав некоторое значение $n \geq 1$, будем иметь

$$I(f) \approx \sum_{i=1}^n f(\xi_i)(x_i - x_{i-1}) \quad (5.4)$$

Графической интерпретацией определенного интеграла является площадь криволинейной трапеции, которая по формуле (5.4) приближенно заменяется площадью ступенчатой фигуры, состоящей из прямоугольников, основаниями которых служат отрезки $[x_{i-1}, x_i]$, а высотами ординаты $f(\xi_i)$. Обозначим через $h_i = x_i - x_{i-1}$ длину элементарного отрезка. Тогда формула (5.4) примет вид:

$$I(f) \approx \sum_{i=1}^n h_i f(\xi_i), \quad \xi_i \in [x_{i-1}, x_i] \quad (5.5)$$

Это приближенное равенство называют *общей формулой прямоугольников*. В зависимости от того, какие точки выберем в качестве ξ_i на элементарных отрезках $[x_{i-1}, x_i]$ (см. рис. 5.1), получим три простейшие формулы численного интегрирования.




Рис. 5.1. Вычисление интеграла по формулам прямоугольников

Пусть $\xi_i = x_{i-1}$, тогда

$$I(f) \approx I^{(\text{лев. пр.})} = \sum_{i=1}^n h_i f(\xi_{i-1}). \quad (5.6)$$

Если $\xi_i = x_i$, то

$$I(f) \approx I^{(\text{прав. пр.})} = \sum_{i=1}^n h_i f(\xi_i). \quad (5.7)$$

Формулы (5.6) и (5.7) называют квадратурными формулами левых и правых прямоугольников соответственно. Их можно применять для приближенного интегрирования таблично заданной функции на произвольной сетке.

В дальнейшем будем пользоваться равномерным разбиением отрезка $[a, b]$ на n частей точками x_i с шагом $h = \frac{b-a}{n}$, полагая $x_0 = a$,

$$x_i = x_{i-1} + h = a + ih \quad (i=1, 2, \dots, n-1), \quad x_n = b.$$

Можно рассчитывать на лучшую точность, если взять в качестве ξ_i точку посередине между точками x_{i-1} и x_i , т.е. $\xi_i = \frac{1}{h}(x_{i-1} + x_i)$. Тогда получаем квадратурную формулу средних прямоугольников:

$$I(f) \approx I^{(\text{сред. пр.})} = h \sum_{i=1}^n f\left(x_{i-1} + \frac{h}{2}\right) = h \sum_{i=1}^n f\left(x_i - \frac{h}{2}\right) \quad (5.8)$$

Погрешность составных квадратурных формул будет уменьшаться при увеличении числа разбиений n за счет более точной аппроксимации подынтегральной функции. Однако при этом будет возрастать вычислительная погрешность суммирования частичных интегралов, и,

начиная с некоторого n_0 , она станет преобладающей. Это обстоятельство должно предостеречь от выбора чрезмерно большого числа n и привлечь внимание к важности как априорной, так и апостериорной оценки погрешности численного интегрирования при помощи элементарных и составных квадратурных формул.

5.2. Квадратурные формулы интерполяционного типа (формулы Ньютона-Котеса).

Подстановка в интеграл $\int_a^b f(x)dx$ вместо функции $f(x)$ интерполирующего ее многочлена Лагранжа той или иной степени n приводит к семейству квадратурных формул, называемыми формулами Ньютона-Котеса.

Многочлен Лагранжа для функции $f(x)$ на произвольной сетке имеет вид:

$$L_n(x) = \sum_{i=0}^n f_i \cdot \prod_{i \neq j} \frac{x - x_j}{x_j - x_i},$$

где $f_i = f(x_i)$.

Если система узлов интерполирования $\{x_i\}_{i=0}^n$ совпадает с точками разбиения отрезка $[a, b]$ с шагом h , то многочлен Лагранжа может быть записан в виде:

$$L_n(x_0 + qh) = \sum_{i=0}^n \frac{(-1)^{n-i} f_i}{i!(n-i)!} \cdot \frac{q(q-1)\dots(q-n)}{q-i}. \quad (5.9)$$

Теперь заменим подынтегральную функцию построенным многочленом, считая, что узлы интерполяции расположены равномерно. Проведя необходимые элементарные преобразования, выполнив замену переменных $dx = h dq$ и сменив в соответствии с подстановкой пределы интегрирования, получим

$$I \approx \sum_{i=0}^n f_i \cdot \frac{(-1)^{n-i}}{i!(n-i)!} \cdot h \times \\ \times \int_0^n q(q-1) \times \dots \times (q-i+1) \cdot (q-i-1) \times \dots \times (q-n) dq.$$

Это приближенное равенство и есть квадратурная формула Ньютона-Котеса:

$$\int_a^b f(x)dx \approx (b-a) \cdot \sum_{i=0}^n f_i \cdot H_i \quad (5.10)$$

где H_i - коэффициенты квадратурной формулы (коэффициенты Ньютона-Котеса):

$$H_i = \frac{(-1)^{n-i}}{i!(n-i)!} \cdot \frac{1}{h} \cdot \int_0^n q(q-1) \times \dots \times (q-i+1) \cdot (q-i-1) \times \dots \times (q-n) dq$$

Они не зависят от значений функции $f(x)$ и являются функциями только количества узлов, на которые разбит отрезок интегрирования. Вычисленные значения H_i для $n=1, \dots, 7$ приведены ниже.

n	H_0	H_1	H_2	H_3	H_4	H_5	H_6	H_7
1	1/2	1/2						
2	1/6	2/3	1/6					
3	1/8	3/8	3/8	1/8				
4	7/90	16/45	2/13	16/45	7/90			
5	19/288	25/96	25/144	25/144	25/96	19/288		
6	41/840	9/35	9/280	34/105	9/280	9/35	41/840	
7	751/17280	3577/17280	1323/17280	2989/17280	2989/17280	1323/17280	3577/17280	751/17280

Поскольку любой алгебраический многочлен $P_n(x)$ степени n однозначно определяется своими значениями в $n+1$ узле, т.е. $P_n(x) = L_n(x)$, то квадратурные формулы интерполяционного типа (5.10) точны для многочленов степени n .

Остаточный член квадратурных формул Ньютона-Котеса можно найти, интегрируя остаточный член интерполяционного многочлена Лагранжа

$$R_n(x) = R_n(a + qh) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \cdot h^{n+1} \prod_{k=0}^n (q - k)$$

и применяя теорему об интегральном среднем (при условии, что подынтегральная функция достаточно гладкая):

$$R_n(f) = \int_a^b (f(x) - L_n(x)) dx = \int_0^n \frac{f^{(n+1)}(\xi)}{(n+1)!} \cdot h^{n+2} \prod_{k=0}^n (q-k) dq. \quad (5.11)$$

Для квадратурных формул Ньютона – Котеса справедлива следующая оценка погрешности:

$$|R_n(f)| \leq \frac{(b-a)^{n+2}}{2^{2n}(n+1)!} \cdot \frac{\max_{x \in [a,b]} |f^{(n+1)}(x)|}{(n+1)!}.$$

5.2.1. Простейшие квадратурные формулы

На самом деле, формулы (5.10), (5.11) определяют семейство квадратурных формул. Параметром этого семейства является число n - степень интерполяционного многочлена, которым заменяется подынтегральная функция. Простейшими из них являются: формулы прямоугольников ($n=0$), формула трапеций ($n=1$), формула Симпсона (парабол) ($n=2$):

при $n = 0$ получаем элементарные формулы прямоугольников

$$\begin{aligned} \int_a^b f(x) dx &\approx (b-a) \cdot f(a) \quad - \text{левых прямоугольников,} \\ \int_a^b f(x) dx &\approx (b-a) \cdot f(b) \quad - \text{правых прямоугольников,} \\ \int_a^b f(x) dx &\approx (b-a) \cdot f\left(\frac{a+b}{2}\right) \quad - \text{средних прямоугольников;} \end{aligned} \quad (5.12)$$

при $n = 1$ получаем элементарную формулу трапеций

$$\int_a^b f(x) dx \approx (b-a) \cdot (f(a) + f(b)) / 2; \quad (5.13)$$

при $n = 2$ получаем элементарную формулу Симпсона (или парабол)

$$\int_a^b f(x) dx \approx (b-a) \cdot \left(f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right) / 6; \quad (5.14)$$

при $n = 3$ получаем элементарную формулу "трех восьмых"

$$\int_a^b f(x)dx \approx 3 \cdot (b-a) \cdot (f(a) + 3f(a+h/3) + 2f(a+2h/3) + f(b))/8. \quad (5.15)$$

5.2.2. Вывод оценок погрешностей простейших квадратурных формул

При выводе оценок погрешностей воспользуемся формулой Тейлора для подынтегральной функции, предполагая, что у функции существует требуемое число непрерывных производных на $[a, b]$:

$$f(x) = f(x_0) + f'(x_0) \cdot (x - x_0) + \frac{f''(x_0)}{2} \cdot (x - x_0)^2 + \dots + \frac{f^{(n+1)}(\xi)}{(n+1)!} \cdot (x - x_0)^{n+1}, \quad \xi \in [a, b] \quad (5.16)$$

Для получения выражений остаточного члена *простейших квадратурных формул прямоугольников* запишем для $n=0$ формулу Тейлора с остаточным членом при $x_0 = a$ и $x_0 = b$:

$$f(x) = f(a) + f'(\xi_1) \cdot (x - a), \quad f(x) = f(b) + f'(\xi_2) \cdot (x - b)$$

Проинтегрировав эти формулы по отрезку $[a, b]$, получим формулы левых и правых прямоугольников с остаточными членами:

$$\int_a^b f(x)dx = (b-a) \cdot f(a) + \frac{1}{2}(b-a)^2 \cdot f'(\xi_1) \quad (5.17)$$

и

$$\int_a^b f(x)dx = (b-a) \cdot f(b) + \frac{1}{2}(b-a)^2 \cdot f'(\xi_2) \quad (5.18)$$

Второе слагаемое в этих формулах, т.е. величина $\frac{1}{2}(b-a)^2 \cdot f'(\xi)$, является локальной погрешностью элементарных формул прямоугольников (5.12). Нетрудно заметить, что формулы (5.17), (5.18) точны для многочленов нулевой степени и ошибка численного интегрирования по этим формулам пропорционально квадрату длины отрезка — $O((b-a)^2)$.

Для получения выражений остаточного члена *простейших квадратурных формул средних прямоугольников* будем считать, что функция $f(x)$ дважды непрерывно дифференцируема и воспользуемся формулой

Тейлора (5.16) с тремя слагаемыми относительно центра элементарного отрезка $x_{0.5} = \frac{a+b}{2}$:

$$f(x) = f(x_{0.5}) + f'(x_{0.5}) \cdot (x - x_{0.5}) + \frac{f''(\xi)}{2} \cdot (x - x_{0.5})^2$$

Проинтегрируем это выражение и получим элементарную формулу средних прямоугольников с остаточным членом:

$$\int_a^b f(x)dx = (b-a) \cdot f(x_{0.5}) + \frac{1}{24}(b-a)^3 \cdot f''(\xi_3) \quad (5.19)$$

Формула точна для многочленов первой степени, т.е. алгебраическая точность формулы на единицы превышает порядок используемого при выводе интерполяционного многочлена ($n=0$). Локальная ошибка численного интегрирования по этой формуле пропорционально кубу длины отрезка $O((b-a)^3)$, в отличие от $O((b-a)^2)$ для формул левых и правых прямоугольников.

Для получения выражений остаточного члена *простейшей квадратурной формулы трапеций* (5.13) воспользуемся выражением для остаточного члена квадратурных формул Ньютона-Котеса (5.11):

$$R_1(f) = \int_a^b (f(x) - L_1(x))dx = \int_0^1 \frac{f^{(2)}(\xi)}{2!} \cdot h^3 \cdot q(q-1)dq = -\frac{f^{(2)}(\xi_4)}{12} \cdot (b-a)^3$$

Элементарная формула трапеций с остаточным членом имеет вид:

$$\int_a^b f(x)dx = (b-a) \cdot (f(a) + f(b))/2 - \frac{f^{(2)}(\xi_4)}{12} \cdot (b-a)^3. \quad (5.20)$$

Локальная ошибка численного интегрирования по формуле трапеций, как и ошибка формулы средних прямоугольников (5.19), пропорционально кубу длины отрезка - $O((b-a)^3)$, т.е. эти формулы одного порядка. Остаточный член формулы средних прямоугольников примерно вдвое меньше, чем у формулы трапеций. Поэтому если значения функции одинаково легко определяются в любых точках, то лучше вести расчёт по более точной формуле средних прямоугольников. Формулу трапеций используют в тех случаях, когда функция задана только в узлах сетки, а в серединах интервалов неизвестна.

Знак оценки погрешности формулы трапеций противоположен знаку оценки погрешности формулы средних прямоугольников. Поэтому, если учесть расчёты по обеим формулам, то точное значение интеграла, как правило, лежит в вилке между ними. Деление этой вилки в отношении 2:1 даёт уточнённый результат, соответствующий формуле Симпсона.

Приведем без вывода несколько часто используемых квадратурных формул Ньютона – Котеса с остаточными членами.

Формула Симпсона (парабол):

$$\int_a^b f(x) dx = (b-a) \cdot \left(f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right) / 6 - \frac{(b-a)^5}{2880} f^{IV}(\xi_5) \quad (5.21)$$

Выражение для остаточного члена показывает, что алгебраический порядок точности формулы Симпсона равен трем, - как и в случае формулы средних прямоугольников на единицу превышает порядок аппроксимации.

Формула Бодэ использует пять узлов на отрезке интегрирования:

$$\int_a^b f(x) dx = \frac{(b-a)}{90} [7f(a) + 32f(a+h) + 12f(a+2h) + 32f(a+3h) + 7f(b)] - \frac{8h^7}{945} f^{VI}(\xi_6), \quad h = (b-a)/4.$$

Формула Уэддлэ используют семь узлов на отрезке:

$$\int_a^b f(x) dx = \frac{(b-a)}{20} \left(\sum_{k=0}^3 f(a+2kh) + 5f(a+h) + 6f(a+3h) + 5f(a+5h) \right) + \frac{47h^7}{12700} f^{VI}(\xi_7), \quad h = (b-a)/6.$$

Формула Ньютона-Котеса с семью узлами имеет повышенную точность по сравнению с методом Уэддлэ:

$$\int_a^b f(x) dx = \frac{(b-a)}{840} [41(f(a) + f(b)) + 216(f(a+h) + f(a+5h)) + 27(f(a+2h) + f(a+4h)) + 272f(a+3h)] + \frac{9h^9}{1400} f^{VIII}(\xi_8).$$

5.2.3. Составные квадратурные формулы Ньютона-Котеса

Для получения выражений простейших составных квадратурных формул Ньютона – Котеса используем свойство аддитивности (5.3), относящееся к промежутку интегрирования и применим к каждому

элементарному отрезку $[x_{i-1}, x_i]$ простейшие квадратурные формулы Ньютона – Котеса с остаточными членами (5.17) – (5.21).

Составные квадратурные формулы левых и правых прямоугольников можно записать следующим образом:

$$I(f) = \sum_{i=1}^n I_i(f) = \sum_{i=1}^n hf(x_{i-1}) + \sum_{i=1}^n \frac{f'(\xi_i)}{2} h^2$$

$$I(f) = \sum_{i=1}^n I_i(f) = \sum_{i=1}^n hf(x_i) + \sum_{i=1}^n \frac{f'(\hat{\xi}_i)}{2} h^2.$$

Второе слагаемое в них является остаточным членом составной формулы прямоугольников. Согласно обобщенной теореме о среднем значении непрерывной функции, существует такая точка $\xi_0 \in (a, b)$, что

$$\sum_{i=1}^n f'(\xi_i) = n \cdot \frac{\sum_{i=1}^n f'(\xi_i)}{n} = n \cdot f'(\xi_0) = \frac{b-a}{h} f'(\xi_0).$$

После подстановки этого выражения в предыдущее равенство приходим к окончательному виду остаточного члена

$$r^{(i \partial \ddot{y} i)}(h) = \frac{b-a}{2} f'(\xi_0) h, \quad \xi_0 \in (a, b)$$

и составной квадратурной формулы прямоугольников:

$$\int_a^b f(x) dx = h \sum_{k=k_1}^{k_2} f(a + kh) + h \frac{b-a}{2} f'(\xi_0), \quad \xi_0 \in [a, b] \quad (5.22)$$

где $k_1 = 0, k_2 = n - 1$ для левых прямоугольников и $k_1 = 1, k_2 = n$ для правых прямоугольников.

Как видно из (5.22), при увеличении числа n элементарных отрезков, на которые разделен промежуток интегрирования $[a, b]$, глобальная погрешность формулы прямоугольников убывает пропорционально шагу разбиения h , т.е. является величиной того же порядка, что и шаг - $O(h)$.

Выражение для *составной квадратурной формулы средних прямоугольников* получим, применяя к каждому элементарному отрезку $[x_{i-1}, x_i]$ формулу (5.19):

$$\int_a^b f(x) dx = h \sum_{k=0}^{n-1} f(a + (k + 0.5)h) + h^2 \frac{b-a}{24} f''(\hat{\xi}_0), \quad \hat{\xi}_0 \in [a, b] \quad (5.23)$$

Как видно из (5.21), при увеличении числа n элементарных отрезков, на которые разделен промежуток интегрирования $[a, b]$, глобальная

погрешность составной формулы средних прямоугольников убывает пропорционально квадрату шага разбиения $h - O(h^2)$.

Составная квадратурная формула трапеций имеет вид:

$$\int_a^b f(x)dx = \frac{h}{2} \left[f(a) + 2 \sum_{k=1}^{n-1} f(a + kh) + f(b) \right] - h^2 \frac{(b-a)}{12} f^{(2)}(\tilde{\xi}) \quad (5.24)$$

Составная квадратурная формула Симпсона (парабол):

$$\int_a^b f(x)dx = \frac{h}{6} \left(f(a) + 2 \sum_{k=1}^{N-1} f(a + kh) + 4 \sum_{k=0}^{N-1} f(a + (k + 0.5)h) + f(b) \right) - h^4 \frac{b-a}{2880} f^{IV}(\hat{\xi}) \quad (5.25)$$

Выражение для остаточного члена показывает, что алгебраический порядок точности формулы Симпсона равен трем. Формула позволяет получить высокую точность, если четвертая производная не слишком велика.

5.3. Квадратурные формулы наивысшей алгебраической точности (формулы Гаусса-Кристоффеля)

При построении квадратурных формул наивысшей алгебраической точности исходят из того, что параметрами квадратурной формулы являются $2n$ не зависящих от функции $f(x)$ величин x_k, A_k ($k = 1, \dots, n$):

$$I(f) = \int_a^b f(x) \rho(x) dx \approx \sum_{k=1}^n A_k f(x_k) .$$

При выводе формул Ньютона-Котеса, мы заранее задавали узлы равномерно на отрезке и по ним находили веса. Поэтому мы не полностью использовали возможности общей формулы. Только в формуле средних прямоугольников положение узла было выбрано из соображений симметрии, что привело к существенному улучшению точности квадратурной формулы.

Будем исходить из того, что формула с n узлами содержит всего $2n$ параметров; столько же и коэффициентов у полинома степени $2n - 1$. Значит, параметры можно подобрать так, чтобы квадратурная формула была точна для любого многочлена степени не выше $2n - 1$. Первую такую формулу для $\rho(x) \equiv 1$ построил Гаусс, случай произвольного веса рассмотрел Кристоффель, поэтому формулы наивысшей алгебраической точности называют также формулами Гаусса-Кристоффеля.

Будем считать, что вес положителен $\rho(x) > 0$ и непрерывен на отрезке (a, b) ; он может обращаться в нуль или бесконечность на концах отрезка так, чтобы существовал $\int_a^b \rho(x) dx$. Известно, что при выполнении этих условий существует полная система алгебраических многочленов $P_m(x)$, ортогональных на $[a, b]$ с заданным весом:

$$\int_a^b P_k(x) P_m(x) \rho(x) dx = \delta_{km} \|P_k(x)\|_{L_2}^2. \quad (5.26)$$

Все нули этих многочленов действительны и расположены на интервале (a, b) .

Составим по узлам интегрирования полином n -ной степени

$$\omega_n(x) = \prod_{k=1}^n (x - x_k).$$

Функция $f(x) = \omega_n(x) P_m(x)$ при $m \leq n-1$ есть полином степени не выше $2n-1$; значит для неё формула Гаусса – Кристоффеля точна. Тогда получим

$$\int_a^b \omega_n(x) P_m(x) \rho(x) dx = \sum_{k=1}^n A_k \omega_n(x_k) P_m(x_k) = 0, \quad (5.27)$$

так как $\omega_n(x_k) = 0$. Значит, многочлен $\omega_n(x)$ ортогонален всем многочленам $P_m(x)$ степени $m \leq n-1$.

Если разложить $\omega_n(x)$ в ряд по нашим ортогональным многочленам и этот ряд подставить в условие ортогональности (5.27), то получим

$$\omega_n(x) = \sum_{k=0}^n b_k P_k(x),$$

$$0 = \int_a^b \omega_n(x) P_m(x) \rho(x) dx = b_m \|P_m\|^2, \quad m \leq n-1,$$

т.е. все коэффициенты разложения $b_m = 0$ при $m \leq n-1$. Это значит, что $\omega_n(x)$ с точностью до численного множителя совпадает с $P_n(x)$. Значит, узлами формулы Гаусса – Кристоффеля являются нули многочленов соответствующей степени $P_n(x)$, ортогональных на $[a, b]$ с весом $\rho(x)$.

Веса интегрирования нетрудно определить, если узлы уже найдены. Запишем интерполяционный многочлен Лагранжа для функции $f(x)$

$$L_n(x) = \sum_{m=0}^n f(x_m) \cdot l_m(x) = \sum_{m=0}^n f(x_m) \cdot \prod_{\substack{k=1, \\ k \neq m}}^n \frac{x - x_k}{x_m - x_k}$$

Функции $l_m(x) = \prod_{\substack{k=1, \\ k \neq m}}^n \frac{x - x_k}{x_m - x_k}$ - коэффициенты Лагранжа

интерполяционного многочлена являются многочленами степени $n - 1$, т.е. для них формула Гаусса – Кристоффеля точна. Учитывая то, что они равны нулю во всех узлах, кроме m -ного, получим веса формулы Гаусса – Кристоффеля:

$$\begin{aligned} \int_a^b f(x) \rho(x) dx &= \int_a^b \left\{ \rho(x) \sum_{m=0}^n f(x_m) \cdot \prod_{\substack{k=1, \\ k \neq m}}^n \frac{x - x_k}{x_m - x_k} \right\} dx = \sum_{m=0}^n f(x_m) \int_a^b \left\{ \rho(x) \prod_{\substack{k=1, \\ k \neq m}}^n \frac{x - x_k}{x_m - x_k} \right\} dx. \\ A_k &= \int_a^b \left\{ \rho(x) \prod_{\substack{k=1, \\ k \neq m}}^n \frac{x - x_k}{x_m - x_k} \right\} dx \end{aligned} \quad (5.28)$$

Из этого выражения ничего нельзя сказать о знаке веса. Но если подставить в формулу интегрирования многочлен $(l_m(x))^2$ степени $2n - 1$, для которого формула тоже точна, то получим соотношение $A_m = \int_a^b l_m^2(x) \rho(x) dx > 0$,

из которого видно, что все веса положительны.

Таблицы узлов и весов, а также оценки погрешности квадратурных формул Гаусса – Кристоффеля приводятся в специальных справочниках.

Рассмотрим некоторые частные случаи формул Гаусса – Кристоффеля.

1. Собственно *формула Гаусса* соответствует $\rho(x) = 1$ и отрезку $[-1; 1]$. На нём ортогональны с единичным весом полиномы Лежандра. Если обозначить их узлы и соответствующие веса через t_k , C_k , то линейным преобразованием можно получить узлы и веса для произвольного отрезка

$$x_k = \frac{1}{2}(a+b) + \frac{1}{2}(b-a) t_k, \quad A_k = \frac{1}{2}(b-a) C_k, \quad 1 \leq k \leq n.$$

Квадратурная формула Гаусса имеет вид

$$\int_a^b f(x) dx \approx \frac{b-a}{2} \sum_{k=1}^n C_k f(x_k). \quad (5.29)$$

Значения узлов и коэффициентов формулы Гаусса для $n=1, \dots, 6$ приведены в таблице.

n	t_k	C_k
1	$t_1 = 0$	$A_1 = 2$
2	$t_2 = -t_1 = 0.5773502692$	$A_1 = A_2 = 2$
3	$t_2 = 0$ $t_3 = -t_1 = 0.7745966692$	$A_2 = 8/9$ $A_1 = A_3 = 5/9$
4	$t_4 = -t_1 = 0.8611363116$ $t_3 = -t_2 = 0.3399810436$	$A_2 = A_3 = 0.6521451549$ $A_1 = A_4 = 0.3478548451$
5	$t_3 = 0$ $t_5 = -t_1 = 0.9061798459$ $t_4 = -t_2 = 0.5384693101$	$A_3 = 0.5688888899$ $A_2 = A_4 = 0.4786286705$ $A_1 = A_5 = 0.2369268851$
6	$t_6 = -t_1 = 0.9324695142$ $t_5 = -t_2 = 0.6612093865$ $t_4 = -t_3 = 0.2386191861$	$A_1 = A_6 = 0.1713244924$ $A_2 = A_5 = 0.3607615730$ $A_3 = A_4 = 0.4679139346$

Погрешность формулы Гаусса (выражение для которой мы приводим без вывода) пропорциональна той производной, которая соответствует низшей неучтённой степени аргумента; верхняя граница погрешности равна

$$\max |R| = \frac{(b-a)^{2n+1} (n!)^4}{(2n+1)[(2n)!]^3} M_{2n} \approx \frac{b-a}{2,5\sqrt{n}} \left(\frac{b-a}{3n} \right)^{2n} M_{2n},$$

$$M_{2n} = \max_{[a,b]} |f^{2n}(x)|.$$

Формула Гаусса рассчитана на функции, имеющие достаточно высокие производные, причём не слишком большие по абсолютной величине. Для таких функций формула обеспечивает очень высокую точность при небольшом числе узлов, ибо численный коэффициент в остаточном члене быстро убывает с ростом n .

Как видно из таблицы узлов, при $n = 1$ частным случаем формулы Гаусса является формула средних прямоугольников.

2. *Формула Эрмита* позволяет интегрировать на отрезке $[-1, 1]$ с весом

$$p(x) \equiv \frac{1}{\sqrt{1-x^2}}. \text{ При этих условиях ортогональны полиномы Чебышева}$$

первого рода $T_m(x)$. Соответствующие узлы и веса интегрирования равны

$$t_k = \cos \frac{(2k-1)\pi}{2n}, \quad C_k = \frac{\pi}{n}, \quad k = 1, \dots, n$$

Отметим, что веса во всех узлах одинаковы. На произвольный отрезок эти узлы и веса преобразуются так же, как и в формуле Гаусса. Погрешность формулы Эрмита не превышает

$$\max |R| = \frac{\pi M_{2n}}{2^{n-1} (2n)!}.$$

По формулам Гаусса – Кристоффеля возможно вычисление интегралов на полупрямой $0 \leq x < \infty$; если весовая функция равна $\rho(x) = x^\alpha \cdot e^{-x}$, то используются ортогональные будут многочлены Лагерра $L_n^\alpha(x)$. То же относится к интегралам на всей прямой $-\infty < x < +\infty$ при весе $\rho(x) = e^{-x^2}$ ортогональными будут многочлены Эрмита.

Формулы Гаусса – Кристоффеля рассчитаны на получение очень высокой точности уже при небольшом числе узлов $n \approx 4 - 10$. Поэтому для них не строят составных формул типа, исключениями являются только рассмотренные выше формулы средних, трапеций и Симпсона, которые являются частными случаями формул Гаусса. Для функций высокой гладкости удобнее формулы Гаусса, а для недостаточно гладких функций – обобщённые формулы трапеций и средних.

В плане практического приложения на первый план выдвигаются эффективность и точность формулы. По этим критериям в практической вычислительной математике несомненным лидером являются формулы Гаусса – Лежандра.

5.4. Вычисление интеграла с заданной точностью. Автоматический выбор шага интегрирования

Вычисление интеграла с заданной точностью по приведенным квадратурным формулам требует либо предварительного определения числа частичных интервалов (или величины шага интегрирования h , что равносильно), либо возможности оценки достигнутой точности (апостериорная оценка) при произвольном числе разбиений отрезка. Полученные выражения остаточных членов квадратурных формул содержат производные подынтегральной функции в некоторых неизвестных точках отрезка интегрирования. С их помощью получают априорные оценки погрешности интегрирования вида

$$R_n(f) \leq C \cdot h^p \cdot M_k. \quad (5.30)$$

Определение шага на основании такой априорной оценки погрешности интегрирования часто оказывается невозможным из-за

трудностей определения максимума производных подынтегральной функции. На практике применяют апостериорные оценки погрешности интегрирования по **правилу Рунге**. Для этого априорные оценки погрешностей квадратурных формул записывают, выделив явно главную часть погрешности, в виде

$$R(f) = Ah^p + O(h^{p+1}),$$

где A - коэффициент, зависящий от метода интегрирования и вида подынтегральной функции, p - порядок метода. Вычисляют интеграл по одной и той же формуле дважды - с шагом h и kh (обычно $k=2$):

$$I = I_h + Ah^p + O(h^{p+1}), \quad I = I_{kh} + A(kh)^p + O((kh)^{p+1}),$$

приравнивают правые части соотношений и определяют главную часть погрешности по *первой формуле Рунге*:

$$Ah^p = \frac{I_h - I_{kh}}{k^p - 1}.$$

Это - апостериорная оценка погрешности, и согласно ей ошибка более точного приближения примерно в k^p-1 раз меньше разности между двумя приближениями. Уточненное (*уточненное по Ричардсону*) значение интеграла определяется по *второй формуле Рунге*:

$$I_h^T = I_h + \frac{I_h - I_{kh}}{k^p - 1}.$$

Возможность апостериорно оценить погрешность позволяет вычислять интеграл с заданной точностью путем *автоматического выбора шага* интегрирования. Если на каком-то частичном отрезке не выполняется неравенство

$$\left| \frac{I_{0.5h,i} - I_{h,i}}{2^p - 1} \right| \leq \frac{\varepsilon h_i}{b-a},$$

то шаг на этом отрезке надо измельчить еще в два раза и снова оценить погрешность. Применение такого подхода приводит к **адаптивным квадратурам**, в которых уменьшается количество вычислений функции в узлах по сравнению с формулами с постоянным шагом за счет выбора различного шага интегрирования в разных частях интервала в зависимости от поведения функции.

ГЛАВА 6. ЧИСЛЕННОЕ РЕШЕНИЕ НЕЛИНЕЙНЫХ УРАВНЕНИЙ

Нелинейное алгебраическое уравнение с одной переменной в общем случае может быть записано в виде

$$f(x)=0 \quad (6.1)$$

где функция $f(x)$ определена и непрерывна на конечном или бесконечном интервале $x \in (a, b)$.

Всякое значение $\xi \in [a, b]$, обращающее функцию $f(x)$ в нуль, называется *корнем уравнения* (6.1) или нулем функции $f(x)$. Число ξ называется *корнем k -й кратности*, если при $x=\xi$ вместе с функцией $f(x)$ равны нулю и ее производные до порядка $(k-1)$ включительно:

$$f(\xi) = f'(\xi) = f''(\xi) = \dots f^{(k-1)}(\xi) = 0. \quad (6.2)$$

Однократный корень называется *простым*. Два уравнения называются *равносильными* (эквивалентными), если множества их решений совпадают.

Нелинейные уравнения с одной переменной подразделяются на алгебраические (функция $f(x)$ является алгебраической) и трансцендентные в противном случае. Уже на примере алгебраического многочлена известно, что нули $f(x)$ могут быть как действительными, так и комплексными. Поэтому более точная постановка задачи состоит в нахождении корней уравнения (6.1), расположенных в заданной области комплексной плоскости. Можно рассматривать также задачу нахождения действительных корней, расположенных на заданном отрезке. Иногда, пренебрегая точностью формулировок, просто говорят, что требуется решить уравнение (6.1). Большинство алгебраических и трансцендентных нелинейных уравнений аналитически (т.е. точно) не решается, поэтому на практике для нахождения корней используются численные методы. В связи с этим под решением уравнения (6.1) будем понимать задачу приближенного нахождения корней уравнения вида (6.1). При этом под близостью приближенного значения $\bar{x}$ к корню ξ уравнения, как правило, понимают выполнение неравенства

$$|\xi - \bar{x}| < \varepsilon \quad \text{при малых } \varepsilon > 0,$$

т.е. абсолютную погрешность приближенного равенства $\bar{x} \approx \xi$.

Используют также и относительную погрешность, т.е. величину $\frac{|\xi - \bar{x}|}{|\bar{x}|}$.

Нелинейная функция $f(x)$ в своей области определения может иметь конечное или бесконечное количество нулей или может не иметь их вовсе.

Численное решение нелинейного уравнения (6.1) заключается в нахождении с заданной точностью значений всех или некоторых корней уравнения и распадается на несколько подзадач:

во-первых, надо исследовать количество и характер корней (вещественные или комплексные, простые или кратные),

во-вторых, определить их приближенное расположение, т.е. значения начала и конца отрезка, на котором лежит только один корень,

в-третьих, выбрать интересующие нас корни и вычислить их с требуемой точностью.

Большинство методов нахождения корней требует знания промежутков, где заведомо имеется и притом единственный нуль функции. В связи с этим вторая задача называется *отделением корней*. Решив ее, по сути дела, находят приближенные значения корней с погрешностью, не превосходящей длины отрезка, содержащего корень.

6.1. Отделение корней нелинейного уравнения

Для функций общего вида нет универсальных способов решения задачи отделения корней. Отметим два простых приема отделения действительных корней уравнения – *табличный* и *графический*.

Первый прием состоит в вычислении таблицы значений функции в заданных точках x_i , расположенных на условно небольшом расстоянии h одна от другой и использовании следующих теорем математического анализа:

1. Если функция $y=f(x)$ непрерывна на отрезке $[a,b]$ и $f(a)f(b)<0$, то внутри отрезка $[a,b]$ существует по крайней мере один корень уравнения $f(x)=0$.
2. Если функция $y=f(x)$ непрерывна на отрезке $[a,b]$, $f(a)f(b) < 0$ и $f'(x)$ на интервале (a,b) сохраняет знак, то внутри отрезка $[a,b]$ существует единственный корень уравнения $f(x)=0$.

Выполнив вычисление значений функции в этих точках (или только определив знаки $f(x_i)$), сравнивают их в соседних точках, т.е. проверяют, не выполняется ли на отрезке $[x_{i-1}, x_i]$ условие $f(x_{i-1})f(x_i) \leq 0$. Таким образом, если при некотором i числа $f(x_{i-1})$ и $f(x_i)$ имеют разные знаки, то это означает, что на интервале (x_{i-1}, x_i) уравнение имеет по крайней мере один действительный корень нечетной кратности (точнее - нечетное число корней). Выявить по таблице корень четной кратности очень сложно. Если заранее известно количество корней в исследуемой области, то, уменьшая шаг поиска h , таким процессом можно либо их локализовать, либо довести


процесс до состояния, позволяющего утверждать наличие пар корней, не различимых с точностью $h = \varepsilon$. Это хорошо известный способ перебора.

По таблице можно построить *график функции* $y = f(x)$. Корнями уравнения (6.1) являются те значения x , при которых график функции пересекает ось абсцисс. Этот способ более нагляден и даёт неплохие приближённые значения корней. Построение графика функции даже с малой точностью обычно даёт представление о расположении и характере корней уравнения (иногда позволяет выявить даже корни четной кратности). Во многих задачах техники такая точность уже достаточна.

Если построение графика функции $y = f(x)$ вызывает затруднение, следует преобразовать исходное уравнение к виду $\varphi_1(x) = \varphi_2(x)$ таким образом, чтобы графики функций $y = \varphi_1(x)$ и $y = \varphi_2(x)$ были достаточно просты. Абсциссы точек пересечения этих графиков и будут корнями уравнения.

Пример: Отделить корни уравнения $x^2 - \sin x - 1 = 0$.

Представим уравнение в виде: $x^2 - 1 = \sin x$ и построим графики функций $y = x^2 - 1$ и $y = \sin x$.



Совместное рассмотрение графиков позволяет сделать заключение, что данное уравнение имеет два корня $\xi_1 \in [-1, 0]$ и $\xi_2 \in [1, \pi]$.

Допустим, что искомый корень уравнения отделен, т.е. найден отрезок $[a, b]$, на котором имеется только один корень уравнения. Для вычисления корня с требуемой точностью ε обычно применяют какую-либо итерационную процедуру уточнения корня, строящую числовую последовательность значений x_n , сходящуюся к искомому корню уравнения.

Начальное приближение x_0 выбирают на отрезке $[a, b]$, продолжают вычисления, пока не выполнится неравенство $|x_{n-1} - x_n| < \varepsilon$, и считают, что x_n — есть корень уравнения, найденный с заданной точностью. Имеется множество различных методов построения таких последовательностей и выбор алгоритма — весьма важный момент при практическом решении задачи. Немалую роль при этом играют такие свойства метода, как простота, надежность, экономичность, важнейшей характеристикой является его скорость сходимости.

Последовательность x_n , сходящаяся к пределу x^* , имеет скорость сходимости порядка α , если при $n \rightarrow \infty$ $|x_{n+1} - x^*| = O(|x_n - x^*|^\alpha)$. При $\alpha=1$ сходимость называется линейной, при $1 < \alpha < 2$ – сверхлинейной, при $\alpha=2$ – квадратичной. С ростом α алгоритм, как правило, усложняется и условия сходимости становятся более жесткими.

Приближённые значения корней уточняют различными итерационными методами. Рассмотрим наиболее эффективные из них.

6.2. Метод половинного деления (бисекции, дихотомии)

Пусть функция $f(x)$ определена и непрерывна при всех $x \in [a, b]$ и на $[a, b]$ меняет знак, т.е. $f(a)f(b) < 0$. Тогда согласно теореме 1 уравнение имеет на (a, b) хотя бы один корень. Возьмем произвольную точку $c \in (a, b)$. Будем называть в этом случае отрезок $[a, b]$ промежутком существования корня, а точку c – пробной точкой. Поскольку речь здесь идет лишь о вещественных функциях вещественной переменной, то вычисление значения $f(c)$ приведет к какой-либо одной из следующих взаимоисключающих ситуаций:

- А) $f(a)f(c) < 0$
- Б) $f(c)f(b) < 0$
- В) $f(c) = 0$

Если $f(c) = 0$, то корень уравнения найден. В противном случае из двух частей отрезка $[a, c]$ или $[c, b]$ выберем ту, на концах которой функция имеет разные знаки, так как один из корней лежит на этой половине. Затем повторяем процесс для выбранного отрезка.




Рис. 6.1. Метод дихотомии

Такой процесс называют *методом дихотомии*. Наиболее употребительным частным случаем метода дихотомии является *метод половинного деления*, реализующий самый простой способ выбора пробной точки – деление промежутка существования корня пополам.

За один шаг метода половинного деления промежуток существования корня сокращается ровно вдвое. Поэтому, если за k -е приближение к корню ξ уравнения примем точку x_k , являющуюся серединой полученного на k -м шаге отрезка $[a_k, b_k]$, полагая $a_0 = a$, $b_0 = b$, то придем к неравенству

$$|\xi - x_k| < \frac{b-a}{2^k}, \quad (6.3)$$

которое, с одной стороны, позволяет утверждать, что последовательность (x_k) имеет предел – искомый корень ξ уравнения (6.1), с другой стороны, является *априорной оценкой* абсолютной погрешности равенства $x_k \approx \xi$, что дает возможность подсчитать число шагов (итераций) метода половинного деления, достаточное для получения корня ξ с заданной точностью ε . Для чего нужно лишь найти наименьшее натуральное k удовлетворяющее неравенству

$$\frac{b-a}{2^k} < \varepsilon.$$

Проще говоря, если требуется найти корень с точностью ε , то продолжаем деление пополам до тех пор, пока длина отрезка не станет меньше 2ε . Тогда середина последнего отрезка даст значения корня с требуемой точностью.

Дихотомия проста и очень надёжна: к простому корню она сходится для любых непрерывных функций $f(x)$, в том числе недифференцируемых; при этом она устойчива к ошибкам округления. Скорость сходимости невелика: за одну итерацию точность увеличивается примерно вдвое, т.е. уточнение трёх цифр требует 10 итераций. Зато точность ответа гарантируется.

К основным недостаткам метода дихотомии можно отнести следующие.

1. Для начала расчёта необходимо найти отрезок, на котором функция изменяет знак. Если в этом отрезке несколько корней, то заранее неизвестно, к какому из них сойдётся процесс (хотя к одному из них обязательно сойдётся).
2. Метод неприменим к корням чётной кратности.
3. Для корней нечётной высокой кратности он сходится, но менее точен и менее устойчив к ошибкам округления, возникающим при вычислении значений функции.

Дихотомия применяется тогда, когда требуется высокая надёжность счёта, а скорость сходимости малосущественна.

Один из недостатков дихотомии – сходимость неизвестно к какому корню – характерен почти для всех итерационных методов. Его можно устранить удалением уже найденного корня.

Если $\bar{x}_1$ есть простой корень уравнения и $f(x)$ липшиц-непрерывна, то вспомогательная функция $g(x) = f(x)/(x - \bar{x}_1)$ непрерывна, причём все нули функций $f(x)$ и $g(x)$ совпадают, за исключением $\bar{x}_1$, так как $g(\bar{x}_1) \neq 0$. Если $\bar{x}_1$ - кратный корень уравнения, то он будет нулём $g(x)$ кратности на единицу

меньше; остальные нули обеих функций по-прежнему будут одинаковы.

Поэтому найденный корень можно удалить, т.е. перейти к функции $g(x)$. Тогда отыскание остальных нулей $f(x)$ сведётся к отысканию нулей $g(x)$. Когда мы найдём какой-нибудь корень $\bar{x}_2$ функции $g(x)$, то этот корень тоже можно удалить, вводя новую вспомогательную функцию $\varphi(x) = g(x)/(x - \bar{x}_2)$. Так можно последовательно найти все корни уравнения.

При использовании описанной процедуры необходимо учитывать следующую тонкость. Строго говоря, мы находим лишь приближённое значение корня $\tilde{x} \approx \bar{x}$. А функция $\tilde{g}(x) = f(x)/(x - \tilde{x}_1)$ имеет нуль в точке $\bar{x}_1$ и полюс в близкой к ней точке $\tilde{x}_1$ (рис. 6.2); только на некотором расстоянии от этого корня она близка к $g(x)$. Чтобы это не сказывалось при нахождении следующих корней, нужно вычислять каждый корень с высокой точностью, особенно если он кратный или вблизи него расположен другой корень уравнения.





Рис. 6.2. Иллюстрация возникновения погрешности в окрестности корня

Кроме того, в любом методе окончательные итерации вблизи определяемого корня рекомендуется выполнять не по функциям типа $g(x)$, а по исходной функции $f(x)$. Последние итерации, вычисленные по функции $g(x)$, используются при этом в качестве нулевого приближения. Особенно важно это при отыскании многих корней, так как чем больше корней удалено, тем меньше нули вспомогательной функции $G(x) = f(x) / \prod_i (x - \tilde{x}_i)$ соответствуют остальным нулям функции $f(x)$.

Учитывая эти предосторожности и вычисляя корни с 8 – 10 верными десятичными цифрами, зачастую можно определить десятка два корней, о расположении которых заранее ничего не известно (в том числе корней высокой кратности $p \sim 5$).

6.3. Метод хорд

Логично предположить, что в семействе методов дихотомии можно достичь несколько лучших результатов, если отрезок $[a, b]$ делить точкой C не пополам, а пропорционально величинам ординат $f(a)$ и $f(b)$.



Это означает, что точку C есть смысл находить, как абсциссу точки пересечения оси Ox с прямой, проходящей через точки $A(a, f(a))$ и $B(b, f(b))$, иначе, с хордой дуги графика функции $f(x)$. Такой способ выбора пробной точки, называют *методом хорд* или *методом линейной интерполяции*.

Запишем уравнение прямой проходящей через точки A и B :

$$\frac{y-f(a)}{f(b)-f(a)} = \frac{x-a}{b-a}$$

и, полагая $y=0$, находим:

$$c = a - \frac{f(a)(b-a)}{f(b)-f(a)}.$$

Метод хорд подобно алгоритму метода бисекции строит последовательность вложенных отрезков $[a_n, b_n]$, но в качестве x_n берется точка пересечения хорды с осью абсцисс :

$$x_{n+1} = a_n - \frac{f(a_n)}{f(b_n)-f(a_n)}(b_n - a_n). \quad (6.4)$$

Длина промежутка локализации корня при этом может не стремиться к нулю, поэтому обычно счет ведется до совпадения значений двух очередных приближений с точностью ε . Метод сходится линейно, но близость двух очередных приближений не всегда означает, что корень найден с требуемой точностью. Поэтому, если $0 < m \leq |f'(x)| \leq M, \forall x \in [a, b]$,

рекомендуют продолжать вычисления до совпадения с точностью $\frac{m\varepsilon}{M-m}$.

Более надежным практическим критерием окончания итераций в методе хорд является выполнение неравенства

$$\frac{(x_n - x_{n-1})^2}{|2x_{n-1} - x_n - x_{n-2}|} < \varepsilon. \quad (6.5)$$

6.4. Метод простой итерации

Заменим уравнение $f(x)=0$ эквивалентным ему уравнением

$$x = \varphi(x). \quad (6.6)$$

Это можно сделать разными способами, например, положив $\varphi(x) = x + \tau(x) \cdot f(x)$, где $\tau(x)$ – произвольная непрерывная знакопостоянная функция. Выберем некоторое нулевое приближение x_0 и вычислим дальнейшие приближения по формулам

$$x_{k+1} = \varphi(x_k), \quad k=0,1,2,\dots \quad (6.7)$$

Эти формулы определяют одношаговый общий итерационный метод, называемый *методом простых итераций*. Попробуем понять, каким требованиям должна удовлетворять функция $\varphi(x)$, чтобы последовательность (x_k) , определяемая (6.7) была сходящаяся, и как построить функцию $\varphi(x)$ по функции $f(x)$, чтобы эта последовательность сходилась к корню данного уравнения $f(x)=0$.

Пусть $\varphi(x)$ – непрерывная на некотором отрезке $[a,b]$ функция. Если определяемая формулой (6.7) последовательность (x_k) сходится к некоторому числу ξ , т.е. $\xi = \lim_{k \rightarrow \infty} x_k$, то, переходя к пределу в равенстве (6.7), получаем $\xi = \varphi(\xi)$. Это равенство означает, что ξ – корень уравнения (6.6) и эквивалентного ему исходного уравнения.

Нахождение корня уравнения (6.6) называется задачей о неподвижной точке. Существование и единственность этого корня основывается на принципе сжимающих отображений.

Определение: Непрерывная функция $\varphi(x)$ называется *сжимающей* на отрезке $[a,b]$ если:

- 1) $\varphi(x) \in [a,b], \forall x \in [a,b]$
- 2) $\exists q \in (0,1) : |\varphi(x_2) - \varphi(x_1)| \leq q|x_2 - x_1|, \forall x_1, x_2 \in [a,b]$.

Второе условие для дифференцируемой на $[a,b]$ функции равносильно выполнению неравенства $|\varphi'(x)| \leq q < 1$ на этом отрезке.

Метод простых итераций имеет простую геометрическую интерпретацию: нахождение корня уравнения $f(x)=0$ равносильно обнаружению неподвижной точки функции $x=\varphi(x)$, т.е. точки пересечения графиков функций $y=\varphi(x)$ и $y=x$. Метод простой итерации не всегда обеспечивает сходимость к корню уравнения. Достаточным условием сходимости этого метода является выполнение неравенства $|\varphi'(x)| \leq q < 1$ на отрезке, содержащем корень и все приближения x_k .

Проиллюстрируем (рис. 6.4) геометрически поведение сходящейся итерационной последовательности (x_k) , не отмечая значения $\varphi(x_k)$, а

отражая их на ось абсцисс с помощью биссектрисы координатного угла $y=x$.




Рис.6.4 Сходимость метода простой итерации при $|\varphi'(x)| \leq q < 1$.

Как видно из рис. 6.4, если производная $\varphi'(x) < 0$, то последовательные приближения колеблются около корня, если же производная $\varphi'(x) > 0$, то последовательные приближения сходятся к корню монотонно.

Справедлива следующая теорема о неподвижной точке.

Теорема: Пусть $\varphi(x)$ определена и дифференцируема на $[a, b]$. Тогда, если выполняются условия:

- 1) $\varphi(x) \in [a, b] \quad \forall x \in [a, b]$
- 2) $\exists q : |\varphi'(x)| \leq q < 1 \quad \forall x \in (a, b)$
- 3) $\forall x_0 \in [a, b];$

(6.8)

то уравнение $x = \varphi(x)$ имеет на $[a, b]$ единственный корень ξ и к этому корню сходится определяемая методом простых итераций последовательность (x_k) , начинающаяся с $\forall x_0 \in [a, b]$.

При этом справедливы следующие оценки погрешности:

$$|\xi - x_k| \leq \frac{q}{1-q} |x_k - x_{k-1}| \quad \text{и}$$

$$|\xi - x_k| \leq \frac{q^k}{1-q} |x_1 - x_0|, \quad \text{если } \varphi'(x) > 0$$

$$|\xi - x_k| < |x_k - x_{k-1}|, \quad \text{если } \varphi'(x) < 0$$

(6.9)

Вблизи корня итерации сходятся примерно как геометрическая прогрессия со

знаменателем $q = \left| \frac{x_k - x_{k-1}}{x_{k-1} - x_{k-2}} \right|$. Метод имеет линейную скорость

сходимости. Очевидно, что чем меньше $q \in (0, 1)$, тем быстрее сходимость.

Таким образом, успех метода зависит от того, насколько удачно

выбрано $\varphi(x)$.

Например, для извлечения квадратного корня, т.е. для решения уравнения $x^2 = a$, можно положить $\varphi_1(x) = a/x$ или $\varphi_2(x) = 1/2 \cdot [x + a/x]$ и соответственно написать такие итерационные процессы:

$$x_{k+1} = \frac{a}{x_k} \text{ или } x_{k+1} = \frac{1}{2} \left(x_k + \frac{a}{x_k} \right).$$

Первый процесс вообще не сходится, а второй сходится при любом $x_0 > 0$ и сходится очень быстро, так как $\varphi'(\xi) = 0$. Второй процесс используется при извлечении корня в "запаянных" командах микрокалькуляторов.

Пример 1: Найти методом итерации с точностью $\varepsilon = \frac{1}{2} \cdot 10^{-4}$ наименьший корень уравнения

$$f(x) = x^3 + 3x^2 - 1 = 0.$$

Решение: Отделяем корни:

x	-4	-3	-2	-1	0	1	2	3
$f(x)$	-	-	+	+	-	+	+	+

Очевидно, уравнение имеет три корня, расположенные на отрезках $[-3; -2]$, $[-1; 0]$ и $[0; 1]$. Наименьший находится на отрезке $[-3; -2]$.

Т.к. на этом отрезке $x^2 \neq 0$, разделим уравнение на x^2 . Получим:

$$x + 3 - \frac{1}{x^2} = 0 \Rightarrow x = \frac{1}{x^2} - 3$$

обозначим $\varphi(x) = \frac{1}{x^2} - 3$. Проверим выполнение условия теоремы:

$$\max_{-3 \leq x \leq -2} |\varphi'(x)| = \max_{-3 \leq x \leq -2} \left| -2x^{-3} \right| = \frac{1}{4}, \text{ т.е. } q = \frac{1}{4}$$

Пусть $x_0 = -2.5$, тогда $\delta = \max[-3 - x_0; -2 - x_0] = 0.5$

$$x_1 = \varphi(-2.5) = \frac{1}{(-2.5)^2} - 3 = -2.84 \in [-3, -2]$$

$$|\varphi(x_0) - x_0| = 0.34 < (1 - q)\delta = 0.357$$

Условия сходимости выполнены.

Найдем число итераций для достижения заданной точности $\varepsilon = \frac{1}{2} \cdot 10^{-4}$,

решая относительно n неравенство

$$\frac{\varphi(x_0)-x_0}{1-q} \cdot q^n \leq \varepsilon \Rightarrow \frac{0.34 \cdot 4}{3 \cdot 4^n} \leq \frac{1}{2} 10^{-4} \Rightarrow n \geq 6$$

n	x_n	$\varphi(x_n) = \frac{1}{x^2} - 3$
0	-2.50000	-2.84000
1	-2.84000	-2.87602
2	-2.87602	-2.87910
3	-2.87910	-2.87936
4	-2.87936	-2.87938
5	-2.87938	-2.87938

Замечание: Для нахождения двух других корней исходного уравнения методом простой итерации уже нельзя пользоваться формулой: $x = \frac{1}{x^2} - 3$,

т.к. $\max_{-1 \leq x \leq 0} |\varphi'(x)| = \max_{-1 \leq x \leq 0} |-2x^{-3}| = -\infty, \quad \max_{-1 \leq x \leq 0} |-2x^{-3}| = -\infty.$

Условие сходимости на этих отрезках не выполнено.

Метод релаксации - один из вариантов метода простой итерации, в котором

$$\varphi(x) = x - \tau f(x),$$

т.е. равносильное уравнение имеет вид:

$$x = x - \tau f(x).$$

Приближения к корню вычисляются по формулам

$$x_{n+1} = x_n - \tau f(x_n), \quad (6.10)$$

Если $f'(x) < 0$, то рассматривают уравнение $-f(x) = 0$.

Конкретные рекомендации по выбору τ могут быть даны в случае, когда, например, известны оценки сверху и снизу для производной исходной функции $f'(x)$. Пусть

$$0 \leq \alpha \leq f'(x) \leq \gamma < \infty$$

Параметр τ подбирается таким, чтобы производная $\varphi'(x) = 1 - \tau f'(x)$ в нужной области была малой по модулю.

$$1 - \tau \cdot \gamma \leq \varphi'(x) \leq 1 - \tau \alpha$$

и значит,

$$|\varphi'(x)| \leq q(\tau) = \max \{|1 - \tau \alpha|, |1 - \tau \gamma|\}$$

Отсюда можно гарантировать $q(\tau) < 1$ при $\forall \tau \in (0, \frac{2}{\gamma})$. В частности, при

$$\tau = \frac{1}{\gamma} \text{ справедлива оценка } 0 \leq \varphi'(x) \leq 1 - \frac{\alpha}{\gamma} < 1.$$

Метод имеет линейную скорость сходимости.

Метод простых итераций и почти все другие итерационные методы имеют важное достоинство: в них не накапливаются ошибки вычислений. Ошибка вычислений эквивалентна некоторому ухудшению очередного приближения. Но это отразится только на числе итераций, а не на точности окончательного результата. Подобные методы устойчивы даже по отношению к грубым ошибкам (сбоям ЭВМ), если только ошибка не выбрасывает очередное приближение за пределы области сходимости.

6.5. Метод Ньютона

Этот метод называется также *методом касательных* или *методом линеаризации*. Если x_k есть некоторое приближение к корню ξ , а $f(x)$ имеет непрерывную производную, то уравнение (6.1) можно преобразовать следующим образом:

$$0 = f(\xi) = f[x_k + (\xi - x_k)] = f(x_k) + (\xi - x_k) \cdot f'(\theta).$$

Приближённо заменяя $f'(\theta)$ на значение в известной точке x_k , получим итерационный процесс Ньютона, который определяется линейным уравнением

$$f(x_k) + f'(x_k)(x_{k+1} - x_k) = 0$$

или в явном виде формулой

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}. \quad (6.11)$$




Рис. 6.5 Итерации метода Ньютона

Геометрически этот процесс означает замену на каждой итерации графика $y = f(x)$ касательной к нему (рис. 6.5).

Интуитивно ясно, что сходимость (x_k) к ξ будет тем быстрее, чем ближе функция $f(x)$ к линейной и чем круче ее график пересекает ось абсцисс; так что имеет смысл потребовать от $f(x)$, чтобы по модулю вторая ее производная была ограничена сверху, а первая снизу. Справедлива следующая теорема:

Теорема 1: Пусть функция $f(x)$ удовлетворяет условиям

$$|f'(x)| \geq \alpha > 0,$$

$$|f''(x)| \leq \beta < \infty, \quad \forall x \in [a, b]$$

тогда, если члены последовательности (x_k) , определенные методом Ньютона (6.11), при любом фиксированном $k \in N_0$ принадлежат отрезку $[a, b]$ и эта последовательность сходится на $[a, b]$ к корню ξ уравнения (6.1), то справедливы неравенства ($k \in N_0$)

$$|\xi - x_{k+1}| \leq \frac{\beta}{2\alpha} |\xi - x_k|^2 \quad (6.12)$$

$$|\xi - x_{k+1}| \leq \frac{\beta}{2\alpha} |x_{k+1} - x_k|^2 \quad (6.13)$$

Первое из этих неравенств позволяет считать (6.11) методом второго порядка, а второе являясь апостериорной оценкой погрешности и может служить в качестве критерия прекращения процесса вычислений.

Метод Ньютона можно рассматривать как частный случай метода простых итераций, если положить $\varphi(x) = x - \frac{f(x)}{f'(x)}$.

$$\text{Тогда} \quad \varphi'(x) = 1 - \frac{f(x) \cdot f''(x)}{(f'(x))^2} \quad (6.14)$$

Если ξ есть p -кратный корень уравнения, то вблизи него $f(x) \approx a(x - \xi)^p$; отсюда нетрудно получить $\varphi'(\xi) = (p - 1) / p$, т.е. $0 \leq \varphi'(\xi) < 1$. Для простого корня $p = 1$ и $\varphi'(\xi) = 0$. Используя ранее полученные результаты, можно сформулировать следующие условия сходимости итераций. Если нулевое приближение выбрано достаточно близко к корню, ньютоновские итерации сходятся; скорость сходимости велика для простого корня и соответствует скорости геометрической прогрессии для кратного корня. При произвольном нулевом приближении итерации сходятся, если всюду $|f(x) \cdot f''(x)| < (f'(x))^2$; в противном случае сходимость будет не при любом нулевом приближении, а только в некоторой окрестности корня.

Сходимость вблизи любого корня монотонна, что легко видеть из рис.6.5; но вдали от корня возможна немонотонность итераций. Отметим, что рис.6.5 указывает ещё на одно достаточное условие сходимости итераций. Пусть $f''(x) \geq 0$ справа от корня на отрезке $[\xi, a]$; если x_0 выбрано также справа от корня на этом отрезке, то итерации сходятся, причём монотонно. То же будет, если $f''(x) \leq 0$ слева от корня на отрезке $[b, \xi]$, и на этом же отрезке выбрано нулевое приближение. Таким образом, итерации сходятся к корню с той стороны, с которой $f(x)f''(x) > 0$ и справедлива следующая теорема:

Теорема 2: Пусть на отрезке $[a, b]$ функция $f(x)$ имеет первую и вторую производные постоянного знака и пусть $f(a)f(b) < 0$. Тогда, если точка x_0 выбрана на $[a, b]$ так, что

$$f(x_0)f''(x_0) > 0,$$

то начатая с неё последовательность (x_k) , определяемая методом Ньютона (6.11), монотонно сходится к корню $\xi \in (a, b)$ уравнения (6.1).

Оценим скорость сходимости вблизи простого корня. По определению простых итераций $\xi - x_k = \varphi(\xi) - \varphi(x_{k-1})$. Разлагая правую часть по формуле Тейлора и учитывая равенство $\varphi'(\xi) = 0$, получим

$$x_k - \xi = \frac{1}{2}(x_{k-1} - \xi)^2 \varphi''(\theta), \quad \theta \in (x_{k-1}, \xi),$$

т.е. погрешность очередного приближения примерно равна квадрату погрешности предыдущего приближения. Например, если $(k-1)$ -я итерация давала 3 верных знака, то k -я даст примерно 6 верных знаков, а $(k+1)$ -я – примерно 12 знаков. Это иллюстрирует быструю сходимость вблизи корня. Разумеется, вдали от корня подобные соображения неприменимы.

Если вычисляется корень высокой кратности, то $f'(x)$ в знаменателе формулы становится малой величиной вблизи корня. Чтобы не было потери точности, отношение $f(x)/f'(x)$ нужно вычислять достаточно аккуратно. К остальным погрешностям расчёта метод Ньютона хорошо устойчив.

Для отыскания корней произвольной дифференцируемой функции чаще всего применяют метод Ньютона, особенно если известны разумные начальные приближения для корней.

Модифицированный метод Ньютона применяют, если хотят избежать многократного вычисления производной:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_0)}, \quad f'(x_0) \neq 0. \quad (6.15)$$

Метод имеет линейную скорость сходимости.

6.6. Метод секущих

В методе Ньютона требуется вычислять производную функции, что не всегда удобно. Можно заменить производную первой разделённой разностью, найденной по двум последним итерациям, т.е. заменить касательную секущей. Тогда получим

$$x_{k+1} = x_k - \frac{(x_k - x_{k-1})f(x_k)}{f(x_k) - f(x_{k-1})}. \quad (6.16)$$

Для начала процесса надо задать x_0 и x_1 (рис. 6.6). Такие процессы, где для вычисления очередного приближения нужно знать два предыдущих, называют двухшаговыми.




Рис. 6.6 Итерации методау секущих

Эти, казалось бы, небольшие изменения сильно влияют на характер итераций. Например, сходимость итераций может быть немонотонной не только вдали от корня, но и в малой окрестности корня.

Скорость сходимости можно оценить, разлагая все функции в по формуле Тейлора с центром ξ . Получим с точностью до бесконечно малых более высокого порядка

$$x_{k+1} - \xi = a (x_k - \xi)(x_{k-1} - \xi), \quad a = \frac{f''(\xi)}{2f'(\xi)}. \quad (6.17)$$

Решение этого рекуррентного соотношения естественно искать в виде степенной функции $x_{k+1} - \xi = a^\alpha (x_k - \bar{x})^\beta$. Подставляя эту форму в соотношение, получим

$$\alpha\beta = 1, \quad \beta^2 - \beta - 1 = 0.$$

Только положительный корень β квадратного уравнения соответствует убыванию ошибки, т.е. сходящемуся процессу. Следовательно, в методе секущих

$$x_{k+1} - \xi = a^{1/\beta} (x_k - \xi)^\beta, \\ \beta = \frac{1}{2}(\sqrt{5} + 1) \approx 1,62; \quad 1/\beta \approx 0,62,$$

в то время как в методе Ньютона ошибка убывает быстрее (соответствуя $\beta = 2$). Но в методе Ньютона на каждой итерации нужно вычислять и функцию, и производную, а в методе секущих, – только функцию. Поэтому при одинаковом объёме вычислений в методе секущих можно сделать вдвое больше итераций и получить более высокую точность.

В знаменателе формулы стоит разность значений функции. (Заметим, что приводить формулу к общему знаменателю не следует: увеличится потеря точности в расчётах.). Вдали от корня это несущественно; но вблизи корня, особенно корня высокой кратности, значения функции малы и очень близки. Возникает потеря значащих цифр, что приводит к увеличению погрешности, начиная с некоторой итерации. Это ограничивает точность, с которой можно найти корень; для простых корней это ограничение невелико, а для кратных может быть существенным.

В такой ситуации применяют так называемый приём Гарвика: выбирают не очень малое ε и ведут итерации до выполнения условия

$|x_{n+1} - x_n| < \varepsilon$ и затем продолжают расчёт до тех пор, пока величины $|x_{n+1} - x_n|$ убывают. Первое же возрастание обычно означает начало увеличения погрешности, тогда расчёт прекращают и последнюю итерацию не используют.

6.7. Метод парабол

Если в методе Ньютона вместо производной вычислять разность первого порядка, то это можно рассматривать как замену функции $f(x)$ интерполяционным многочленом первой степени, построенным по узлам x_n, x_{n-1} . Но по трем последним итерациям можно построить интерполяционный многочлен второй степени, т.е. заменить график функции $f(x)$ параболой. Если воспользуемся интерполяционным многочленом Ньютона в конце таблицы, то приравняв его к нулю, получим квадратное уравнение:

$$az^2 + bz + c = 0, \quad (6.18)$$

где

$$z = x - x_n, \quad a = f(x_n, x_{n-1}, x_{n-2}), \quad b = a(x - x_n) + F(x_n, x_{n-1}), \quad c = F(x_n).$$

Тогда, решив уравнение, выбирают меньший по модулю корень, который будет определять новое приближение: $x_{n+1} = x_n + z$.

Очевидно, что для начала расчетов надо определить первые три приближения x_0, x_1 и x_2 . Обычно задают любые три числа из отрезка, на котором ищется корень, но можно определить эти значения и иначе.

Метод парабол относится к трехшаговым методам. По сравнению с ранее изученными он сходится гораздо медленнее, но имеет следующее достоинство: даже если все предыдущие приближения действительны, этот метод может привести к комплексным числам. Во всех же остальных методах для сходимости к комплексному корню требуется задание комплексного начального приближения. Кроме того, метод парабол исключительно эффективен для нахождения всех корней многочлена высокой степени. Интересно заметить, что если $f(x)$ – некоторый многочлен высокой степени, то, хотя сходимость метода не доказана [Касаткин, 1978], при произвольном начальном приближении, на практике итерации всегда сходятся к какому-либо корню. По теореме Горнера для алгебраического многочлена частное $f(x)/(x - x_n)$ будет тоже многочленом, но меньшей степени. Поэтому, последовательно удаляя найденные корни, можно найти все корни многочлена.

6.8. Комбинированный метод (хорд и касательных)

Методы хорд и касательных дают приближения корня с разных сторон. Поэтому их часто применяют в сочетании. Комбинации методов могут быть

различны, но во всех случаях уточнение корня идет быстрее. Рассмотрим несколько вариантов расчетных схем комбинированного метода.




Рис. 6.7 Графическая интерпретация комбинированного метода при $f'(x)f''(x) > 0$

Если $f'(x)f''(x) > 0$ (рис. 6.7), то метод хорд дает приближение корня с недостатком, а метод касательных – с избытком. Если же $f'(x)f''(x) < 0$ (рис. 6.8), то, наоборот, метод хорд дает приближение корня с избытком, а касательных – с недостатком.




Рис. 6.8 Графическая интерпретация комбинированного метода при $f'(x)f''(x) < 0$

Однако во всех случаях истинный корень ξ заключен между промежуточными корнями, получающимися по методу хорд и методу касательных, т.е. выполняется неравенство

$$a < x < \xi < X < b,$$

где x – значение корня с недостатком, а X – с избытком.

Из этих соображений складывается следующая схема вычислений: в первом случае, когда выполняется условие $f'(x)f''(x) > 0$, то

последовательность $\{x_i\}$ (слева) образуется по методу хорд, а последовательность $\{X_i\}$ (справа) образуется по методу касательных:

$$x_i = x_{i-1} - \frac{f(x_{i-1}) \cdot (X_{i-1} - x_{i-1})}{f(X_{i-1}) - f(x_{i-1})}; \quad (6.19)$$

$$X_i = X_{i-1} - \frac{f(X_{i-1})}{f'(X_{i-1})}.$$

Во втором случае, когда $f'(x)f''(x) < 0$, слева лежит приближенное значение корня, найденное по методу касательных, а справа – по методу хорд. При этом расчетные формулы будут несколько иные:

$$x_i = x_{i-1} - \frac{f(x_{i-1})}{f'(x_{i-1})}; \quad (6.20)$$

$$X_i = X_{i-1} - \frac{f(X_{i-1})(x_{i-1} - X_{i-1})}{f(x_{i-1}) - f(X_{i-1})}.$$

Другая вычислительная схема этого же метода дает более быструю сходимость:

$$x_i = x_{i-1} - \frac{f(x_{i-1})(X_{i-1} - x_{i-1})}{f(X_{i-1}) - f(x_{i-1})}; \quad (6.21)$$

$$X_i = x_i - \frac{f(x_i)}{f'(x_i)}.$$

Для начала процесса в этом случае полагают $x_0 = a, X_0 = b$. За приближенное значение после окончания вычислений при любой из рассмотренных схем принимают среднее между X_n и x_n : $\xi \sim 1/2 (X_n + x_n)$.

6.9. Методы ускорения сходимости

В применении к некоторым уравнениям рассмотренные итерационные методы сходятся довольно медленно. В таких случаях особое значение приобретают способы, позволяющие оптимизировать итерационный процесс путем ускорения сходимости метода итераций. Один из наиболее часто употребляющихся алгоритмов – *метод Эйткена ускорения сходимости*.

Главным является требование линейной сходимости основного итерационного метода. В случае методов, имеющих более высокую скорость сходимости, ускорение по Эйткену неэффективно. Метод состоит в том, что после вычисления x_n, x_{n+1} и x_{n+2} производится пересчет по формуле

$$y_{n+1} = x_{n+2} - \frac{(x_{n+2} - x_{n+1})^2}{x_{n+2} - 2x_{n+1} + x_n} \quad (6.22)$$

и значение y_{n+1} принимается за новое приближение. Оно дает лучшее приближение к корню, чем очередная итерация x_{n+2} . На практике не обязательно проводить пересчет на каждой итерации. Обычно он

осуществляется циклически, т.е. через определенное число основных итераций.

С помощью метода Эйткена на основе известных итерационных методов получены новые, обладающие более высокой сходимостью.

Метод Вегстейна – улучшенный по Эйткену метод простой итерации; – записан в виде, позволяющем проверять целесообразность пересчета:

$$y_n = x_{n+1} - \frac{x_{n+1} - x_n}{r_n - 1}, \quad r_n = \frac{x_n - x_{n-1}}{x_{n+1} - x_n}. \quad (6.23)$$

Если r_n почти постоянны, то использование в качестве очередного приближения y_{n+1} сильно ускорит сходимость. Итерации прекращают, если выполняется

$$\frac{(x_{n+2} - x_{n+1})^2}{|x_{n+2} - 2x_{n+1} + x_n|} < \varepsilon.$$

Метод Стеффенсена имеет квадратичную сходимость, – более быструю, чем исходный метод релаксации:

$$x_{n+1} = x_n - \frac{f^2(x_n)}{f(x_n) - f(x_n - f(x_n))}. \quad (6.24)$$

ГЛАВА 7. ЧИСЛЕННОЕ РЕШЕНИЕ СИСТЕМ НЕЛИНЕЙНЫХ УРАВНЕНИЙ

Задача нахождения некоторых или всех решений системы из n нелинейных алгебраических или трансцендентных уравнений с n неизвестными

$$\begin{cases} f_1(x_1, \dots, x_n) = 0 \\ f_2(x_1, \dots, x_n) = 0 \\ \dots\dots\dots \\ f_n(x_1, \dots, x_n) = 0 \end{cases} \quad (7.1)$$

является одной из самых распространенной вычислительных задач. Подобные системы уравнений могут возникать непосредственно, например, при конструировании физических систем, или к таким системам сводится решение других задач. Так, к примеру, при решении задачи минимизации некоторой функции $G(x_1, x_2, \dots, x_n)$ часто необходимо определить те точки, в которых градиент этой функции равен нулю. Полагая $\mathbf{F} = \mathbf{grad} \mathbf{G}$, получаем нелинейную систему.

Векторная запись нелинейных систем. Введем векторные обозначения:

$$\vec{x} = \begin{pmatrix} x_1 \\ \dots \\ x_n \end{pmatrix}, \quad F(\vec{x}) = \begin{pmatrix} f_1(\vec{x}) \\ \dots\dots\dots \\ f_n(\vec{x}) \end{pmatrix} = \begin{pmatrix} f_1(x_1, \dots, x_n) \\ \dots\dots\dots \\ f_n(x_1, \dots, x_n) \end{pmatrix}$$

где $f_1, \dots, f_n$ - заданные, в общем случае, нелинейные вещественные функции n переменных $(x_1, x_2, \dots, x_n)$ и запишем систему уравнений в виде

$$F(\vec{x}) = 0$$

относительно векторной функции F векторного аргумента $\vec{x}$. Таким образом, исходная задача может быть рассмотрена как задача о нулях нелинейного отображения $F: R_n \rightarrow R_n$. Фактически это та же задача, которую рассматривали в предыдущей главе, только в пространствах большей размерности и для ее решения применяются итерационные методы. Например, итерационный процесс, где компоненты приближений определяются из соотношений

является аналогом метода Зейделя в случае системы нелинейных уравнений. Нахождение каждого нового значения x_i^{k+1} требует в общем случае решения нелинейного уравнения

С ОДНИМ НЕИЗВЕСТНЫМ.

Рассмотрим семейство итерационных методов с матричными параметрами A_k . Пусть (A_k) - некоторая последовательность невырожденных вещественных матриц $n \times n$. Тогда, очевидно, последовательность задач

имеет те же решения, что и исходное уравнение (7.1), и для приближенного нахождения этих решений можно формально записать итерационный процесс

Эта формула определяет большое семейство итерационных методов. В случае $A_k \equiv A$ получают метод простых итераций с линейной сходимостью последовательности $(\vec{x}^{(k)})$. Если $A_k = \left[F'(\vec{x}^{(k)}) \right]^{-1}$, получим метод Ньютона (7.7).

7.1. Метод простой итерации

Преобразуем систему уравнений к виду

или иначе, в компактной записи,

где

$$\Phi(\vec{x}) = \begin{pmatrix} \varphi_1(\vec{x}) \\ \varphi_2(\vec{x}) \\ \vdots \\ \varphi_n(\vec{x}) \end{pmatrix} = \begin{pmatrix} \varphi_1(x_1, \dots, x_n) \\ \varphi_2(x_1, \dots, x_n) \\ \vdots \\ \varphi_n(x_1, \dots, x_n) \end{pmatrix}.$$

Это можно сделать, например, умножив (7.1) на некоторую невырожденную матрицу $-A$ и прибавив затем к тождеству $\vec{x} = \vec{x}$.

Получится система

$$\vec{x} = \vec{x} - AF(\vec{x})$$

эквивалентная исходной, где $\Phi(\vec{x}) = \vec{x} - AF(\vec{x})$. Проблема теперь состоит лишь в подборе матричного параметра A такого, при котором $\Phi(\vec{x})$ обладала бы нужными свойствами.

Задача о решении системы нелинейных уравнений в записи (7.4) – это задача о неподвижной точке нелинейного отображения $\Phi: R_n \rightarrow R_n$.

Запишем рекуррентное равенство

$$\vec{x}^{(k+1)} = \Phi(\vec{x}^{(k)}),$$

которое определяет *метод простых итераций* (или метод последовательных приближений). Если начать процесс построения последовательности $(\vec{x}^{(k)})$ с некоторого вектора $\vec{x}^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)})^T$ и продолжить по формуле

$$x_i^{k+1} = \varphi_i(x_1^k, \dots, x_n^k), \quad i=1, \dots, n, \quad (7.5)$$

то при определенных условиях эта последовательность со скоростью геометрической прогрессии будет приближаться к вектору $\vec{x}^*$ – неподвижной точке отображения $\Phi(\vec{x})$.

Справедлива следующая теорема:

Теорема: Пусть функция $\Phi(\vec{x})$ и замкнутое множество $M \subseteq D(\Phi) \subseteq R_n$ таковы, что

1. $\Phi(\vec{x}) \in M \quad \forall \vec{x} \in M$;
2. $\exists q < 1 \quad : \quad \|\Phi(\vec{x}) - \Phi(\vec{x}^*)\| \leq q \|\vec{x} - \vec{x}^*\|.$

Тогда:

- $\Phi(\vec{x})$ имеет в M единственную неподвижную точку $\vec{x}^*$;
- последовательность $(\vec{x}^{(k)})$, определяемая методом простых итераций (7.5) сходится к этой точке;
- справедливы следующие оценки:

$$\|\vec{x}^* - \vec{x}^{(k)}\| \leq \frac{q}{1-q} \|\vec{x}^{(k)} - \vec{x}^{(k-1)}\| \leq \frac{q^k}{1-q} \|\vec{x}^{(1)} - \vec{x}^{(0)}\| \quad \forall k.$$

Можно вместо (7.5) компоненты приближений x_i^{k+1} определять из соотношений

[illegible]

Этот метод также является аналогом метода Зейделя и наряду с (7.5) широко используется на практике, так как они требуют малого объема памяти и просты в реализации.

7.2. Метод Ньютона

Основная идея метода Ньютона состоит в *выделении из уравнений линейных частей*, которые являются главными при малых приращениях аргументов. Это позволяет свести исходную задачу к решению последовательности линейных систем.

Метод Ньютона для n уравнений применим только тогда, когда могут быть вычислены все частные производные функций $f_i(\vec{x})$ по переменным x_j . Пусть $J(\vec{x}^k)$ обозначает матрицу Якоби и ее (i, j) -й элемент есть значение производной в точке $\vec{x}^k$:

$$J(\vec{x}^k) = F'(\vec{x}^k) = \begin{pmatrix} \frac{\partial f_1(\vec{x}^k)}{\partial x_1} & \frac{\partial f_1(\vec{x}^k)}{\partial x_2} & \cdots & \frac{\partial f_1(\vec{x}^k)}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n(\vec{x}^k)}{\partial x_1} & \frac{\partial f_n(\vec{x}^k)}{\partial x_2} & \cdots & \frac{\partial f_n(\vec{x}^k)}{\partial x_n} \end{pmatrix}$$

Как и в одномерном случае ($n = 1$), метод Ньютона начинается с произвольного $\vec{x}$, обозначенного $\vec{x}^0$. Разложим $F(\vec{x})$ в ряд Тейлора:

$$F(\vec{x}) = F(\vec{x}^0) + F'(\vec{x}^0)(\vec{x} - \vec{x}^0) + \dots$$

и, учитывая лишь первые члены, получим линейное приближение к уравнению $F(\vec{x})=0$:

$$F(\vec{x}^0) + F'(\vec{x}^0)(\vec{x} - \vec{x}^0) = 0$$

Естественно записать решение в форме

$$\vec{x} = \vec{x}^0 - F'(\vec{x}^0)^{-1} \cdot F(\vec{x}^0),$$

сильно напоминающей одномерную формулу метода Ньютона. Здесь $F'(\vec{x}^0)^{-1}$ - матрица, обратная матрице Якоби $J(\vec{x}^0)$.

В общем случае, имея $\vec{x}^k$, можно найти $\vec{x}^{k+1}$ по явной формуле метода Ньютона:

$$\vec{x}^{(k+1)} = \vec{x}^{(k)} - \left[F'(\vec{x}^{(k)}) \right]^{-1} \cdot F(\vec{x}^{(k)}). \quad (7.7)$$

Новым, по сравнению со скалярным случаем, фактором, осложняющим применение метода Ньютона к решению n -мерной системы, является необходимость обращения матриц $J(\vec{x}^k)$ на каждой итерации.

Однако, вычисление обратной матрицы $F'(\vec{x}^0)^{-1}$ не является необходимым. Этого можно избежать, если формулу (7.7), требующую обращения матриц на каждой итерации, переписать в неявном виде:

$$F'(\vec{x}^{(k)}) \left(\vec{x}^{(k+1)} - \vec{x}^{(k)} \right) = -F(\vec{x}^{(k)}) \quad (7.8)$$

Применение метода Ньютона в форме (7.8) позволяет найти $\vec{x}^{k+1}$ прибавлением к $\vec{x}^k$ векторной поправки $\vec{r}^{(k)} = \vec{x}^{(k+1)} - \vec{x}^{(k)}$, полученной из решения линейной алгебраической системы

$$F'(\vec{x}^{(k)}) \vec{r}^{(k)} = -F(\vec{x}^{(k)}), \quad (7.9)$$

т.е.

$$\vec{x}^{(k+1)} = \vec{x}^{(k)} + \vec{r}^{(k)}. \quad (7.10)$$

К решению таких линейных систем (7.9) можно привлекать самые разные методы как прямые, так и итерационные в зависимости от размерности n решаемой задачи и особенностей матрицы Якоби.

Сходимость итерационного процесса (7.10) доказывается теоремой, смысл которой сводится к следующему.

Пусть $\vec{x}^*$ - решение системы $F(\vec{x}) = 0$ такое, при котором матрица Якоби $J(\vec{x}^*)$ не вырождена и вторые частные производные функции $F(\vec{x})$ непрерывны вблизи $\vec{x}^*$. Тогда, если $\vec{x}^0$ достаточно близко к $\vec{x}^*$, то итерации по методу Ньютона сходятся. Более того, для $\vec{e}^{(k)} = \vec{x}^* - \vec{x}^{(k)}$ отношение

$$\frac{\|\vec{e}^{(k+1)}\|}{\|\vec{e}^{(k)}\|^2}$$

второго порядка.

Как и в одномерном случае, здесь основная проблема состоит в удачном выборе начального приближения, которое желательно было бы выбрать достаточно близко к предполагаемому решению, чтобы могла начаться быстрая сходимость.

На практике такое приближение достигается или очень большим везением (удачно выбран $\vec{x}^{(0)}$), или мужеством и настойчивостью исследователя (выполняется очень много итераций до того, как процесс начнет быстро сходиться).

Если матрицу Якоби $F'(\vec{x})$ вычислить и обратить лишь один раз – для начального приближения $\vec{x}^{(0)}$, и использовать на последующих итерациях, то получим модифицированный метод Ньютона:

$$\vec{x}^{(k+1)} = \vec{x}^{(k)} - \left[F'(\vec{x}^{(0)}) \right]^{-1} \cdot F(\vec{x}^{(k)}) \quad (7.11)$$

Этот метод требует значительно меньших вычислительных затрат на один итерационный шаг, но итераций при этом может потребоваться значительно больше для достижения заданной точности.

ГЛАВА 8. ЧИСЛЕННОЕ РЕШЕНИЕ ОБЫКНОВЕННЫХ ДИФФЕРЕНЦИАЛЬНЫХ УРАВНЕНИЙ

8.1. Основные понятия

Обыкновенными дифференциальными уравнениями называются уравнения, содержащие одну независимую переменную и одну или несколько производных от искомой функции $u = u(x)$. Например,

$$F(x, u(x), u'(x), u''(x), \dots, u^{(p)}(x)) = 0 \quad (8.1)$$

Здесь x - независимая переменная, $u^{(k)}(x)$ - k -тая производная функции. Порядок дифференциального уравнения определяется наивысшим порядком n , входящей в уравнение производной

Если в уравнении (8.1) старшую производную явно выразить через производные более низкого порядка и независимую переменную, то получаем уравнение, разрешенное относительно старшей производной. Например,

$$u^{(p)}(x) = f(x, u(x), u'(x), u''(x), \dots, u^{(p-1)}(x)). \quad (8.2)$$

Решением дифференциального уравнения называется произвольная функция $\varphi(x)$, которая удовлетворяет этому уравнению, т.е. после подстановки в уравнение превращает его в тождество.

Общее решение обыкновенного дифференциального уравнения n -го порядка, как известно, содержит n произвольных постоянных $C_1, C_2, \dots, C_n$ и имеет вид

$$u = \varphi(x, C_1, C_2, \dots, C_n). \quad (8.3)$$

Частное решение получается из общего (8.3) путем задания определенных значений произвольным постоянным. Например, для уравнения первого порядка $u'(x) = f(x, u(x))$ из общего решения $u = \varphi(x, C)$ частное получается в результате задания произвольной константе C некоторого значения $C = C_0$:

$$u = \varphi(x, C_0)$$

Для выделения частного решения из общего для уравнений высшего порядка нужно задавать столько дополнительных условий, сколько произвольных постоянных в общем решении, т.е. каков порядок уравнения. В качестве дополнительных условий задаются значения искомой функции и ее производных при некоторых x . Конкретная прикладная задача может приводить к дифференциальному уравнению любого порядка, или к системе

уравнений любого порядка. Но известно, что обыкновенное дифференциальное уравнение p -го порядка

$$u^{(p)}(x) = f(x, u, u', u'', \dots, u^{(p-1)})$$

при помощи замены $u^{(k)}(x) = u_k(x)$ можно свести к эквивалентной системе p уравнений первого порядка

$$u'_k(x) = u_{k+1}(x), \quad 0 \leq k \leq p-2$$

$$u'_{p-1}(x) = f(x, u_0, u_1, \dots, u_{p-1})$$

где $u_0(x) = u(x)$. Аналогично, произвольную систему дифференциальных уравнений любого порядка можно заменить некоторой эквивалентной системой уравнений первого порядка. Поэтому в дальнейшем будем рассматривать системы уравнений первого порядка

$$u'_k(x) = f_k(x, u_1, u_2, \dots, u_p), \quad 1 \leq k \leq p, \quad (8.5)$$

записывая их для краткости в векторной форме

$$\vec{u}'(\vec{x}) = \vec{f}(\vec{x}, \vec{u}(\vec{x}))$$

$$\vec{u} = \{u_1, u_2, \dots, u_p\}, \quad \vec{f} = \{f_1, f_2, \dots, f_p\}$$

Известно, что система p -го порядка (8.5) имеет множество решений, которое в общем случае зависит от p параметров $\vec{C} = (C_1, C_2, \dots, C_p)$. Для определения значений этих параметров, т. е. для выделения единственного (или нужного) решения, надо наложить p дополнительных условий на функции $u_k(x)$.

В зависимости от способа задания дополнительных условий для получения частного решения дифференциального уравнения различают три типа задач: задачи Коши, краевые задачи и задачи на собственные значения.

Задача Коши. Если дополнительные условия задаются в одной точке x_0 , то задача называется *задачей Коши*, а эти условия называются начальными условиями. Точка $x = x_0$, в которой они задаются - начальной точкой.

Для системы p -го порядка задача Коши имеет дополнительные условия вида

$$u_k(x_0) = \eta_k, \quad 1 \leq k \leq p. \quad (8.6)$$

Эти условия можно рассматривать как задание координат начальной точки $(x_0, \eta_1, \eta_2, \dots, \eta_p)$ интегральной кривой в $(p+1)$ -мерном пространстве $(x, u_0, u_1, \dots, u_{p-1})$. Решение при этом обычно требуется найти на некотором $x_0 \leq x \leq X$ (или $X \leq x \leq x_0$) так что точку $x = x_0$ можно считать начальной точкой этого отрезка.

Если правые части (8.2) непрерывны и ограничены в некоторой окрестности начальной точки $(\xi, \eta_1, \eta_2, \dots, \eta_p)$, то задача Коши (8.2) – (8.6) имеет решение, но, вообще говоря, не единственное. Если правые части не только непрерывны, но и удовлетворяют условию Липшица по переменным u_k , то решение задачи Коши единственно и непрерывно зависит от координат начальной точки, т. е. задача корректно поставлена. Если вдобавок правые части имеют непрерывные производные по всем аргументам вплоть до q -го порядка, то решение $u(x)$ имеет $q+1$ непрерывную производную по x .

Краевая задача. Если дополнительные условия задаются в нескольких точках (т.е. при разных x), то такая задача называется *краевой*, а дополнительные условия – краевыми или граничными условиями. Обычно граничные условия задаются в точках $x=a$ и $x=b$, являющихся границами области решения дифференциального уравнения.

Например, требуется найти решения уравнения, $u'' + au + bu = cx^2$ на отрезке $0 \leq x \leq 1$, при краевых условиях $u(0) = 1$, $u(1) = 0$.

8.2. О методах решения дифференциальных уравнений

Для решения обыкновенных дифференциальных уравнений применяются аналитические, приближенные и численные методы.

Аналитические методы, позволяющие получать решения дифференциальных уравнений через элементарные или специальные функции в конечном виде, являются эффективным средством исследования уравнений, однако используются лишь для ограниченного класса дифференциальных уравнений. Часто в практических задачах они оказываются неприменимыми.

Приближенные методы используют различные упрощения исходных уравнений – линеаризацию, разложения в ряд по некоторому малому параметру, асимптотические методы. Однако они также имеют ограниченную область применения, хотя и являются эффективным средством исследования решения.

Наиболее мощными и универсальными методами решения обыкновенных дифференциальных уравнений являются численные методы, позволяющие получать решения тогда, когда традиционные, классические методы не помогают. Численные методы – это алгоритмы вычисления приближенных (а иногда – точных) значений искомого решения $u(x)$ на некоторой выбранной сетке значений аргумента. Решение при этом получается в виде таблицы. Численные методы не позволяют найти общего решения уравнения (8.1) или системы (8.5); они могут дать только какое-то частное решение, например, решение задачи Коши (8.5) — (8.6). Это основной недостаток численных методов. Зато эти методы применимы к очень широкому классу уравнений и всем типам задач для них. Поэтому с появлением быстродействующих ЭВМ численные методы решения стали

одним из основных способов решения конкретных практических задач для обыкновенных дифференциальных уравнений.

Численные методы можно применять только к корректно поставленным (или регуляризованным) задачам. Заметим, однако, что для успешного применения численных методов формальное выполнение условий корректности может оказаться недостаточным. Надо, чтобы задача была *хорошо обусловлена*, т. е. малые изменения начальных условий приводили бы к достаточно малому изменению интегральных кривых. Если это условие не выполнено, т. е. задача *плохо обусловлена (слабо устойчива)*, то небольшие изменения начальных условий или эквивалентные этим изменениям небольшие погрешности численного метода могут сильно исказить решение.

В качестве примера плохой обусловленности рассмотрим задачу

$$\begin{aligned}u'(x) &= u - x, \quad 0 \leq x \leq 100 \\ u(0) &= 1\end{aligned}$$

Общее решение уравнения содержит одну произвольную постоянную:

$$u(x, c) = 1 + x + ce^x$$

При указанном начальном условии она равна $c=0$, так что $u(100) = 101$. Однако небольшое изменение начального условия $\bar{u}(0) = 1,000001$ слегка меняет постоянную: $c = 10^{-6}$; тогда $\bar{u}(100) = 2.7 \cdot 10^{37}$, т. е. решение изменилось очень сильно.

Среди численных методов решения обыкновенных дифференциальных уравнений одним из важнейших является *метод конечных разностей*.

Метод конечных разностей основывается:

- на замене непрерывной области определения дискретным множеством точек, называемых сеткой ω_h ;
- на замене непрерывных функций дискретными (сеточными), определенными на введенной сетке изменения аргумента;
- на замене производных, входящих в уравнение, конечными разностями.

В результате вместо дифференциального уравнения получается конечно-разностное уравнение, определенное в узлах разностной сетки. Решение его сводится к отысканию значений сеточной функции в этих узлах.

При использовании приближенных методов основным является вопрос о *сходимости*. Говорят, что *метод сходится в точке x^** , если построена последовательность сеток таких, что $x^* = x_0 + nh$ ($h \rightarrow 0, n \rightarrow \infty$), и $|u(x^*) - y_n| \rightarrow 0$ при $h \rightarrow 0$. Если существует такое $p > 0$, что $|u(x^*) - y_n| = O(h^p)$ при $h \rightarrow 0$, то говорят, что *метод имеет p -ый порядок точности*. Доказано, что при очень общих предположениях порядок точности разностного метода совпадает с порядком аппроксимации дифференциального уравнения (8.1) разностным.

Погрешность метода численного решения определяется нормой разности $u(x_k) - y_k$. *Локальной погрешностью* называют ошибку на данном шаге при условии, что предыдущие значения верны. *Глобальная погрешность* - это разность между вычисленным и точным решением, определяемым начальным условием.

8.3. Численное решение задачи Коши

Рассмотрим задачу Коши для ОДУ первого порядка:

требуется найти решение дифференциального уравнения

$$\frac{du(x)}{dx} = f(x, u), x \in [x_0, b] \quad (8.7)$$

удовлетворяющее начальному условию

$$u(x_0) = u_0. \quad (8.8)$$

Будем считать, что функция $f(x, u(x))$ в некоторой области удовлетворяет всем необходимым требованиям и задача поставлена корректно, т.е. решение задачи Коши для уравнения (8.7) существует и единственно.

В большинстве случаев интегрирование таких уравнений невозможно не только в элементарных функциях, но и в специальных (функции Бесселя, интегралы Френеля и др.). Рассмотрим численные методы, позволяющие вместо точного решения получить приближенное.

Введем по переменному x равномерную сетку ω_h с шагом $h, (h > 0)$, т.е. рассмотрим множество точек $x_k = x_0 + kh, k=1, 2, \dots, n$. Точки x_k называются узлами сетки. Введем сеточные функции $u_k = u(x_k)$, $y_k = y(x_k)$, $f_k = f(x_k, y_k)$, определенные в узлах сетки ω_h . Функции $y_k, f_k = f(x_k, y_k)$ соответствуют численному решению разностной задачи, а $u(x)$ - решению дифференциальной (8.7).

Численное решение задачи состоит в построении таблицы приближенных значений $y_1, y_2, \dots, y_n$ решения уравнения $y(x)$ в точках $x_1, x_2, \dots, x_n$. С этой целью дифференциальное уравнение (8.7) заменяют некоторым разностным

$$y_{k+1} = \Phi(x_k, y_{k+1}, y_k, \dots, y_{k-p+1}),$$

которое необходимо решить на каждом шаге для нахождения y_{k+1} . Выбор функции Φ определяет метод численного решения дифференциального

уравнения: если она не зависит от y_{k+1} , то получают *явный метод* (явную формулу для вычисления y_{k+1}), и *неявный* - в противном случае.

Метод, дающий формулу для вычисления y_{k+1} по M предыдущим значениям $y_k, y_{k-1}, \dots, y_{k-M+1}$, называется *M-шаговым*. Существуют две группы численных методов решения задачи Коши: одношаговые (или методы Рунге -Кутта) и многошаговые разностные методы.

Рассмотрим вначале простейшие методы типа Рунге-Кутта, основанные на замене производной простейшей конечной разностью.

8.3.1. Простейшие методы

Метод Эйлера является самым простым методом типа Рунге-Кутта для решения задачи Коши (8.7)-(8.8). Будем считать, что вычисления проводятся с шагом $h = \frac{b-x_0}{n}$ и целью является построение таблицы:

x	x_0	x_1	$\dots$	$x_n=b$
y	y_0	y_1	$\dots$	$y_n \approx u(b)$

Предположим, что нам известно значение y_k в точке x_k , тогда, применяя к левой части уравнения (8.7) аппроксимацию производной правым разностным отношением первого порядка точности, заменим производную

$u'(x_k)$ выражением $u'(x_k) = \frac{y(x_{k+1}) - y(x_k)}{h} - \frac{y''(\xi_1)}{2}h$, а значение

$u(x_k)$ в $f(x, u) - y_k$. В результате получим разностное уравнение

$$\frac{y_{k+1} - y_k}{h} = f(x_k, y_k) + \frac{y''(\xi_1)}{2}h.$$

Отсюда получаем

$$y_{k+1} = y_k + h \cdot f(x_k, y_k) + \frac{y''(\xi_1)}{2}h^2.$$

Вычисление y_{k+1} явным образом по рекуррентной формуле

$$y_{k+1} = y_k + h \cdot f(x_k, y_k) \quad (8.9)$$

называется *методом Эйлера* решения задачи Коши для ОДУ.

Формула Эйлера легко обобщается на случай нормальных систем ОДУ вида

Приведем без вывода оценку глобальной погрешности приближенного решения $z_k = y_k - u_k$:

$$|z_k| \leq M(x_k) \max_{0 \leq i \leq k} h_i = O(\max h),$$

где $M(x_k) \leq \frac{M_4}{3M_3} e^{M_3(x_k - x_0)},$

в предположении, что $f(x, u)$ непрерывна и ограничена вместе со своими первыми производными: $|f| \leq M_1, |f'_x| \leq M_2, |f'_u| \leq M_3$, (отсюда следует $|u''| \leq M_4 = M_2 + M_1 M_3$).

Пример. Решим методом Эйлера задачу Коши для уравнения

$$u'(x) = x^2 + u^2, 0 \leq x \leq 1, \quad u(0) = 0.$$

В таблице даны численные решения $y(x)$, полученные на сетках с шагами $h = 1, 0.5, 0.25$. Приведено также точное решение $u(x_k)$. Видно, что схема Эйлера для получения удовлетворительной точности требует гораздо более малого шага, чем использованный здесь.

x_k	y_k			$\tilde{y}_k$	u_k
	$h = 1$	$h = 0.5$	$h = 0.25$	$h = 0.25$	
0,00	0,000	0,000	0,000	0,000	0,000
0,25			0,000	0,008	0,005
0,50		0,000	0,016	0,031	0,042
0,75			0,078	0,114	0,143
1,00	0,000	0,125	0,220	0,316	0,350

Геометрическая интерпретация метода




Рис. 8.1

Метод допускает простую геометрическую интерпретацию (рис.8.1).

Предположим, что известна точка (x_k, y_k) на искомой интегральной кривой. Тогда касательная к этой кривой с углом наклона равным $f(x_k, y_k)$, проходящая через точку (x_k, y_k) , определяется уравнением

$$y = y_k + f(x_k, y_k)(x - x_k),$$

Точка пересечения этой касательной с ординатой точки x_{k+1} дает приближенное значение функции y_{k+1} в точке x_{k+1} . Следовательно, метод Эйлера есть линейная экстраполяция функции в точку x_{k+1} по значениям ее и ее производной в точке x_k и формула (8.9) равносильна замене интегральной кривой ломаной линией, представляющей собой отрезки касательных к этой функции в узлах $x_0, x_1, \dots$. То есть метод Эйлера имеет первый порядок аппроксимации.

Неявный метод Эйлера первого порядка Этот метод является простейшим неявным одношаговым методом. Уравнение (8.7) заменяется разностным уравнением

$$\frac{y_{k+1} - y_k}{h} = f(x_{k+1}, y_{k+1}), \quad k = 0, 1, 2, \dots, \quad (8.13)$$

которое неразрешимо относительно y_{k+1} . Для решения этого уравнения можно применить любой метод решения нелинейных уравнений, например метод простой итерации:

$$y_{k+1}^s = y_k + hf(x_k, y_{k+1}^{s-1}), \quad s = 1, 2, \dots \quad y_{k+1}^0 = y_k. \quad (8.14)$$

Обычно достаточно сделать 2-3 итерации. Этот метод абсолютно устойчив.

Метод трапеций (неявный метод второго порядка) получается в результате замены уравнения (8.7) разностным по симметричной схеме

$$\frac{y_{k+1} - y_k}{h} = 0.5[f(x_k, y_k) + f(x_{k+1}, y_{k+1})]. \quad (8.15)$$

Для решения этого уравнения относительно y_{k+1} также можно применить метод простой итерации, используя в качестве начального приближения $y_{k+1}^0 = y_k$.

8.3.2. Методы Рунге - Кутты

В методах Рунге-Кутты используются значения производной $y' = f(x, y)$, вычисленной в нескольких точках плоскости (x, y) . Идея построения явных методов Рунге-Кутты p -го порядка заключается в получении приближений к значениям $u(x_{k+1})$ по формуле вида

$$y_{k+1} = y_k + h \cdot \Phi(x_m, y_m, h), \quad (8.16)$$

где $\Phi(x_m, y_m, h)$ - некоторая функция, приближающая отрезок ряда Тейлора

$$u_{i+1} = u(x_i) + h \cdot u'(x_i) + \frac{1}{2!} h^2 u''(x_i) + \dots + \frac{1}{p!} h^p u^{(p)}(x_i) + O(h^{p+1})$$

до p -го порядка и не содержащая частных производных функции $f(x, y)$, т.е. $\Phi(x_m, y_m, h)$ — некоторое среднее производных в некоторых точках (x, y) . В зависимости от старшей степени h , с которой учитываются члены ряда, можно строить схемы разных порядков точности. Так, полагая в (8.16) $\Phi(x_m, y_m, h) = f(x, y)$, приходим к методу Эйлера, т.е. метод Эйлера можно считать простейшим примером методов Рунге-Кутты, соответствующему случаю $p=1$.

Для построения методов Рунге-Кутты порядка выше первого функцию $\Phi(x_m, y_m, h)$ берут многопараметрической

$$\begin{aligned} \Phi(x_m, y_m, h) &= a_1 f(x_m, y_m) + a_2 f(x_m + b_1 h, y_m + b_2 h k_1) + \\ &\quad + a_3 f(x_m + c_1 h, y_m + c_2 h k_2) + \dots, \\ k_1 &= f(x_m, y_m), \quad k_2 = f(x_m + b_1 h, y_m + b_2 h k_1), \\ k_3 &= f(x_m + c_1 h, y_m + c_2 h k_2), \quad \dots \end{aligned} \quad (8.17)$$

и подбирают ее параметры такими, чтобы достичь максимального совпадения с точным тейлоровским разложением.

Для второго порядка получено однопараметрическое семейство схем вида

$$y_{k+1} = y_k + h \left[(1-\alpha) f_k + \alpha f \left(x_k + \frac{h}{2\alpha}, y_k + \frac{h}{2\alpha} f_k \right) \right] + O(h^3), \quad (8.18)$$

где $0 < \alpha \leq 1$ - свободный параметр.

Локальная погрешность схем (8.18) имеет третий порядок, глобальная – второй; т.е. решение ОДУ, полученное по этой схеме, равномерно сходится к точному решению с погрешностью $O(h^2)$.

Методов Рунге-Кутты второго порядка (как и более высоких порядков) бесконечно много. Наиболее известные из них: исправленный метод Эйлера (метод Эйлера - Коши.) ($\alpha=0.5$) и усовершенствованный (или модифицированный) метод Эйлера ($\alpha = 1$).

Усовершенствованный метод Эйлера. При $\alpha = 1$ формула (8.18) приобретает вид

$$y_{k+1} = y_k + h \left[f \left(x_k + \frac{h}{2}, y_k + \frac{h}{2} f_k \right) \right] + O(h^3) \quad (8.19)$$

Здесь вначале методом Эйлера определяется решение в средней точке интервала $x_{k+\frac{1}{2}} = x_k + \frac{h}{2}$ и вычисляется наклон касательной $f\left(x_{k+\frac{1}{2}}, y_{k+\frac{1}{2}}\right)$ к интегральной кривой в найденной точке. Затем находится решение с учетом этого наклона. Формула (8.19) обобщается на системы ОДУ аналогично схеме Эйлера.

Метод Эйлера - Коши. При $\alpha = 0.5$ формула (8.18) может быть записана в виде

$$y_{k+1} = y_k + \frac{h}{2} \left[f_k + f\left(x_k + h, y_k + hf_k\right) \right] + O(h^3) \quad (8.20)$$

Вначале вычисляется приближённое решение в точке $x_k + h$ по формуле Эйлера, затем в найденной точке определяется наклон интегральной кривой $f(x_{k+1}, y^{\circ})$. После нахождения среднего наклона на шаге h находится уточнённое значение решения.

Реализация этого метода в виде двух этапов называется **методом прогноза и коррекции (метод "предиктор-корректор")**, что подразумевает грубое вычисление решения по формуле низкого порядка, а затем уточнение решения с учётом полученной информации о поведении интегральной кривой. Для прогноза обычно используют одну из следующих формул:

$$y_{k+1}^{(0)} = y_k + hf(x_k, y_k), \quad (8.21)$$

или

$$y_{k+1}^{(0)} = y_{k-1} + 2hf(x_k, y_k). \quad (8.22)$$

В простейшем варианте метода применяется следующий итерационный процесс коррекции:

$$y_{k+1}^{(m)} = y_k + 0.5h \left[f(x_k, y_k) + f(x_{k+1}, y_{k+1}^{(m-1)}) \right], \quad (8.23)$$

где $y_{k+1}^{(m)}$ - m -е приближение решения. Итерационный процесс (8.23) продолжают до тех пор, пока $y_{k+1}^{(m)}$ и $y_{k+1}^{(m-1)}$ не совпадут с заданной точностью. Обычно точность должна достигаться за две-три итерации, иначе надо уменьшить шаг сетки.

В формуле (8.21) используется информация только о последней вычисленной точке, поэтому методом (8.21) - (8.23) можно начинать решение задачи. "Прогноз" по формуле (8.22) более точен, но для ее использования необходимо совершить один шаг каким-либо другим методом, т.к. метод (8.22) - (8.23) является двухшаговым.

Метод Рунге-Кутты четвертого порядка точности. Наиболее часто в вычислительной практике используется следующая формула:

$$y_{i+1} = y_i + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4);$$

$$k_1 = f(x_i, y_i), \quad k_2 = f(x_i + 0,5h, y_i + 0,5hk_1), \quad (8.24)$$

$$k_3 = f(x_i + 0,5h, y_i + 0,5hk_2), \quad k_4 = f(x_i + h, y_i + hk_3).$$

Отметим, что формулы более высокого порядка точности практически не употребляются по причине громоздкости, возрастающей значительно быстрее, чем точность формулы.

Метод Рунге-Кутты-Мерсона. Это модификация метода Рунге-Кутты четвертого порядка, позволяющая оценивать погрешность на каждом шаге и принимать решение об изменении шага:

$$y_{i+1} = y_i + (k_4 + k_5)/2,$$

$$k_1 = h_3 f(x_i, y_i), \quad h_3 = h/3,$$

$$k_2 = h_3 f(x_i + h_3, y_i + k_1), \quad k_3 = hf(x_i + h_3, y_i + 0.5(k_1 + k_2)), \quad (8.25)$$

$$k_4 = k_1 + 4h_3 f(x_i + 0.5h, y_i + 0.375(k_1 + k_3)),$$

$$k_5 = h_3 f(x_i + h, y_i + 1.5(k_4 - k_3)).$$

Формула требует на каждом шаге вычислять правую часть в пяти точках, но за счет одного дополнительного коэффициента по сравнению с классической формулой (8.24) на каждом шаге можно определить погрешность R решения:

$$R = (2k_4 - 3k_3 - k_5)/10.$$

Если абсолютное значение погрешности R больше требуемой, то шаг h уменьшается в два раза, если же $|R| < \varepsilon/32$, то шаг можно удвоить.

Методы Рунге-Кутты имеют ряд важных достоинств:

- 1) обладают достаточно высокой степенью точности (за исключением метода Эйлера);
- 2) являются явными, т.е. значение y_{k+1} вычисляется по ранее найденным значениям;
- 3) допускают использование переменного шага, что дает возможность уменьшить его там, где функция быстро меняется, и увеличить в противном случае;

- 4) являются легко применимыми, так как для начала расчета достаточно выбрать сетку и задать значение $y_0 = f(x_0)$.

8.3.3. Погрешность схем Рунге-Кутта. Правило Рунге оценки погрешности

При решении конкретной задачи возникает вопрос, какой из формул Рунге-Кутта целесообразно пользоваться и как выбирать шаг сетки? Оценки погрешностей различных методов Рунге-Кутта связаны с максимумами модулей соответствующих производных функции $f(x, y)$ достаточно сложными формулами. Учитывая это, *априорной оценкой* точности для выбора шага при практических расчетах не пользуются, а заменяют ее, например, расчетами со сгущением сетки и дают *апостериорную оценку* точности. Шаг сетки следует выбирать настолько малым, чтобы обеспечить требуемую точность расчета, других ограничивающих шаг условий в методе Рунге-Кутта нет.

Если $f(x, y)$ непрерывна и ограничена вместе со своими четвертыми производными, то хорошие результаты дает метод четвертого порядка (8.24). Если правая часть уравнения не имеет указанных производных, то предельный порядок точности метода не может быть реализован. Тогда целесообразно пользоваться методами меньшего порядка точности, равного порядку имеющихся производных, например для дважды непрерывной дифференцируемой функции $f(x, y)$ - формулами (8.19) или (8.20).

Так же, как и при вычислении определённых интегралов, одним из наиболее простых, широко применяемых и достаточно эффективных методов оценки погрешности и уточнения полученного решения является правило Рунге. Для оценки погрешности решения дифференциального уравнения применяют *первую формулу Рунге*:

$$R_0 = \frac{y_h(x) - y_{kh}(x)}{k^p - 1}, \quad (8.26)$$

где $y_h(x)$ - приближенное решение дифференциального уравнения в точке x , полученное с шагом h , $y_{kh}(x)$ - приближенное решение того же уравнения с шагом kh ; p - порядок метода. Формула (8.26) позволяет опытным путём определить шаг h , обеспечивающий требуемую точность решения. Для уточнения решения применима *вторая формула Рунге*

$$\tilde{y}_k = y_k + R_0 \quad (8.27)$$

Отметим еще раз, что выполнить уточнение обычно проще, чем составить и использовать схему высокого порядка точности.

8.3.4. Метод Адамса

Методы Адамса относятся к числу многошаговых: для определения значения приближенного решения в следующем узле требуется знание значений в нескольких предыдущих узлах. При их построении рассматривают правую часть уравнения на интегральной кривой $y = y(x)$. Тогда $f(x, y(x)) = F(x)$ - функция одного аргумента x . Пусть известны значения приближенного решения $y_k, y_{k-1}, \dots, y_{k-m+1}$ в m узлах сетки $x_k, x_{k-1}, \dots, x_{k-m+1}$. Тогда в этих точках известны также значения $f_i = f(x_i, y_i)$ и функцию $F(x)$ можно приближенно заменить интерполяционным многочленом Ньютона:

$$F(x) = F(x_k) + F(x_k, x_{k-1})(x - x_k) + F(x_k, x_{k-1}, x_{k-2})(x - x_k)(x - x_{k-1}) + \dots + F(x_k, x_{k-1}, x_{k-2}, \dots, x_{k-m+1})(x - x_k)(x - x_{k-1}) \dots (x - x_{k-m+2})$$

Для вычисления решения в следующей точке запишем дифференциальное уравнение в интегральной форме

$$u_{k+1} = u_k + \int_{x_k}^{x_{k+1}} f(x, u(x)) dx = \int_{x_k}^{x_{k+1}} F(x) dx \quad (8.28)$$

и подставим в него интерполяционный многочлен. Получим формулу Адамса для переменного шага. Например, при использовании четырех точек получим формулу четвертого порядка точности:

$$y_{k+1} = y_k + h_k F(x_k) + \frac{1}{2} h_k^2 F(x_k, x_{k-1}) + \frac{1}{6} h_k^2 (2h_k + 3h_{k-1}) F(x_k, x_{k-1}, x_{k-2}) + \dots + \frac{1}{12} h_k^2 (3h_k^2 + 8h_k h_{k-1} + 4h_k h_{k-2} + 6h_{k-1}^2 + 6h_{k-1} h_{k-2}) \cdot F(x_k, x_{k-1}, x_{k-2}, x_{k-3}). \quad (8.29)$$

Если отбросить последнее слагаемое, получим формулу третьего порядка точности. Аналогично получаются формулы низших порядков. Формула первого порядка совпадает со схемой ломаных.

Чаще пользуются менее громоздким вариантом формулы (8.29), рассчитанным на постоянный шаг интегрирования. Вместо разделенных разностей вводят конечные разности и получают

$$y_{k+1} = y_k + h_k F_k + \frac{1}{2} h_k^2 \Delta^1 F_k + \frac{5}{12} h_k^3 \Delta^2 F_k + \frac{3}{8} h_k^4 \Delta^3 F_k. \quad (8.30)$$

Метод без изменений переносится на системы уравнений первого порядка.

Явный экстраполяционный метод Адамса

После преобразований из (8.30) получим

$$y_{k+1} = y_k + h(55f_k - 59f_{k-1} + 37f_{k-2} - 9f_{k-3}) / 24. \quad (8.31)$$

Остаточный член формулы (8.31) равен $\frac{251}{750}h^5 F^{(4)}(\xi)$, т.е. формула имеет пятый порядок локальной погрешности и четвертый - глобальной.

Неявный метод Адамса четвертого порядка записывается следующим образом:

$$y_{k+1} = y_k + h(9f_{k+1} + 19f_k - 5f_{k-1} + f_{k-2}) / 24 \quad (8.32)$$

и использует приближенные решения в трех предыдущих узлах. Для его реализации можно применить метод итераций и в качестве начального значения использовать решение, полученное с помощью явного метода Адамса (8.31).

Для начала расчета по формулам (8.31) и (8.32) надо знать значения решения y_0, y_1, y_2, y_3 в четырех точках с достаточной точностью. Обычно эти значения вычисляют методом Рунге-Кутты четвертого порядка. Кроме того, так как эти формулы рассчитаны на постоянный шаг, то при его изменении требуется вычислять значения решения в четырех предыдущих точках заново каким-либо другим методом. Все это делает методы Адамса неудобными для расчетов на ЭВМ.

8.4. Разностные методы численного решения краевых задач для обыкновенных дифференциальных уравнений

Отличие *краевой задачи* от задачи Коши состоит в том, что решение дифференциального уравнения должно удовлетворять граничным условиям, связывающим значения искомой функции более чем в одной точке. Простейшим представителем краевой задачи является двухточечная граничная задача, для которой граничные условия задаются на концах интервала, на котором ищется решение.

Рассмотрим краевую задачу для линейного дифференциального уравнения второго порядка с переменными коэффициентами. Пусть на отрезке $[0; l]$ требуется найти решение уравнения

$$y'' + p(x)y' + q(x)y = r(x), \quad (8.33)$$

удовлетворяющее следующим граничным условиям:

$$\begin{aligned} \alpha_1 y(0) + \beta_1 y'(0) &= \gamma_1, \\ \alpha_2 y(l) + \beta_2 y'(l) &= \gamma_2, \end{aligned} \quad (8.34)$$

где $p(x), q(x), r(x)$ - известные функции, а $\alpha_i, \beta_i, \gamma_i$ - заданные числа, причем $\alpha_i^2 + \beta_i^2 > 0, i = 1, 2$.

Идея разностных методов решения дифференциальных уравнений состоит в замене области непрерывного изменения аргументов областью дискретного их изменения, а дифференциального уравнения - системой линейных или нелинейных уравнений. Решение последней и является приближенным решением задачи для дифференциального уравнения в некоторых точках.

Для решения задачи (8.33) - (8.34) разностным методом введем сетку на отрезке $[0; l]$, т.е. разобьем отрезок на N равных частей и обозначим $h = l / N, x_i = (i - 1)h, i = 1, \overline{N + 1}$. Крайние точки x_1 и x_{N+1} называют *граничными*, остальные - *внутренними узлами сетки*. Множество внутренних узлов сетки обозначим через ω_h , множество граничных узлов - через ω_h^Γ , а множество всех узлов - $\overline{\omega}_h$. Функцию, определенную в узлах сетки, называют *сеточной функцией*.

Будем предполагать, что граничная задача имеет единственное решение $y(x)$, непрерывно дифференцируемое до четвертого порядка включительно. Для аппроксимации дифференциального уравнения и граничных условий представим искомую функцию в виде ряда Тейлора в окрестности узла x_i :

$$y(x) = y(x_i) + (x - x_i)y'(x_i) + (x - x_i)^2 y''(x_i)/2 + \dots \quad (8.35)$$

Пользуясь тремя первыми слагаемыми разложением (8.35) в узлах x_{i-1} и x_{i+1} , получим следующие выражения для аппроксимации первой производной функции $y(x)$:

$$\begin{aligned} y'(x_i) &= \frac{y(x_{i+1}) - y(x_i)}{h} + 0.5hy''(\xi_1), \\ y'(x_i) &= \frac{y(x_i) - y(x_{i-1}))}{h} + 0.5hy''(\xi_2), \end{aligned} \quad (8.36)$$

Если y'' непрерывна на отрезке $[0; l]$, а следовательно, и ограничена, то

$$\begin{aligned} y'(x_i) &= \frac{y(x_{i+1}) - y(x_i)}{h} + O(h), \\ y'(x_i) &= \frac{y(x_i) - y(x_{i-1}))}{h} + O(h). \end{aligned} \quad (8.37)$$

Величину $(y(x_{i+1}) - y(x_i)) / h$ называют *правым разностным отношением*, а величину $(y(x_i) - y(x_{i-1})) / h$ - *левым разностным отношением первого порядка*.

Аналогично можно получить

$$\begin{aligned} y'(x_i) &= \frac{y(x_{i+1}) - y(x_{i-1}))}{2h} + O(h^2), \\ y''(x_i) &= \frac{y(x_{i-1}) - 2y(x_i) + y(x_{i+1}))}{h^2} + O(h^2). \end{aligned} \quad (8.38)$$

Равенства (8.38) справедливы, если существуют и непрерывны $y'''(x)$ и $y^{IV}(x)$ соответственно. Выражение $(y(x_{i+1}) - y(x_{i-1})) / (2h)$ называется *симметричным разностным отношением второго порядка*, а $(y(x_{i-1}) - 2y(x_i) + y(x_{i+1})) / h^2$ — *разностным отношением второго порядка*. Разностные отношения (8.36) - (8.38) называют также *разностными производными*.

Заменяя в уравнении (8.33) производные разностными отношениями (8.38), для внутренних узлов сетки получаем систему:

$$\begin{aligned} &\frac{y(x_{i-1}) - 2y(x_i) + y(x_{i+1}))}{h^2} + p(x_i) \frac{y(x_{i+1}) - y(x_{i-1}))}{2h} + \\ &+ q(x_i)y(x_i) = r(x_i) + R_i, \quad R_i = O(h^2), \quad i = \overline{2, N}. \end{aligned}$$

Отбрасывая остаточный член R_i и обозначая приближенное значение $y(x_i)$ через y_i , получим уравнения, называемые *разностными*:

$$\frac{y_{i-1} - 2y_i + y_{i+1}}{h^2} + p_i \frac{y_{i+1} - y_{i-1}}{2h} + q_i y_i = r_i, \quad i = \overline{2, N}, \quad (8.39)$$

где $p_i = p(x_i)$, $q_i = q(x_i)$, $r_i = r(x_i)$.

Перейдем к аппроксимации граничных условий (8.34). Заменяя входящие в них производные односторонними разностными по формулам (8.37), получим:

$$\begin{aligned} \alpha_1 y(x_1) + \beta_1 \frac{y(x_2) - y(x_1)}{h} &= \gamma_1 + R_1, \\ \alpha_2 y(x_{N+1}) + \beta_2 \frac{y(x_{N+1}) - y(x_N)}{h} &= \gamma_2 + R_{N+1}, \end{aligned}$$

где $R_1 = O(h)$ и $R_{N+1} = O(h)$. Отбрасывая R_1 и R_{N+1} , получим уравнения :

$$\begin{aligned}\alpha_1 y_1 + \beta_1 \frac{y_2 - y_1}{h} &= \gamma_1, \\ \alpha_2 y_{N+1} + \beta_2 \frac{y_{N+1} - y_N}{h} &= \gamma_2.\end{aligned}\tag{8.40}$$

Таким образом, получена разностная аппроксимация исходной задачи разностными уравнениями (8.39), (8.40). Их коэффициенты зависят от шага сетки, поэтому они представляют собой однопараметрическое семейство разностных задач, называемое *разностной схемой*. Порядок аппроксимации разностной схемы определяется максимальной погрешностью R_i . Разностная схема (8.39)-(8.40) аппроксимирует краевую задачу (8.33) - (8.34) с погрешностью первого порядка относительно h .

Разностную схему (8.39) - (8.40) можно записать в виде:

$$\begin{cases} B_1 y_1 + C_1 y_2 = D_1, \\ A_i y_{i-1} + B_i y_i + C_i y_{i+1} = D_i, \quad i = \overline{2, N}, \\ A_{N+1} y_N + B_{N+1} y_{N+1} = D_{N+1}, \end{cases}\tag{8.41}$$

где

$$\begin{aligned}B_1 &= \alpha_1 - \beta_1/h, \quad C_1 = \beta_1/h, \quad D_1 = \gamma_1, \\ A_i &= \frac{1}{h} - \frac{p_i}{2}, \quad B_i = h q_i - 2, \quad C_i = \frac{1}{h} + \frac{p_i}{2}, \quad D_i = h r_i, \quad i = \overline{2, N} \\ A_{N+1} &= -\beta_2/h, \quad B_{N+1} = \alpha_2 + \beta_2/h, \quad D_{N+1} = \gamma_2.\end{aligned}\tag{8.42}$$

Соотношения (8.41) представляют собой систему $(n + 1)$ линейного алгебраического уравнения относительно неизвестных значений y_i функции в узлах сетки.

Для того чтобы получить для краевой задачи (8.33) - (8.34) разностную схему, имеющую второй порядок аппроксимации, достаточно улучшить приближение граничных условий (8.34). На основании разложения в ряд Тейлора (8.35) в окрестности узла x_i можем записать

$$y'(x_1) = \frac{y(x_2) - y(x_1)}{h} - \frac{h}{2} y''(x_1) - \frac{h^2}{6} y'''(\xi).\tag{8.43}$$

Так как функция $y(x)$ есть решение дифференциального уравнения (8.33), то $y''(x_1) = r(x_1) - p(x_1)y'(x_1) - q(x_1)y(x_1)$ или, используя формулу (8.37),

$$y''(x_1) = r(x_1) - p(x_1) \frac{y(x_2) - y(x_1)}{h} - q(x_1)y(x_1) - \frac{h}{2} p(x_1)y''(\xi). \quad (8.44)$$

Учитывая ограниченность функций $p(x)$, $y''(x)$ и $y'''(x)$, из (8.43) - (8.44) нетрудно получить разностное уравнение, аппроксимирующее первое из граничных условий (8.34) с погрешностью второго порядка относительно h :

$$B_1 y_1 + C_1 y_2 = D_1, \quad (8.45)$$

где

$$C_1 = \beta_1 \left(\frac{1}{h} + \frac{p_1}{2} \right), \quad B_1 = \alpha_1 - C_1 + \frac{1}{2} h \beta_1 q_1, \quad (8.46)$$

$$D_1 = \gamma_1 + \frac{1}{2} h \beta_1 r_1.$$

Аналогично можно получить разностное уравнение, аппроксимирующее второе из граничных условий с погрешностью второго порядка:

$$A_{N+1} y_N + B_{N+1} y_{N+1} = D_{N+1}, \quad (8.47)$$

где

$$A_{N+1} = -\beta_2 \left(\frac{1}{h} - \frac{P_{N+1}}{2} \right), \quad B_{N+1} = \alpha_2 - A_{N+1} - \frac{1}{2} h \beta_2 q_{N+1}, \quad (8.48)$$

$$D_{N+1} = \gamma_2 - \frac{1}{2} h \beta_2 r_{N+1}.$$

Разностная схема (8.39), (8.45) и (8.47) аппроксимирует исходную краевую задачу (8.33) - (8.34) с погрешностью второго порядка относительно h . Она также может быть записана как система $(n + 1)$ линейного алгебраического уравнения в виде (8.41). Матрица коэффициентов системы для разностной схемы второго порядка отличается от (8.42) первой и последней строками, которые вычисляются по формулам (8.46) и (8.48).

Системы уравнений (8.9) представляют собой частный случай систем линейных алгебраических уравнений с трехдиагональной матрицей. Такие системы легко решаются *методом прогонки*, который представляет собой вариант метода Гаусса. Будем искать решение системы в виде

$$y_i = u_i + v_i y_{i+1}. \quad (8.49)$$

Прямой ход сводится к последовательному вычислению прогоночных коэффициентов u_i, v_i по рекуррентным формулам

$$v_i = -\frac{C_i}{B_i + A_i v_{i-1}}, \quad u_i = \frac{D_i - A_i u_{i-1}}{B_i + A_i v_{i-1}}, \quad i = 2, N + 1, \quad (8.50)$$

исходя из значений $v_1 = -\frac{C_1}{B_1}$, $u_1 = \frac{D_1}{B_1}$.

Так как $C_{N+1} = 0$, то $y_{N+1} = u_{N+1}$ и остальные неизвестные могут быть вычислены в обратном ходе по рекуррентной формуле (8.49).

Метод прогонки можно применять, если знаменатели выражений (8.50) не обращаются в нуль. Для этого достаточно диагонального преобладания матрицы коэффициентов: $|B_i| > |A_i| + |C_i|$.

Разностную схему называют *устойчивой*, если существует такое h_0 , что при любом $h < h_0$ и произвольных правых частях r_i и граничных условиях y_i разностная задача имеет единственное решение. Свойство устойчивости является внутренним свойством разностной схемы.

Справедлива следующая **основная теорема теории разностных схем**:

Если разностная схема аппроксимирует краевую задачу с p -м порядком относительно h и устойчива, то решение разностной схемы сходится к точному при $h \rightarrow 0$ и погрешность решения имеет тот же порядок.

Для краевой задачи (8.33), (8.34) рассмотренные разностные схемы (8.39), (8.40) и (8.39), (8.45) и (8.47) устойчивы при $q(x) \leq 0$, $\alpha_1 \beta_1 \leq 0$, $\alpha_2 \beta_2 \geq 0$

и $h < h_0 = \min \left(1, \frac{2}{\max_{x \in [0, l]} |p(x)|} \right)$. Поэтому погрешности их решений имеют,

соответственно, первый и второй порядки.

При практической оценке погрешности найденного численного решения обычно проводят вычисления на сгущающихся сетках и используют *первую формулу Рунге*:

$$R_0 = \frac{y_{h,i} - y_{kh,i}}{k^p - 1}, \quad (8.51)$$

где $y_h(x)$ - решение разностной задачи, полученное на сетке с шагом h , $y_{kh}(x)$ - с шагом kh ; p - порядок метода. Формула (8.51) позволяет опытным путём определить шаг h , обеспечивающий требуемую точность решения.

ГЛАВА 9. Численные методы решения экстремальных задач

9.1. Основные понятия

Многие задачи, с которыми приходится сталкиваться в повседневной практике, являются многовариантными и среди множества возможных вариантов необходимо найти наилучшее в некотором смысле решение. Оптимизационные задачи часто возникают непосредственно в контексте поисков наилучшей конструкции какого-либо объекта. Иногда - опосредовано как средство решения какой-то другой задачи. Стандартным примером является сведение решения системы нелинейных уравнений к минимизации функции:

$$\begin{cases} f_1(x_1, x_2, x_n) = 0, \\ \dots\dots\dots \\ f_n(x_1, x_2, x_n) = 0, \end{cases} \Leftrightarrow g(\vec{x}) = \sum_{i=1}^n \left(f_i(x_1, x_2, x_n)^2 \right).$$

Очевидно, что точка минимума функции $g(\mathbf{x})$ с нулевым значением есть решение системы.

Таким образом, решение многих теоретических и практических задач сводится к отысканию экстремума (наибольшего или наименьшего значения) функции нескольких переменных. Оптимизируемую функцию в практических задачах часто называют *целевой функцией*, *функцией качества*, *показателем эффективности*, *критерием оптимальности* и т.п.. Для сокращения записи используют векторное обозначение аргумента: $\mathbf{x} = (x_1, x_2, \dots, x_n)$. Вектор $\mathbf{x}^*$, доставляющий экстремум целевой скалярной функции $f(\mathbf{x})$, называют *оптимальным*.

Задачу поиска экстремума целевой функции называют *задачей на безусловный экстремум*, подчеркивая, что на переменные x_i никакие дополнительные условия и ограничения не накладываются.

В реальных условиях на возможные значения переменных x_i наложены ограничения, обычно вытекающие из законов сохранения, ограниченности наличных ресурсов, возможностей технической реализации, нежелательности каких-либо состояний и т.п.. Математически они записываются в виде системы равенств

$$\varphi_i(x) = 0, \quad i = 1, \dots, m_1$$

и (или) неравенств

$$g_j(x) \leq 0, \quad j = 1, \dots, m_2,$$

определяющих область допустимых значений переменных x_i . В этом случае говорят о задаче на условный экстремум или задаче математического программирования.

Методы решения задач безусловной оптимизации и задач математического программирования существенно различаются с точки зрения их трудоемкости. В связи с этим задачу математического программирования часто пытаются свести к последовательности задач безусловной оптимизации.

Существуют различные типы оптимальных решений - *глобальное, локальное, условное*. (В зависимости от того, определяет ли оно экстремальное решение функции во всей области допустимых значений, в некоторой окрестности решения или на границе области допустимых значений.)

Классический метод решения экстремальных задач основан на дифференциальном исчислении и заключается в следующем:

- поиске всех точек, подозрительных на экстремум. (Ими являются те точки, где выполняется одно из следующих условий: 1) функция терпит разрыв; 2) частные производные равны нулю или не существуют.);
- дополнительном исследовании этих точек и отборе точек локального экстремума;
- определении точки глобального экстремума, учитывая, если необходимо, граничные точки области допустимых значений.

Этот метод имеет очень ограниченное применение из-за трудностей, связанных с вычислением частных производных и решением системы нелинейных уравне-

ний $\frac{\partial f}{\partial x_i} = 0$.

В зависимости от особенностей целевой функции $f(\mathbf{x})$ и функций $g_i(\mathbf{x})$, $\varphi_j(\mathbf{x})$, задающих ограничения, экстремальные задачи делятся на ряд типов. Под *линейным программированием* понимается раздел экстремальных задач, в котором изучаются задачи минимизации (или максимизации) линейных функций на множествах, задаваемых системами линейных равенств и неравенств. Можно показать, что решение задачи линейного программирования лежит в вершине выпуклого многогранника, определяемого ограничениями в n -мерном пространстве. Метод решения состоит в поиске нужной вершины, осуществляемом целенаправленным перемещением от очередной вершины к смежной, и называется *симплекс-методом*.

Численные методы отыскания экстремума в задачах *нелинейного программирования* состоят, как правило, в построении последовательности векторов $\{\mathbf{x}^{(k)}\}$, удовлетворяющих условию: $f(\mathbf{x}^{(0)}) > f(\mathbf{x}^{(1)}) > \dots > f(\mathbf{x}^{(n)})$. Методы построения таких последовательностей называются *релаксационными методами*, или *методами спуска*. В этих методах элементы последовательности $\{\mathbf{x}^{(k)}\}$ вычисляются по формуле

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}, \quad k=0, 1, 2, \dots,$$

где $\mathbf{p}^{(k)}$ - направление спуска; α_k - длина шага в этом направлении. На практике не существует методов нахождения глобального экстремума функции общего вида - сходимость последовательности $\{\mathbf{x}^{(k)}\}$ к глобальному оптимуму не может быть гарантирована без дополнительных сведений относительно природы целевой функции и ограничений. Предположение о том, что локальный экстремум является глобальным, может быть проверено на практике путем использования нескольких начальных векторов $\mathbf{x}^{(0)}$.

Алгоритмы безусловной минимизации делят на классы в зависимости от максимального порядка используемых производных целевой функции. Методы, использующие только значения целевой функции, называют *методами нулевого порядка*. Если, кроме того, требуется вычисление первых производных минимизируемой функции, то имеют место *методы первого порядка*, при необходимости вычисления вторых производных - *методы второго порядка*.

9.2. Безусловная минимизация функций методами нулевого порядка

Общая задача нелинейного программирования без ограничений состоит в минимизации функции $f(\mathbf{x}) = f(x_1, x_2, \dots, x_n)$, заданной во всем n -мерном евклидовом пространстве.

Рассмотрим вначале задачу поиска минимума функции одной переменной, которая является важным элементом различных процедур минимизации функций многих переменных. В общем случае функция может иметь несколько экстремумов в области определения. Задача сводится к их локализации и уточнению значения x_{min} , т.е. построению *интервала неопределенности* $[x_{k-1}, x_k]$, содержащего только одну точку локального минимума x_{min} (функция на каждом таком интервале называется *унимодальной*), и имеющего длину меньше некоторого заданного числа ϵ . Локализация близка по идеологии к задаче отделения корней уравнений и не поддается строгой алгоритмизации. Можно использовать

Метод равномерного поиска. Выбирают точку x_0 , величину постоянного шага h и определяют направление убывания функции. Для этого вычисляют $f(x_0-h)$ и $f(x_0+h)$ и сравнивают со значением $f(x_0)$. Если $f(x_0+h) < f(x_0)$, то дальше двигаются с шагом h , иначе - меняют знак шага на противоположный $h = -h$. Вычисляют значения функции в точках $x_{k+1} = x_k + h$. Как только $f(x_{k+1})$ станет больше $f(x_k)$, поиск прекращают и в качестве отрезка, содержащего точку минимума, выбирают $[x_{k-1}, x_{k+1}]$.

Одним из способов улучшения метода, делающим его пригодным для уточнения значения x_{min} , является осуществление возрастающих по величине шагов до тех пор, пока не будет пройдена точка минимума функции.

Метод поиска с удвоением шага (метод поразрядного приближения). Выбирают x_0 , h и определяют направление убывания функции так же как в предыдущем методе. Если $f(x_0+h) < f(x_0)$, то полагают $x_1 = x_0 + h$, удваивают шаг

$h=2h$. Если на каком-то шаге $f(x_{k+1}) > f(x_k)$, то полагают $h=h/4$, т.е. осуществляют поиск в противоположном направлении с шагом в четыре раза меньше прежнего.

Метод золотого сечения. Пусть $f(x)$ унимодальна $[a, b]$. Начальный отрезок делят точками по правилу "золотого сечения":

$$\begin{aligned} x_1 &= a + (1 - \tau)(b - a), & x_2 &= a + \tau(b - a), \\ \tau &= (1 - \sqrt{5}) / 2 = 0.61803 \end{aligned} \quad (9.1)$$

и вычисляют значения функций $f(x_1)$ и $f(x_2)$. Затем выбирают новый интервал неопределенности - $[a, x_2]$, если $f(x_1) < f(x_2)$ и $[x_1, b]$, если $f(x_1) > f(x_2)$. На выбранном интервале уже есть одна точка, производящая его золотое сечение, и задача состоит в построении второй такой точки. После этого процесс повторяется до тех пор, пока длина интервала неопределенности не станет меньше ε .

Метод гарантирует нахождение минимума в самых неблагоприятных условиях - он применим даже к недифференцируемым функциям и всегда сходится. Если на отрезке $[a, b]$ функция имеет несколько минимумов, то процесс сойдется к одному из них, но не обязательно наименьшему. Метод имеет линейную скорость сходимости и при заданном количестве вычислений функции $f(x)$ приводит к меньшему интервалу неопределенности, чем метод поразрядного приближения.

Метод парабол. Пусть для унимодальной на $[a, b]$ функции известны три значения аргумента x_1, x_2, x_3 таких, что $f(x_2) < f(x_1)$ и $f(x_2) < f(x_3)$ (например, $a, (a+b)/2, b$). Интерполяционный многочлен второго порядка, построенный по этим точкам, имеет минимум в точке

$$x_4 = x_2 - \frac{1}{2} \frac{(x_2 - x_1)^2 (f(x_2) - f(x_3)) - (x_3 - x_2)^2 (f(x_2) - f(x_1))}{(x_2 - x_1)(f(x_2) - f(x_3)) - (x_3 - x_2)(f(x_2) - f(x_1))}.$$

Вычисляют $f(x_4)$, выбирают новый интервал неопределенности:

$$\begin{aligned} [x_1, x_4], & \text{ если } x_2 < x_4 \text{ и } f(x_2) < f(x_4); \\ [x_2, x_3], & \text{ если } x_2 < x_4 \text{ и } f(x_2) > f(x_4); \\ [x_4, x_3], & \text{ если } x_2 > x_4 \text{ и } f(x_2) < f(x_4); \\ [x_1, x_2], & \text{ если } x_2 > x_4 \text{ и } f(x_2) > f(x_4) \end{aligned}$$

и повторяют процесс до тех пор, пока длина интервала неопределенности не станет меньше ε .

Метод имеет квадратичную скорость сходимости вблизи точки экстремума, поэтому его рекомендуется применять после того, как найден отрезок достаточно малой длины, содержащий x_{min} .

Алгоритмы отыскания экстремума функций многих переменных методами нулевого порядка, называемыми также *методами поиска*, заключаются в построении последовательности векторов $\{\mathbf{x}^{(k)}\}$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}, \quad k=0,1,2,\dots, \quad (9.2)$$

где направления спуска $\mathbf{p}^{(k)}$ полностью определяются на основании последовательных вычислений целевой функции $f(\mathbf{x})$. В качестве начальной точки $\mathbf{x}^{(0)}$ может быть выбрана любая, однако необходимо использовать всю имеющуюся информацию о поведении функции $f(\mathbf{x})$, чтобы $\mathbf{x}^{(0)}$ располагалась не слишком далеко от точки минимума.

По существу методы поиска простейшего типа - методы координатного спуска - заключаются в изменении каждый раз одной переменной, тогда как другие остаются постоянными, пока не будет достигнут минимум. Каждый цикл метода состоит из n итераций и направление спуска $\mathbf{p}^{(m)}$ на m -й итерации совпадает с единичным координатным вектором $\mathbf{e}_m = (0, \dots, 0, 1, 0, \dots, 0)$. Различные варианты метода отличаются выбором длины шага. Наиболее простым является

Метод координатного спуска с удвоением шага. Пусть в результате завершения предыдущего цикла получена точка $\mathbf{x}^{(k)}$ и величина шага равна α . На каждой итерации нового цикла проверяют выполнение двух неравенств

$$f(\mathbf{x}^{(k)} + \alpha \mathbf{e}_m) < f(\mathbf{x}^{(k)}), \quad f(\mathbf{x}^{(k)} - \alpha \mathbf{e}_m) < f(\mathbf{x}^{(k)}). \quad (9.3)$$

Итерацию считают удачной, если справедливо выполняется хотя бы одно из неравенств. В этом случае принимают $\mathbf{x}^{(k)} = \mathbf{x}^{(k)} \pm \alpha \mathbf{e}_m$, выбирая соответствующий знак.

Если за один цикл реализовалась хотя бы одна удачная итерация, то величина шага остается постоянной в течение всех итераций следующего цикла. Если же среди n итераций цикла не оказалось ни одной удачной, то шаг уменьшают вдвое и переходят к следующему циклу поиска минимума, повторяя процесс до тех пор, пока величина шага не станет меньше ε .

Метод спирального координатного спуска отличается от предыдущего лишь тем, что величину шага пересматривают при каждой итерации как в методе поразрядного приближения - увеличивают шаг вдвое, если выполняется хотя бы одно из неравенств (9.3), и делят шаг на четыре, если итерация была неудачной.

Метод координатного спуска с выбором шага методами одномерной минимизации. Алгоритм метода заключается в сведении многомерной задачи к последовательности одномерных, которые решаются методами минимизации функции одной переменной, например, методом золотого сечения. При этом точность определения одномерного минимума следует выбирать так, чтобы число требуемых вычислений значений функции на одной итерации не отличалось от n более, чем на порядок. Необходимость повышения точности одномер-

ной минимизации обычно возникает в окрестности точки минимума и при попадании $\mathbf{x}^{(k)}$ в так называемый овраг.

Прямой поиск. Пусть известны начальная (базисная) точка $\mathbf{x}^{(0)}$ и вектор начальных приращений координат $\Delta\mathbf{x}^{(0)}$. Этот алгоритм включает два этапа - "исследующий поиск" в окрестности базисной точки и спуск по выбранному направлению.

На первом этапе циклически изменяют каждую координату базисной точки $x_k^{(0)}$ на величину приращения $\Delta x_k^{(0)}$, т.е. вычисляют координаты двух пробных точек $\mathbf{x}^{(0)} \pm \Delta x_k^{(0)} \mathbf{e}_k$ (как и в методе координатного спуска). Затем сравнивают значения функции в этих точках со значением в базисной точке. Если изменение было удачным, то k -я координата приобретает новое значение, в противном случае она остается неизменной.

После проведения полного цикла "исследующего поиска" на основании удачных изменений переменных определяют направление спуска $\mathbf{p}^{(k)}$, в котором выполняют серию шагов до тех пор, пока уменьшается значение целевой функции. Затем выполняют новый "исследующий поиск". Если он не дает нового удачного направления спуска, то последовательно уменьшают величину приращения Δx_k пока не будет достигнута требуемая точность.

Достоинством метода является простота реализации и то, что он легко учитывает ограничения на область поиска. Недостаток состоит в том, он может оказаться не способным обеспечить продвижение к точке минимума у функций с сильно вытянутыми или изогнутыми линиями уровня.

9.3. Безусловная минимизация функций градиентными методами

Алгоритмы отыскания экстремума функций многих переменных численными методами заключаются в построении последовательности векторов $\{\mathbf{x}^{(k)}\}$, удовлетворяющих условию: $f(\mathbf{x}^{(0)}) > f(\mathbf{x}^{(1)}) > \dots > f(\mathbf{x}^{(n)})$. Элементы последовательности $\{\mathbf{x}^{(k)}\}$ вычисляются по формуле

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}, \quad k=0,1,2,\dots, \quad (9.4)$$

где $\mathbf{p}^{(k)}$ - направление спуска; α_k - длина шага в этом направлении. В качестве начальной точки $\mathbf{x}^{(0)}$ может быть выбрана любая, однако необходимо использовать всю имеющуюся информацию о поведении функции $f(\mathbf{x})$, чтобы $\mathbf{x}^{(0)}$ располагалась не слишком далеко от точки минимума. Затем необходимо выбрать направление, вдоль которого предполагается расположить следующую точку, и величину шага вдоль этого направления. На практике применяются только методы, обладающие сходимостью. Они позволяют за конечное число шагов получить точку минимума или интервал неопределенности, содержащий точку минимума и имеющий длину меньше некоторого заданного числа ε .

Градиентные методы. Как известно, градиент функции в некоторой точке $\mathbf{x}^{(k)}$ направлен в сторону наискорейшего локального возрастания функции. Следовательно, спускаться нужно в направлении, противоположном градиенту. Вектор, противоположный градиенту, называется *антиградиентом*. Выбирая антиградиент в качестве направления спуска, приходят к итерационному процессу вида

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k f'(\mathbf{x}^{(k)}), \quad (9.5)$$

где $f'(\mathbf{x}^{(k)}) \equiv \text{grad } f(\mathbf{x})|_{\mathbf{x}=\mathbf{x}^{(k)}}$.

В координатной форме этот процесс записывается следующим образом:

$$x_i^{(k+1)} = x_i^{(k)} - \alpha_k \frac{\partial f}{\partial x_i} \left(x^{(k)} \right), \quad i = 1, \dots, n.$$

Все методы спуска, в которых вектор $\mathbf{p}^{(k)}$ совпадает с антиградиентом, называются *градиентными методами*. Они отличаются друг от друга только способом выбора шага. В методах с *постоянным шагом* выбирается некоторая постоянная для всех итераций величина шага. Достаточно малый шаг α_k обеспечит убывание функции, однако это может привести к необходимости проводить неприемлемо большое количество итераций для достижения точки минимума. С другой стороны, слишком большой шаг может вызвать неожиданный рост функции либо привести к колебаниям около точки минимума. Из-за отсутствия необходимой информации для выбора величины шага методы с постоянным шагом применяются редко. Более экономичными в смысле количества итераций и надежными являются градиентные методы с *переменным шагом*, среди которых наиболее употребительны метод наискорейшего спуска и метод дробления шага.

Метод наискорейшего спуска. Здесь на каждой итерации величина шага α_k выбирается из условия минимума функции $f(\mathbf{x})$ в направлении движения:

$$f\left(\mathbf{x}^{(k)} - \alpha_k f'(\mathbf{x}^{(k)})\right) = \min_{\alpha \geq 0} f\left(\mathbf{x}^{(k)} - \alpha f'(\mathbf{x}^{(k)})\right), \quad (9.6)$$

т.е. на каждом шаге решается одномерная задача минимизации. Геометрическая интерпретация этого метода достаточно проста.




Рис.9.1

Алгоритм метода наискорейшего спуска состоит в следующем :

- 1) в точке $\mathbf{x}^{(0)}$ вычисляются значения градиента $f'(\mathbf{x}^{(0)})$ и шага α_0 путем решения задачи одномерной минимизации (9.6);
- 2) осуществляется спуск в направлении антиградиента с вы-

бранным шагом α_0 до тех пор, пока значение функции $f(\mathbf{x})$ убывает;
 3) если на некотором m -м шаге $f(\mathbf{x}^{(m)}) > f(\mathbf{x}^{(m-1)})$, то в точке $\mathbf{x}^{(m-1)}$ вычисляются новые значения градиента $f'(\mathbf{x}^{(m-1)})$ и шага α_{m-1} и выполняется переход к п.2.

Если $f(\mathbf{x})$ - ограниченная снизу непрерывно дифференцируемая функция и для некоторой начальной точки $\mathbf{x}^{(0)}$ множество $\{\mathbf{x}: f(\mathbf{x}) < f(\mathbf{x}^{(0)})\}$ также ограничено, то для метода наискорейшего спуска последовательность $\{\mathbf{x}^{(k)}\}$ либо сходится к точке минимума при $k \rightarrow \infty$, либо достигает точки минимума за конечное число шагов.

Метод градиентного спуска с дроблением шага. Выбираем некоторое начальное значение $\mathbf{x}^{(0)}$. Затем выбираем некоторое $\alpha_k = \alpha = \text{const}$ и на каждом шаге процесса (9.5) проверяем условие монотонности $f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)})$. Если это условие нарушается, то α дробим до тех пор, пока монотонность не восстановится. Для окончания счета можно использовать различные критерии, например,

$$|| \text{grad } f(\mathbf{x}^{(k+1)}) || < \varepsilon.$$

Градиентные методы медленно сходятся, когда поверхности уровня $f(\mathbf{x}) = \text{const}$ функции сильно вытянуты. В таких случаях вдоль некоторых направлений функция изменяется гораздо быстрее (иногда на несколько порядков), чем в других направлениях. Это явление называют *эффектом оврагов*. Суть эффекта в том, что небольшие изменения одних переменных приводят к резкому изменению значений функции - эта группа переменных характеризует "склон оврага", а по остальным переменным, задающим направления "дна оврага", функция меняется незначительно. Направление антиградиента в таких случаях существенно отклоняется от направления в точку минимума, что и приводит к замедлению скорости сходимости. Траектория градиентного метода характеризуется довольно быстрым спуском на "дно оврага", и затем медленным зигзагообразным движением в точку минимума.

Скорость сходимости градиентных методов существенно зависит от точности вычислений градиента и величины шага спуска. Потеря точности, а это




Рис. 9.2

обычно происходит в окрестности точек минимума или в овражной ситуации, может вообще нарушить сходимость процесса градиентного спуска. Вследствие перечисленных причин градиентные методы на начальной стадии решения задачи зачастую используются с другими, более эффективными методами. Такими методами являются методы, использующие *сопряженные направления*. (Два вектора $\mathbf{x}$ и $\mathbf{y}$ называются *сопряженными* относительно матрицы A , если скалярное произведение $(\mathbf{x}, A\mathbf{y})$ равно нулю.) Методы обладают замечательным свойством: минимум квадратичной функции n переменных находится ими не более чем за n шагов. При минимизации неквадратичных функций метод из конечного становится итеративным и состоит их циклов по n итераций в каждом.

Метод сопряженных градиентов Флетчера-Ривса. В методе строится последовательность направлений спуска, являющихся линейными комбинациями текущего направления наискорейшего спуска и предыдущих направлений спуска $\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots, \mathbf{p}^{(k-1)}$, причем весовые коэффициенты подбираются так, чтобы сделать направления спусков сопряженными. Алгоритм метода состоит в следующем:

- 1) в точке $\mathbf{x}^{(0)}$ вычисляют антиградиент $\mathbf{p}^{(0)} = -f'(\mathbf{x}^{(0)})$;
- 2) на k -й итерации решают задачу минимизации по α функции $f(\mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)})$, в результате чего определяют величину шага α_k и точку

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)} \quad (k=1, 2, \dots);$$

- 3) вычисляют величины $f(\mathbf{x}^{(k+1)})$ и $f'(\mathbf{x}^{(k+1)})$;
- 4) если $\|f'(\mathbf{x}^{(k+1)})\| < \varepsilon$, то точка $\mathbf{x}^{(k+1)}$ является точкой минимума функции $f(\mathbf{x})$. В противном случае определяем коэффициент β_k из соотношения

$$\beta_k = \begin{cases} \frac{(f'(x^{(k+1)}), f'(x^{(k+1)}) - f'(x^{(k)}))}{(f'(x^{(k)}), f'(x^{(k)}))}, & k \neq 0, n, 2n, \dots \\ 0, & k = 0, n, 2n, \dots \end{cases}$$

Вычисляем новое направление $\mathbf{p}^{(k+1)} = -f'(\mathbf{x}^{(k+1)}) + \beta_k f'(\mathbf{x}^{(k)})$ и осуществляем переход к следующей итерации.

Значения k , для которых $\beta_k = 0$, называются моментами обновления метода. Таким образом, обновление метода, т.е. градиентный спуск и замена $\mathbf{x}^{(0)}$ на $\mathbf{x}^{(k)}$, происходит на каждом цикле метода (через каждые n итераций).

Методы сопряженных направлений – наиболее эффективные из градиентных методов, однако они чувствительны к ошибкам, возникающим в процессе счета. При большом числе переменных погрешность может настолько возрасти, что цикл метода придется повторять даже для квадратичной функции.

9.4. Линейное программирование

9.4.1. Постановка задачи линейного программирования

Рассмотрим постановку задачи линейного программирования на примере задачи планирования производства. Будем считать, что предприятие может производить n различных видов продукции (товаров). Количество j -го продукта, выпускаемого по производственному плану, обозначим через x_j , $j = \overline{1, n}$. В этом случае план производства может быть описан с помощью вектора-столбца $\vec{x} = (x_1, x_2, \dots, x_n)^T$, компоненты которого указывают количество каждого продукта, выпускаемого по данному плану производства. При производстве этих видов продукции предприятие располагает m видами различных ресурсов для организации производственного процесса. Количество ресурса i -го вида, которым располагает предприятие для использования в производственном процессе, обозначим b_i , $i = \overline{1, m}$.

Обозначим через a_{ij} количество i -го ресурса, расходуемого на производство единицы j -го продукта. Матрицу коэффициентов $A_{mn} = [a_{ij}]$, $i = \overline{1, m}$, $j = \overline{1, n}$ называют *технологической*. Если x_j -план выпуска j -го продукта, то $a_{ij} x_j$ - расход i -го ресурса на производство x_j единиц j -й продукции, а сумма

$$a_{i1}x_1 + a_{i2}x_2 + \dots + a_{in}x_n$$

даёт общий расход i -го ресурса на выпуск всех видов продукции. Так как общий расход i -го ресурса не может превышать его объём, равный b_i , то имеем ограничения

$$a_{i1}x_1 + a_{i2}x_2 + \dots + a_{in}x_n \leq b_i, \quad i = \overline{1, m}.$$

Выясним экономический смысл строк и столбцов технологической матрицы A . Затраты всех ресурсов на производство единицы j -го продукта описываются j -м вектором-столбцом матрицы A , а затраты i -го ресурса на производство единицы каждого из n производимых продуктов - i -й строкой матрицы A .

Пусть c_j - цена реализации единицы j -й продукции, тогда $c_j x_j$ - стоимость реализованных x_j единиц j -й продукции, а сумма

$$Z = c_1x_1 + c_2x_2 + \dots + c_nx_n$$

есть прибыль, получаемая при реализации плана производства $\vec{x} = (x_1, x_2, \dots, x_n)^T$.

Основная задача производства - выбор плана производства $\vec{x} = (x_1, x_2, \dots, x_n)$, обеспечивающего получение максимальной прибыли. Функ-

ция Z , определённая равенством (9.8), которую необходимо максимизировать (или минимизировать), называется *целевой функцией*. Так как при выборе плана $\vec{x}$ решается вопрос производить или не производить некоторый продукт и если производить, то в каком количестве (запрещается покупка продукта со стороны с целью его перепродажи), то числа $x_1, x_2, \dots, x_n$ - объёмы выпуска - либо положительные, либо равны нулю, т.е. $x_j \geq 0, j = \overline{1, n}$. Таким образом, окончательно основная задача планирования состоит в выборе плана производства, который обеспечивает получение максимальной прибыли при соблюдении ограничений на ресурсы.

Математически же эта задача состоит в следующем: найти такой вектор $\vec{x} = (x_1, x_2, \dots, x_n)$, удовлетворяющий системе ограничений

$$\begin{aligned} a_{i1}x_1 + a_{i2}x_2 + \dots + a_{in}x_n &\leq b_i, \quad i = \overline{1, m}, \\ x_j &\geq 0, \quad j = \overline{1, n}, \end{aligned} \quad (9.7)$$

при котором целевая функция

$$Z = c_1x_1 + c_2x_2 + \dots + c_nx_n \quad (9.8)$$

имеет максимальное значение. Эта задача и есть задача линейного программирования (ЗЛП). Она допускает запись в векторно-матричной форме:

$$\begin{aligned} \max Z &= \vec{c} \cdot \vec{x} \\ A\vec{x} &\leq \vec{b} \\ x_j &\geq 0, \quad j = \overline{1, n}. \end{aligned} \quad (9.9)$$

ЗЛП – задача выпуклого анализа, т.к. линейные функции являются выпуклыми. Её особенность заключается в том, что $\max Z$ всегда достигается на границе области, образованной ограничениями (т.е. оптимальное решение удовлетворяет хотя бы одному равенству в ограничениях).

9.4.2. Различные формы записи ЗЛП

Общей задачей линейного программирования (ОЗЛП) называют следующую задачу:

$$\max(\min)Z = c_1x_1 + \dots + c_nx_n = \sum_{j=1}^n c_jx_j \quad (9.10)$$

$$\sum_{j=1}^n a_{ij}x_j \leq b_i, \quad i = \overline{1, m_1}, \quad (9.11)$$

$$\sum_{j=1}^n a_{ij}x_j = b_i, \quad i = \overline{m_1 + 1, m_2}, \quad (9.12)$$

$$\sum_{j=1}^n a_{ij}x_j \geq b_i, \quad i = \overline{m_2 + 1, m}, \quad (9.13)$$

$$x_j \geq 0, \quad j = \overline{1, n}, \quad (9.14)$$

где c_j , a_{ij} , b_i заданные действительные числа, (9.10) - целевая функция, (9.11) - (9.14) - ограничения. Вектор $\vec{x} = (x_1, x_2, \dots, x_n)$, координаты которого удовлетворяют ограничениям, называется допустимым решением задачи. Множество допустимых решений называют областью допустимых решений (ОДР). Допустимое решение, на котором целевая функция достигает своего максимума (минимума), называется оптимальным решением или планом задачи ЛП.

Симметричной формой записи ЗЛП называют задачу максимизации целевой функции (9.10) при ограничениях вида (9.11):

$$\begin{aligned} \max Z &= \sum_{j=1}^n c_j x_j \\ \sum_{j=1}^n a_{ij} x_j &\leq b_i, \quad i = \overline{1, m}, \\ x_j &\geq 0, \quad j = \overline{1, n}, \end{aligned}$$

или задачу минимизации целевой функции (9.10) при ограничениях вида (9.13):

$$\begin{aligned} \min Z &= \sum_{j=1}^n c_j x_j \\ \sum_{j=1}^n a_{ij} x_j &\geq b_i, \quad i = \overline{1, m}, \\ x_j &\geq 0, \quad j = \overline{1, n}. \end{aligned}$$

Стандартной задачей будем называть задачу линейного программирования, записанную в виде:

$$\begin{aligned} \max(\min) Z &= \sum_{j=1}^n c_j x_j, \\ \sum_{j=1}^n a_{ij} x_j &= b_i, \quad i = \overline{1, m}, \end{aligned} \quad (9.15)$$

$$x_j \geq 0, \quad j = \overline{1, n},$$

если правые части ограничений неотрицательны.

Канонической формой записи ЗЛП называют стандартную задачу линейного программирования, если в системе ее ограничений-равенств m различных переменных имеют коэффициенты равные единице, а остальные коэффициенты при этих переменных в соответствующих столбцах матрицы системы ограничений равны нулю. Эти переменные в канонической форме задачи линейного программирования называются *базисными* (иногда - *предпочтительными*), остальные переменные - *небазисными*. Небазисные переменные называются *свободными*, они могут принимать произвольные значения из области D допустимых значений. Базисные переменные вычисляются в зависимости от того, какие значения приняли свободные переменные. Отсюда вытекает, что ранг матрицы A системы ограничений равен m .

Задача линейного программирования, имеющая каноническую форму, характеризуется тем, что все ее переменные $x_1, x_2, \dots, x_n$ неотрицательные, правые части уравнений-ограничений тоже неотрицательные числа, а m различных переменных в m различных уравнениях-ограничениях имеют при соответствующих переменных коэффициенты, равные единице.

Например, система ограничений

$$\begin{cases} x_1 & & + a_{1m+1}x_{m+1} & + \dots & + a_{1j}x_j & + \dots & + a_{1n}x_n & = b_1, \\ & x_2 & + a_{2m+1}x_{m+1} & + \dots & + a_{2j}x_j & + \dots & + a_{2n}x_n & = b_2, \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ & & x_m & + a_{mm+1}x_{m+1} & + \dots & + a_{mj}x_j & + \dots & + a_{mn}x_n & = b_m, \end{cases}$$

имеет предпочтительный вид, т.е. записана в канонической форме. Здесь базисными переменными являются $x_1, x_2, \dots, x_m$, а свободными - $x_{m+1}, \dots, x_n$. Придав свободным переменным нулевые значения, получаем неотрицательное решение системы $\vec{x} = (b_1, b_2, \dots, b_m, 0, \dots, 0)$, которое является базисным для этой канонической формы.

Базисное решение называется *вырожденным*, если значение одной или нескольких базисных (зависимых) переменных равны нулю. В частности, базисное решение (9.70) является вырожденным, если $b_i = 0$ хотя бы для одного i .

Метод, разработанный специально для решения задач линейного программирования, применяется к задаче в стандартной форме.

Для того, чтобы общую задачу линейного программирования привести к стандартной форме, в левую часть исходных ограничений вида (9.11) прибавляют дополнительную, так называемую *остаточную* переменную $S_i \geq 0, i = \overline{1, m}$.

В результате получают систему ограничений-равенств:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n + S_1 & = b_1, \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n & + S_2 = b_2, \\ \dots & \dots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n & + S_m = b_m, \end{cases} \quad (9.16)$$

где

$$x_1 \geq 0, x_2 \geq 0, \dots, x_n \geq 0, S_1 \geq 0, S_2 \geq 0, \dots, S_m \geq 0.$$

Остаточной переменной S_i можно дать следующую интерпретацию. Если i -ое ограничение определяет заказ некоторого ресурса, то

$$S_i = b_i - a_{i1}x_1 - a_{i2}x_2 - \dots - a_{in}x_n = b_i - \sum_{j=1}^n a_{ij}x_j \geq 0 \quad (9.17)$$

можно интерпретировать как остаток или неиспользованную часть данного ресурса. Если теперь целевую функцию (9.10), записать в виде

$$Z = c_1x_1 + c_2x_2 + \dots + c_nx_n + 0 \cdot S_1 + 0 \cdot S_2 + \dots + 0 \cdot S_m, \quad (9.18)$$

то получим задачу линейного программирования в канонической форме.

Из левой части исходных ограничений вида (9.13) вычитают так называемую *избыточную* переменную $w_i \geq 0$, $i = \overline{1, m}$.

В результате получают систему ограничений

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n - w_1 & = b_1, \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n & - w_2 = b_2, \\ \dots & \dots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n & - w_m = b_m, \end{cases} \quad (9.19)$$

где

$$x_1 \geq 0, x_2 \geq 0, \dots, x_n \geq 0, w_1 \geq 0, w_2 \geq 0, \dots, w_m \geq 0,$$

и избыточная переменная $w_i \geq 0$ представляет собой объем i -го ресурса, расходованного сверх его запаса b_i :

$$w_i = a_{i1}x_1 + a_{i2}x_2 + \dots + a_{in}x_n - b_i, \quad i = \overline{1, m} \quad (9.20)$$

Приписав нулевые веса избыточным переменным $w_1, w_2, \dots, w_m$, получим целевую функцию

$$Z = c_1x_1 + c_2x_2 + \dots + c_nx_n + 0 \cdot w_1 + 0 \cdot w_2 + \dots + 0 \cdot w_m.$$

Однако, система ограничений не имеет канонического вида, так как дополнительные переменные w_i входят в левую часть уравнения при $b_i \geq 0$ с отрицательными коэффициентами. Поэтому базисное решение $(0, 0, \dots, 0, -b_1, -b_2, \dots, -b_m)$ будет, вообще говоря, недопустимым. В этом случае в систему ограничений (9.19) вводятся добавочные переменные.

Этот способ приведения ОЗЛП к каноническому виду является также и рациональным способом нахождения начального допустимого базисного решения для решения задачи симплекс-методом. Он называется *методом искусственных переменных* и предполагает включение искусственных неотрицательных переменных R_i в левую часть каждого из уравнений, не содержащих "очевидных" начальных базисных переменных. Однако, поскольку такие искусственные переменные не имеют отношения к содержательной стороне задачи, их введение допустимо только в том случае, если соответствующая схема будет обеспечивать получение оптимального решения, в котором все искусственные переменные равны нулю. Добиться этого позволяет введение "штрафа" за использование этих переменных в составе целевой функции: в целевую функцию они включаются с достаточно большим коэффициентом ("штрафом") M . В случае решения задачи на минимум $M > 0$, а при решении задачи на максимум полагают $M < 0$. Полученная задача называется *M -задачей*, соответствующей исходной. Введение искусственных переменных R_i с большим штрафом в случае задачи минимизации целевой функции приводит в итоге к тому (если, конечно, оптимальное решение существует), что искусственные переменные в оптимальном решении обратятся в нуль. Аналогичная ситуация складывается и для задач максимизации целевой функции. Этот факт обосновывается следующей теоремой.

$$Z = C_1x_1 + C_2x_2 + \dots + C_nx_n \quad (9.21)$$

$$\begin{aligned} & a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1, \\ & a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2, \\ & \\ & a_mx_1 + a_mx_2 + \dots + a_mnx_n = b_m, \\ & x_1 \geq 0, x_2 \geq 0, \dots, x_n \geq 0 \end{aligned} \tag{9.22}$$

$$b_1 \geq 0, b_2 \geq 0, \dots, b_m \geq 0.$$

$$\bar{Z} = C_1x_1 + C_2x_2 + \dots + C_nx_n + M(R_1 + R_2 + \dots + R_m) \quad (9.23)$$

9.4.3. Графическое решение задачи линейного программирования

Графический способ является наиболее простым методом решения задачи линейного программирования. Однако его применение возможно лишь для самых простых задач. Метод целесообразно использовать для решения задач с двумя переменными, записанных в симметричной форме, а также для задач со многими переменными при условии, что в их канонической записи содержится не более двух свободных переменных, т.е. число неизвестных n и число независимых уравнений m связаны соотношением $n-m \leq 2$.

1. *Случай двух переменных.* Его рассмотрение проясняет свойства ОЗЛП, делает геометрически наглядным способ решения. Задачу можно записать в следующей симметричной форме:

$$\max Z = c_1x_1 + c_2x_2 \quad (9.28)$$

$$a_{i1}x_1 + a_{i2}x_2 \leq b_i \quad (i = 1, \dots, m), \quad (9.29)$$

$$x_1 \geq 0, \quad x_2 \geq 0$$

Дадим геометрическую интерпретацию элементов этой задачи. Каждое ограничение (9.29) задаёт на плоскости Ox_1x_2 некоторую полуплоскость. Пересечение m полуплоскостей образует область допустимых решений задачи, которая является выпуклой фигурой. На рис 9.3 представлены возможные формы ОДР: выпуклый многоугольник (а), выпуклая многоугольная неограниченная область (б), пустая область (в), луч (г), отрезок прямой (д), единственная точка (е).




Рис. 9.3

Геометрической интерпретацией целевой функции (9.28) на плоскости Ox_1x_2 является семейство параллельных прямых, называемых линиями уровня, каждой из которых отвечает определенное значение параметра Z . Вектор $\vec{c} = (c_1, c_2)$, называемый градиентом функции, перпендикулярен к этим прямым (при условии, что масштабы по осям координат одинаковы). Он указывает направление наискорейшего возрастания параметра Z (целевой функции), а противоположный вектор $-\vec{c}$ - направление наискорейшего убывания. Если в одной и той же системе координат изобразить область допустимых решений и семейство прямых (9.28), то задача определения максимума функции Z сведется к нахождению в допустимой области точки, через которую проходит прямая семейства $Z = \text{const}$, отвечающая наибольшему значению параметра Z (рис.9.3). Искомая точка может быть найдена параллельным перемещением вспомогательной прямой $Z = 0$ в направлении вектора $\vec{c}$. (Минимум целевая функция достигает в противоположной вершине допустимой области). Координаты точек можно определить по чертежу или решить для этого совместно уравнения прямых, пересекающихся в этой точке.

В зависимости от формы области допустимых решений и взаимного расположения области и вектора $\vec{c}$ ЗЛП может иметь единственное решение, бесконечно много решений и не иметь решений. В изображенных на рис.9.4 геометрически задачах:




Рис. 9.4

- (а) - функция достигает минимума в единственной точке A , а максимума - в любой точке отрезка BC ;
- (б) - минимум достигается в точке A , максимума целевая функция не имеет ($Z \rightarrow \infty$);
- (в) - функция не имеет ни максимума, ни минимума.

Рис 9.4 иллюстрирует важнейшее свойство оптимальных решений ЗЛП:

Если ЗЛП имеет решение, то целевая функция достигает экстремального значения в одной из крайних точек (вершин) многогранника ОДР.

2. Задача со многими переменными. Как указывалось выше, задачу можно решить графически, если в ее канонической записи присутствует не более двух свободных переменных, т.е. $n-r \leq 2$, где n - число переменных, r - ранг матрицы

системы ограничительных уравнений задачи. Для этого систему ограничительных уравнений надо решить относительно r неизвестных, т.е. выделить некоторый базис переменных:

$$x_{\text{баз } j} = \sum_{j=1}^n a_{ij} x_{\text{своб } j}, \quad i = 1, \dots, r; \quad j = 1, \dots, n - r.$$

Затем базисные переменные следует опустить и перейти к эквивалентной системе неравенств $\sum_{j=1}^n a_{ij} x_{\text{своб } j} \geq 0$. Целевая функция также должна быть выра-

жена только через свободные переменные. Полученную задачу решают графическим методом и определяют таким образом значения двух компонент оптимального решения. Подставляя их в выражения для базисных переменных, определяют остальные компоненты оптимального решения.

Пример 9.1. Найти максимум функции:

$$Z = 2x_1 + 3x_2 \quad (9.30)$$

на множестве неотрицательных решений системы неравенств

$$\begin{cases} x_1 + x_2 \leq 4, \\ x_1 + 3x_2 \leq 6. \end{cases} \quad (9.31)$$

Допустимое множество D (заштриховано на рис. 9.5) образовано осями Ox и Oy и отрезками прямых $x_1 + x_2 = 4$ и $x_1 + 3x_2 = 6$ и является выпуклым четырехугольником.




Рис. 9.5

Чтобы найти оптимальное решение, следует перемещать прямую $2x_1 + 3x_2 = C$, характеризующую целевую функцию, в направлении вектора $\vec{n}$, т.е. возрастания C , до тех пор, пока она не сместится в область недопустимых значений.

Поскольку функция Z возрастает, если переменные x_1 и x_2 перемещаются в направлении вектора $\vec{n}=(2,3)$, то из рисунка видно, что оптимальному решению соответствует точка пересечения прямых $x_1 + x_2 = 4$ и $x_1 + 3x_2 = 6$ с координатами $x_1 = 3, x_2 = 1$. Максимальное значение целевой функции равно $Z_{max} = 9$.

9.4.4. Симплексный метод решения задачи линейного программирования.

Общая идея симплексного метода решения ЗЛП вытекает из основной теоремы линейного программирования:

Если ЗЛП имеет решение, то целевая функция достигает экстремального значения по крайней мере в одной из крайних точек (вершин) многогранника ОДР.

Отсюда следует, что, перебирая все вершины многогранника ОДР (а их обязательно конечное число), можно найти вершину, в которой целевая функция достигает своего экстремума. Симплексный метод представляет собой метод направленного (а не полного!) перебора вершин с переходом по ребру из одной вершины в другую, соседнюю с ней вершину многогранника ОДР, для которой значение целевой функции больше (если задача решается на максимум). За конечное число шагов оптимальное решение задачи будет найдено, если задача разрешима, или показано, что задача не имеет решения – не ограничена или несовместна.

Каждой вершине многогранника ОДР в алгебраических терминах соответствует неотрицательное базисное решение системы ограничений в каноническом виде, называемое опорным решением (планом). В соответствии с этим алгоритм симплекс - метода состоит из двух частей - подготовительной и основной. Первая заключается в построении некоторого базисного решения системы ограничений - начального опорного плана задачи. Вторая состоит из итераций (шагов) симплекс - метода. На каждом шаге проверяется, является ли текущее опорное решение оптимальным и, если это не так, определяется какую переменную ввести в базис, а какую из него вывести, чтобы прирост значения целевой функции был при этом наибольшим. (Это соответствует выбору лучшей соседней вершины).

Таким образом, симплексный метод предполагает:

- умение находить начальный опорный план;
- наличие признака оптимальности опорного плана;
- умение переходить к нехудшему опорному плану.

Построение начального опорного плана легко осуществляется в двух случаях.

1. Если система ограничений ЗЛП имеет предпочтительный вид, т.е. записана в канонической форме. Тогда в качестве базисных выбирают предпочтительные переменные.

2. Если система ограничений задана в виде $\sum_{j=1}^n a_{ij}x_j \leq b_i, \quad i = \overline{1, m}, \quad b_i \geq 0$ то

задача сводится к канонической добавлением к левым частям системы ограничений дополнительных (остаточных) переменных x_{n+i} ($i = \overline{1, m}$). Эти переменные и образуют базис.

Если система ограничений канонической ЗЛП не имеет предпочтительного вида, то, как отмечалось выше, вводят *искусственный базис* (переменные $x_{n+1}, \dots, x_{n+m}$) и переходят к вспомогательной М-задаче. Если некоторые из уравнений исходной системы ограничений имеют предпочтительный вид, то в них не вводят искусственные переменные. М-задачу решают симплекс-методом и анализируют получившееся оптимальное решение: если все искусственные переменные равны нулю (выведены из базиса), то значения оставшихся переменных дадут оптимальный план исходной задачи; если вывести искусственные переменные не удалось, то исходная задача не имеет решения (система ограничений несовместна).

Симплексная таблица заполняется после построения опорного плана (т.е. преобразования системы ограничений канонической ЗЛП к предпочтительному виду) и имеет следующий вид:

БП	$\vec{C}_B$	$x_1, \dots, x_l, \dots, x_j, \dots, x_k, \dots, x_n$ $c_1, \dots, c_l, \dots, c_j, \dots, c_k, \dots, c_n$	$\vec{b}$	Коэф. при x_k	Отн. b_i/a_{ik}	min b_i/a_{ik}
x_1	c_1	1 ... 0 ... a_{1j} ... a_{1k} ... a_{1n}	b_1	a_{1k}	b_1/a_{1k}	b_l/a_{lk}
...	...	...	...	...	...	
x_i	c_i	0 ... 0 ... a_{ij} ... a_{ik} ... a_{in}	b_i	a_{ik}	b_i/a_{ik}	
...	...	...	...	...	...	
x_l	c_l	0 ... 1 ... a_{lj} ... a_{lk} ... a_{ln}	b_l	a_{lk}	b_l/a_{lk}	
...	...	...	...	...	...	
x_m	c_m	0 ... 0 ... a_{mj} ... a_{mk} ... a_{mn}	b_m	a_{mk}	b_m/a_{mk}	
$\Delta_j = Z_j - c_j$		0 ... 0 ... Δ_j ... Δ_k ... Δ_n Оценки свободных переменных Δ_j своб.	Z_B	Новое базисное решение $x_k = b_l/a_{lk}, \quad x_l = 0$		

Последняя строка таблицы называется *индексной строкой*. В ней записаны оценки свободных переменных, вычисляемые по следующим формулам,

$$\Delta_0 = \sum c_{bi} \beta_i, \quad \Delta_j = \sum c_{bi} \alpha_{ij} - c_j \quad (9.32)$$

которые используются в качестве признака оптимальности опорного плана:


Если для некоторого опорного плана задачи на максимум все оценки свободных переменных неотрицательны, то такой план оптимален. Причём, если все оценки положительны, то найденный оптимальный план единственный. Если же хотя бы одна оценка свободной переменной нулевая, то ЗЛП имеет бесконечное множество оптимальных решений.

Если в индексной строке есть отрицательные оценки, то выбирается наибольшая по абсолютной величине. (Если таких оценок несколько - выбирают любую.) Столбец j_0 , содержащий выбранную оценку, называется *разрешающим столбцом*. Для всех положительных элементов α_{ij} разрешающего столбца вычисляют симплексные отношения $\theta_i = \beta_{ij} / \alpha_{ij}$ и выбирают наименьшее. (Если в разрешающем столбце нет положительных элементов, то целевая функция на ОДР не ограничена.) Строка i_0 , соответствующая выбранному отношению называется *разрешающей строкой*. Элемент, стоящий на пересечении разрешающего столбца и разрешающей строки, называется *разрешающим (или ведущим) элементом*.

Переход к нехудшему опорному плану состоит в преобразовании ЗЛП к новому базису, в котором базисная переменная x_{bi_0} , соответствующая разрешающей строке i_0 , заменена переменной x_{j_0} , соответствующей разрешающему столбцу j_0 . Преобразование выполняется по следующим правилам и завершается заполнением новой симплексной таблицы:

- элементы строки i_0 новой таблицы равны соответствующим элементам разрешающей строки, делённым на разрешающий элемент;
- все элементы столбца j_0 равны нулю, за исключением $\alpha_{i_0 j_0} = 1$;
- чтобы найти любой другой элемент $\underline{\alpha}_{ij}$ новой таблицы (включая элементы индексной строки), нужно воспользоваться правилом прямоугольника по схеме

$$\underline{\alpha}_{ij} = \alpha_{ij} - \alpha_{i j_0} \times \alpha_{i_0 j} \div \alpha_{i_0 j_0}$$



(9.33)

Пример 9.2. Минимизировать функцию

$$Z = 3x_1 + 9x_2 \quad (9.34)$$

при ограничениях

$$\begin{aligned}
x_1 + 4x_2 &\leq 8, \\
x_1 + 2x_2 &\leq 4, \\
x_1 \geq 0, x_2 &\geq 0.
\end{aligned}
\tag{9.35}$$

Введем дополнительные переменные x_3 и x_4 в систему ограничений (9.35) и получим соотношения

$$\begin{aligned}
x_1 + 4x_2 + x_3 &= 8, \\
x_1 + 2x_2 + x_4 &= 4, \\
x_1 \geq 0, x_2 \geq 0, x_3 \geq 0, x_4 &\geq 0.
\end{aligned}
\tag{9.36}$$

По системе (9.36) и целевой функции (9.34), учитывая, что базисными переменными будут x_3 и x_4 , составим начальную симплекс-таблицу (нулевая итерация).

БП	С _Б	x_1 3	x_2 9	x_3 0	x_4 0	$\bar{b}$	Кэф. при x_2	Отн. b_i/a_{i2}	min b_i/a_{i2}
x_3	0	1	4	1	0	8	4	2	
x_4	0	1	2	0	1	4	2	2	2
$\Delta_j = Z_j - c_j$		-3	-9	0	0	$Z_B = 0$	Новое базисное решение $x_4 = 0, x_2 = 2$		

Согласно таблице $x_2 = x_k$ вводится в базисное решение, а $x_4 = x_l$ выводится и становится свободной переменной. Таким образом, $k=2$ - номер переменной, которая вводится в базис, $l=4$ - номер переменной, которая переводится из базиса. Разрешающим элементом является число 2, расположенное на пересечении столбца под переменной x_2 и строки, начинающейся с переменной x_4 .

Разделив элементы второй строки, соответствующей переменной x_4 , на разрешающий элемент 2, получим соответствующую строку $\left(\frac{1}{2}, 1, 0, \frac{1}{2}\right)$ новой симплекс-таблицы, где уже на месте x_4 будет записана новая базисная переменная x_2 . Затем заполним столбец, соответствующий переменной x_2 - $(0, 1, 0)^T$.

Новая таблица примет вид

БП	С _Б	x_1 3	x_2 9	x_3 0	x_4 0	$\bar{b}$	Кэф. при x_k	Отн. b_i/a_{ik}	min b_i/a_{ik}
x_3	0	-1	0	1	-2	0			
x_2	9	$\frac{1}{2}$	1	0	$\frac{1}{2}$	2			
$\Delta_j = Z_j - c_j$		$\frac{3}{2}$	0	0	$\frac{9}{2}$	$Z_B = 9$			

По формуле (9.33) находим

$$a'_{11} = \frac{1}{2} \cdot \begin{vmatrix} 1 & 4 \\ 1 & 2 \end{vmatrix} = -1, \quad a'_{13} = \frac{1}{2} \cdot \begin{vmatrix} 1 & 4 \\ 0 & 2 \end{vmatrix} = 1, \quad a'_{14} = \frac{1}{2} \cdot \begin{vmatrix} 0 & 4 \\ 1 & 2 \end{vmatrix} = -2$$

$$b'_1 = \frac{1}{2} \cdot \begin{vmatrix} b_1 & a_{12} \\ b_2 & a_{22} \end{vmatrix} = \frac{1}{2} \cdot \begin{vmatrix} 8 & 4 \\ 4 & 2 \end{vmatrix} = 0.$$

И, наконец, по формуле (9.32) получаем оценки

$$\Delta'_1 = \frac{1}{2} \begin{vmatrix} -3 & -9 \\ 0 & 2 \end{vmatrix} = \frac{3}{2}, \quad \Delta'_3 = \frac{1}{2} \begin{vmatrix} 0 & -9 \\ 0 & 2 \end{vmatrix} = 0,$$

$$\Delta'_4 = \frac{1}{2} \begin{vmatrix} 0 & -9 \\ 1 & 2 \end{vmatrix} = \frac{9}{2}$$

Так как в последней таблице относительные ячейки неотрицательные, то полученный план является оптимальным. Он имеет вид:

$$x_2 = 2, x_1 = x_3 = x_4 = 0.$$

Пример 9.3 Найти минимум целевой функции

$$Z = 4x_1 + x_2 \tag{9.37}$$

при ограничениях

$$\begin{aligned} 3x_1 + x_2 &= 3, \\ 4x_1 + 3x_2 &\geq 6, \\ x_1 + 2x_2 &\leq 4, \\ x_1 &\geq 0, x_2 \geq 0. \end{aligned} \tag{9.38}$$

Чтобы записать задачу в стандартной форме, введем в левую часть второго ограничения избыточную переменную x_3 , а в левую часть третьего ограничения - остаточную переменную x_4 . В результате получим следующую формулировку исходной задачи: найти минимум целевой функции

$$Z = 4x_1 + x_2$$

при ограничениях

$$\begin{aligned}
3x_1 + x_2 &= 3, \\
4x_1 + 3x_2 - x_3 &= 6, \\
x_1 + 2x_2 + x_4 &= 4, \\
x_1 \geq 0, x_2 \geq 0, x_3 \geq 0, x_4 \geq 0.
\end{aligned}$$

Переменную x_4 можно принять за базисную. Первое и второе уравнение таких переменных в явном виде не содержат. Поэтому введем в каждое из этих уравнений по одной искусственной переменной, обозначив их w_1 и w_2 . Эти переменные введем в целевую функцию, положив на них большой "штраф" $M > 0$. Таким образом, получим следующую M -задачу: найти минимум целевой функции

$$Z = 4x_1 + x_2 + Mw_1 + Mw_2 \quad (9.39)$$

при ограничениях

$$\begin{aligned}
3x_1 + x_2 + w_1 &= 3, \\
4x_1 + 3x_2 - x_3 + w_2 &= 6, \\
x_1 + 2x_2 + x_4 &= 4, \\
x_1 \geq 0, x_2 \geq 0, x_3 \geq 0, x_4 \geq 0, w_1 \geq 0, w_2 \geq 0.
\end{aligned} \quad (9.40)$$

Теперь система (9.40) имеет канонический вид, причем базисными переменными являются $x_4 = 4, w_1 = 3, w_2 = 6$, а свободными переменными - $x_1 = 0, x_2 = 0, x_3 = 0$.

По системе (9.40) и целевой функции (9.39) составим симплекс - таблицу (итерация 0):

БП	С _Б	x_1 4	x_2 1	x_3 0	w_1 M	w_2 M	x_4 0	$\vec{b}$	Коэф. при x_1	Отн. b_i/a_{i1}	Min b_i/a_{i1}
w_1	M	3	1	0	1	0	0	3	3	1	1
w_2	M	4	3	-1	0	1	0	6	4	6/4	
x_4	0	1	2	0	0	0	1	4			
$\Delta_j = Z_j - c_j$		$7M-4$	$4M-1$	$-M$	0	0	0	$9M$	Следующее пробное решение $x_1 = 1, w_1 = 0$		

Так как M - положительное большое число, то максимальной положительной оценкой будет $7M-4$, что соответствует переменной x_1 . Эта переменная вводится в базис, а, так как минимальное отношение b_i/a_{ik} находится в первой строчке, то переменная w_1 выводится из базиса. Таким образом, с учетом ведущего элемента $a_{11}=3$, взятого в рамочку, строим новую симплекс-таблицу (итерация 1), в которой переменную w_1 заменяем на x_1 , первую строку делим на ве-

душий элемент, остальные элементы таблицы находим по формулам (9.32), (9.33):

БП	С _Б	x_1 4	x_2 1	x_3 0	w_1 M	w_2 M	x_4 0	$\bar{b}$	Коеф. при x_2	Отн. b_i/a_{i2}	Min b_i/a_{i2}
x_1	4	1	$\frac{1}{3}$	0	$\frac{1}{3}$	0	0	1	$\frac{1}{3}$	3	
w_2	M	0	$\frac{5}{3}$	-1	$-\frac{4}{3}$	1	0	2	$\frac{5}{3}$	$\frac{6}{5}$	$\frac{6}{5}$
x_4	0	0	$\frac{5}{3}$	0	0	0	1	3	$\frac{5}{3}$	$\frac{9}{5}$	
$\Delta_j = Z_j - c_j$		0	$\frac{5M+1}{3}$	$-M$	$\frac{-7M+4}{3}$	0	0	$2M+4$	Следующее пробное решение $x_1 = \frac{6}{5}$, $w_2 = 0$		

Согласно таблице, в базис следующего решения вводится переменная x_2 и выводится переменная w_2 . Заменяем w_2 на x_2 в левом столбце и строим новую симплекс-таблицу (итерация 2):

БП	С _Б	x_1 4	x_2 1	x_3 0	w_1 M	w_2 M	x_4 0	$\bar{b}$	Коеф. при x_3	Отн. b_i/a_{i3}	Min b_i/a_{i3}
x_1	4	1	0	$\frac{1}{5}$	$\frac{3}{5}$	$-\frac{1}{5}$	0	$\frac{3}{5}$	$\frac{1}{5}$	3	
x_2	1	0	$\frac{5}{3}$	-1	$-\frac{4}{3}$	1	0	$\frac{6}{5}$	—	—	—
x_4	0	0	0	1	1	-1	1	1	1	1	1
$\Delta_j = Z_j - c_j$		0	0	$\frac{1}{5}$	$\frac{-5M+8}{5}$	$\frac{-5M+1}{5}$	0	$\frac{18}{5}$	Следующее пробное решение $x_3 = 1$, $x_4 = 0$		

Заменяв x_4 на x_3 , строим новую симплекс-таблицу (итерация 3):

БП	С _Б	x_1 4	x_2 1	x_3 0	w_1 M	w_2 M	x_4 0	$\bar{b}$	Коеф. при x_k	Отн. b_i/a_{ik}	Min b_i/a_{ik}
----	----------------	------------	------------	------------	--------------	--------------	------------	-----------	--------------------	----------------------	---------------------

x_1	4	1	0	0	$\frac{2}{5}$	0	$-\frac{1}{5}$	$\frac{2}{5}$			
x_2	1	0	1	0	$-\frac{1}{5}$	0	$\frac{3}{5}$	$\frac{9}{5}$			
x_4	0	0	0	1	1	-1	1	1			
$\Delta_j = Z_j - c_j$		0	0	0	$\frac{-5M+7}{5}$	$-M$	$-\frac{1}{5}$	$\frac{17}{5}$			

Так как все относительные оценки в нижней строке таблицы неположительные, то полученное решение $x_1 = \frac{2}{5}, x_2 = \frac{9}{5}, x_3 = 1, w_1 = 0, w_2 = 0, x_4 = 0$ является оптимальным для M -задачи. В силу теоремы 9.1 решение $x_1 = \frac{2}{5}, x_2 = \frac{9}{5}$ является оптимальным для исходной задачи, при этом минимальное значение целевой функции $Z = 4x_1 + x_2$ равно $\frac{17}{5}$.

9.4.5. Прямая и двойственная задачи линейного программирования

Постановку двойственной задачи линейного программирования рассмотрим на примере задачи планирования производства. Рассмотрим задачу об использовании четырех видов сырья S_1, S_2, S_3, S_4 для изготовления двух видов $П_1$ и $П_2$. Запасы сырья и его расход задаются таблицей:

Виды сырья	Виды продукции		Запасы сырья
	$П_1$	$П_2$	
S_1	2	3	19
S_2	2	1	13
S_3	0	3	15
S_4	3	0	18
Доход	7	5	

Математическая формулировка этой задачи состоит в том, чтобы среди неотрицательных решений системы неравенств:

$$\begin{aligned}
 2x_1 + 3x_2 &\leq 19, \\
 2x_1 + x_2 &\leq 13, \\
 0x_1 + 3x_2 &\leq 15, \\
 3x_1 + 0x_2 &\leq 18
 \end{aligned}
 \tag{9.41}$$

выбрать такое, при котором целевая функция

$$Z = 7x_1 + 5x_2 \quad (9.42)$$

принимает наибольшее значение. Здесь x_1 и x_2 - объемы выпускаемой продукции Π_1 и Π_2 .

Поставим теперь следующий вопрос. Как оценить стоимость сырья в зависимости от доходов предприятия при изготовлении или выпуске необходимых объемов продукции? Заметим только, что в этом вопросе речь идет о стоимости сырья при его приобретении; которая по существу включена в доходы при реализации готовой продукции.

Нас, вообще говоря, с экономической точки зрения интересует относительная стоимость сырья с точки зрения доходов, получаемых предприятием при переработке этого сырья в продукцию Π_1 и Π_2 .

Предположим, что некоторая организация желает приобрести сырье, которым располагает предприятие. Возникает вопрос: по какой цене эта организация стала бы покупать это сырье? Обозначим через y_1, y_2, y_3, y_4 соответственно цену единицы сырья S_1, S_2, S_3, S_4 .

Производство единицы продукции Π_1 приносит предприятию 7 единиц дохода. При этом расходуется 2 единицы сырья S_1 , 2 единицы сырья S_2 , 0 единиц сырья S_3 и 3 единицы сырья S_4 . Выручка от продажи всего сырья, расходуемого на единицу продукции Π_1 составит

$$2y_1 + 2y_2 + 0y_3 + 3y_4$$

Ясно, что предприятие не станет продавать сырье, если выручка от этой продажи окажется меньше тех доходов, которые оно получит при переработке сырья, т.е. 7 единиц. Таким образом, должно выполняться неравенство

$$2y_1 + 2y_2 + 0y_3 + 3y_4 \geq 7$$

Аналогичные рассуждения в отношении единицы продукции Π_2 приводят к следующему неравенству

$$3y_1 + 1y_2 + 3y_3 + 0y_4 \geq 5$$

С другой стороны, общая стоимость Z^* всех запасов сырья, приобретенного организацией, составит

$$Z^* = 19y_1 + 13y_2 + 15y_3 + 18y_4 \quad (9.43)$$

Ясно, что организация стремится приобрести сырье по возможности дешевле, т.е. при $\min Z^*$.

Таким образом, мы пришли к следующей задаче линейного программирования: требуется среди всех неотрицательных решений системы неравенств

$$\begin{aligned} 2y_1 + 2y_2 + 0y_3 + 3y_4 &\geq 7, \\ 3y_1 + 1y_2 + 3y_3 + 0y_4 &\geq 5 \end{aligned} \quad (9.44)$$

[illegible]

Минимизация функции Z^* равносильна максимизации функции:

$$Z^* = -b_1 y_1 - b_2 y_2 - \dots - b_m y_m \quad (9.50)$$

Теперь задача 1* приняла вид задачи 1. Следовательно, по определению двойственной к задаче (9.49), (9.50) является следующая задача: минимизировать функцию:

$$-Z = -c_1x_1 - c_2x_2 - \dots - c_nx_n \quad (9.51)$$

на множестве неотрицательных решений системы неравенств:

$$\begin{aligned} & -a_{11}x_1 - a_{12}x_2 - \dots - a_{1n}x_n \geq -b_1, \\ & -a_{21}x_1 - a_{22}x_2 - \dots - a_{2n}x_n \geq -b_2, \\ & \dots\dots\dots, \\ & -a_{m1}x_1 - a_{m2}x_2 - \dots - a_{mn}x_n \geq -b_m \end{aligned} \tag{9.52}$$

Минимизация функции (9.51) равносильна максимизации функции (9.45). Если каждое из неравенств системы (9.52) умножим на (-1) , то получим систему ограничений (9.46). Таким образом, если построить задачу двойственную к двойственной, то будет получена исходная задача (9.45), (9.46). Это обстоятельство позволяет говорить о паре двойственных задач, не выделяя среди них прямой и двойственной.

Для запоминания того, как формируется двойственная и исходная задачи, удобно прибегнуть к помощи следующей таблицы:

	Прямая задача						
Двойственная	Переменные	$x_1 \geq 0 \quad x_2 \geq 0 \quad \dots \quad x_n \geq 0$				Неравенства	Свободные члены
	$y_1 \geq 0$	a_{11}	a_{12}	$\dots$	a_{1n}	$\leq$	b_1
	$y_2 \geq 0$	a_{21}	a_{22}	$\dots$	a_{2n}	$\leq$	b_2
	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
	$y_m \geq 0$	a_{m1}	a_{m2}	$\dots$	a_{mn}	$\leq$	b_m

Неравенства	$\geq \quad \geq \quad \dots \quad \geq$		$\min Z^* = \sum_{i=1}^m b_i y_i$
Свободные члены	$c_1 \quad c_2 \quad \dots \quad c_n$	$\min Z = \sum_{j=1}^n c_j x_j$	

Пример 9.4. Построить задачу, двойственную к задаче, рассмотренной ранее в примере 1: найти максимум функции:

$$Z = 2x_1 + 3x_2 \quad (9.53)$$

на множестве неотрицательных решений системы неравенств:

$$\begin{aligned} x_1 + x_2 &\leq 4, \\ x_1 + 3x_2 &\leq 6. \end{aligned} \quad (9.54)$$

Согласно определению, двойственной для этой задачи будет следующая задача: найти минимум функции

$$Z^* = 4y_1 + 6y_2 \quad (9.55)$$

на множестве неотрицательных решений системы неравенств:

$$\begin{aligned} y_1 + y_2 &\geq 2, \\ y_1 + 3y_2 &\geq 3. \end{aligned} \quad (9.56)$$

Основная задача решена графически и допустимое множество D изображено на рис. 9.5, а допустимое множество двойственной задачи (9.55), (9.56) - на рис. 9.6. Как видно из рисунков, оптимальным решением задачи (9.53), (9.54) является $x_1 = 3$, $x_2 = 1$, максимальное значение целевой функции (9.53) $Z_{\max} = 9$. Для двойственной задачи (9.55), (9.56) оптимальным решением является $y_1 = 3/2$, $y_2 = 1/2$, минимальное значение целевой функции (9.55) $Z^*_{\min} = 9$. Таким образом $Z_{\max} = Z^*_{\min}$. Как будет установлено ниже, этот факт не является случайным.




Рис. 9.6

Сравнив теперь задачу (9.41) и (9.42) об использовании сырья с задачей (9.43) и (9.44) об определении относительных цен на сырье, замечаем следующие особенности:

- 1) Матрица, составленная из коэффициентов при неизвестных y_1, y_2, y_3, y_4 в системе ограничений (9.44), получается из матрицы коэффициентов при неизвестных x_1, x_2 в системе ограничений (9.41) транспонированием, т.е. $B = A^T$;
- 2) неравенства в системах ограничений (9.44) и (9.41) имеют противоположный смысл;
- 3) правыми частями системы ограничений (9.44) являются коэффициенты целевой функции (9.42) исходной задачи. В то же время коэффициентами минимизирующей целевой функции (9.43) являются правые части системы неравенств-ограничений (9.41) исходной задачи.
- 4) в задаче (9.41) и (9.42) об использовании сырья целевая функция Z максимизируется, а в задаче (9.43), (9.44) об относительных ценах целевая функция Z^* минимизируется.

Две задачи линейного программирования, связанные подобного рода соотношениями, называются *взаимно двойственными*.

Оптимальный план производства $\vec{x}^* = (x_1^*, x_2^*, \dots, x_n^*)$ и оптимальные цены (оценки) $\vec{y}^* = (y_1^*, y_2^*, \dots, y_m^*)$ ресурсов, используемых в производственном процессе, также связаны между собой. Если по оптимальному плану производства какой-то i -ый ресурс расходуется не полностью, т.е. $\sum_{j=1}^n a_{ij} x_j^* < b_i$, то его опти-

мальная оценка равна нулю, т.е. $y_i^* = 0$. Если же оказывается, что затраты на ресурсы, потребляемые при производстве единицы j -го продукта, оцененные в оптимальных оценках, превышают доход от реализации единицы этого продукта, т.е. $\sum_{i=1}^m y_i^* a_{ij} > c_j$, то этот продукт по оптимальному плану не производится

т.е. $\sum_{i=1}^m y_i^* a_{ij} > c_j$, то этот продукт по оптимальному плану не производится вовсе, т.е. $x_j^* = 0$.

Другими словами, если по некоторому оптимальному плану $\vec{x}^*$ производства расход i -го ресурса строго меньше его запаса т.е. $\sum_{j=1}^n a_{ij} x_j^* < b_i$, то в оптимальном плане соответствующая относительная цена единицы этого ресурса равна нулю. Если же в некотором оптимальном плане $\vec{y}^*$ оценок его i -ая оценка $y_i^* > 0$, то в оптимальном плане $\vec{x}^*$ производства расход соответствующего ресурса равен его запасу, т.е. $\sum_{j=1}^n a_{ij} x_j^* = b_i$. Отсюда вытекает следующий результат:

относительные цены могут служить мерой дефицитности ресурсов. Дефицитный ресурс, т.е. полностью используемый по оптимальному плану производства, имеет положительную относительную цену, а избыточный ресурс, т.е. используемый не полностью, имеет нулевую относительную цену.

Более того, имеет место следующее утверждение.

Теорема 9.2 (О дополняющей нежесткости). Пусть $\vec{x}^* = (x_1^*, x_2^*, \dots, x_n^*)$ - решение исходной задачи, а $\vec{y}^* = (y_1^*, y_2^*, \dots, y_m^*)$ - решение соответствующей двойственной задачи. Оба решения являются оптимальными тогда и только тогда, когда

$$y_i^* \left(\sum_{j=1}^n a_{ij} x_j^* - b_i \right) = 0, \quad i = 1, 2, \dots, m, \quad (9.57)$$

$$x_j^* \left(\sum_{i=1}^m y_i^* a_{ij} - c_j \right) = 0, \quad j = 1, 2, \dots, n. \quad (9.58)$$

Пример 9.5. Предприятие может выпускать 4 вида продукции. Для изготовления этой продукции используются трудовые ресурсы, полуфабрикаты и станочное оборудование. Общий объем ресурсов в расчете на трудовую неделю, расход каждого ресурса на единицу выпускаемой продукции и прибыль, получаемая за реализацию единицы продукции, приведены в таблице:

Ресурсы		Выпускаемая продукция				Объем ресурсов
		P_1	P_2	P_3	P_4	
S_1	Трудовые ресурсы, чел/час	4	2	2	8	4800
S_2	Полуфабрикаты, кг	2	10	6	0	2400
S_3	Станочное оборудование, станков/час	1	0	2	1	1500

Цена единицы продукции, руб	65	70	60	120	
--------------------------------	----	----	----	-----	--

Требуется определить план выпуска, обеспечивающий предприятию максимальную прибыль.

Пусть x_1, x_2, x_3, x_4 - объем продукции $\Pi_1, \Pi_2, \Pi_3, \Pi_4$, планируемой к выпуску. Согласно таблице имеем задачу: найти максимум целевой функции

$$Z = 65x_1 + 70x_2 + 60x_3 + 120x_4 \quad (9.59)$$

при ограничениях:

$$\begin{aligned} 4x_1 + 2x_2 + 2x_3 + 8x_4 &\leq 4800, \\ x_1 + 2x_2 + 2x_3 + 3x_4 &\leq 2400, \\ x_1 + 0x_2 + 2x_3 + x_4 &\leq 1500, \\ x_1 \geq 0, x_2 \geq 0, x_3 \geq 0, x_4 &\geq 0. \end{aligned} \quad (9.60)$$

Двойственная задача для задачи (9.59), (9.60) имеет вид: найти минимум функции

$$Z^* = 4800y_1 + 2400y_2 + 1500y_3 \quad (9.61)$$

при ограничениях:

$$\begin{aligned} 4y_1 + 2y_2 + y_3 &\geq 65 \\ 2y_1 + 10y_2 + 0y_3 &\geq 70 \\ 2y_1 + 6y_2 + 2y_3 &\geq 60 \\ 8y_1 + 0y_2 + y_3 &\geq 120 \\ y_1 \geq 0, y_2 \geq 0, y_3 &\geq 0. \end{aligned} \quad (9.62)$$

Введем дополнительные переменные x_5, x_6, x_7 и приведем систему (9.59) к каноническому виду:

$$\begin{aligned} 4x_1 + 2x_2 + 2x_3 + 8x_4 + x_5 &= 4800, \\ x_1 + 2x_2 + 3x_3 + 3x_4 + x_6 &= 2400, \\ x_1 + 0x_2 + 2x_3 + x_4 + x_7 &= 1500, \\ x_1 \geq 0, x_2 \geq 0, x_3 \geq 0, x_4 &\geq 0, \\ x_5 \geq 0, x_6 \geq 0, x_7 &\geq 0. \end{aligned} \quad (9.63)$$

Базисными переменными служат $x_5=4800, x_6=2400, x_7=1500$, переменные $x_1=0, x_2=0, x_3=0, x_4=0$ - свободные. По системе (9.63) и целевой функции (9.59) составляем начальную симплекс-таблицу (нулевая итерация) и затем симплекс методом строим последующие симплекс-таблицы (итерации).

Б П	С _Б	x_1	x_2	x_3	x_4	x_5	x_6	x_7	b	a_{i4}	Отн b_i/a_{i4}	min b_i/a_{i4}
		65	70	60	120	0	0	0				
x_5	0	4	2	2	8	1	0	0	4800	8	600	600
x_6	0	1	2	2	3	0	1	0	2400	3	800	
x_7	0	1	0	2	1	0	0	1	1500	1	1500	
$z_i - c_i = \Delta_i$		-65	-70	-60	-120	0	0	0	0	Следующее пробное решение $x_4=600, x_5=0$		

Б П	С _Б	x_1	x_2	x_3	x_4	x_5	x_6	x_7	b	a_{i4}	Отн b_i/a_{i4}	min b_i/a_{i4}
		65	70	60	120	0	0	0				
x_4	120	1/2	1/4	1/4	1	1/8	0	0	600	1/4	240	600
x_6	0	1/2	-	-	0	-	1	0	2400	6	400	400
			5/4	5/4		3/8						
x_7	0	1/2	-	7/4	0	-	0	1	900	7/4	3600/7	
			1/4			1/8						
$z_i - c_i = \Delta_i$		-5	-40	-30	0	15	0	0	72000	Следующее пробное решение $x_4=600, x_5=0$		

Б П	С _Б	x_1	x_2	x_3	x_4	x_5	x_6	x_7	b		Отн b_i/a_{in}	Min b_i/a_{ik}
		65	70	60	120	0	0	0				
x_4	120	5/12	-1/6	0	1	1/8	-1/24	0	500			
x_3	60	1/3	0	1	0	0	1/6	0	400			
x_7	0	-1/12	-98/5	0	0	-1/8	-7/24	1	200			
$z_i - c_i = \Delta_i$		5	10	0	0	15	5	0	87000	Оптимальное решение $x_3=400, x_4=500$		

Итак, получено оптимальное решение:

$$x_1^* = 0, x_2^* = 0, x_3^* = 400, x_4^* = 500, x_5^* = 0, x_6^* = 0, x_7^* = 200. \quad (9.64)$$

Основные переменные x_1, x_2, x_3, x_4 решения (9.64) означают, что продукцию P_1 и P_2 выпускать нецелесообразно, а продукцию P_3 следует выпускать в объеме 400 единиц, продукцию P_4 - в объеме 500 единиц.

Дополнительные переменные x_5, x_6, x_7 показывают, что согласно равенствам (9.61) ресурсы S_1 и S_2 используются полностью, а равенство $x_7=200$ свиде-

тельствует о том, что 200 единиц ресурса S_3 оказалось неиспользованным. И поэтому третье ограничение в системе (9.60) выполняется как строгое неравенство: $0 \cdot 0 + 0 \cdot 0 + 2 \cdot 400 + 500 = 1300 < 1500$. Это означает, что ресурс S_3 (станочное оборудование) избыточный. Поэтому в двойственной задаче соответствующая переменная $y_3^* = 0$. Из соотношения (9.57) получаем ($y_3^* = 0$), что:

$$\begin{aligned}x_3^*(2y_1^* + 6y_2^* - 60) &= 400(2y_1^* + 6y_2^* - 60) = 0 \\x_4^*(8y_1^* - 120) &= 500(2y_1^* - 120) = 0\end{aligned}$$

Отсюда находим $y_1^* = 15$, $y_2^* = 5$, $y_3^* = 0$. Из того, что относительные оценки $y_1^* > 0$, $y_2^* > 0$, следует что ресурсы S_1 и S_2 дефицитные, они используются полностью.

Поскольку $y_1^* > y_2^*$, т.е. относительная цена ресурса S_1 больше относительной цены ресурса S_2 , то ресурс S_1 можно считать более дефицитным, чем ресурс S_2 .

Первое и второе ограничения (9.62) двойственной задачи для оптимального плана выполняются как строгие неравенства: $4 \cdot 15 + 2 \cdot 5 + 0 = 80 < 70$, $2 \cdot 15 + 10 \cdot 5 + 0 = 80 < 70$. Это означает, что относительные оценки ресурсов, расходуемых на изготовление единицы продукции Π_1 и Π_2 превышают оценки единицы этой продукции. Такую продукцию предприятию не выгодно выпускать, поэтому в оптимальном плане $x_1^* = 0$, $x_2^* = 0$.

Для продукции Π_3 и Π_4 относительная цена израсходованных средств совпадает с ценой произведенной продукции: $2 \cdot 15 + 10 \cdot 5 + 0 = 60$, $8 \cdot 5 + 0 = 120$. Такую продукцию предприятию выпускать невыгодно.

Таким образом, в оптимальный план выпуска продукции входит только та продукция, выпуск которой выгоден предприятию, и не входит убыточная продукция. В этом состоит рентабельность оптимального плана.

В начальной симплекс-таблице (нулевая итерация) базисными переменными являются x_5 , x_6 , x_7 . В последней симплекс-таблице под этими переменными в строке $Z_j - c_j = \Delta_j$ расположены числа 15, 5, 0 - это, как получено ранее, оптимальное решение двойственной задачи. Этот вывод справедлив для общих двойственных задач вида (9.45), (9.46) и (9.47), (9.48). А именно, коэффициенты при базисных переменных в начальной (нулевая итерация) симплекс-таблице на последней симплекс-итерации при решении задачи максимизации совпадают с оптимальными значениями переменных двойственной задачи. Таким образом, симплекс-алгоритм позволяет найти одновременно оптимальное решение и прямой и двойственной задач.

ЛИТЕРАТУРА

1. Алберг Дж., Нильсон Э., Уолш Дж. Теория сплайнов и ее приложения / Пер. с англ.: М.: Мир, 1972.
2. Ашкрофт Дж., Элдридж Р., Полсон Р. и др. Программирование на ФОРТРАНЕ 77 / Пер. с англ. Н.А.Геодакова, Д.П. Матюшина. М.: Радио и связь, 1990.
3. Банди Б. Основы линейного программирования. - М.: Радио и связь, 1984.
4. Бахвалов Н.С. Численные методы (анализ, алгебра, обыкновенные дифференциальные уравнения). Т. 1. М.: Наука, 1973, -632с.
5. Бахвалов Н.С., Жидков Н.П., Кобельков Г.М. Численные методы. – М.: Наука, 1987. –600 с.
6. Белашов В.Ю., Чернова Н.М. Эффективные алгоритмы и программы вычислительной математики. Магадан: СВКНИИ ДВО РАН, 1997, -160 с.
7. Белецкий Я. Турбо Паскаль с графикой для персональных компьютеров / Пер. с польск. Д.И.Юренкова. М.: Машиностроение. 1991.
8. Березин И.С., Жидков Н.П. Методы вычислений. Т. 2. М.: Физматгиз, 1962.
9. Боглаев Ю.П. Вычислительная математика и программирование. –М.: Высшая школа, 1990
- 10.Бородич Л.И. и др. Справочное пособие по приближенным методам решения задач высшей математики. - Мн.: "Вышэйшая школа", 1986, -188 с.
- 11.Бородич Ю.С. "Паскаль для персональных компьютеров". Справочное пособие. Минск, 1991.
- 12.Васильев Ф.П. Численные методы решения экстремальных задач. М.: Наука, 1988, -552с.
- 13.Вержбицкий В.М. Численные методы. Линейная алгебра и нелинейные уравнения. М.: Высшая школа, 2000, -266с.
- 14.Волков Е.А. Численные методы. – М.: Наука, 1987. –254 с.
- 15.Воробьева Г.Н., Данилова А.Н. Практикум по вычислительной математике. Изд. 2. М.: Высшая школа, 1990.
- 16.Гринчишин Я.Т., Ефимов В.И., Ломакович А.Н. Алгоритмы и программы на Бейсике. М.: Просвещение, 1988.
- 17.Гусак А.А. "Элементы методов вычислений". Минск: БГУ, 1974.
- 18.Данциг Дж. Б. Линейное программирование, его применение и обобщения / Пер. с англ. М.: Прогресс, 1966.
- 19.Де Бор К. Практическое руководство по сплайнам. – М.: Радио и связь, 1985. –304с.
- 20.Демидович В.М., Марон Б.В. Численные методы вычислительной математики. М.: Высшая школа, 1962

21. Дорот В.Л., Троицкий В.А., Шелест В.Д. Элементы вычислительной математики. Л.: Изд-во ЛПИ им. Калинина, 1977. Калиткин Н.Н. Численные методы. – М.: Наука, 1978. –512 с.
22. Дьяконов В.П. Справочник по алгоритмам и программам на языке бейсик для персональных ЭВМ. - М.: Наука, 1987, -240 с.
23. Жевняк Р.М., Карпук А.А. Высшая математика. В 5 ч. – Мн.: Выш.шк., 1984-1988.- Ч.5.-1988.-256 с.
24. Жевняк Р.М., Карпович С.Е., Карпук А.А., Сорко С. Численные методы решения задач на ПЭВМ. Пособие в 2-х частях. Ч.1- МН.:УП «Технопринт», 2004, -150с.
25. Жевняк Р.М., Карпович С.Е., Карпук А.А., Сорко С. Численные методы решения задач на ПЭВМ. Пособие в 2-х частях. Ч.2- МН.:УП «Технопринт», 2005, -235с.
26. Калиткин В.Г. Численные методы. М.: Наука, 1978, -512 с.
27. Касаткин В.И. Лекции по методам вычислений. М.: Наука, 1978.
28. В.И. Крылов, В.В. Бобков, П.И. Монастырный. "Вычислительные методы". М.: Наука, 1976
29. Крылов В.И., Бобков В.В., Монастырный П.И. Вычислительные методы высшей математики. Т. 1. Минск: Вышэйшая школа, 1972.
30. Кузнецов А.В., Сакович В.А., Холод Н.И. Высшая математика : Математическое программирование. - Мн.: Выш. шк., 1994.
31. Кузнецов А.В., Холод Н.И., Костевич Л.С. Руководство к решению задач по математическому программированию. - Мн.: Выш. шк., 1978.
32. Линейное программирование. Учебно-методическое пособие под редакцией Ю.Н. Черемных. - Изд. МГУ, 1992.
33. Методические указания к лабораторно-практическим занятиям по курсу "Вычислительная техника и программирование". Минск: БАТУ, 1993.
34. С.Г. Мулярчик. "Численные методы". Конспект лекций. Минск: БГУ, 2001.
35. Д.В. Офицеров, В.А. Старых. "Программирование в интегрированной среде ТУРБО-Паскаль". Справочное пособие. Минск: Беларусь, 1992.
36. Молчанов И.Н. Машинные методы решения прикладных задач. Алгебра, приближение функций. – Киев: Наукова думка, 1987. –288 с.
37. Мудров А.Е. Численные методы для ПЭВМ на языках БЕЙСИК, ФОРТРАН и ПАСКАЛЬ. –Томск, МП "Раско", 1992. –270 с.
38. Ортега Дж., Рейнболд В. Итерационные методы решения нелинейных уравнений со многими неизвестными / Пер. с англ. М.: Мир, 1975.
39. Плис А.И., Славина Н.А. Лабораторный практикум по высшей математике. - М.: Высш. шк., 1983, -208 с.
40. Руководство к лабораторным работам по численным методам курса высшей математики. Ч. 1 - Таганрог: ТРТИ, 1987, -44 с.
41. Самарский А.А., Гулин А.В. Численные методы. – М.: Наука, 1989 –432 с.
42. А.А. Самарский. "Введение в численные методы". М.: Наука, 1982.

- 43.Сборник задач и упражнений по высшей математике: Математическое программирование / Под общ. ред. проф. А.В. Кузнецова. – Мн.: Выш. шк., 1995.
- 44.Сборник задач по методам вычислений. / Под ред. П.И. Монастырного. – Минск: БГУ, 1983.
- 45.Л.И. Турчак. Основы численных методов. – М.: Наука, 1981.
- 46.Уилкинсон Дж. Алгебраическая проблема собственных значений / Пер. с англ. – М.: Наука, 1970.
- 47.Уилкинсон Дж. Райнш. Справочник алгоритмов на языке АЛГОЛ. Линейная алгебра / Пер. с англ. М.: Машиностроение, 1976.
- 48.Фаддеев Д.К., Фаддеева В.Н. Вычислительные методы линейной алгебры. М.: Физматгиз, 1963.
- 49.Форсайт Дж., Малькольм М., Моулер К. Машинные методы математических вычислений. – М.: Мир, 1980, – 280 с.
- 50.Хемминг Р.В. Численные методы. – М.: Наука, 1968. –400 с.
- 51.Conte S.D., Carl de Boor Elementary numerical analysis. An algorithmic approach. – McGraw-Hill Book Company, New-York, 1980, –432p.
- 52.Engeln-Mullges G., Uhlig F. Numerical Algorithms with Fortran. – Springer, New-York, Berlin, Heidelberg , 1996, –602p.

УЧЕБНО–МЕТОДИЧЕСКИЕ МАТЕРИАЛЫ

по численным методам кафедры высшей математики БГУИР

1. Князева Л.П. Аппроксимация функций. (Учебное пособие по численным методам высшей математики). – Мн.: БГУИР, 2000. – 53 с.
2. Князева Л.П. Численные методы. Лабораторные работы по высшей математике для студентов всех специальностей БГУИР. В 2-х частях, ч.1. – Минск: БГУИР, 1998. – 54 с.
3. Князева Л.П. Численные методы. Лабораторные работы по высшей математике для студентов всех специальностей БГУИР. В 2-х частях, ч.2. – Минск: БГУИР, 1998, -36с.
4. Методические указания к лабораторным работам по высшей математике для студентов всех специальностей БГУИР. – Минск: БГУИР, 2001. – 49с.